

Examen Projet Statistique sous R, Session 2025 2026

Ingénieurs Statisticiens Économistes, première année (ISE1)

Enseignant: Aboubacar HEMA, Analyste de recherche, IFPRI

L'examen se trouve dans le compte github du cours

Partie 1: Vulnerabilite aux chocs et securite alimentaire des menages

Vous intervenez comme consultant data scientist auprès d'un institut national de la statistique dans un pays sahélien qui vient de conduire une enquête nationale sur la sécurité alimentaire et les stratégies d'adaptation des ménages, l'ENSAN 2026. Cette enquête fait suite à une combinaison de chocs survenus au cours des deux dernières années: une sécheresse marquée dans les régions du nord, une hausse durable des prix des céréales et une recrudescence de l'insécurité civile dans certaines zones frontalières.

La direction des statistiques agricoles et de la sécurité alimentaire souhaite disposer, sous 4 heures, d'une note technique reproductible identifiant les déterminants de l'insécurité alimentaire des ménages, la vulnérabilité différenciée par région et par milieu, ainsi que des recommandations opérationnelles pour cibler les interventions à venir.

Votre livrable doit être exploitable par un cadre technique qui ne lira pas votre code, mais doit pouvoir faire confiance à vos résultats et les reproduire si nécessaire.

Les fichiers sont mis à votre disposition dans le dossier data/raw/ du projet distribué. **Aucun fichier ne doit être modifié manuellement en dehors de R.**

Fichier	Contenu	Format
ensan_menages.dta	Module ménage: identifiant, région, milieu, grappe, strate, poids_final, revenu, taille du ménage	Stata (.dta), avec labels
ensan_individus.csv	Module individu: âge, sexe, niveau d'éducation, rang dans le ménage	CSV, encodage UTF-8
ensan_consommation.xlsx	Consommation des 12 groupes alimentaires FAO (0/1) et dépenses par poste, plusieurs feuilles	Excel, feuilles multiples
chocs_menages.csv	Chocs subis (sécheresse, hausse des prix, conflit, maladie) et stratégies d'adaptation (vente d'actifs, réduction du nombre de repas, migration, endettement)	CSV
tcd_admin1.shp (+ fichiers associés)	Limites administratives des régions du pays d'étude	Shapefile
prix_marches.csv	Prix mensuels des céréales par marché sur 24 mois, type données WFP	CSV

Consignes

- Le projet doit être organisé selon l'arborescence vue en cours (**data/raw, data/processed, R/, output/figures, output/tables, rapport/**), initialisé comme projet RStudio (**.Rproj**).
- La gestion des dépendances doit être assurée avec renv, avec un renv.lock livré et fonctionnel.
- Tout le code doit être écrit avec la syntaxe **tidyverse** et le pipe natif **|>**, commenté et organisé en scripts numérotés.
- Toutes les statistiques doivent être correctement pondérées lorsque le plan de sondage est mobilisé; toute statistique non pondérée présentée comme représentative sera pénalisée.
- Les résultats régionaux doivent être présentés comme descriptifs et associatifs, sans interprétation causale, sauf si un modèle explicite le justifie et que ses limites sont discutées.

- Un dépôt Git local est exigé, avec un historique de commits reflétant l'avancement réel du travail (5 commits minimum, messages explicites).

Section 1. Import, structuration et nettoyage

1. Importer les cinq sources avec les packages appropriés, en respectant les types de colonnes et les encodages.
2. Fusionner les modules en un jeu de données ménages enrichi comportant les caractéristiques du chef de ménage, la consommation alimentaire agrégée et les chocs subis, par des jointures adaptées. Vérifier explicitement que le nombre de lignes du jeu de données ménages reste inchangé après chaque jointure.
3. Identifier et corriger les libellés de régions incohérents entre fichiers avant toute jointure spatiale.
4. Produire un diagnostic complet des valeurs manquantes avec naniar (résumé, visualisation, cooccurrences), en distinguant les valeurs manquantes standards des valeurs manquantes taguées Stata.
5. Justifier, pour deux variables clés de votre choix, une hypothèse de mécanisme de non-réponse (MCAR, MAR ou MNAR) et appliquer une imputation multiple par équations chaînées adaptée avec mice.
6. Recoder les variables catégorielles nécessaires à l'analyse (milieu, niveau d'éducation du chef de ménage, quintiles de revenu par tête).

Section 2. Statistiques descriptives pondérées et indices composites

7. Déclarer le plan de sondage complet (grappes, strates, poids finaux) avec srvyr.
8. Construire le score de diversité alimentaire des ménages (HDDS) et la classification FAO associée.
9. Construire un indice composite de vulnérabilité aux chocs, combinant le nombre et la gravité des chocs subis avec l'intensité des stratégies d'adaptation mobilisées. La construction, la pondération des composantes et les choix de seuils doivent être explicitement justifiés dans le rapport.
10. Produire un tableau descriptif pondéré de type Tableau 1 avec gtsummary, comparant les indicateurs clés par milieu et par région, avec test de comparaison et colonne d'effectifs.
11. Calculer le coefficient de Gini du revenu par tête au niveau national et par région, avec un intervalle de confiance obtenu par bootstrap.

Section 3. Visualisation

12. Représenter la distribution du revenu par tête par région (graphique de densités superposées ou équivalent), avec une échelle adaptée à l'asymétrie de la variable.
13. Produire une carte choroplèthe de l'indice de vulnérabilité par région avec sf et ggplot2, ainsi qu'une version interactive avec tmap.
14. Composer une figure unique regroupant au moins trois graphiques avec patchwork, en appliquant un thème graphique cohérent et personnalisé sur l'ensemble des graphiques du rapport.
15. Exporter l'ensemble des figures du rapport en PNG haute résolution et en PDF dans output/figures/.

Section 5. Reproductibilité et communication

16. Produire un document R Markdown unique (rapport.md) se compilant sans erreur en HTML et en Word, avec une table des matières, des sections numérotées et un en-tête complet.
17. Intégrer au moins trois résultats chiffrés directement dans le texte du rapport par inline code, de façon à ce qu'ils se recalculent automatiquement si les données changent.
18. Livrer un dépôt Git local avec au moins cinq commits documentés retraçant les grandes étapes du travail, et un fichier README.md décrivant le projet, les données et la manière de reproduire les résultats.

Automatiser, à l'aide d'un rapport R Markdown paramétré, la génération d'une note régionale individuelle pour chacune des régions du pays d'étude, comprenant les indicateurs clés de la région, sa position relative par rapport à la moyenne nationale, et une recommandation opérationnelle d'une phrase fondée sur les résultats obtenus. Les notes régionales doivent être produites par une seule commande.

Partie 2: Récupération de données via l'API

Cette partie vise à tester vos techniques de récupération et de traitement des données ainsi que vos techniques de visualisation de base.

Ressources

Documentation de l'API de la base de données mondiale SDG

1. Créez une requête API pour récupérer les données des indicateurs suivants (par seriesCodes au format .csv) pour tous les pays/monde/toutes les années de la base de données mondiale des ODD :

codes de série	Nom de l'indicateur (pour référence)
SP_DYN_MRBFI5	Proportion de femmes âgées de 20 à 24 ans mariées avant l'âge de 15 ans
SP_DYN_MRBFI8	Proportion de femmes âgées de 20 à 24 ans mariées avant l'âge de 18 ans
SH_STA_MORT	Taux de mortalité maternelle
SL_TLF_NEET	Proportion de jeunes (âgés de 15 à 24 ans) ne suivant pas d'études, d'emploi ou de formation
SP_DYN_ADKL	Taux de natalité chez les adolescentes
SH_STA_BRTC	Accouchements assistés par du personnel qualifié

2. Affichez les 10 premières lignes de l'ensemble de données extraites
3. Enregistrez les données récupérées au format .csv.
4. Importez l'ensemble de données .csv extraites de l'API
5. Fusionnez les indicateurs SP_DYN_MRBFI5 et SP_DYN_MRBFI8 en un seul indicateur et appelez-le "Proportion combinée de femmes âgées de 20 à 24 ans mariées avant 18 ans", créez une nouvelle colonne "marie_avant_age" et remplissez-la avec "avant_age_15" ou "avant_age_18" en fonction des indicateurs d'origine.
6. Ne conservez que les valeurs qui sont soit vides, soit **A** sous **Observation Status**, laissez tomber le reste.
7. Remplacer "-" par "_" pour toutes les valeurs de désagrégation
8. Créer une nouvelle colonne **Region_UNFPA** en utilisant le fichier de correspondance : • link et assigner à chaque pays unfpa_region_name
9. Supprimer les lignes pour tous les pays qui ont une région **non-UNFPA**, à l'exception des valeurs des régions World et SDG (vous pouvez utiliser le **sdg_region_name** dans le fichier de correspondance pays-région) en utilisant le m49/global_code.
10. Créer une nouvelle colonne **geoareanote** qui devrait avoir soit **country**, **sdg_region** ou **global** pour chaque ligne en fonction du fichier de correspondance pays-région.

Toutes les colonnes de désagrégation et les valeurs qu'elles contiennent sont en minuscules.

11. Arrondissez toutes les valeurs à deux décimales.
12. Remplir toutes les cellules vides avec _t
13. Vérifiez que les données ne contiennent pas de valeurs en double avant d'enregistrer le cadre de données. Si c'est le cas, corrigez les problèmes avant d'enregistrer le cadre de données.
14. Imprimez les 10 premières lignes, enregistrez le cadre de données et exportez-le au format .csv (il s'agit de l'ensemble de données que vous devez soumettre).

Rendu

- Une archive .zip unique nommée Nom_Prenom_Examen_Partix_ISE1_2026.zip (x = 1, 2) contenant le **projet complet (structure de dossiers, code, renv.lock, rapport.qmd, rapport.html, rapport.docx, output/figures)**.
- L'historique Git complet doit être inclus dans l'archive (dossier .git non supprimé).
- Le code doit s'exécuter de bout en bout sur R 4.4.x sans intervention manuelle, à partir d'un renv::restore().
- **Tout dépôt rendu après la fin de la session de 4 heures ne sera pas corrigé, sauf accord préalable du chargé de cours.**