École Nationale de la Statistique et de l'Analyse Économique Pierre NDIAYE

Projet Statistique sous R et Python 2025-2026

Aboubacar HEMA

Statistiques Descriptives · Tests Statistiques · Visualisation

Données: Nigeria General Household Survey (GHS) Panel

Waves 1-4 | 2010 · 2012 · 2015 · 2018

Post-Planting & Post-Harvest · | Sections: Ménage · Agriculture · Communauté

Accessible: World Bank LSMS-ISA

Introduction

Ce document propose dix travaux pratiques (TP) conçus spécifiquement pour le Nigeria General Household Survey (GHS) Panel, enquête longitudinale en quatre vagues (2010, 2012, 2015, 2018) du programme LSMS-ISA de la Banque Mondiale. Chaque TP est ancré dans des fichiers **.dta** réels identifiés par le dictionnaire des données.

Tous les TP sont strictement limités à l'analyse descriptive, aux tests statistiques et à la visualisation - aucune modélisation ni économétrie n'est requise. Les compétences entraînées couvrent:

→ Analyse univariée: distribution, tendance centrale, dispersion, asymétrie, normalité.

→ Analyse bivariée: tableaux de contingence, corrélations de rang, comparaisons de groupes.

→ Tests statistiques: Shapiro-Wilk, Wilcoxon, chi-deux, Fisher, Kruskal-Wallis, Dunn, K-S.

→ Visualisation: histogrammes, boxplots, violin plots, barplots, heatmaps, dot plots, pyramides des âges, courbes de Lorenz, graphiques polaires.

Chaque TP précise les fichiers **.dta** concernés, les variables mobilisées, les vagues disponibles, les tâches à réaliser, les livrables attendus et les packages R.

Vue d'ensemble des 10 TP

N°	Titre	Modules GHS	Thème
1	**Profil démographique des ménages**	*sect1 + secta*	**Démographie**
2	**Éducation et alphabétisation**	*sect2a + sect2b*	**Capital humain**
3	**Accès aux soins et dépenses de santé**	*sect3a + sect3b*	**Santé**
4	**Parcelles: superficie et tenure foncière**	*secta1 + secta2*	**Foncier agricole**
5	**Cultures, intrants et rendements**	*secta3 + secta5 + secta9*	**Production agricole**
6	**Élevage et revenus animaux**	*secta6 + secta7*	**Élevage**
7	**Dépenses de consommation et inégalités**	*cons_agg (W1-W4)*	**Bien-être**
8	**Marchés, finance et infrastructures**	*sect5 + sectc*	**Accès aux services**
9	**Activités non agricoles et revenus**	*sect8 + sect9 (planting)*	**Pluriactivité**
10	**Évolution inter-vagues 2010-2018**	*Tous modules (W1→W4)*	**Analyse longitudinale**

Analyse 1 - Profil démographique des ménages nigérians [sect1 | Ménage-Post-Harvest & Post-Planting]

Objectif

Décrire la composition et les caractéristiques démographiques des ménages enquêtés dans les quatre vagues du GHS Panel à partir des sections sect1_harvest et sect1_planting.

Contexte & données mobilisées

sect1 est la section d'identification et de composition du ménage. Elle est collectée à chaque visite et contient les informations de base sur chaque membre: sexe, âge, lien de parenté avec le chef de ménage, statut matrimonial, état de résidence. C'est la porte d'entrée naturelle pour tout portrait statistique de la population enquêtée.

Fichiers .dta concernés

Fichier .dta	Variables clés	Vagues disponibles
`sect1_harvestw1/w2/w3/w4`	indiv_id, s1q2 (sexe), s1q4 (âge), s1q1 (lien parenté)	W1 W2 W3 W4
`sect1_plantingw1/w2/w3/w4`	Mêmes variables, visite Post-Planting	W1 W2 W3 W4
`secta_harvestw1/w2/w3/w4`	hhid, zone (rural/urbain), état, LGA	W1 W2 W3 W4

Tâches à réaliser

1. Charger sect1_harvestw4 avec haven. Explorer la structure: str(), glimpse(), summary(). Vérifier les doublons sur hhid + indiv_id et les valeurs manquantes (naniar::vis_miss).
2. Analyse univariée de l'âge des membres: histogramme (binwidth = 5), boîte à moustaches, statistiques descriptives (moyenne, médiane, Q1, Q3, CV, asymétrie). Tester la normalité avec Shapiro-Wilk.
3. Pyramide des âges (groupes de 5 ans) par sexe pour la vague 4 (package apyramid ou ggplot2 + coord_flip). Commenter la structure d'ensemble.
4. Fréquences du lien de parenté (chef de ménage, conjoint, enfant, autre): diagramme en barres horizontales ordonné par fréquence. Calculer les proportions avec IC à 95% (package PropCIs ou binom.test).
5. Comparer la taille moyenne des ménages entre zones rurales et urbaines (variable zone dans secta): boxplot groupé + test de Wilcoxon-Mann-Whitney. Interpréter la taille d'effet (r de rang).
6. Tableau récapitulatif gtsummary stratifié par zone (rural/urbain) pour l'âge, le sexe et la taille du ménage, avec p-valeurs des tests de comparaison.

Livrables attendus

→ Pyramide des âges annotée par vague (W4).
→ Tableau gtsummary exportable: statistiques démographiques par zone.
→ Rapport R Markdown de 8 pages commentant chaque analyse.

Packages R

`haven, dplyr, ggplot2, apyramid, naniar, gtsummary, rstatix, PropCIs, patchwork`

Analyse 2 - Éducation et alphabétisation des membres des ménages

[sect2a / sect2b | Ménage-Post-Harvest]

Objectif

Analyser les niveaux d'instruction et les taux d'alphabétisation des membres des ménages du Nigeria à partir des sections éducation du GHS, et comparer les profils entre sexes, tranches d'âge et zones géographiques.

Contexte & données mobilisées

sect2a collecte le statut scolaire actuel (scolarisé ou non, type d'établissement) et sect2b renseigne le niveau d'instruction atteint pour les individus ayant arrêté l'école. Ces deux fichiers, combinés,

permettent de construire le niveau d'éducation de tous les membres adultes. La comparaison entre les quatre vagues (2010-2018) illustre l'évolution du capital humain.

Fichiers .dta concernés

Fichier .dta	Variables clés	Vagues disponibles
`sect2a_harvestw1/w2`	s2aq1 (scolarisé ?), s2aq2 (type établissement)	W1 W2
`sect2a_harvestw3/w4`	Mêmes dimensions, nouvelle structure de vague	W3 W4
`sect2b_harvestw1/w2/w3/w4`	s2bq1 (niveau atteint), s2bq2 (diplôme obtenu)	W1 W2 W3 W4
`sect1_harvestwX`	Sexe, âge (pour jointure)	W1 W2 W3 W4

Tâches à réaliser

7. Charger sect2b_harvestw4 et sect1_harvestw4. Joindre les deux fichiers sur hhid + indiv_id. Inspecter les valeurs manquantes du niveau d'éducation.
8. Construire une variable ordonnée niveau_educ à 5 catégories (Aucun, Primaire, Junior Secondary, Senior Secondary, Tertiaire) à partir de s2bq1. Calculer les fréquences et proportions, visualiser avec un barplot horizontal coloré par catégorie.
9. Comparer la distribution du niveau d'éducation entre hommes et femmes (adultes 18+): graphique en barres 100% empilées côte à côte, test du chi-deux sur le tableau de contingence, V de Cramér.
10. Analyser la relation entre âge et niveau d'éducation: boxplot du niveau d'éducation (axe y numérique ou ordonné) par groupe d'âge (18-30, 31-45, 46-60, 60+). Kruskal-Wallis + post-hoc Dunn.
11. Comparer le taux de scolarisation des 6-17 ans entre zones rurales et urbaines (sect2a + secta): tableau de contingence, test du chi-deux, graphique en barres groupées avec IC à 95%.
12. Heatmap (geom_tile) croisant État nigérian (state) et niveau d'éducation: part d'adultes sans instruction par État, colorée par quintile.

Livrables attendus

→ Barplot du niveau d'éducation par sexe (barres 100% empilées).
→ Heatmap des taux d'analphabétisme par État.
→ Tableau de contingence commenté avec test du chi-deux et V de Cramér.
→ Rapport de 8-10 pages.

Packages R

`haven, dplyr, forcats, ggplot2, rstatix, ggpubr, gtsummary, viridis, patchwork`

Analyse 3 - Accès aux services de santé et chocs sanitaires des ménages [sect3a / sect3b | Ménage-Post-Harvest]

Objectif

Décrire les épisodes de maladie, les types de soins consultés et les coûts de santé supportés par les ménages nigérians, et analyser les disparités par sexe, âge, milieu de résidence et niveau de richesse.

Contexte & données mobilisées

sect3a renseigne les maladies ou blessures survenues dans les 4 semaines précédant l'enquête pour chaque membre, et sect3b détaille le type de prestataire consulté et les dépenses engagées. Ces données permettent d'analyser le recours aux soins et les inégalités d'accès dans un contexte de faible couverture sanitaire.

Fichiers .dta concernés

Fichier .dta	Variables clés	Vagues disponibles
`sect3a_harvestw1/w2/w3/w4`	s3aq1 (maladie/blessure ?), s3aq3 (type maladie)	W1 W2 W3 W4

sect3b_harvestw1/w2/w3/w4	s3bq1 (consultations), s3bq8 (dépense totale santé)	W1 W2 W3 W4
sect1_harvestwX	Sexe, âge (jointure individus)	W1 W2 W3 W4
cons_agg_wave4_visit2	total_cons_lcu (quintile de consommation)	W4

Tâches à réaliser

13. Importer sect3a_harvestw4 et calculer le taux de morbidité (part des individus ayant déclaré une maladie/blessure). Décrire par sexe et par groupe d'âge avec des barplots avec IC à 95%.
14. Analyser la distribution des types de maladies déclarées (s3aq3): diagramme en barres horizontales des 10 affections les plus fréquentes, coloré par catégorie (infectieuse, traumatique, chronique).
15. Décrire le recours aux soins (sect3b): fréquence de consultation selon le type de prestataire (hôpital public, clinique privée, pharmacie, tradipraticien, aucun). Barplot ordonné.
16. Analyser la distribution des dépenses de santé (s3bq8): histogramme avec échelle log, statistiques par décile, boxplot par type de prestataire. Identifier les valeurs aberrantes.
17. Test d'indépendance: croiser le recours aux soins (consulté/non consulté) avec le quintile de consommation (5 groupes). Chi-deux, test exact de Fisher si effectifs < 5, V de Cramér. Barplot 100% empilé.
18. Comparer les dépenses médianes de santé entre zones rurales et urbaines: test de Wilcoxon, visualisation par violin plot + boxplot superposé.

Livrables attendus

→ Barplot des types de maladies et des prestataires consultés.
→ Violin plots des dépenses de santé par zone et par quintile.
→ Tableau de contingence recours aux soins × quintile de richesse avec résultats des tests.
→ Rapport de 8-10 pages.

Packages R

haven, dplyr, ggplot2, rstatix, ggpubr, scales, patchwork, gtsummary, naniar

Analyse 4 - Analyse des parcelles agricoles: superficie, tenure foncière et utilisation des terres [secta1 / secta2 | Agriculture-Post-Harvest]

Objectif

Décrire la structure foncière des exploitations agricoles nigérianes à partir des modules parcelles du GHS: superficie, régime de tenure, mode d'acquisition et localisation géographique, avec comparaison entre vagues.

Contexte & données mobilisées

secta1 est le roster des parcelles cultivées par le ménage. Il contient pour chaque parcelle son identifiant, le mode de tenure (propriété, location, métayage, héritage, prêt), la superficie déclarée et mesurée au GPS lorsque disponible. secta2 donne les caractéristiques agronomiques de chaque parcelle (type de sol, pente, irrigation). C'est la base de toute analyse de la structure agraire.

Fichiers .dta concernés

Fichier .dta	Variables clés	Vagues disponibles
secta1_harvestw1/w2/w3/w4	s1q3 (superficie déclarée), s1q4 (superficie GPS), s1q7 (tenure)	W1 W2 W3 W4
secta2_harvestw1/w2/w3/w4	s2q4 (type de sol), s2q5 (pente), s2q9 (irrigation)	W1 W2 W3 W4
secta_harvestwX	zone, état, LGA (géolocalisation administrative)	W1 W2 W3 W4

Tâches à réaliser

19. Importer secta1_harvestw4 et construire la variable superficie en hectares (convertir depuis acres si nécessaire). Calculer la superficie totale par ménage (sum par hhid). Décrire les valeurs manquantes et les valeurs aberrantes (superficie < 0 ou > 500 ha).
20. Analyse univariée de la superficie par parcelle et par ménage: histogramme (échelle log), statistiques descriptives par décile, boxplot. Comparer superficie déclarée vs. superficie GPS (scatter plot + ligne 45°, corrélation de Spearman).
21. Analyse du régime de tenure (s1q7): fréquences et proportions des modalités (propriété pleine, héritage, location, métayage, prêt). Barplot horizontal. Tester l'indépendance avec la zone (rural/urbain) via chi-deux.
22. Comparer la distribution des superficies entre les 4 vagues (W1-W4): boxplots côte à côte avec ggplot2, test de Kruskal-Wallis. Calculer le coefficient de variation interannuel pour évaluer la stabilité.
23. Analyser la relation entre superficie totale du ménage et le nombre de parcelles: scatter plot, calcul de la corrélation de Spearman avec intervalle de confiance, ajout d'une courbe de tendance loess.
24. Produire une heatmap (État × vague) de la superficie médiane des exploitations pour cartographier les disparités géographiques et temporelles.

Livrables attendus

→ Scatter plot superficie déclarée vs. GPS avec interprétation des biais de déclaration.
→ Heatmap superficie médiane par État et par vague.
→ Tableau comparatif inter-vagues des indicateurs de structure foncière.
→ Rapport de 10 pages.

Packages R

haven, dplyr, ggplot2, ggrepel, scales, patchwork, rstatix, gtsummary, viridis

Analyse 5 - Cultures pratiquées, intrants utilisés et rendements agricoles [secta3 / secta5a / secta5b | Agriculture-Post-Harvest]

Objectif

Analyser les choix de cultures, les types d'intrants utilisés (semences améliorées, engrais, pesticides) et les rendements obtenus par les exploitations du GHS Panel, avec comparaison entre zones et entre vagues.

Contexte & données mobilisées

secta3 liste toutes les cultures pratiquées sur chaque parcelle. secta5a et secta5b détaillent les quantités d'intrants utilisées (engrais organique et chimique, pesticides) par parcelle. La production est renseignée dans secta9a et secta9b. Ces fichiers permettent de construire des indicateurs agronomiques de base: rendements à l'hectare, taux d'utilisation des intrants, diversification des cultures.

Fichiers .dta concernés

Fichier .dta	Variables clés	Vagues disponibles
`secta3_harvestw1/w2`	s3q2 (code culture), s3q6 (superficie cultivée par culture)	W1 W2
`secta3i/3ii_harvestw3/w4`	Même contenu, fichier scindé à partir de W3	W3 W4
`secta5a_harvestw1/w2/w3`	s5aq1 (type engrais), s5aq4 (quantité engrais chimique)	W1 W2 W3
`secta9a1/9a2_harvestw1/w2`	s9q2 (quantité récoltée), s9q3 (unité)	W1 W2 W3 W4

Tâches à réaliser

25. Construire la liste des 15 cultures les plus fréquentes dans la vague 4 à partir de secta3i et secta3ii. Barplot horizontal ordonné par fréquence, coloré par type de culture (céréale, légumineuse, tubercule, culture de rente).
26. Calculer le nombre de cultures différentes par ménage (indice de diversification culturale). Décrire la distribution (histogramme), comparer entre zones rurales et urbaines (test de Wilcoxon), visualiser par violin plot.
27. Analyser l'utilisation des engrais (secta5a): taux d'utilisation par type (organique, chimique NPK, urée) selon la zone et l'État. Barplot groupé avec IC à 95%. Test du chi-deux pour l'association zone × utilisation engrais.
28. Construire le rendement à l'hectare pour la culture principale du ménage (maïs ou millet): production en kg (secta9) / superficie (secta3). Identifier et écarter les outliers (IQR × 3). Comparer la distribution des rendements par État via boxplots.
29. Analyser la relation entre utilisation d'engrais chimique (oui/non) et rendement via des boxplots groupés. Tester la différence de médianes (Wilcoxon). Calculer la taille d'effet.
30. Comparer les taux d'adoption des semences améliorées et des engrais entre les vagues W1 et W4: barplot côte à côte par type d'intrant, annoté avec les évolutions en points de pourcentage.

Livrables attendus

→ Barplot des 15 cultures principales avec classement et proportions.
→ Boxplots des rendements par État et par vague.
→ Graphique comparatif d'adoption des intrants W1 vs. W4.
→ Rapport de 10 pages.

Packages R

haven, dplyr, forcats, ggplot2, rstatix, ggpubr, scales, patchwork, gtsummary

Analyse 6 - Élevage: cheptel, espèces et ventes d'animaux [secta6 / secta7 | Agriculture-Post-Harvest]

Objectif

Décrire la structure de l'élevage des ménages agricoles nigérians: espèces détenues, taille du cheptel, ventes d'animaux et revenus de l'élevage, avec comparaison entre zones agro-écologiques et vagues.

Contexte & données mobilisées

secta6 est le roster du cheptel: pour chaque type d'animal (bovins, ovins, caprins, volailles, porcs, ânes…), il renseigne le nombre possédé en début de période, les naissances, les achats, les ventes et les décès. secta7 collecte les revenus tirés des produits animaux (lait, œufs, fumier). Ces fichiers permettent de caractériser la place de l'élevage dans les stratégies de revenu des ménages ruraux.

Fichiers .dta concernés

Fichier .dta	Variables clés	Vagues disponibles
`secta6_harvestw1/w2/w3/w4`	s6q2 (espèce), s6q3 (nb possédé début), s6q6 (nb vendus), s6q7 (px vente unitaire)	W1 W2 W3 W4
`secta7_harvestw1/w2/w3/w4`	s7q1 (produit animal), s7q2 (quantité), s7q3 (valeur)	W1 W2 W3 W4
`secta_harvestwX`	zone, état (géolocalisation)	W1 W2 W3 W4

Tâches à réaliser

31. Importer secta6_harvestw4. Calculer le taux de possession de chaque espèce animale (% ménages possédant au moins un animal de ce type). Classer les espèces par fréquence: barplot horizontal avec annotation des taux.

32. Analyse de la taille du cheptel par espèce (bovin, caprin, ovin, volaille séparément): statistiques descriptives, histogramme log-transformé, identification des ménages à grand cheptel (top 5%).
33. Construire la valeur totale des ventes d'animaux par ménage (nb vendus × prix unitaire, agrégé toutes espèces). Décrire la distribution, comparer rural/urbain via violin plot + test de Wilcoxon.
34. Analyser la diversification de l'élevage: nombre d'espèces différentes par ménage. Barplot de fréquence, comparaison entre zones (Kruskal-Wallis).
35. Croiser la possession de bovins (oui/non) avec la zone et l'État: tableau de contingence, chi-deux, carte de chaleur (geom_tile) du taux de possession de bovins par État.
36. Comparer les revenus des produits animaux (secta7) entre les vagues W2 et W4: boxplots côte à côte par type de produit (lait, œufs, fumier), test de Wilcoxon apparié sur le sous-panel commun.

Livrables attendus

→ Barplot des taux de possession par espèce animale.
→ Heatmap du taux de possession de bovins par État.
→ Boxplots comparatifs des revenus de l'élevage W2 vs. W4.
→ Rapport de 8 pages.

Packages R

`haven, dplyr, ggplot2, forcats, scales, rstatix, patchwork, viridis, gtsummary`

Analyse 7 - Dépenses de consommation et bien-être économique des ménages [cons_agg | Root-toutes vagues]

Objectif

Décrire et comparer la distribution des dépenses de consommation des ménages du GHS Panel entre les quatre vagues (2010-2018), analyser les inégalités et étudier les disparités entre États nigérians.

Contexte & données mobilisées

Les fichiers cons_agg_waveX_visit1/2 contiennent les agrégats de consommation construits par la Banque Mondiale: dépenses alimentaires, non alimentaires et totales par équivalent adulte, exprimées en prix constants. Ces agrégats sont la mesure standard du niveau de vie dans les enquêtes LSMS. Ce TP est central pour analyser les inégalités et l'évolution du bien-être.

Fichiers .dta concernés

Fichier .dta	Variables clés	Vagues disponibles
`cons_agg_wave1_visit2`	total_cons_lcu, food_cons, nonfood_cons, hhsize, adulteq	W1 Post-Harvest
`cons_agg_wave2_visit2`	Même structure	W2 Post-Harvest
`cons_agg_wave3_visit2`	Même structure	W3 Post-Harvest
`cons_agg_wave4_visit2`	Même structure	W4 Post-Harvest
`secta_harvestwX`	zone (rural/urbain), état (pour jointure géo)	W1 W2 W3 W4

Tâches à réaliser

37. Charger les 4 fichiers cons_agg et les empiler (bind_rows) après harmonisation des noms de colonnes. Construire la dépense par équivalent adulte en prix constants (déflatée si nécessaire). Inspecter les valeurs manquantes et les outliers extrêmes.
38. Analyse univariée de la consommation par équivalent adulte dans la vague 4: histogramme (log), boîte à moustaches, statistiques par décile. Tester la normalité sur la variable log-transformée.

39. Calculer le coefficient de Gini avec intervalle de confiance bootstrap (package ineq + boot) et tracer la courbe de Lorenz pour chaque vague. Comparer les 4 courbes sur un même graphique.
40. Comparer les distributions de consommation entre zones rurales et urbaines dans chaque vague: violin plots avec médiane annotée, test de Wilcoxon. Calculer l'écart rural/urbain en pourcentage.
41. Analyser la dispersion de la consommation médiane entre États: dot plot de Cleveland des 36 États + FCT classés par consommation médiane en W4. Colorier selon le tiers (top/mid/bottom).
42. Décrire la structure des dépenses: part alimentaire vs. non-alimentaire par quintile de consommation. Barplot 100% empilé par quintile et par vague.

Livrables attendus

→ Courbes de Lorenz superposées pour W1-W4 avec Gini annotés.
→ Dot plot de Cleveland des consommations médianes par État (W4).
→ Barplots 100% empilés de la structure alimentaire/non-alimentaire.
→ Rapport de 10-12 pages.

Packages R

haven, dplyr, ggplot2, ineq, boot, scales, forcats, patchwork, gtsummary, ggrepel

Analyse 8 - Accès aux marchés, aux services financiers et aux infrastructures communautaires [sect5 | Ménage + sectc | Communauté-Post-Harvest & Post-Planting]

Objectif

Décrire l'accès des ménages et des communautés aux marchés, services financiers (épargne, crédit) et infrastructures (routes, téléphonie, eau), et analyser les disparités entre zones et entre États nigérians.

Contexte & données mobilisées

sect5_harvest renseigne les activités non agricoles des membres et leur accès aux services financiers (compte bancaire, crédit, épargne). Les sections sectc (Community) décrivent les caractéristiques du village/quartier: infrastructure routière, distance aux marchés, présence d'école, de centre de santé, d'antenne téléphonique. Ces données permettent une analyse de l'environnement dans lequel opèrent les ménages.

Fichiers .dta concernés

Fichier .dta	Variables clés	Vagues disponibles
`sect5_harvestw1/w2`	s5q1 (activité NF), s5q4 (compte banque), s5q6 (crédit)	W1 W2
`sectc_harvestw1/w2/w3/w4`	sc_q1 (distance marché), sc_q2 (état route), sc_q3 (téléphone)	W1 W2 W3 W4
`sectc1_harvestwX`	Infrastructures scolaires et sanitaires de la communauté	W1 W2 W3 W4
`sectc2_harvestwX`	Accès à l'eau potable, assainissement	W1 W2 W3 W4

Tâches à réaliser

43. Importer sectc_harvestw4 (niveau communauté). Décrire la distribution de la distance au marché le plus proche: histogramme, statistiques descriptives, comparaison rural/urbain (Wilcoxon).
44. Analyser l'état des routes (sectc): fréquences des catégories (piste, route latérite, route bitumée), barplot. Tester l'association entre état de la route et zone (chi-deux, V de Cramér).
45. Décrire les taux d'accès aux services de base (eau courante, électricité, téléphonie mobile, internet) par zone et par vague (W1 vs. W4): barplot groupé avec évolutions annotées.

46. Analyser l'accès aux services financiers (sect5_harvestw2): taux de bancarisation et d'accès au crédit selon le sexe du chef de ménage, zone, quintile de consommation. Barplot et test du chi-deux.
47. Construire un indice d'accès aux infrastructures (score 0-5: eau + électricité + route bitumée + téléphone + marché < 5 km). Décrire la distribution par État: dot plot coloré par quintile d'indice.
48. Analyser la corrélation entre la distance au marché et les dépenses de consommation (cons_agg_wave4): scatter plot, corrélation de Spearman avec IC, identification des communautés très isolées (ggrepel).

Livrables attendus

→ Barplot des taux d'accès aux services de base W1 vs. W4.
→ Dot plot de l'indice d'accès aux infrastructures par État.
→ Scatter plot distance au marché vs. consommation.
→ Rapport de 8-10 pages.

Packages R

haven, dplyr, ggplot2, ggrepel, scales, rstatix, patchwork, forcats, gtsummary

Analyse 9 - Activités non agricoles, emploi et sources de revenus des ménages [sect8 / sect9 | Ménage-Post-Planting]

Objectif

Analyser la pluriactivité des ménages ruraux nigérians: part du revenu non agricole, types d'activités secondaires (commerce, artisanat, emploi salarié), et comparer les profils entre hommes et femmes, zones et vagues.

Contexte & données mobilisées

Les sections sect8 et sect9 de la visite Post-Planting collectent les informations sur les activités génératrices de revenus non agricoles des membres: type d'activité, heures travaillées, revenus. Elles permettent d'analyser la diversification des sources de revenus, cruciale pour comprendre les stratégies de résilience des ménages ruraux africains.

Fichiers .dta concernés

Fichier .dta	Variables clés	Vagues disponibles
sect8a_plantingw1	s8aq2 (type activité NF), s8aq4 (heures par semaine)	W1
sect8a_plantingw2/w3/w4	Même structure avec adaptations inter-vagues	W2 W3 W4
sect8b_plantingwX	s8bq2 (revenu activité 1), s8bq3 (revenu activité 2)	W1 W2 W3 W4
sect9_plantingwX	s9q2 (salaire mensuel), s9q3 (avantages en nature)	W1 W2 W3 W4
sect1_harvestwX	Sexe, âge, lien parenté (pour profil individuel)	W1 W2 W3 W4

Tâches à réaliser

49. Importer sect8a_plantingw4 et sect9_plantingw4. Calculer le taux de participation aux activités non agricoles par sexe et tranche d'âge. Barplot groupé avec IC à 95%.
50. Analyser la distribution des types d'activités non agricoles (commerce, artisanat, prestation de service, emploi salarié, autre): barplot horizontal des 10 activités les plus fréquentes, séparé par sexe (facet_wrap).
51. Analyser la distribution des revenus non agricoles (sect8b): histogramme log-transformé, statistiques par décile. Comparer les distributions de revenus entre hommes et femmes (violin plot, test de Wilcoxon).
52. Calculer le nombre de sources de revenus actives par ménage (diversification). Décrire la distribution et croiser avec le quintile de consommation (boxplot par quintile, Kruskal-Wallis).

53. Comparer les taux de participation aux activités non agricoles entre les zones rurales et urbaines, par sexe, dans les vagues W1 et W4: graphique en barres groupées annotées avec les écarts.
54. Analyser la relation entre heures travaillées en activité non agricole (s8aq4) et revenu non agricole: scatter plot, corrélation de Spearman, identification des outliers.

Livrables attendus

→ Barplot des types d'activités non agricoles par sexe.
→ Violin plots des revenus NF hommes vs. femmes avec résultat du test.
→ Graphique comparatif des taux de participation W1 vs. W4.
→ Rapport de 8-10 pages.

Packages R

haven, dplyr, forcats, ggplot2, rstatix, ggpubr, scales, patchwork, gtsummary

Analyse 10 - Analyse intégrée inter-vagues: évolution des conditions de vie et de l'agriculture (2010-2018) [Modules transversaux-toutes vagues GHS Panel]

Objectif

Produire un rapport R Markdown comparatif des quatre vagues du GHS Panel (2010-2018) en assemblant des indicateurs clés issus des modules ménage, agriculture et consommation, pour décrire l'évolution des conditions de vie et des pratiques agricoles du Nigeria sur une décennie.

Contexte & données mobilisées

Ce TP intégrateur mobilise tous les modules vus dans les TP précédents. En combinant les données de panel sur quatre vagues, il permet de décrire des tendances temporelles: évolution de la consommation, de l'adoption des intrants, de la structure démographique, de la diversification des revenus. Le livrable principal est un rapport de synthèse au format R Markdown avec un tableau de bord d'indicateurs.

Fichiers .dta concernés

Fichier .dta	Variables clés	Vagues disponibles
`sect1_harvestwX`	Taille du ménage, sexe, âge du chef	W1 W2 W3 W4
`secta1_harvestwX`	Superficie totale de l'exploitation	W1 W2 W3 W4
`secta5a_harvestwX`	Taux d'utilisation des engrais	W1 W2 W3 W4
`cons_agg_waveX_visit2`	Consommation totale par équivalent adulte	W1 W2 W3 W4
`sect2b_harvestwX`	Niveau d'éducation du chef de ménage	W1 W2 W3 W4
`sectc_harvestwX`	Accès aux infrastructures communautaires	W1 W2 W3 W4

Tâches à réaliser

55. Construire pour chaque vague les indicateurs synthétiques suivants (un calcul par vague): taille médiane du ménage, % chefs de ménage féminins, superficie médiane de l'exploitation, taux d'adoption des engrais chimiques, consommation médiane par équivalent adulte, coefficient de Gini, % ménages scolarisant tous leurs enfants 6-14 ans.
56. Assembler ces indicateurs dans un tableau comparatif (8 lignes × 4 vagues). Visualiser l'évolution de chaque indicateur par un graphique en lignes avec points (W1→W4), annoté avec les valeurs. Utiliser patchwork pour assembler 8 graphiques en une figure de synthèse.
57. Analyser l'évolution de la distribution de la consommation entre W1 et W4: boxplots côte à côte, courbes de densité superposées (geom_density), test de Kolmogorov-Smirnov pour comparer les distributions.
58. Comparer les taux d'adoption des intrants agricoles (engrais, semences améliorées, pesticides) entre W1 et W4: barplot côte à côte avec annotation des évolutions en points de pourcentage et test du chi-deux.

59. Analyser la dispersion des indicateurs par zone (rural/urbain) et par géopolitical zone (Nord-Ouest, Nord-Est, Nord-Centre, Sud-Ouest, Sud-Est, Sud-Sud) dans la vague 4: small multiples (facet_wrap) pour 4 indicateurs clés.
60. Assembler toutes les analyses dans un rapport R Markdown paramétré (paramètre = vague à mettre en vedette), avec table des matières, résumé exécutif d'une page, et au moins 10 graphiques ggplot2.

Livrables attendus

→ Tableau de bord des 8 indicateurs clés × 4 vagues, mis en forme (gt).

→ Figure patchwork de l'évolution des indicateurs W1-W4.

→ Rapport R Markdown HTML complet de 15-20 pages, paramétré et reproductible.

Packages R

haven, dplyr, tidyr, ggplot2, ineq, boot, patchwork, gtsummary, gt, scales, forcats, knitr, R Markdown