TP1 – Profil démographique des ménages nigérians

Nigeria General Household Survey Panel (W1-W4, 2010-2018)

Cheikh Ahmadou Bamba FALL Cheikh Omar TRAORE

2026-03-25

Table des matières

Introduction **1**

Données et Méthodologie **2**

Source des données 2

Fichiers utilisés 2

Nettoyage des données 2

Résultats **3**

Exploration et qualité des données (Question 1) 3

Analyse univariée de l'âge pondérée (Question 2) 3

Pyramide des âges pondérée (Question 3) 6

Lien de parenté (Question 4) 6

Taille des ménages selon la zone (Question 5) 6

Tableau récapitulatif pondéré (Question 6) 6

Conclusion **6**

Références **10**

Introduction

Ce rapport présente les résultats du TP1 réalisé dans le cadre du cours de Statistique Descriptive à l'École Nationale de la Statistique et de l'Analyse Économique Pierre Ndiaye (ENSAE). L'objectif est de décrire le profil démographique des ménages nigérians à partir du Nigeria General Household Survey (GHS) Panel, enquête longitudinale en quatre vagues (2010, 2012, 2015, 2018) financée par la Banque Mondiale.

Les analyses portent principalement sur la **vague 4 (2018)** et couvrent :

- La structure par âge des membres des ménages
- La répartition par sexe

- Le lien de parenté avec le chef de ménage
- La taille des ménages selon le milieu de résidence

Toutes les statistiques sont **pondérées** par le poids de sondage `wt_wave4` issu de `secta_harvestw4`.

Données et Méthodologie

Source des données

Les données proviennent du programme **LSMS-ISA (Living Standards Measurement Study – Integrated Surveys on Agriculture)** de la Banque Mondiale. Le GHS Panel nigérian couvre 4 vagues :

Vague	Année	Période
W1	2010	Post-Harvest & Post-Planting
W2	2012	Post-Harvest & Post-Planting
W3	2015	Post-Harvest & Post-Planting
W4	2018	Post-Harvest & Post-Planting

Fichiers utilisés

- `sect1_harvestw4.dta` : composition du ménage (âge, sexe, lien de parenté)
- `secta_harvestw4.dta` : zone rurale/urbaine (`sector`), État, LGA, poids `wt_wave4`

Nettoyage des données

```r
sect1_w4_clean <- readRDS(here("data", "processed", "sect1_w4_clean.rds"))
secta_w4       <- charger_dta("secta_harvest", 4)

sector_hh <- secta_w4 %>%
  select(hhid, sector, wt_wave4) %>%
  distinct(hhid, .keep_all = TRUE)
```

Les étapes de nettoyage ont consisté à :

- Vérifier et supprimer les doublons sur `hhid + indiv`
- Filtrer les âges aberrants (valeurs hors [0, 120])
- Joindre le poids `wt_wave4` et la variable `sector` (rural/urbain) depuis `secta_harvestw4` via `hhid`
- Exclure les individus sans poids valide

Résultats

Exploration et qualité des données (Question 1)

```
## Dimensions du fichier : 30311 individus, 62 variables

## Valeurs manquantes par variable :

##       zone    state.x        lga   sector.x         ea       hhid      indiv
##          0          0          0          0          0          0          0
##      s1q4a       s1q2       s1q3    s1q3_os       s1q4      s1q5a      s1q5b
##        789       3779       3779          0       3779      24830      28531
##   s1q6_day s1q6_month  s1q6_year      s1q8a      s1q8b      s1q8c       s1q7
##      24830      24830      22705       3779       3779      12495      12979
##      s1q11    s1q12_1    s1q12_2    s1q12_3    s1q12_4   s1q13a_1   s1q13a_2
##      21942      22239      29696      30213      30297      22241      29696
##   s1q13a_3   s1q13a_4     s1q13b     s1q13c      s1q13      s1q15      s1q16
##      30213      30297      21942      29826       3779      29522      29522
##   s1q16_os      s1q17   s1q17_os      s1q18      s1q19      s1q20      s1q21
##          0      28751          0      25341      27910      27750      27750
##      s1q22  s1q22_oth      s1q23      s1q24      s1q25      s1q26      s1q27
##      27750          0      25341      27422      28230      28230      28230
##   s1q27_os      s1q28   s1q28_os      s1q29      s1q30     s1q31d      s1q31
##          0      26535          0      26776      26778      26821      26821
##     s1q31b      s1q32      s1q33   sector.y    state.y   wt_wave4
##      27387      30268      30268          0          0          0

## Somme totale des poids : 166411972
```

Analyse univariée de l'âge pondérée (Question 2)

La distribution de l'âge est analysée à travers des statistiques pondérées (`Hmisc::wtd.mean`, `Hmisc::wtd.quantile`, `Hmisc::wtd.var`).

Table 2: Statistiques pondérées de l'âge – W4

Indicateur	Valeur
Moyenne pondérée	23.180
Médiane pondérée	17.000
Q1 pondéré	8.000
Q3 pondéré	35.000
CV (%)	83.280
Asymétrie	0.995

Test de normalité de Shapiro-Wilk :

```
## Statistique W = 0.903

## p-valeur = 1.05e-48

## Conclusion : La distribution de l'âge n'est PAS normale (p < 0.05).
```

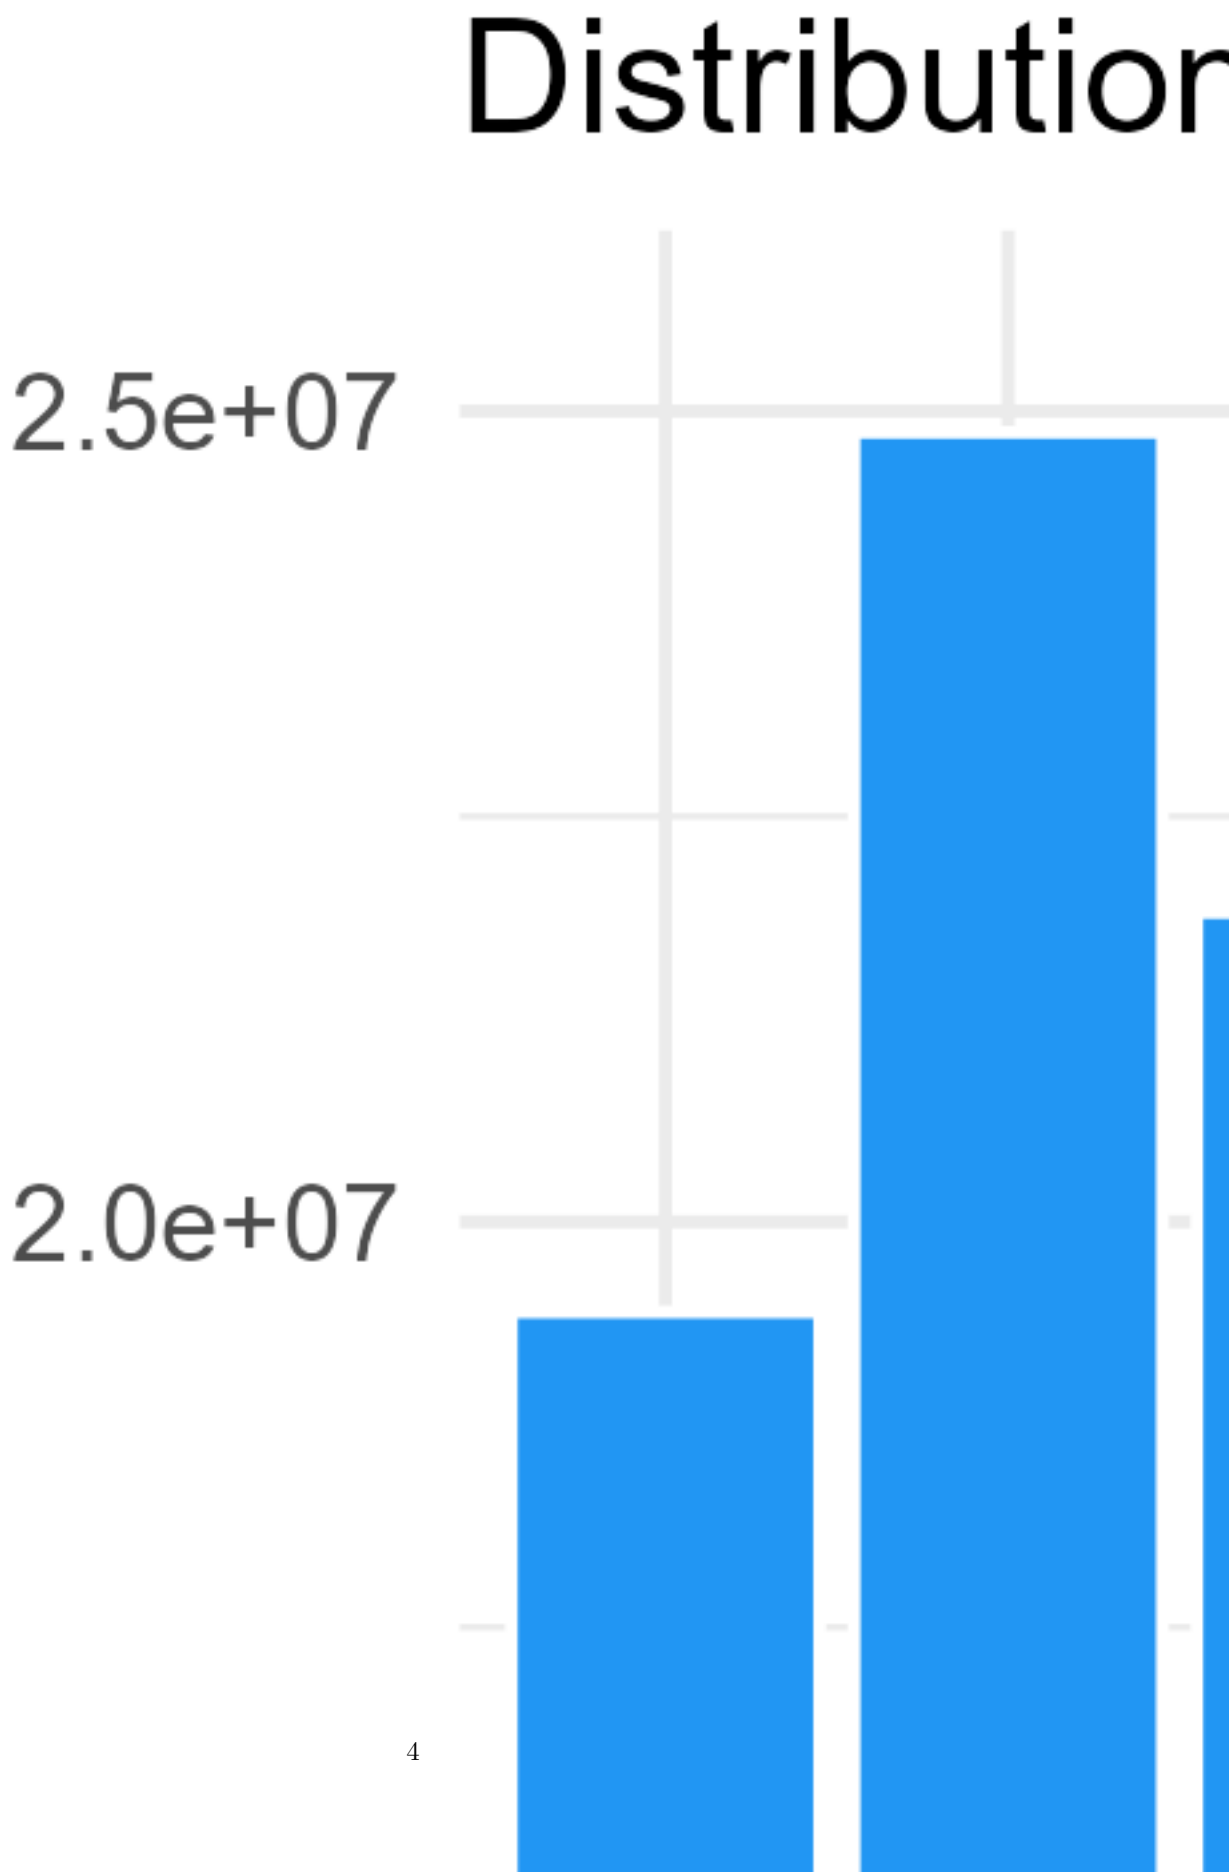
Distribution
2.5e+07
2.0e+07

Boîte à moust

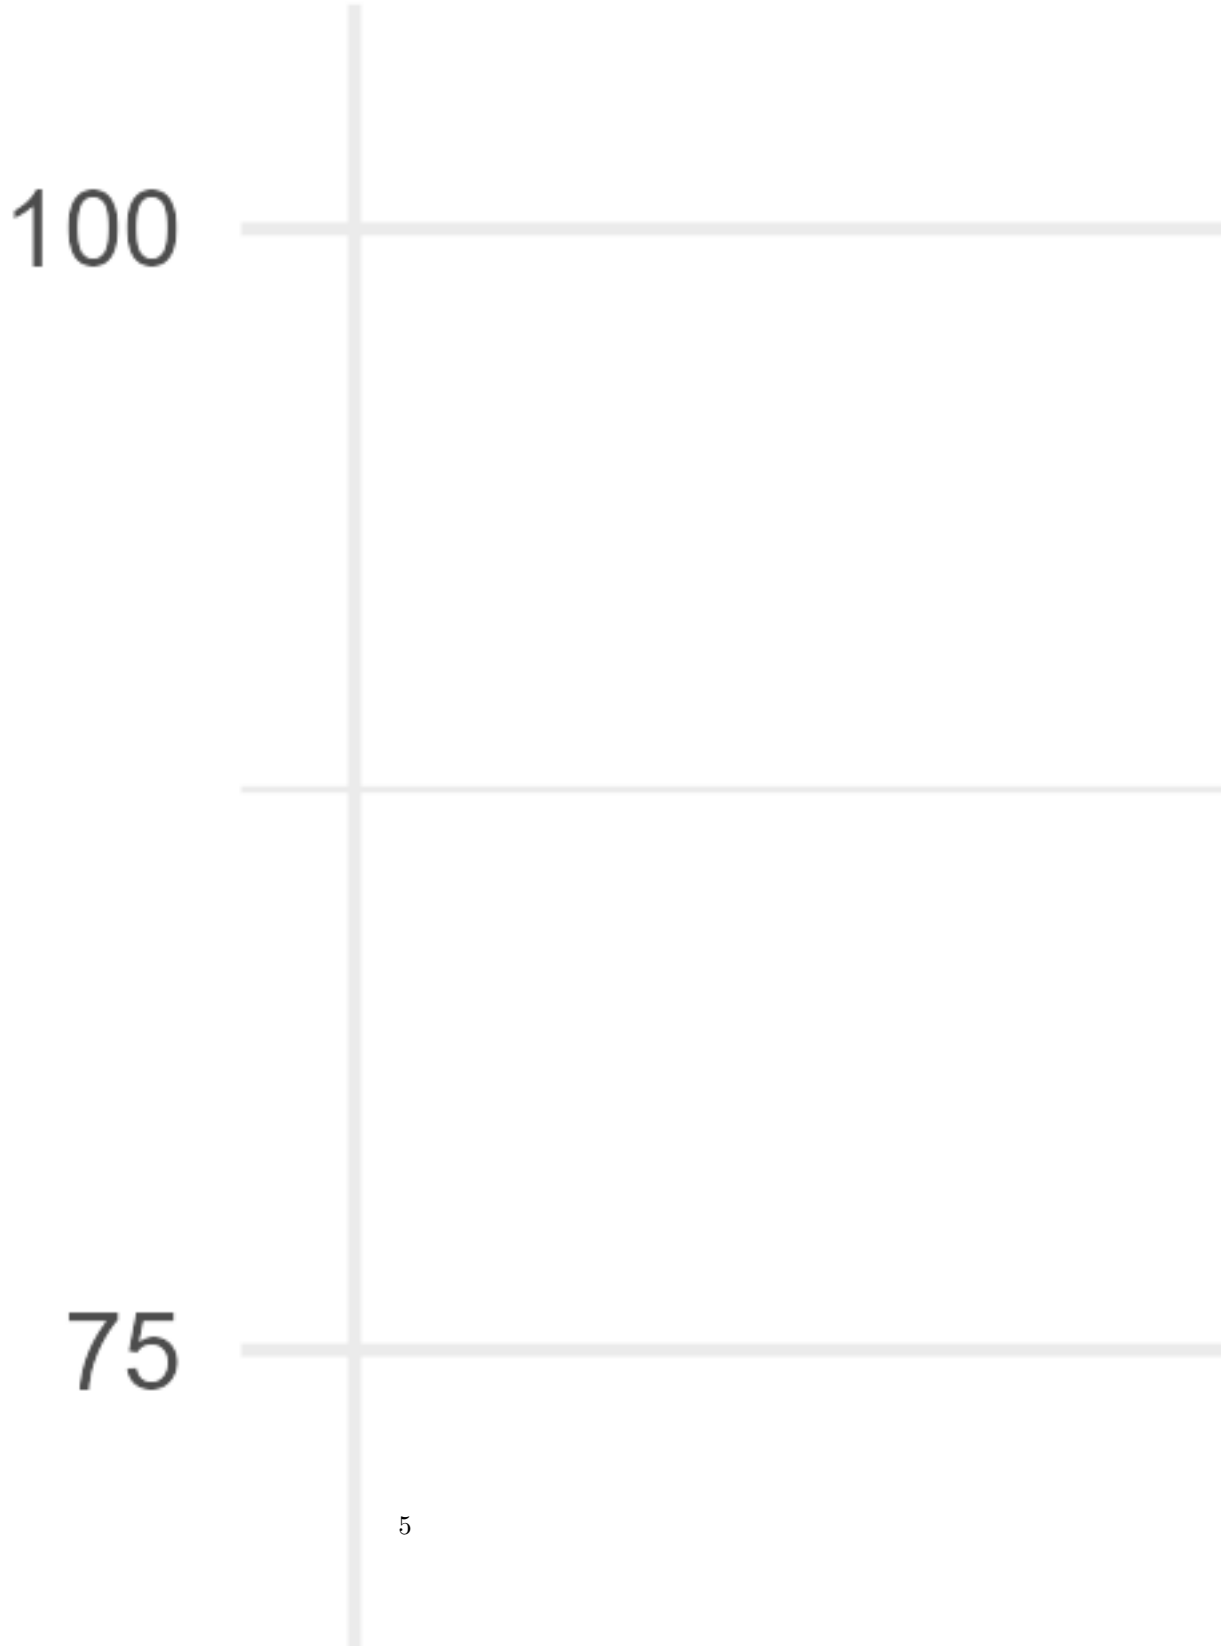

Pyramide des âges pondérée (Question 3)

La pyramide des âges révèle une structure démographique typiquement jeune. Les proportions sont calculées à partir des effectifs pondérés (`wt_wave4`), ce qui garantit la représentativité de la population nigériane couverte par le GHS.

Lien de parenté (Question 4)

Table 3: Fréquences pondérées du lien de parenté avec IC à 95% – W4

Lien de parenté	Effectif pondéré	Proportion (%)	IC Bas (%)	IC Haut (%)
Autre	30068834	18.1	19.9	20.8
Chef de ménage	26954602	16.2	16.0	16.8
Conjoint(e)	24025955	14.4	13.7	14.5
Enfant	85362581	51.3	48.6	49.7

Taille des ménages selon la zone (Question 5)

```
## Test de Wilcoxon pondéré (svyranktest)

## p-valeur = 5.153e-13

## Taille d'effet r = 0.102

## Conclusion : Différence significative entre rural et urbain (p < 0.05).
```

Tableau récapitulatif pondéré (Question 6)

Characteristic	**Overall** N = 166,411,972	**Rural** N = 120,766,215	**Urbain** N = 45,645,757	**p-value**
Âge (années)	23 (19)	23 (19)	24 (19)	<0.001
Unknown	17,397,484	12,222,337	5,175,147	
Sexe				0.8
Féminin	13,356 (50%)	9,531 (51%)	3,825 (50%)	
Masculin	13,176 (50%)	9,457 (49%)	3,719 (50%)	
Unknown	17,397,484	12,222,337	5,175,147	
Taille du ménage	8 (4)	9 (4)	7 (4)	<0.001

Conclusion

1. **Structure par âge** : La moyenne pondérée est inférieure à 25 ans. Le test de Shapiro-Wilk confirme une distribution non normale.

Pyramide des

Groupes quinque

Lien de p

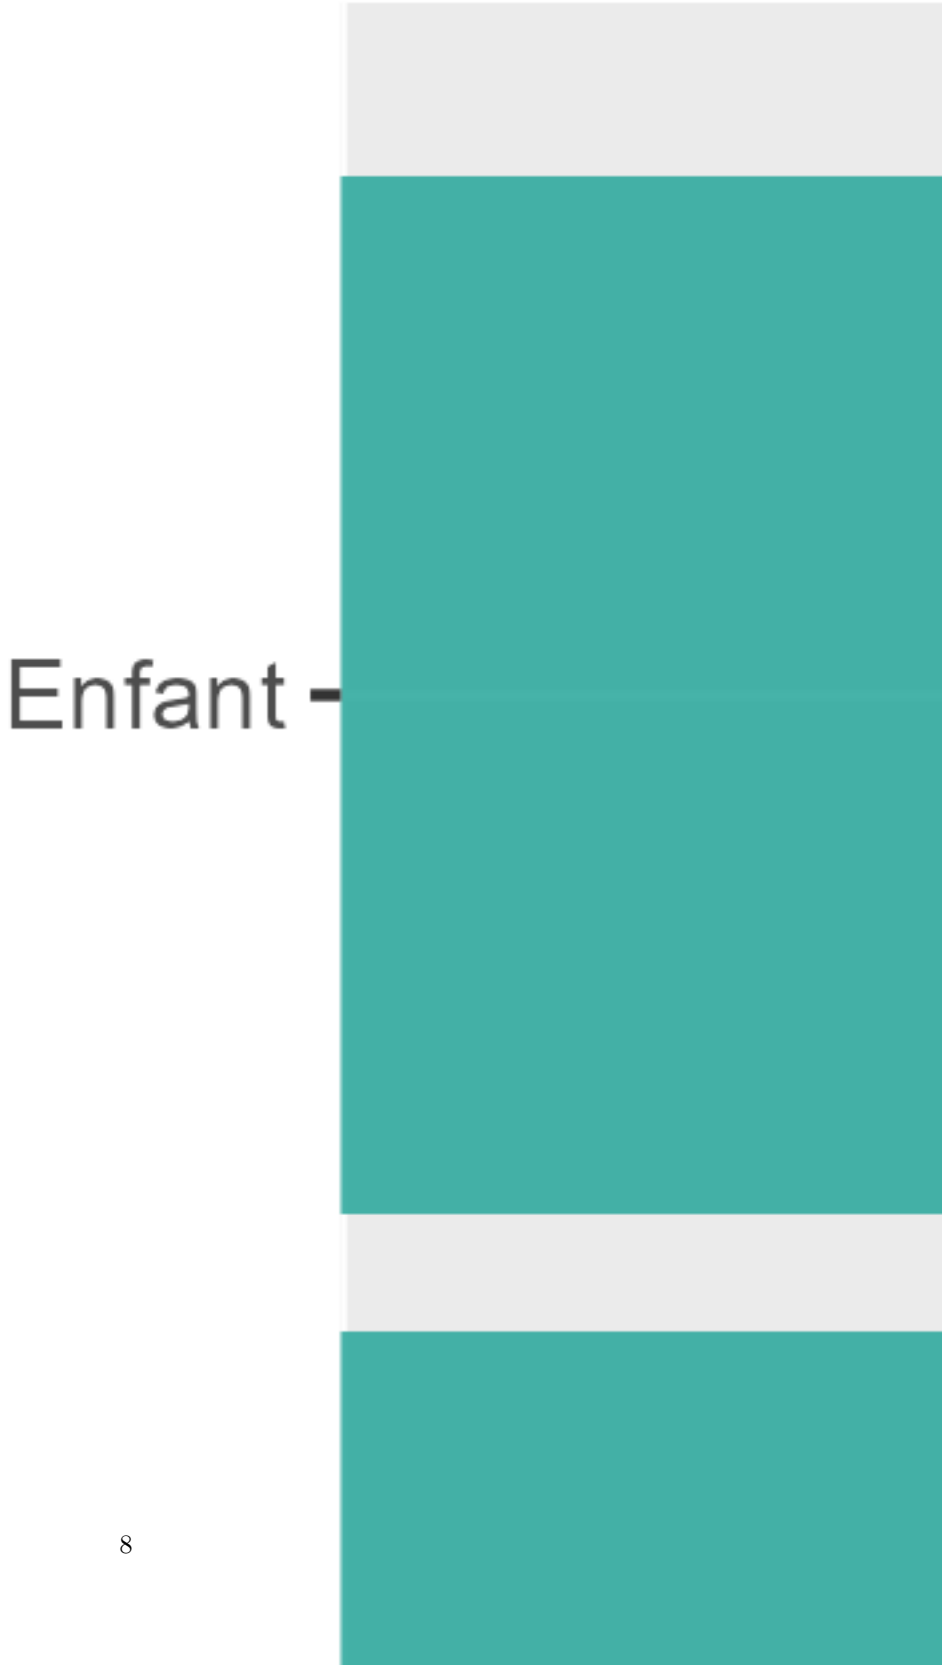

Taille des ménag

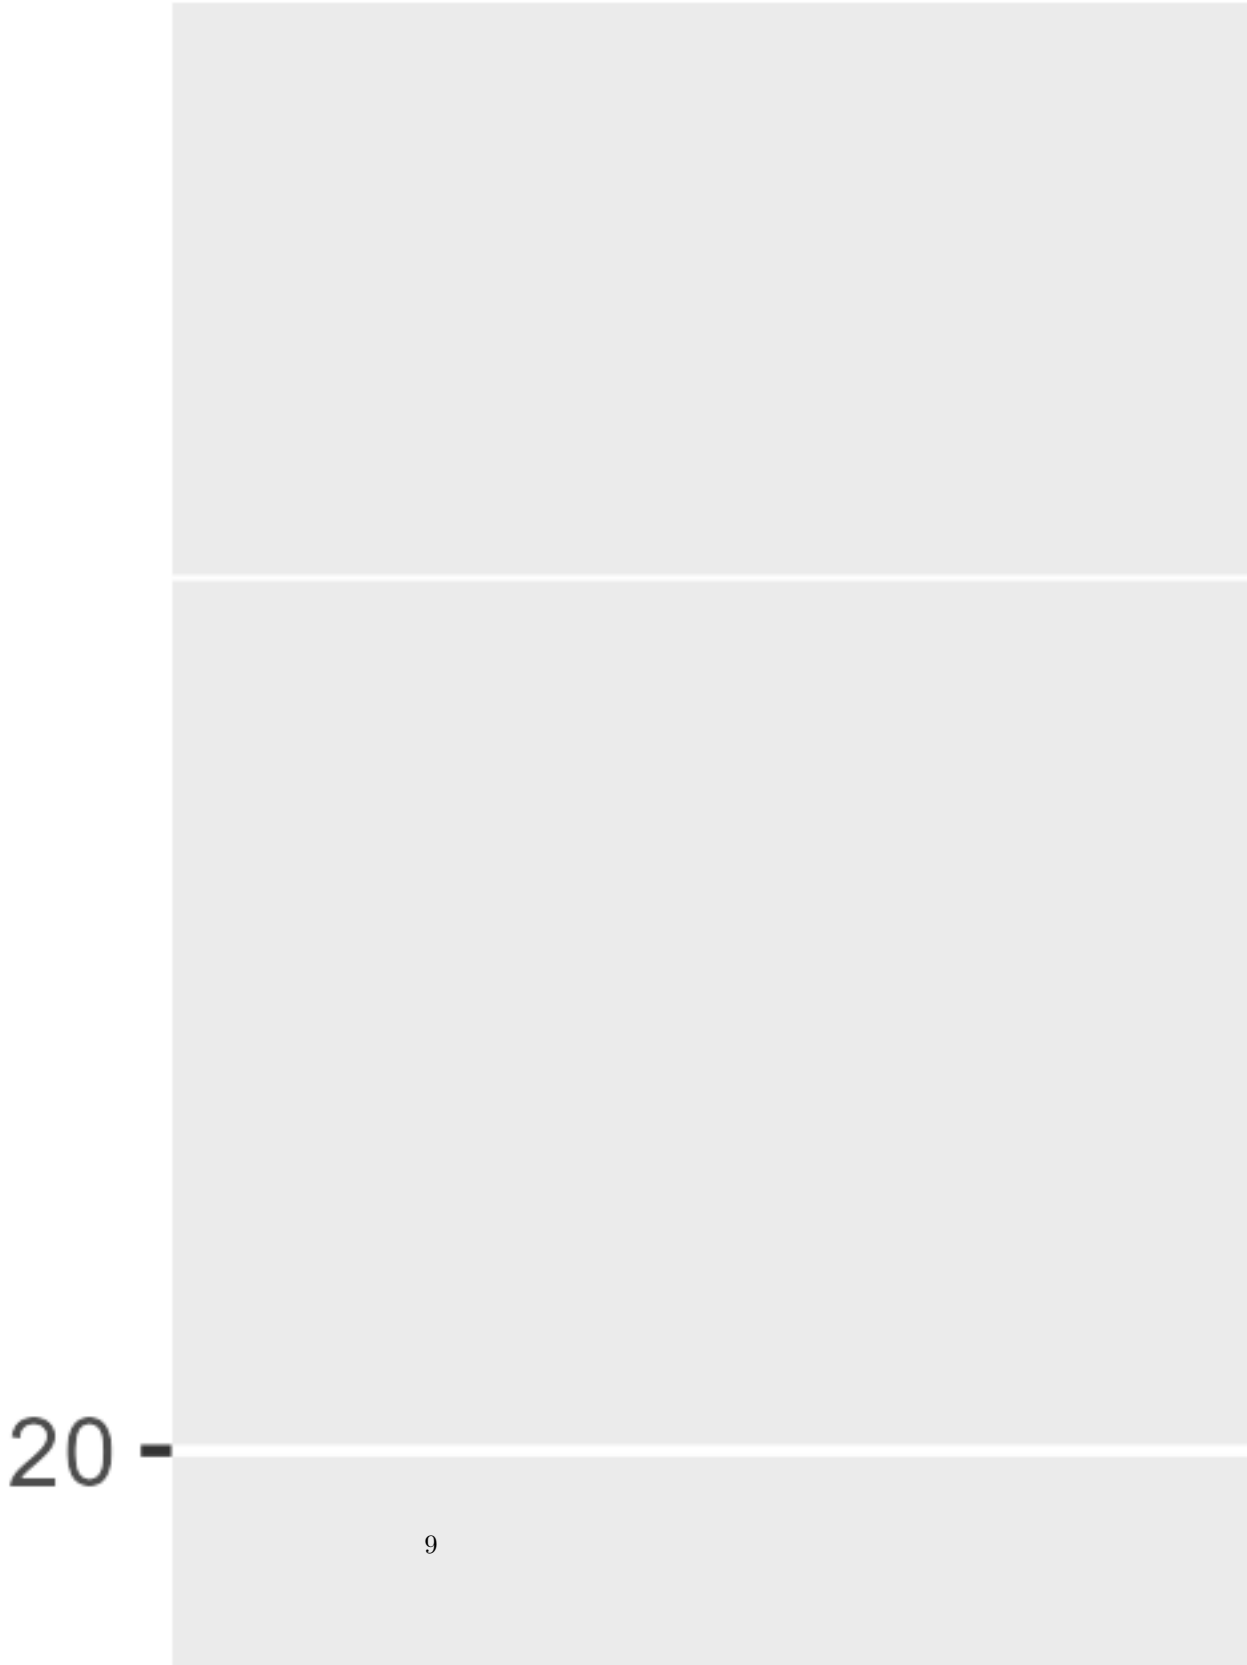

2. **Pyramide des âges** : La structure en pyramide large à la base, obtenue à partir des effectifs pondérés, confirme le profil jeune de la population nigériane.

3. **Lien de parenté** : Les enfants constituent la catégorie la plus représentée selon les proportions pondérées, suivis des chefs de ménage et de leurs conjoints.

4. **Taille des ménages** : Le test de rang pondéré (`svyranktest`) confirme que les ménages ruraux sont significativement plus grands que les ménages urbains.

Références

- World Bank LSMS-ISA. *Nigeria General Household Survey Panel 2010-2018*. https://microdata.worldbank.org
- R Core Team (2025). *R: A language and environment for statistical computing*.
- Wickham H. et al. (2019). *Welcome to the tidyverse*. Journal of Open Source Software.
- Lumley T. (2023). *survey: analysis of complex survey samples*. R package.