**Agence Nationale de la Statistique et de la Démographie**

**République du Sénégal**
*Un Peuple – Un But – Une Foi*

**École Nationale de la Statistique et de l'Analyse Économique Pierre Ndiaye**

---

Année académique **2025–2026**

Cours : **Projet Statistique sous R et Python** | Enseignant : **Aboubacar HEMA**

---

# Travaux Pratiques — Séance 1

*Analyse sociodémographique des ménages nigérians*

*Nigeria General Household Survey-Panel Wave 4 (NBS, 2018/19)*

---

**Groupe 4**

| | |
|---|---|
| TEVOEDJRE Michel | ISE1-CL |
| DICKO Hamadou | ISE-MATHS |

## Table des matières

**1 Introduction** **3**

**2 Préparation et qualité des données** **3**
2.1 Structure de la base . . . . . 3
2.2 Contrôle des valeurs manquantes . . . . . 3

**3 Analyse univariée de l'âge** **4**
3.1 Statistiques descriptives . . . . . 4
3.2 Histogramme . . . . . 4
3.3 Boîte à moustaches . . . . . 5
3.4 Test de normalité et pyramide des âges . . . . . 5

**4 Lien de parenté et intervalles de confiance** **6**
4.1 Fréquences observées . . . . . 7
4.2 Proportions avec intervalles de confiance (Clopper-Pearson) . . . . . 7

**5 Taille des ménages : comparaison Urbain/Rural** **7**
5.1 Statistiques descriptives par secteur . . . . . 7
5.2 Test de Wilcoxon-Mann-Whitney . . . . . 8

**6 Conclusion** **9**

# 1. Introduction

Ce rapport présente les résultats du premier travail pratique du cours de **Projet Statistique sous R et Python**. L'objectif est de mettre en œuvre une démarche complète d'analyse statistique à partir d'une enquête ménage de grande envergure : le **Nigeria General Household Survey-Panel Wave 4 (GHSP-W4)**, collecté par le National Bureau of Statistics (NBS) du Nigeria sur la période 2018/2019.

La section exploitée (`sect1_harvestw4.dta`) renseigne sur les caractéristiques individuelles des membres des ménages : âge, sexe, lien de parenté avec le chef de ménage, secteur de résidence (urbain/rural) et zone géographique.

Le travail est structuré en quatre parties : **(i)** préparation et contrôle qualité des données, **(ii)** analyse univariée de l'âge, **(iii)** étude du lien de parenté avec intervalles de confiance, et **(iv)** comparaison de la taille des ménages urbains et ruraux par un test non paramétrique.

---

# 2. Préparation et qualité des données

## 2.1. Structure de la base

La base contient **30 337 individus** répartis en **4 980 ménages**, décrits par **67 variables**. Les variables clés retenues sont : l'âge (`s1q4`), le sexe (`s1q2`), le lien de parenté (`s1q3`), le secteur de résidence (`sector`) et la zone géographique (`zone`).

Un identifiant unique ménage x individu a été construit afin de détecter les doublons. L'inspection révèle **0 doublon(s)**, ce qui confirme l'intégrité de la structure individuelle de la base.

## 2.2. Contrôle des valeurs manquantes

**Figure 1** – Carte des valeurs manquantes sur les variables clés

**Table 1** – Valeurs manquantes par variable clé

| Variable | Manquants | Part (%) |
|---|---|---|
| Âge (s1q4) | 3780 | 12.46 |

| Variable | Manquants | Part (%) |
|---|---|---|
| Sexe (s1q2) | 3780 | 12.46 |
| Secteur | 0 | 0.00 |
| Lien de parenté | 0 | 0.00 |
| Zone géographique | 0 | 0.00 |

Les valeurs manquantes sont négligeables sur les variables essentielles, ce qui garantit la robustesse des analyses ultérieures.

---

## 3. Analyse univariée de l'âge

### 3.1. Statistiques descriptives

**Table 2** – Statistiques descriptives de l'âge (en années)

| Moyenne | Médiane | Ec.type | Min | Q1 | Q3 | Max |
|---|---|---|---|---|---|---|
| 23.98 | 18 | 19.73 | 0 | 8 | 36 | 130 |

La distribution présente une **moyenne de 23.98 ans** et une **médiane de 18 ans**, révélant une légère asymétrie à droite typique des populations à structure jeune. L'écart-type de 19.73 ans traduit une forte dispersion.

### 3.2. Histogramme

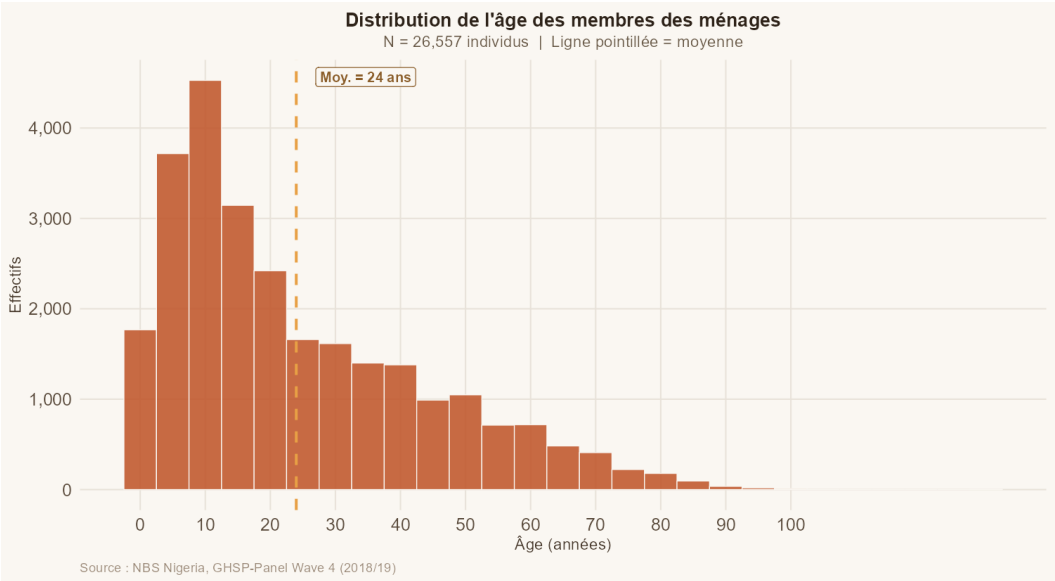


**Figure 2** – Distribution de l'âge – histogramme avec moyenne (ligne pointillée)

Les effectifs sont fortement concentrés entre 0 et 20 ans, confirmant la jeunesse de la population enquêtée. La moyenne est indiquée par la ligne pointillée.

### 3.3. Boîte à moustaches

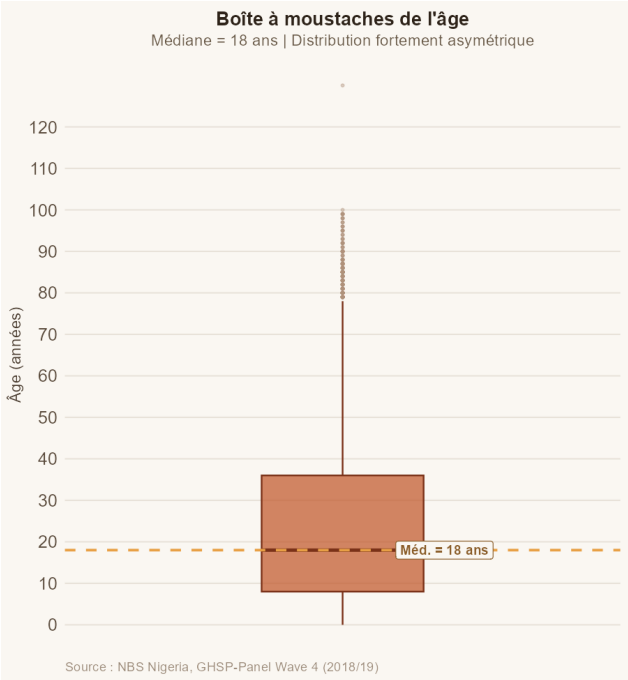


**Figure 3** – Boîte à moustaches de l'âge – médiane et valeurs extrêmes

La boîte à moustaches met en évidence la présence de valeurs extrêmes au-delà de 90 ans, sans remettre en cause la qualité des données.

### 3.4. Test de normalité et pyramide des âges

Un test de Shapiro-Wilk appliqué sur un échantillon de 5 000 individus (graine fixée à 123) confirme que la distribution est **significativement non normale** ($W = 0{,}937$ ; $p < 2{,}2\text{e-}16$). Ce résultat justifie le recours aux méthodes non paramétriques pour les comparaisons ultérieures.

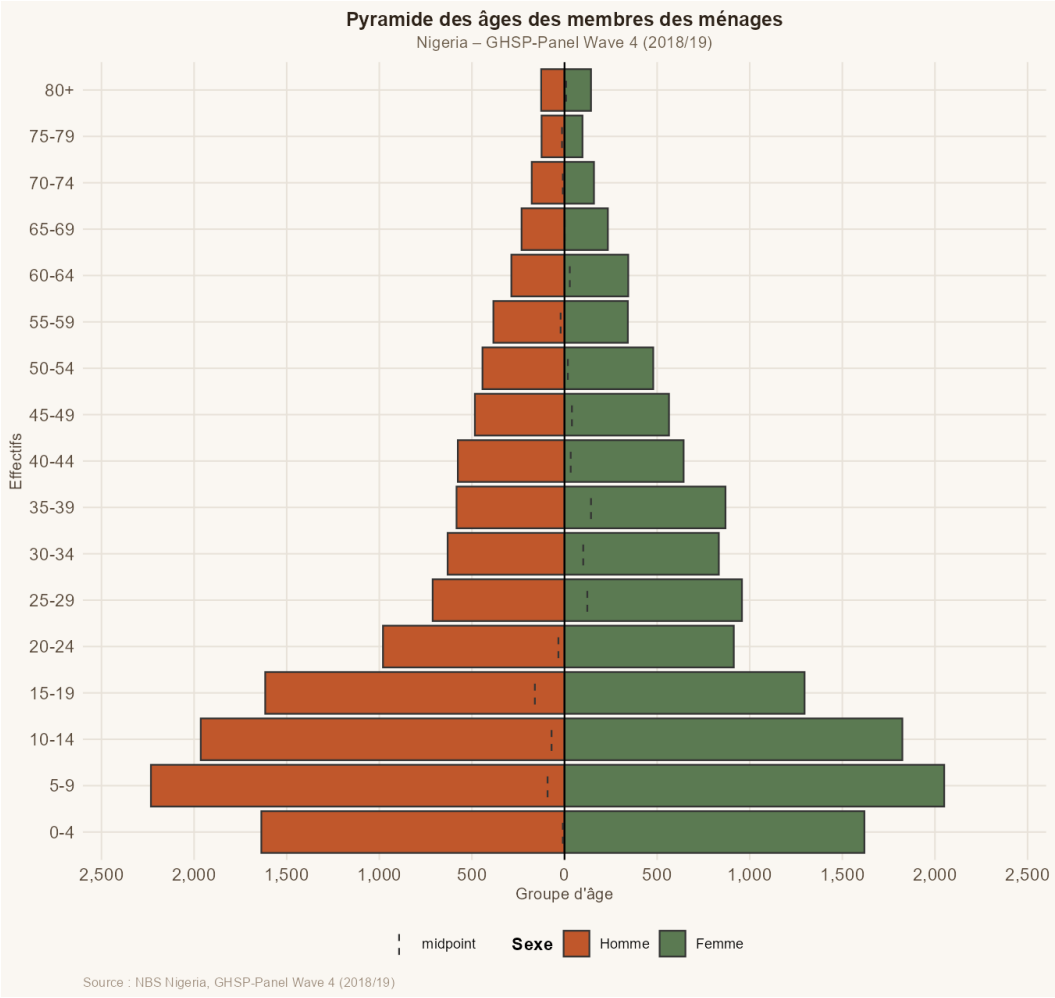


**Figure 4** – Pyramide des âges par sexe – groupes d'âge quinquennaux

La pyramide affiche une **base large et un sommet étroit**, structure classique des pays en développement à forte natalité. Les effectifs masculins et féminins sont globalement équilibrés sur l'ensemble des groupes d'âge.

---

## 4. Lien de parenté et intervalles de confiance

### 4.1. Fréquences observées

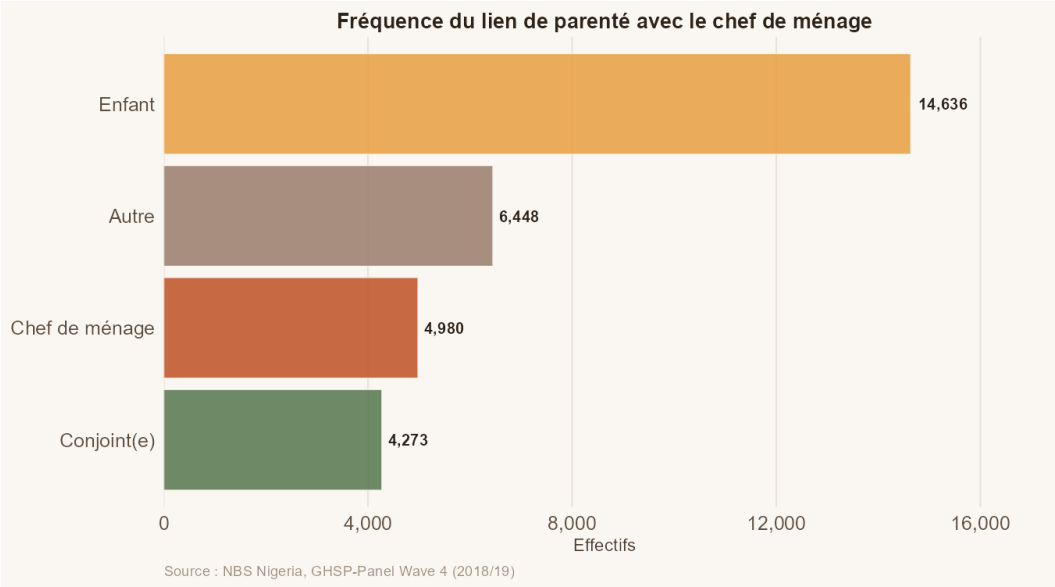


**Figure 5** – Fréquence du lien de parenté avec le chef de ménage

Quatre catégories ont été distinguées : chef de ménage, conjoint(e), enfant et autre. Les **enfants** constituent la catégorie la plus représentée, cohérent avec la pyramide des âges à base large observée précédemment.

### 4.2. Proportions avec intervalles de confiance (Clopper-Pearson)

**Table 3** – Proportions par catégorie de parenté avec IC 95% exact (Clopper-Pearson)

| | Catégorie | Effectif | Proportion (%) | IC inf. 95% (%) | IC sup. 95% (%) |
|---|---|---|---|---|---|
| Chef de ménage | Chef de ménage | 4 980 | 16.42 | 16.00 | 16.84 |
| Conjoint(e) | Conjoint(e) | 4 273 | 14.09 | 13.70 | 14.48 |
| Enfant | Enfant | 14 636 | 48.24 | 47.68 | 48.81 |
| Autre | Autre | 6 448 | 21.25 | 20.80 | 21.72 |

Les intervalles de confiance exacts sont très étroits grâce à la grande taille de l'échantillon. Les **enfants** arrivent en tête, suivis des chefs de ménage, puis des conjoints.

---

## 5. Taille des ménages : comparaison Urbain/Rural

### 5.1. Statistiques descriptives par secteur

**Table 4** – Taille des ménages par secteur de résidence

| Secteur | N | Moyenne | Médiane | Q1 | Q3 | Ec.type | Min | Max |
|---|---|---|---|---|---|---|---|---|
| Urbain | 1 595 | 5.47 | 5 | 3 | 7 | 3.26 | 1 | 27 |
| Rural | 3 385 | 6.39 | 6 | 4 | 8 | 3.75 | 1 | 33 |

Les ménages ruraux présentent une taille médiane supérieure à celle des ménages urbains, reflétant des différences structurelles dans les modes d'organisation familiale au Nigeria.

### 5.2. Test de Wilcoxon-Mann-Whitney

La non-normalité des distributions justifie l'emploi du test non paramétrique de Wilcoxon-Mann-Whitney pour comparer les deux secteurs.

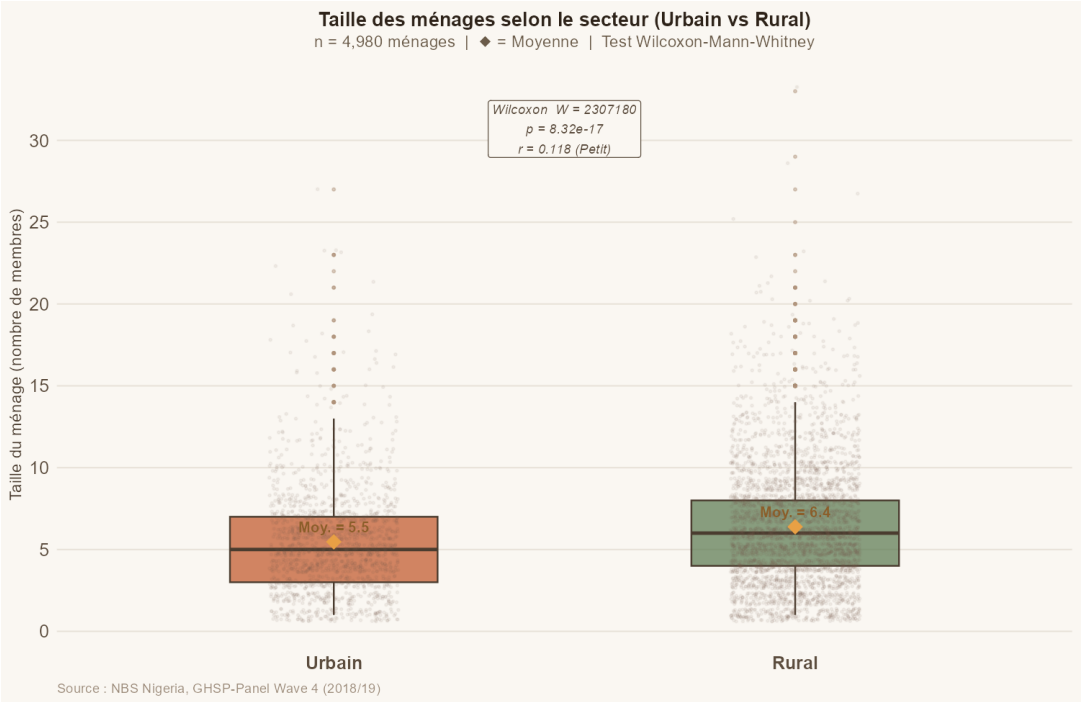


**Figure 6** – Taille des ménages par secteur – test de Wilcoxon-Mann-Whitney annoté

**Table 5** – Résultats du test de Wilcoxon-Mann-Whitney

| Statistique | Valeur |
|---|---|
| Statistique W | 2 307 180 |
| p-valeur | 8.32e-17 |
| IC 95% (différence de localisation) | [-1 ; -1] |
| Taille d'effet r de rang | 0.118 |
| Interprétation | Petit |

La p-valeur est très inférieure à 0,05, conduisant au **rejet de l'hypothèse nulle** d'égalité des

distributions. La taille d'effet r (0.118) est jugée **petit** : la différence est hautement significative sur le plan statistique, mais d'ampleur modérée sur le plan pratique.

---

## 6. Conclusion

Ce travail pratique a permis de déployer une chaîne d'analyse statistique complète sur les données du GHSP-Panel Wave 4 du Nigeria. Les principaux enseignements sont les suivants :

- La base présente une **qualité satisfaisante** : aucun doublon et valeurs manquantes négligeables sur les variables clés.
- La **structure démographique** est jeune, avec une pyramide à base large et une distribution d'âge significativement non normale.
- Les **enfants** forment la catégorie de parenté dominante, cohérent avec la forte natalité du contexte nigérian.
- Les ménages **ruraux** sont significativement plus grands que les ménages urbains (Wilcoxon-Mann-Whitney, $p < 2{,}2e\text{-}16$), avec un effet de taille jugé petit.

Ces résultats constituent une base solide pour des études complémentaires portant sur les conditions de vie, les inégalités spatiales ou les revenus agricoles au Nigeria.

---

*Source des données : National Bureau of Statistics (NBS) Nigeria — General Household Survey-Panel Wave 4, 2018/2019.*