TP1 : Profil démographique des ménages nigérians

Rapport d'analyse

Auteurs :

Mouhamet SECK

Manampisoa Clarrat FINARITRINIAINA

Projet statistique avec R ou python

ENSAE - ISE1-CL / ISE1 MATH - Mars 2026

Contents

1 Introduction **2**

2 Méthodologie **2**
2.1 Données et Variables Clés 2
2.2 Traitements Effectués 2

3 Résultats **3**
3.1 Qualité des Données et Valeurs Manquantes 3
3.2 Analyse Univariée de l'Âge 3
3.3 Pyramide des Âges par Sexe 5
3.4 Lien de Parenté 6
3.5 Taille des Ménages et Comparaison Rural / Urbain 7
3.6 Tableau Récapitulatif Stratifié 9

4 Discussion **10**

5 Conclusion **10**

1 Introduction

Ce rapport présente les analyses descriptives et les tests statistiques réalisés dans le cadre du TP1, à partir des données de la Nigeria General Household Survey (GHS) Panel – vague 4 (2018–2019). L'objectif est d'étudier le profil démographique des ménages nigérians : structure par âge, répartition par sexe, liens de parenté, taille des ménages et disparités entre milieux rural et urbain.

2 Méthodologie

2.1 Données et Variables Clés

Les fichiers suivants ont été utilisés :

- **sect1_harvestw4.dta** : 30 337 individus, variables démographiques (sexe, âge, lien de parenté, secteur).
- **secta_harvestw4.dta** : 5 025 ménages, informations de couverture (utilisé pour vérifier la cohérence des identifiants).

Les variables clés retenues sont :

- **Sexe** : `s1q2` (1 = MALE, 2 = FEMALE).
- **Âge** : `s1q4` (en années).
- **Lien de parenté** : `s1q3` (recodé en quatre catégories : Chef, Conjoint, Enfant, Autre).
- **Milieu de résidence** : `sector` (1 = Urban, 2 = Rural).
- **Taille du ménage** : calculée comme le nombre d'individus par `hhid`.

2.2 Traitements Effectués

```
# Exploration : vérification des doublons, analyse des valeurs manquantes,
# cohérence des identifiants

# Analyse univariée de l'âge : statistiques descriptives,
# test de normalité de Shapiro-Wilk, histogramme, boxplot

# Pyramide des âges : groupes quinquennaux, effectifs par sexe

# Lien de parenté : fréquences, intervalles de confiance à 95 %, barplot

# Taille des ménages : comparaison rural/urbain (statistiques,
# test de Wilcoxon, taille d'effet, boxplot, violin plot)

# Tableau récapitulatif : âge, sexe, taille du ménage stratifiés par zone,
# avec tests de comparaison
```

Les traitements réalisés comprennent l'exploration des fichiers (vérification des doublons, analyse des valeurs manquantes, cohérence des identifiants), l'analyse univariée de l'âge avec test de

normalité de Shapiro-Wilk, la construction de la pyramide des âges par groupes quinquennaux, l'analyse des liens de parenté avec intervalles de confiance à 95 %, la comparaison de la taille des ménages entre milieux rural et urbain via un test de Wilcoxon-Mann-Whitney, et un tableau récapitulatif stratifié par zone de résidence.

3 Résultats

3.1 Qualité des Données et Valeurs Manquantes

L'examen des valeurs manquantes sur les variables clés révèle une situation très satisfaisante. Dans `sect1_w4`, les variables démographiques `s1q2` (sexe), `s1q4` (âge) et `s1q3` (lien de parenté) présentent moins de 1 % de valeurs manquantes, principalement pour les individus partis ou non membres du ménage, ce qui est structurellement attendu. La variable `sector` (milieu de résidence) est complète. Par ailleurs, 4 980 ménages sont communs entre `sect1` et `secta` sur les 5 025 de `secta`, confirmant la cohérence des identifiants. Aucun doublon n'a été détecté sur la clé (`hhid`, `indiv`). Les quelques NA présents seront exclus des analyses concernées.

3.2 Analyse Univariée de l'Âge

L'analyse porte sur les 28 068 individus ayant un âge renseigné.

Table 1: Statistiques descriptives de l'âge

moyenne	mediane	Q1	Q3	min	max	ecart_type	cv	skewness
24	18	8	36	0	130	19.7	0.8	1

La population enquêtée est très jeune : la moyenne est de 24,0 ans et la médiane de 18 ans, ce qui signifie que plus de la moitié des individus ont moins de 18 ans. Le coefficient de variation (0,82) traduit une forte dispersion des âges, tandis que le coefficient d'asymétrie (skewness = 1,00) indique une distribution étirée vers la droite, avec une queue de personnes âgées relativement peu nombreuses. La valeur maximale déclarée de 130 ans constitue vraisemblablement une erreur de déclaration. Le test de Shapiro-Wilk (sur un échantillon de 5 000) rejette très nettement la normalité ($p < 2{,}2e\text{-}16$), ce qui est cohérent avec la structure par âge d'une population en développement à base large et sommet étroit.

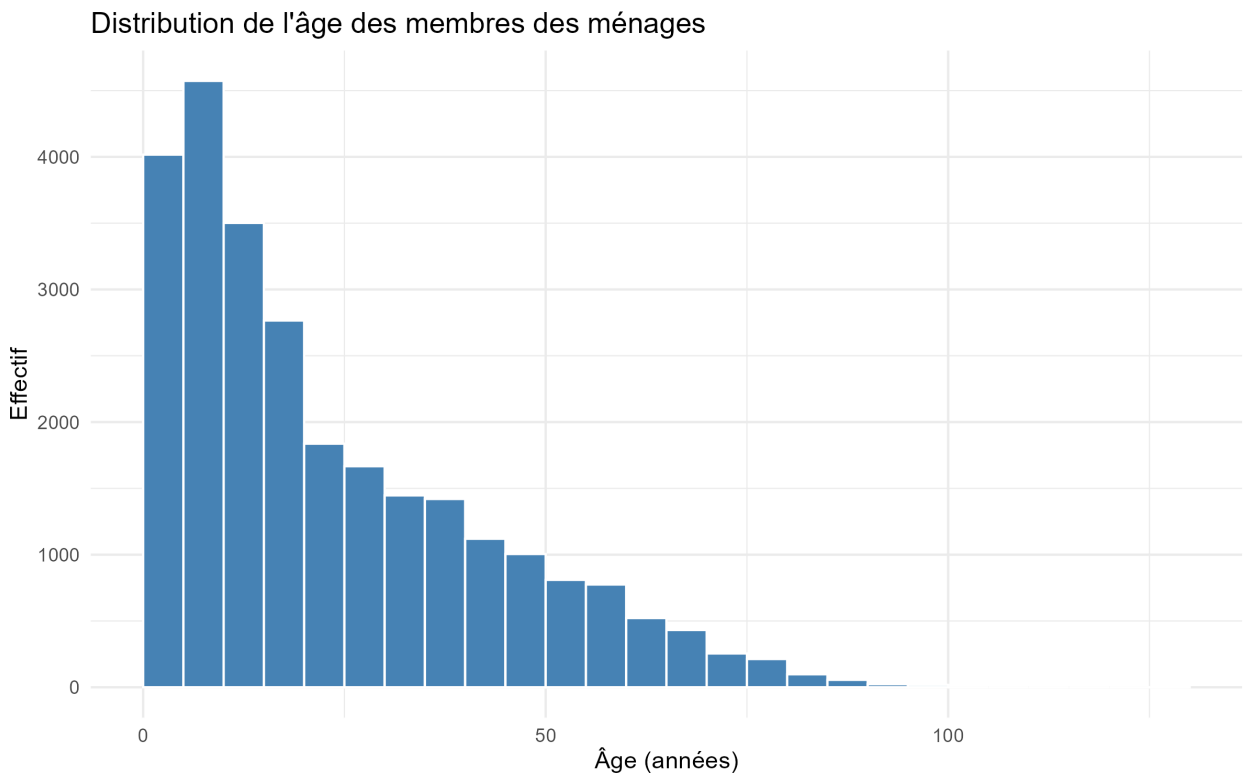
Distribution de l'âge des membres des ménages
Effectif
4000
3000
2000
1000
0
0
50
100
Âge (années)

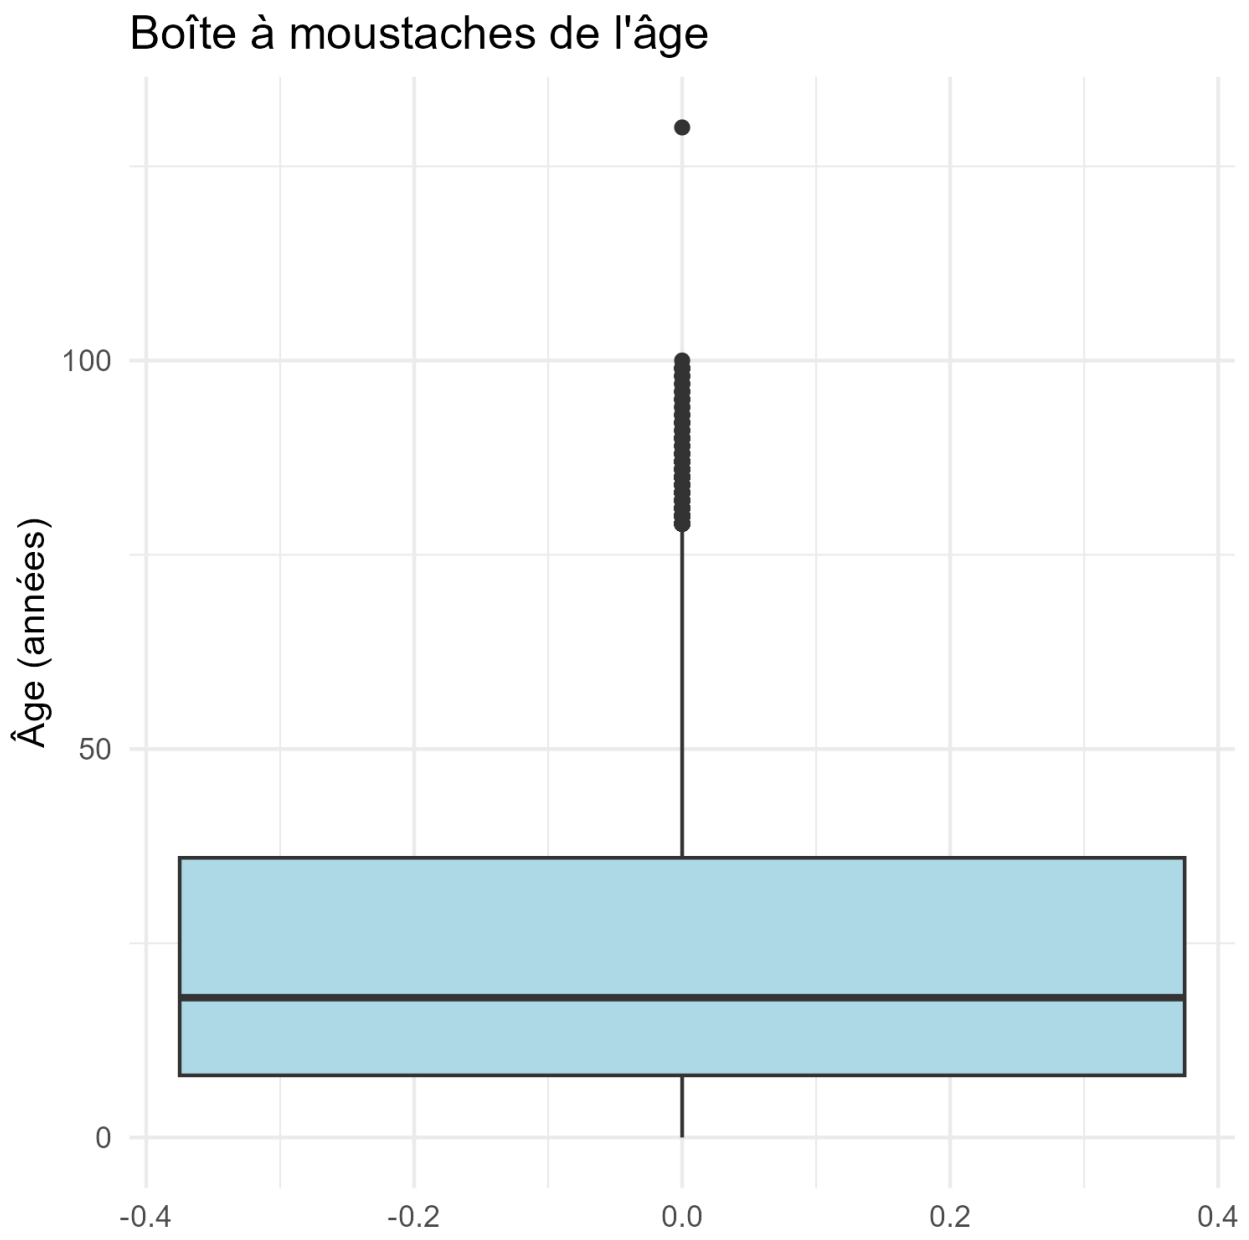

L'histogramme montre une forte concentration des effectifs dans les premières classes d'âge avec un pic chez les 0–4 ans, puis une décroissance progressive typique d'une population jeune. Le boxplot confirme la présence de valeurs extrêmes aux âges élevés et la médiane basse à 18 ans.

3.3 Pyramide des Âges par Sexe

La pyramide des âges (groupes quinquennaux) visualise la structure par sexe de la population enquêtée.

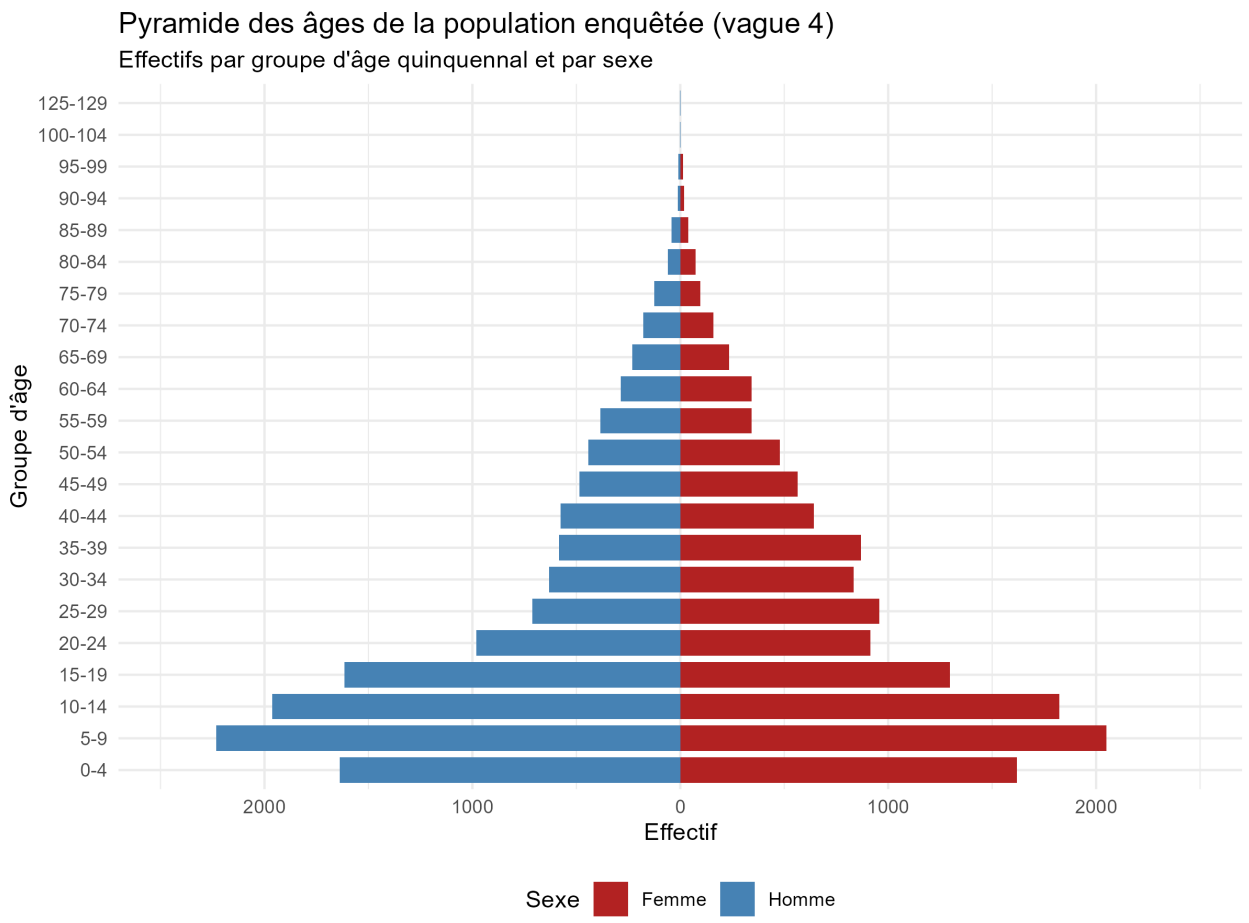

La pyramide présente une base large (classe 0–4 ans la plus fournie dérrière 5–9 et 10–14), caractéristique d'une population jeune à forte natalité. Ce profil suit une forme expansive typique des pays en développement, où chaque génération est plus nombreuse que la précédente. On observe un déséquilibre entre les sexes dans les classes d'âge actives (15–30 ans), où les hommes sont plus nombreux, probablement en raison d'une migration masculine temporaire vers les zones d'emploi. À partir de 30 ans, les femmes deviennent progressivement plus nombreuses, conformément aux tendances démographiques liées à une espérance de vie féminine plus élevée.

3.4 Lien de Parenté

La variable `s1q3` a été regroupée en quatre catégories : Chef, Conjoint, Enfant, Autre.

Table 2: Fréquences des liens de parenté avec IC à 95 %

relation	n	prop_label	ic_low	ic_high
Enfant	14636	55.1%	0.545	0.557
Chef	4980	18.8%	0.183	0.192
Conjoint	4273	16.1%	0.156	0.165
Autre	2668	10%	0.097	0.104

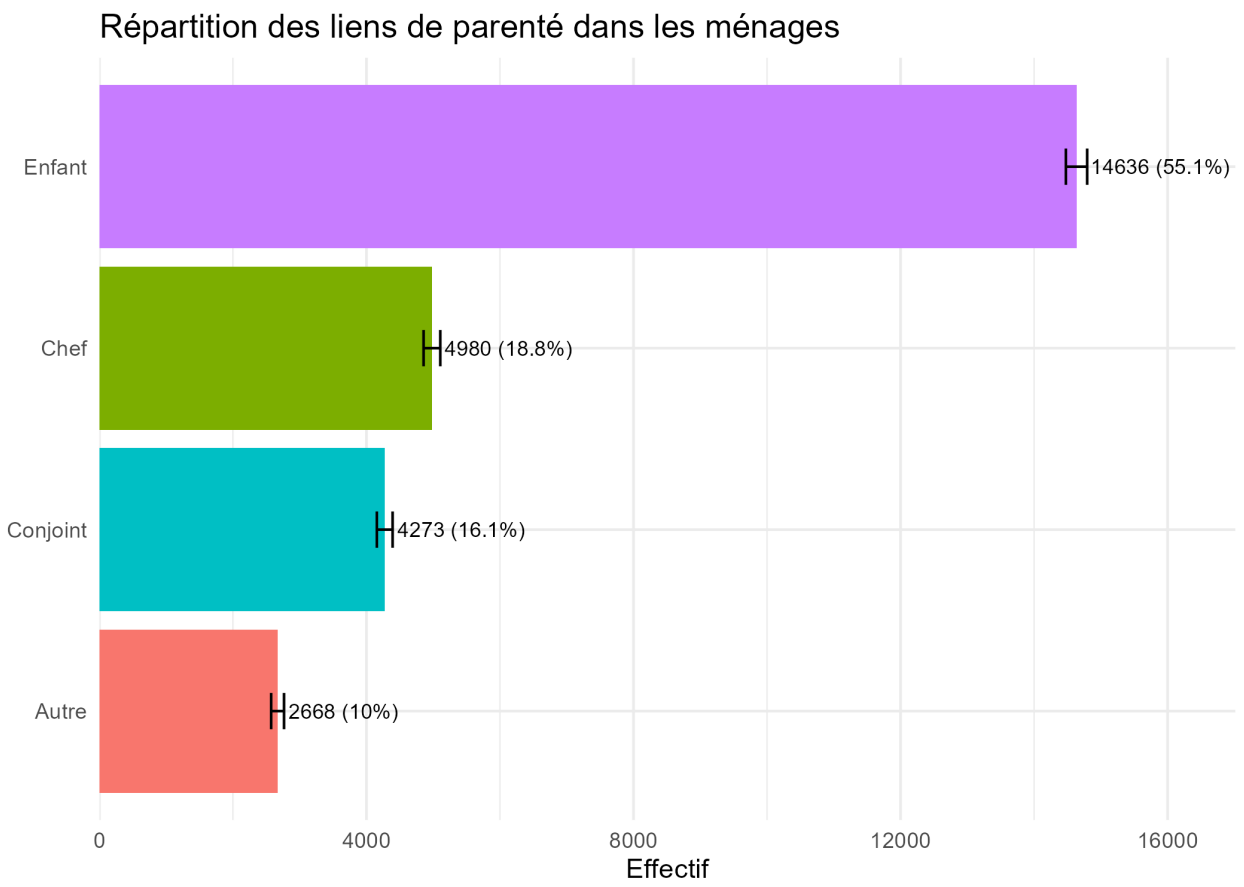

Les enfants représentent 55,1 % des membres enquêtés, soit plus de la moitié de la population, ce qui confirme la jeunesse de la structure démographique nigériane. Les chefs de ménage constituent 18,8 % de l'échantillon et les conjoints 16,1 %, proportions cohérentes avec une structure familiale où chaque ménage compte en moyenne un chef, un conjoint et plusieurs enfants. La catégorie Autre (10,0 %) regroupe des situations diverses telles que les parents, beaux-parents et neveux/nièces, reflétant la fréquence des ménages élargis au Nigeria.

3.5 Taille des Ménages et Comparaison Rural / Urbain

La taille des ménages a été calculée par décompte des individus membres effectifs par `hhid`, conformément à la définition du ménage dans l'enquête. Le recours à une échelle d'équivalence adulte n'est pas approprié ici, cette dernière étant réservée aux analyses de consommation ou de bien-être.

Table 3: Taille des ménages selon le milieu de résidence

zone	n_menages	moyenne	mediane	ecart_type	Q1	Q3	min	max
Rural	3385	6.4	6	3.8	4	8	1	33
Urbain	1595	5.5	5	3.3	3	7	1	27

En zone rurale (3 385 ménages), la taille moyenne est de 6,4 personnes (médiane 6), avec un écart-type de 3,8 et un maximum de 33 personnes. En zone urbaine (1 595 ménages), elle est plus

faible : 5,5 personnes en moyenne (médiane 5), écart-type 3,3, maximum 27. Le test de Wilcoxon-Mann-Whitney confirme une différence très significative entre les deux distributions ($p < 2{,}2e\text{-}16$). La taille d'effet ($r = 0{,}12$) est qualifiée de faible selon les conventions de Cohen, indiquant que si la différence est statistiquement robuste, son amplitude pratique reste modeste et que d'autres facteurs tels que le niveau d'éducation, l'accès aux services, la fécondité contribuent également à expliquer la composition des ménages.

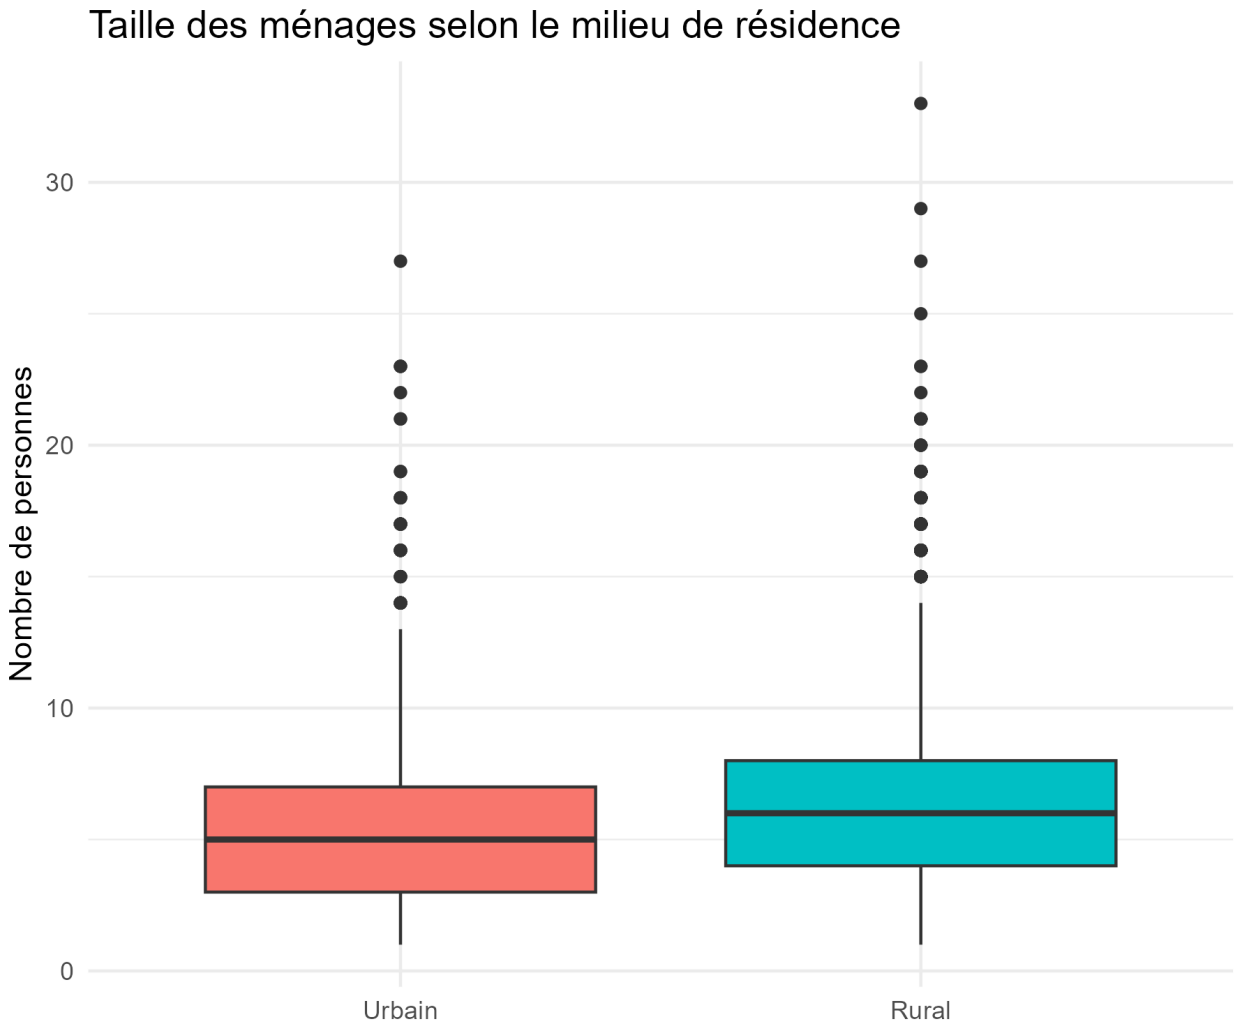

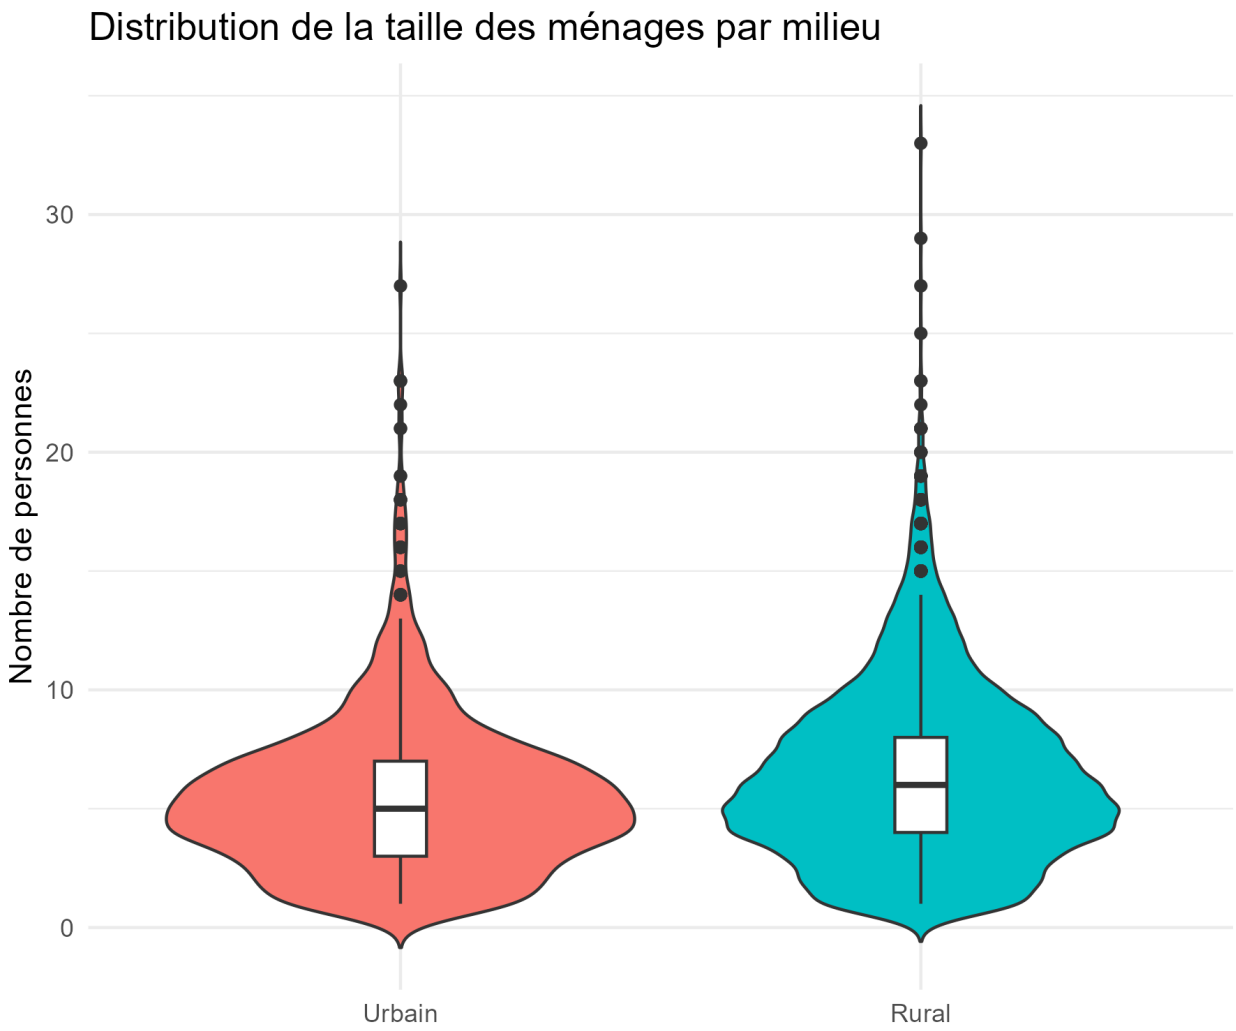

Le boxplot montre des médianes distinctes (6 vs 5) et une dispersion plus forte en milieu rural. Le violin plot confirme une asymétrie à droite plus marquée en zone rurale, avec une queue de distribution plus étendue traduisant la présence de ménages très nombreux.

3.6 Tableau Récapitulatif Stratifié

Le tableau ci-dessous synthétise les principales caractéristiques démographiques selon la zone de résidence.

Table 4: Caractéristiques démographiques des ménages selon la zone

Caractéristique	Overall N = 26 557	| Urbain N = 7 56	| Rural N = 18 9	0 | p-val
Sexe				
Homme	13 189 (50%)	3 730 (49%)	9 459 (50%)	
Femme	13 368 (50%)	3 837 (51%)	9 531 (50%)	
Âge (années)	24,0 (19,7)	25,0 (19,4)	23,6 (19,8)	
Taille du ménage	7 (5, 10)	6 (5, 9)	8 (5, 11)	

L'âge moyen est légèrement plus élevé en ville (25,5 ans contre 23,2 ans en milieu rural), différence significative au test de Wilcoxon, probablement liée à une migration des jeunes adultes vers les zones urbaines. La répartition hommes/femmes est comparable dans les deux zones (environ 47–48 % d'hommes), sans différence significative (chi-deux, $p = 0,4$), ce qui indique une structure de genre homogène entre milieux. La taille des ménages reste la caractéristique la plus discriminante entre les deux zones, comme analysé à la section précédente.

4 Discussion

Les analyses confirment une structure démographique typique d'un pays en développement à forte croissance démographique. La population est très jeune (âge médian 18 ans) avec une forte proportion d'enfants (55,1 % des membres enquêtés), ce qui se traduit par une pyramide des âges à base large caractéristique d'une fécondité élevée. Les ménages ruraux sont significativement plus grands que les ménages urbains (6,4 contre 5,5 personnes en moyenne), reflet de structures familiales élargies, d'une fécondité plus forte et d'un moindre accès aux services de planification familiale en zone rurale. La déséquilibre observé dans les classes d'âge actives (15–30 ans), où les hommes sont surreprésentés, suggère l'existence de flux migratoires masculins temporaires, phénomène courant dans les économies en développement.

Au-delà des disparités quantitatives, ces résultats soulèvent la question de la pression démographique sur les ressources des ménages. Une population majoritairement composée d'enfants et de jeunes dépendants implique un ratio de dépendance élevé, susceptible de peser sur les capacités d'épargne et d'investissement des ménages, en particulier en milieu rural où les ménages sont déjà plus nombreux.

Limites :

- L'analyse repose sur une coupe transversale (vague 4) ; elle ne permet pas d'étudier les évolutions temporelles de la structure démographique.
- La catégorie « Autre » pour le lien de parenté regroupe des situations diverses ; une ventilation plus fine pourrait apporter des nuances sur la prévalence des ménages élargis.
- La valeur maximale d'âge déclarée (130 ans) n'a pas été corrigée dans cette analyse ; une procédure de nettoyage des valeurs aberrantes d'âge pourrait améliorer la qualité des statistiques descriptives.

5 Conclusion

Ce travail a permis de dresser un portrait démographique détaillé des ménages nigérians à partir de la vague 4 du GHS Panel. Il met en évidence une population très jeune, des ménages ruraux significativement plus grands, et une structure familiale dominée par les enfants. Le déséquilibre de genre observé dans les classes d'âge actives suggère des flux migratoires masculins temporaires. Ces résultats constituent une base solide pour des analyses ultérieures portant sur l'éducation, la santé ou l'agriculture, qui exploiteront d'autres modules de l'enquête.