# TP1: Profil démographique des ménages nigérians

Parfait Jemmy Prodige NGOYI, Analyste statisticien

2026-03-13

Téléchargement des packages nécessaires

```
# 1. Liste complète et propre (sans doublons)
packages <- c("haven", "dplyr", "ggplot2", "apyramid", "naniar",
              "rstatix", "PropCIs", "patchwork", "coin", "gtsummary",
              "broom.helpers", "labelled")

invisible(lapply(packages, library, character.only = TRUE))
```

```
# 2. Identification des packages manquants
missing_pkgs <- packages[!(packages %in% installed.packages()[, "Package"])]

# 3. Installation avec gestion des dépendances
if (length(missing_pkgs)) {
  install.packages(missing_pkgs, dependencies = TRUE)
}

# 4. Chargement sécurisé
# On utilise invisible() pour ne pas encombrer la console
invisible(lapply(packages, library, character.only = TRUE))

# Vérification rapide du chargement de gtsummary
if ("gtsummary" %in% .packages()) {
  message("gtsummary est prêt à l'emploi !")
} else {
  warning("gtsummary n'est toujours pas chargé. Vérifiez les erreurs d'installation.")
}
```

1. Chargement des données de sect1_harvestw4

```
data <- read_dta("sect1_harvestw4.dta")
data
```

```
## # A tibble: 30,337 x 59
##    zone    state   lga       sector     ea  hhid indiv s1q4a   s1q2     s1q3
##    <dbl+l> <dbl+l> <dbl+lbl> <dbl+l> <dbl> <dbl> <dbl> <dbl+l> <dbl+lb> <dbl+lb>
##  1 4 [4. ~ 1 [1. ~ 115 [115~ 1 [1. ~   670 10001     1 1 [1. ~  1 [1. ~  1 [1. ~
##  2 4 [4. ~ 1 [1. ~ 115 [115~ 1 [1. ~   670 10001     2 1 [1. ~  2 [2. ~  2 [2. ~
##  3 4 [4. ~ 1 [1. ~ 115 [115~ 1 [1. ~   670 10001     3 1 [1. ~  2 [2. ~  3 [3. ~
##  4 4 [4. ~ 1 [1. ~ 115 [115~ 1 [1. ~   670 10001     4 1 [1. ~  2 [2. ~ 12 [12.~
```

```
##  5 4 [4. ~ 1 [1. ~ 115 [115~ 1 [1. ~   670 10001     6 2 [2. ~ NA       NA
##  6 4 [4. ~ 1 [1. ~ 115 [115~ 1 [1. ~   670 10001     7 2 [2. ~ NA       NA
##  7 4 [4. ~ 1 [1. ~ 115 [115~ 1 [1. ~   670 10001     8 1 [1. ~  1 [1. ~  3 [3. ~
##  8 4 [4. ~ 1 [1. ~ 115 [115~ 1 [1. ~   670 10001     9 1 [1. ~  1 [1. ~  3 [3. ~
##  9 4 [4. ~ 1 [1. ~ 115 [115~ 1 [1. ~   670 10002     1 1 [1. ~  1 [1. ~  1 [1. ~
## 10 4 [4. ~ 1 [1. ~ 115 [115~ 1 [1. ~   670 10002     2 1 [1. ~  2 [2. ~  2 [2. ~
## # i 30,327 more rows
## # i 49 more variables: s1q3_os <chr>, s1q4 <dbl>, s1q5a <dbl+lbl>,
## #   s1q5b <dbl+lbl>, s1q6_day <dbl+lbl>, s1q6_month <dbl+lbl>, s1q6_year <dbl>,
## #   s1q8a <dbl+lbl>, s1q8b <dbl+lbl>, s1q8c <dbl+lbl>, s1q7 <dbl+lbl>,
## #   s1q11 <dbl+lbl>, s1q12_1 <dbl>, s1q12_2 <dbl>, s1q12_3 <dbl>,
## #   s1q12_4 <dbl>, s1q13a_1 <dbl>, s1q13a_2 <dbl>, s1q13a_3 <dbl>,
## #   s1q13a_4 <dbl>, s1q13b <dbl+lbl>, s1q13c <dbl>, s1q13 <dbl+lbl>, ...
```

Exploration de la structure

```r
# Avec str()
data %>%
  select(sector, s1q2, s1q4, s1q3) %>%
  str()
```

```
## tibble [30,337 x 4] (S3: tbl_df/tbl/data.frame)
##  $ sector: dbl+lbl [1:30337] 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1...
##    ..@ label       : chr "Sector"
##    ..@ format.stata: chr "%8.0g"
##    ..@ labels      : Named num [1:2] 1 2
##    .. ..- attr(*, "names")= chr [1:2] "1. Urban" "2. Rural"
##  $ s1q2  : dbl+lbl [1:30337]  1,  2,  2,  2, NA, NA,  1,  1,  1,  2,  1, NA, NA, ...
##    ..@ label       : chr "What is the sex of [NAME]?"
##    ..@ format.stata: chr "%8.0g"
##    ..@ labels      : Named num [1:2] 1 2
##    .. ..- attr(*, "names")= chr [1:2] "1. MALE" "2. FEMALE"
##  $ s1q4  : num [1:30337] 55 41 11 53 NA NA 8 2 52 45 ...
##   ..- attr(*, "label")= chr "How old is [NAME] (IN COMPLETED YEARS)?"
##   ..- attr(*, "format.stata")= chr "%8.0g"
##  $ s1q3  : dbl+lbl [1:30337]  1,  2,  3, 12, NA, NA,  3,  3,  1,  2,  3, NA, NA, ...
##    ..@ label       : chr "What  is the relationship of [NAME] to the head of household?"
##    ..@ format.stata: chr "%8.0g"
##    ..@ labels      : Named num [1:14] 1 2 3 4 5 6 7 8 9 10 ...
##    .. ..- attr(*, "names")= chr [1:14] "1. HEAD" "2. SPOUSE" "3. OWN CHILD" "4. STEP CHILD" ...
```

```r
# Avec glimpse()

data %>%
  select(sector, s1q2, s1q4, s1q3) %>%
  glimpse()
```

```
## Rows: 30,337
## Columns: 4
## $ sector <dbl+lbl> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,~
## $ s1q2   <dbl+lbl>  1,  2,  2,  2, NA, NA,  1,  1,  1,  2,  1, NA, NA, NA, NA,~
## $ s1q4   <dbl> 55, 41, 11, 53, NA, NA, 8, 2, 52, 45, 17, NA, NA, NA, NA, 8, 6,~
## $ s1q3   <dbl+lbl>  1,  2,  3, 12, NA, NA,  3,  3,  1,  2,  3, NA, NA, NA, NA,~
```

```r
data %>%
  select(s1q4) %>%
  summary()
```

```
##       s1q4
##  Min.   :  0.00
##  1st Qu.:  8.00
##  Median : 18.00
##  Mean   : 23.98
##  3rd Qu.: 36.00
##  Max.   :130.00
##  NA's   :3780
```

Verification des doublons et valeurs manquantes

```r
# Voir les doublons
library(dplyr)

doublons <- data %>%
  group_by(hhid, indiv) %>%
  filter(n() > 1)

doublons
```

```
## # A tibble: 0 x 59
## # Groups:   hhid, indiv [0]
## # i 59 variables: zone <dbl+lbl>, state <dbl+lbl>, lga <dbl+lbl>,
## #   sector <dbl+lbl>, ea <dbl>, hhid <dbl>, indiv <dbl>, s1q4a <dbl+lbl>,
## #   s1q2 <dbl+lbl>, s1q3 <dbl+lbl>, s1q3_os <chr>, s1q4 <dbl>, s1q5a <dbl+lbl>,
## #   s1q5b <dbl+lbl>, s1q6_day <dbl+lbl>, s1q6_month <dbl+lbl>, s1q6_year <dbl>,
## #   s1q8a <dbl+lbl>, s1q8b <dbl+lbl>, s1q8c <dbl+lbl>, s1q7 <dbl+lbl>,
## #   s1q11 <dbl+lbl>, s1q12_1 <dbl>, s1q12_2 <dbl>, s1q12_3 <dbl>,
## #   s1q12_4 <dbl>, s1q13a_1 <dbl>, s1q13a_2 <dbl>, s1q13a_3 <dbl>, ...
```

```r
# Compter les doublons
data %>%
  count(hhid, indiv) %>%
  filter(n > 1)
```

```
## # A tibble: 0 x 3
## # i 3 variables: hhid <dbl>, indiv <dbl>, n <int>
```

Il n'y a aucun doublon dans le jeu de données.

```r
# Compter les valeurs manquantes par variable
miss_var_summary(data)
```

```
## # A tibble: 59 x 3
##    variable n_miss pct_miss
##    <chr>     <int>    <num>
##  1 s1q12_4   30323    100.
```

```
##  2 s1q13a_4  30323    100.
##  3 s1q32     30294     99.9
##  4 s1q33     30294     99.9
##  5 s1q12_3   30239     99.7
##  6 s1q13a_3  30239     99.7
##  7 s1q13c    29851     98.4
##  8 s1q12_2   29721     98.0
##  9 s1q13a_2  29721     98.0
## 10 s1q15     29547     97.4
## # i 49 more rows
```

Les variables s1q2(sexe) et s1q4(age) comptent 3780 valeurs manquantes, soit 12,5% de sa taille. nous allons supprimer ces enregistrements.

```r
# Suppression des enregistrements ayant des valeurs manquantes sur les variables s1q2 et s1q4.
data_traite <- data %>%
  drop_na(s1q2, s1q4)
```

```r
# Verification
sum(is.na(data_traite$s1q2))
```

```
## [1] 0
```

```r
sum(is.na(data_traite$s1q4))
```

```
## [1] 0
```

```r
sum(is.na(data_traite$s1q3))
```

```
## [1] 0
```

2. Analyse univariée de l'âge des membres

```r
# Avec un histogramme

ggplot(data_traite, aes(x = s1q4)) +
  geom_histogram(binwidth = 5, fill = "skyblue", color = "black") +
  labs(
    title = "Distribution de l'âge des membres",
    x = "Âge",
    y = "Effectif"
  ) +
  theme_minimal()
```

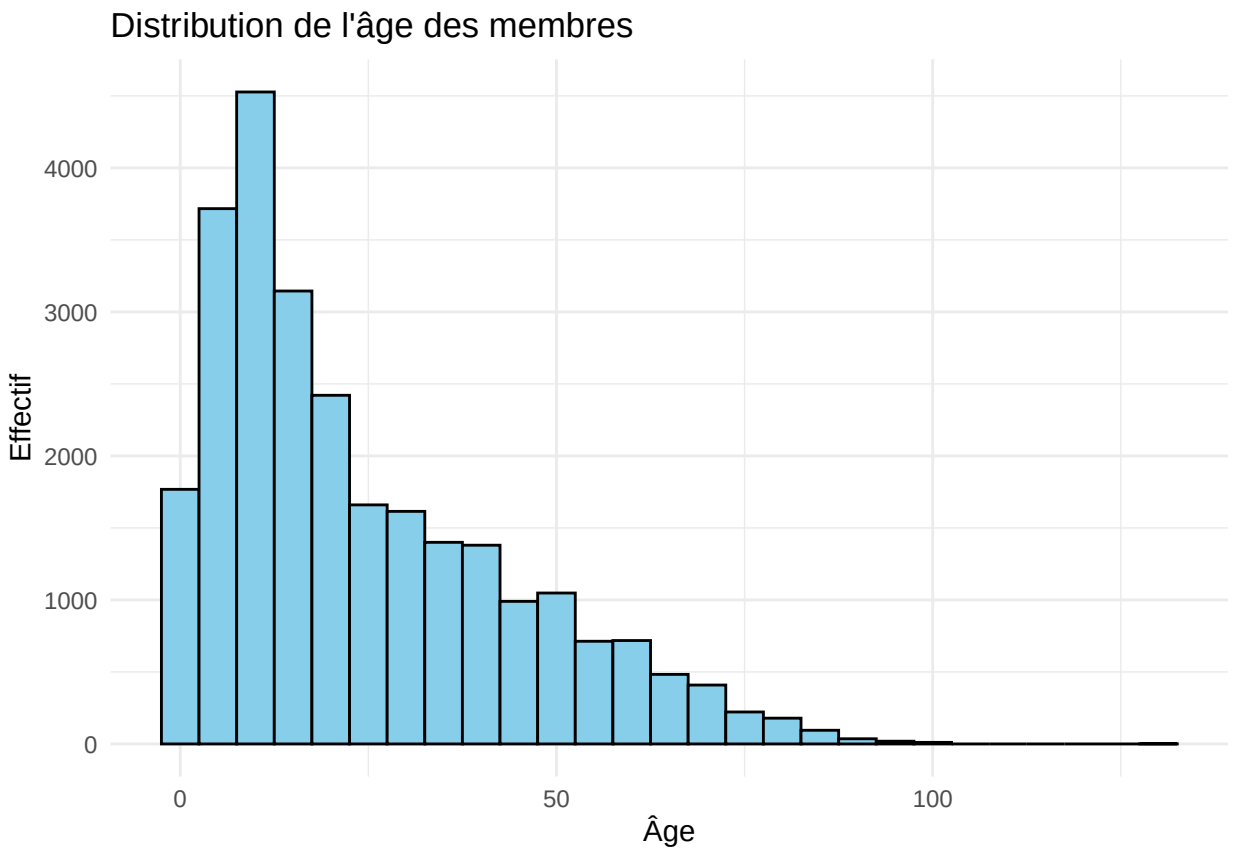


Il ressort de cet histogramme que la classe d'age de 10-15 a un effectif de plus de 4500 individus, ce qui fait d'elle la classe modale. Nous observons aussi que la distribution d'age est étalée à droite,avec un changement de tendance significativement observable à partir de la classe 30-35. Cela signifie que les individus d'ages inférieurs à 30 ans sont plus nombreux que ceux qui en plus de 30 ans.

```
# Avec une boîte à moustaches


ggplot(data_traite, aes(y = s1q4)) +
  geom_boxplot(fill = "lightblue") +
  labs(
    title = "Boîte à moustaches de l'âge des membres",
    y = "Âge"
  ) +
  theme_minimal()
```

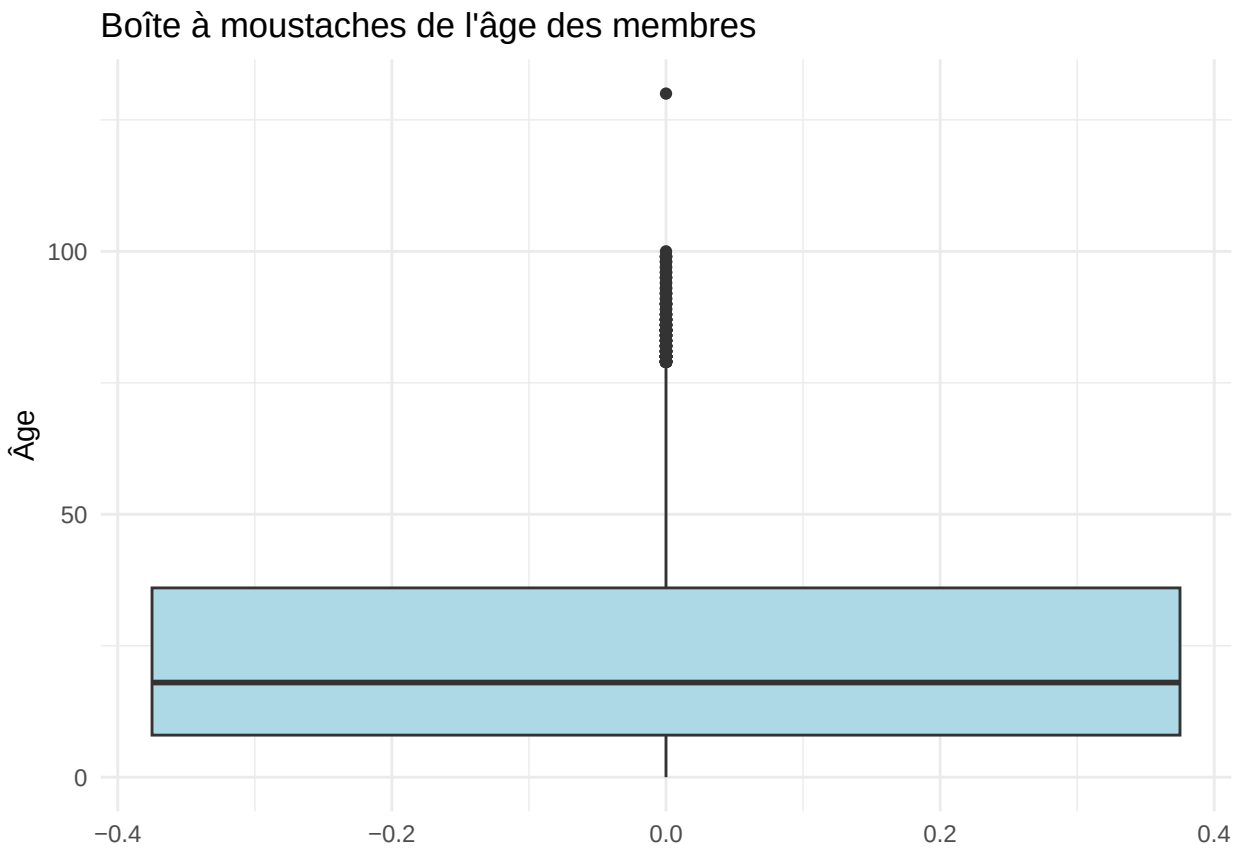


Le boxplot permet d'observer que l'age moyen est inférieur à 25 ans. De plus, quelques individus ont plus de 55ans. Ces derniers s'écartent considérablement du reste des individus. Le boxplot présente aussi un individu agé de plus de 125 ans. Cette valeur peut être considérée comme valeur aberrante, au vue de la tendance des données.

```
# correction de la valeur aberrente en le remplacant par NA.
data_traite$s1q4 <- ifelse(data_traite$s1q4 == 130, NA, data_traite$s1q4)
```

```
# Avec les statistiques descriptives (moyenne, médiane, Q1, Q3, CV, asymétrie)

data_traite %>%
  summarise(
    moyenne = mean(s1q4, na.rm = TRUE),
    mediane = median(s1q4, na.rm = TRUE),
    Q1 = quantile(s1q4, 0.25, na.rm = TRUE),
    Q3 = quantile(s1q4, 0.75, na.rm = TRUE),
    ecart_type = sd(s1q4, na.rm = TRUE),
    CV = sd(s1q4, na.rm = TRUE) / mean(s1q4, na.rm = TRUE),
  )
```

```
## # A tibble: 1 x 6
##   moyenne mediane    Q1    Q3 ecart_type    CV
##     <dbl>   <dbl> <dbl> <dbl>      <dbl> <dbl>
## 1    24.0      18     8    36       19.7 0.822
```

L'age moyen est de 23,97 ans, environ 24 ans. L'age médian est de 18 ans. Cela signifie que la moitié des individus ont moins de 18 ans. Le 1er quartile est de 8 ans. Cela veut dire que le quart des individus ont

moins de 8 ans. Par ailleurs, le 3e quartile est de 36 ans, c'est-a-dire, 3 individus sur 4 ont moins de 36 ans. Le CV de 0,822 soit 82,2 % indique une très forte dispersion des âges autour de la moyenne.

Test de normalité avec Shapiro-Wilk.

Le test de Shapiro-Wilk n'est pas adapté à la taille de nos données (taille supérieure à 5000). On va effectuer un échantillonnage aléatoire de 5000 observations.

```
set.seed(123)
sample_data <- sample(data_traite$s1q4, 5000)
shapiro.test(sample_data)
```

```
##
##  Shapiro-Wilk normality test
##
## data:  sample_data
## W = 0.90372, p-value < 2.2e-16
```

La p-value du test étant inférieure à 0,05. Alors,on rejette l'hypothese de normalité. La distribution d'age ne suit pas une distribution normale.

3. Pyramide des âges (groupes de 5 ans) par sexe pour la vague 4

```
# Creation des groupes d'ages de 5 ans
data_traite <- data_traite %>%
  mutate(age_group = cut(
    s1q4,
    breaks = seq(0, 100, 5),
    right = FALSE
  ))
```

```
data_traite <- data_traite %>%
  rename(sexe = s1q2)

data_traite <- data_traite %>%
  mutate(sexe = factor(sexe,
                       levels = c(1, 2),
                       labels = c("Homme", "Femme")))
```

```
# Pyramide des âges (groupes de 5 ans) par sexe pour la vague 4
pyramid_data <- data_traite %>%
  count(age_group, sexe)
# mettre les les hommes en négatif
pyramid_data <- pyramid_data %>%
  mutate(effectif = ifelse(sexe == "Homme", -n, n))
```

```
sum(is.na(data_traite$age_group))
```

```
## [1] 2
```

```r
pyramid_data <- pyramid_data %>%
  drop_na(age_group)

sum(is.na(pyramid_data$age_group))
```

```
## [1] 0
```

```r
# Construction de la pyramide

ggplot(pyramid_data, aes(x = age_group, y = effectif, fill = sexe)) +
  geom_bar(stat = "identity") +
  coord_flip() +
  labs(
    title = "Pyramide des âges - Vague 4",
    x = "Groupes d'âge",
    y = "Effectif"
  ) +
  theme_minimal()
```

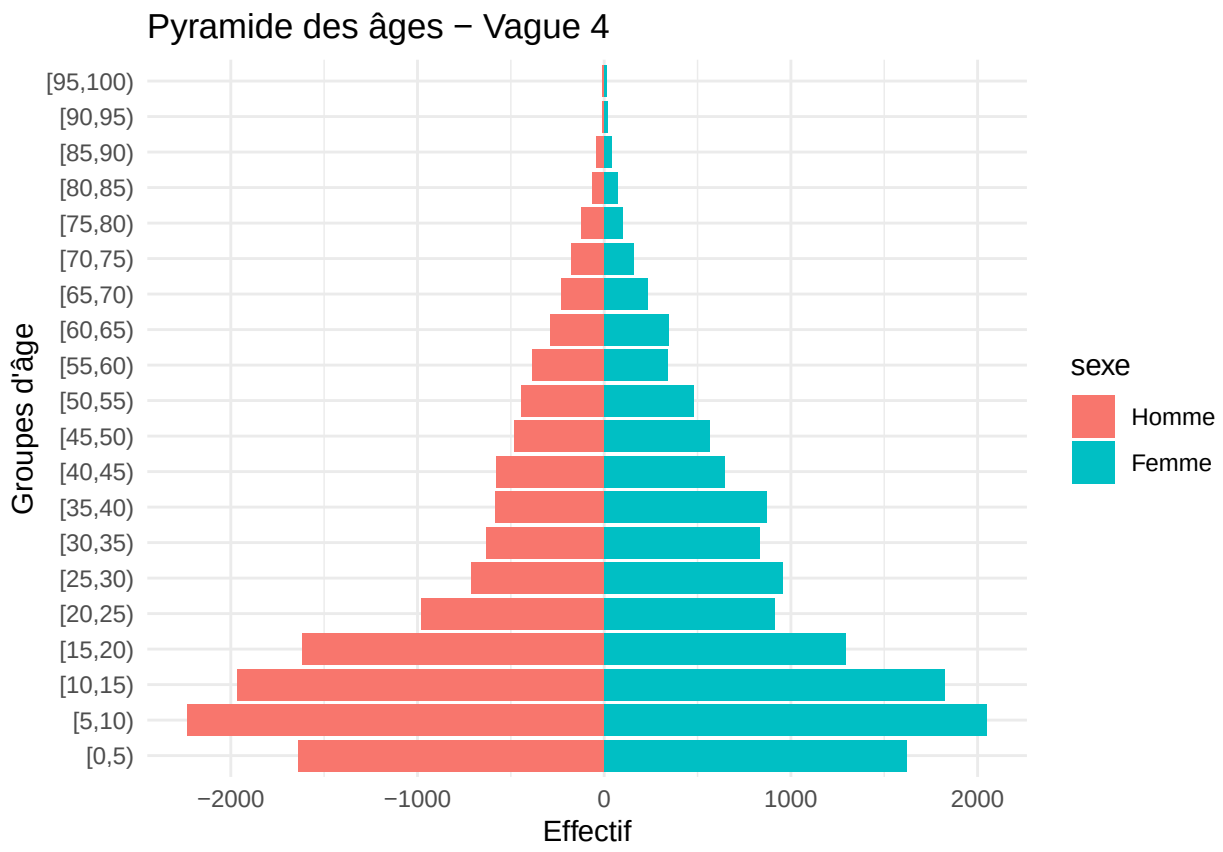


```r
# Avec apyramid
age_pyramid(
  data = pyramid_data,
  age_group = age_group,
  split_by = sexe,
  count = n
)
```

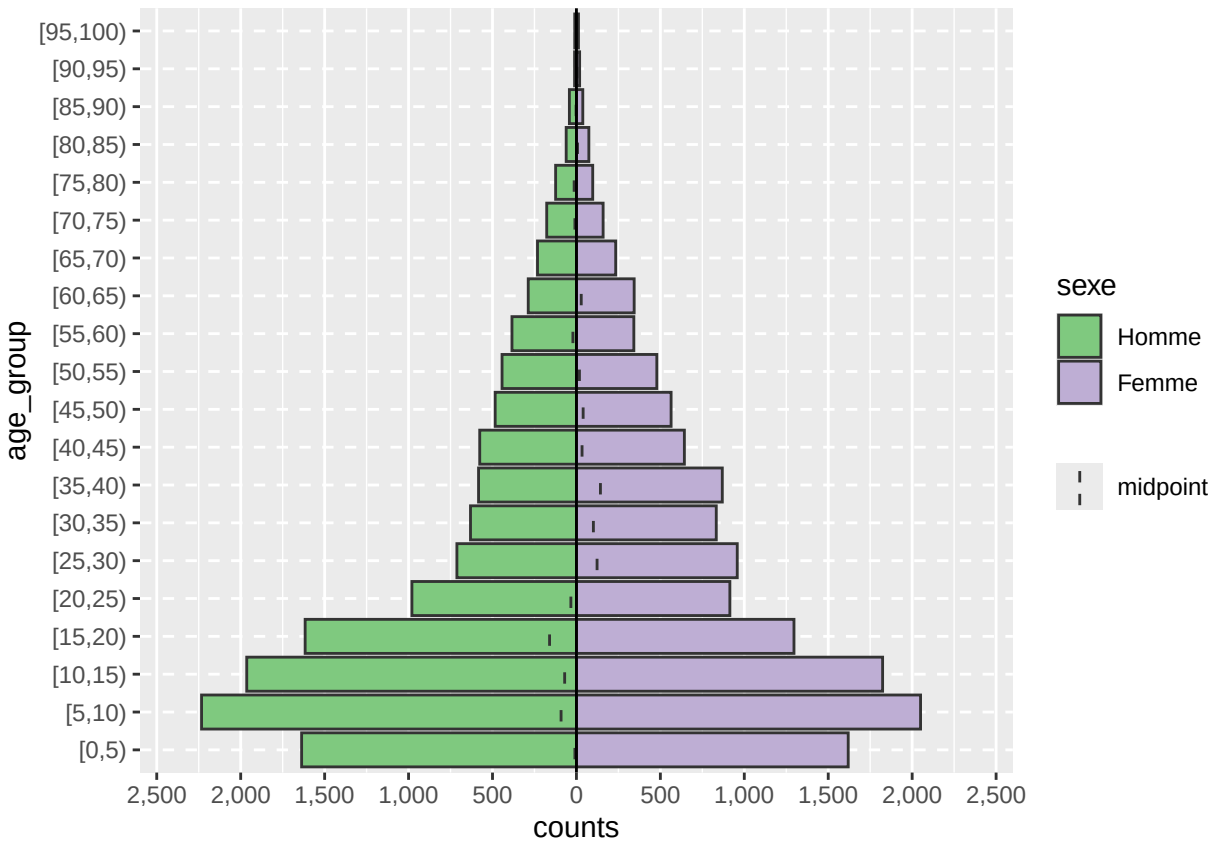


Commentaire:la pyramide des âges met en évidence une structure démographique très jeune, caractérisée par une forte base (les enfants et les jeunes de 0 à 20 ans) et une diminution progressive des effectifs avec l'âge. La pyramide montre une répartition globalement équilibrée entre les hommes et les femmes dans la plupart des groupes d'âge. Les écarts observés restent relativement faibles, ce qui suggère l'absence de déséquilibre majeur entre les sexes.

4. Fréquences du lien de parenté (chef de ménage, conjoint, enfant, autre):

renommer les modalités de la variable s1q3 (lien de parenté)

```
#voir les modalités
unique(data_traite$s1q3)
```

```
## <labelled<double>[14]>: What  is the relationship of [NAME] to the head of household?
##  [1]  1  2  3 12  7  6 15 14  8 10  9  4 11  5
##
## Labels:
##  value                          label
##      1                        1. HEAD
##      2                      2. SPOUSE
##      3                   3. OWN CHILD
##      4                  4. STEP CHILD
##      5               5. ADOPTED CHILD
##      6                  6. GRANDCHILD
##      7              7. BROTHER/SISTER
##      8                8. NIECE/NEPHEW
```

```
##      9         9. BROTHER/SISTER-IN-LAW
##     10                       10. PARENT
##     11                11. PARENT-IN-LAW
##     12                12. DOMESTIC HELP
##     14     14. OTHER RELATION (SPECIFY)
##     15 15. OTHER NON-RELATION (SPECIFY)
```

```r
# traitement de la variable s1q3
data_traite$s1q3 <- factor(data_traite$s1q3,
  levels = c(1,2,3,4,5,6,7,8,9,10,11,12,14,15),
  labels = c(
    "Chef de ménage",
    "Conjoint",
    "Enfant",
    "Beau-fils / Belle-fille",
    "Enfant adopté",
    "Petit-enfant",
    "Frère / Soeur",
    "Neveu / Nièce",
    "Beau-frère / Belle-soeur",
    "Parent",
    "Beau-parent",
    "Employé domestique",
    "Autre parent",
    "Autre non-parent"
  )
)
```

```r
# Calculer les fréquences et proportions de chaque modalité

freq_data <- data_traite %>%
  count(s1q3) %>%
  mutate(
    proportion = n / sum(n)
  )
freq_data
```

```
## # A tibble: 14 x 3
##    s1q3                        n proportion
##    <fct>                   <int>      <dbl>
##  1 Chef de ménage           4980   0.188
##  2 Conjoint                 4273   0.161
##  3 Enfant                  14636   0.551
##  4 Beau-fils / Belle-fille   192   0.00723
##  5 Enfant adopté              88   0.00331
##  6 Petit-enfant             1045   0.0393
##  7 Frère / Soeur             487   0.0183
##  8 Neveu / Nièce             229   0.00862
##  9 Beau-frère / Belle-soeur  137   0.00516
## 10 Parent                    291   0.0110
## 11 Beau-parent                20   0.000753
## 12 Employé domestique         39   0.00147
## 13 Autre parent              123   0.00463
## 14 Autre non-parent           17   0.000640
```

```r
# calcul des intervalles de confiance à 95%, avec binom.test
freq_data <- freq_data %>%
  rowwise() %>%
  mutate(
    ic = list(binom.test(n, sum(freq_data$n))$conf.int),
    ic_inf = ic[1],
    ic_sup = ic[2]
  ) %>%
  ungroup()
```

```r
# barplot
ggplot(freq_data, aes(x = reorder(s1q3, proportion), y = proportion)) +
  geom_bar(stat = "identity", fill = "steelblue") +
  geom_errorbar(aes(ymin = ic_inf, ymax = ic_sup), width = 0.2) +
  geom_text(aes(label = scales::percent(proportion, accuracy = 1)),
            hjust = -0.1, size = 3) +   # ajuste hjust pour que le texte soit à droite des barres
  coord_flip() +
  labs(
    title = "Lien de parenté avec le chef de ménage",
    x = "Modalités",
    y = "Proportion"
  ) +
  theme_minimal()
```

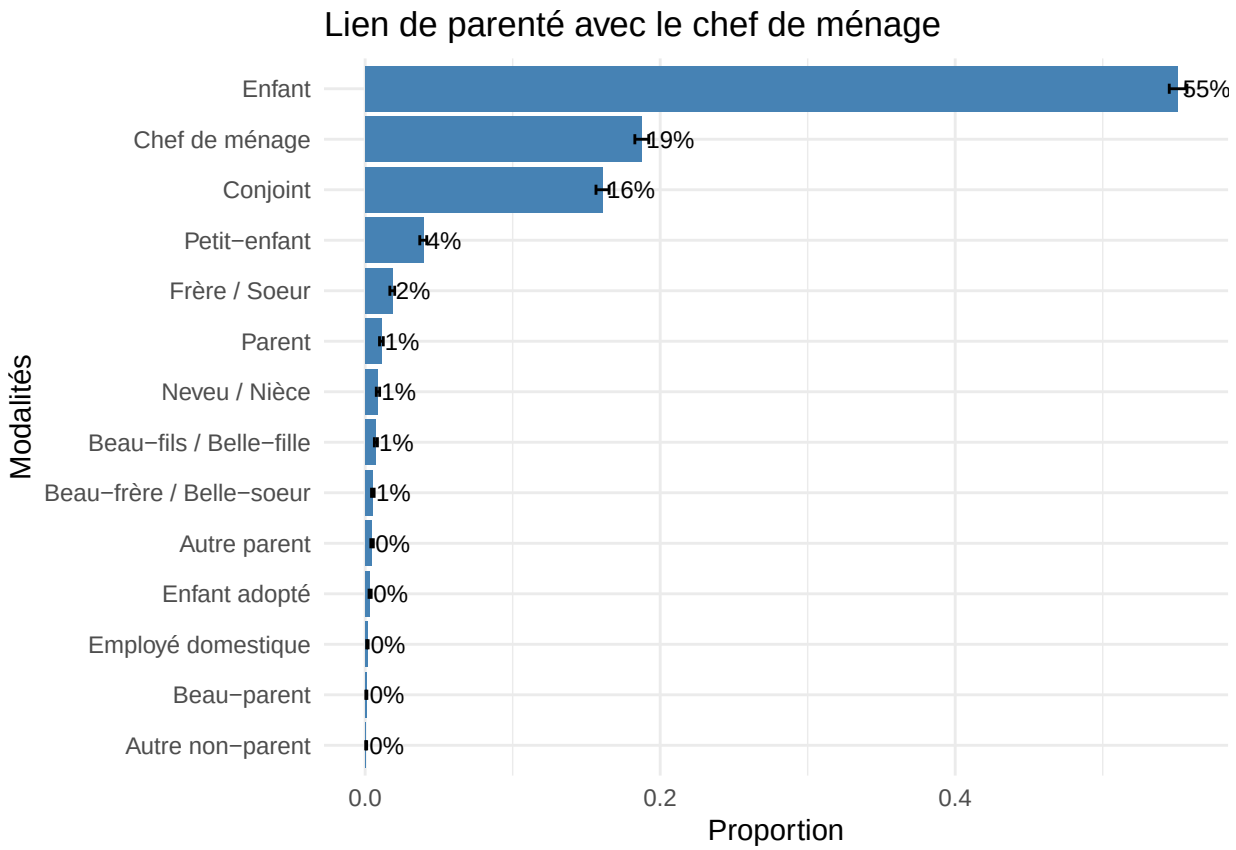


La proportion d'enfants (55%) domine largement toutes les catégories de lien de parenté. Cela signifie que les ménages sont composés en grande partie d'enfants du chef de ménage,plus de la moitié des ménages. La deuxieme modalité la plus importante est la modalté "conjoint" (16%). Ce qui montre que les ménages sont

majoritairement des cellules familiales constituées du CM, de son ou ses conjoint.e.s et en grande partie(plus de la moitié des ménages) de ses enfants.

```
# avec un regroupement de modalités

data_traite <- data_traite %>%
  mutate(s1q3_group = ifelse(s1q3 %in% c("Chef de ménage", "Conjoint", "Enfant", "Petit-enfant"),
                             s1q3, "Autres"))
# Transformer en facteur avec les labels souhaités
data_traite$s1q3_group <- factor(data_traite$s1q3_group,
                                 levels = c("1", "2", "3", "6", "Autres"),
                                 labels = c("Chef de ménage", "Conjoint", "Enfant", "Petit-enfant", "Au
```

```
# Calculer les fréquences et proportions de chaque modalité

freq_data <- data_traite %>%
  count(s1q3_group) %>%
  mutate(
    proportion = n / sum(n)
  )
freq_data
```

```
## # A tibble: 5 x 3
##   s1q3_group         n proportion
##   <fct>          <int>      <dbl>
## 1 Chef de ménage  4980     0.188
## 2 Conjoint        4273     0.161
## 3 Enfant         14636     0.551
## 4 Petit-enfant    1045     0.0393
## 5 Autres          1623     0.0611
```

```
# ordonner les frequences
freq_data <- freq_data %>%
  arrange(proportion)
```

```
# ordonner les frequences
freq_data <- freq_data %>%
  arrange(proportion)

# barplot

ggplot(freq_data, aes(x = reorder(s1q3_group, proportion), y = proportion)) +
  geom_bar(stat = "identity", fill = "steelblue") +
  geom_text(aes(label = scales::percent(proportion, accuracy = 0.1)),
            hjust = -0.1, size = 4) +  # étiquette à droite de la barre
  coord_flip() +
  labs(
    title = "Lien de parenté avec le chef de ménage",
    x = "Modalités",
    y = "Proportion"
  ) +
  theme_minimal() +
  scale_y_continuous(labels = scales::percent_format(accuracy = 1), expand = expansion(mult = c(0, 0.1)
```

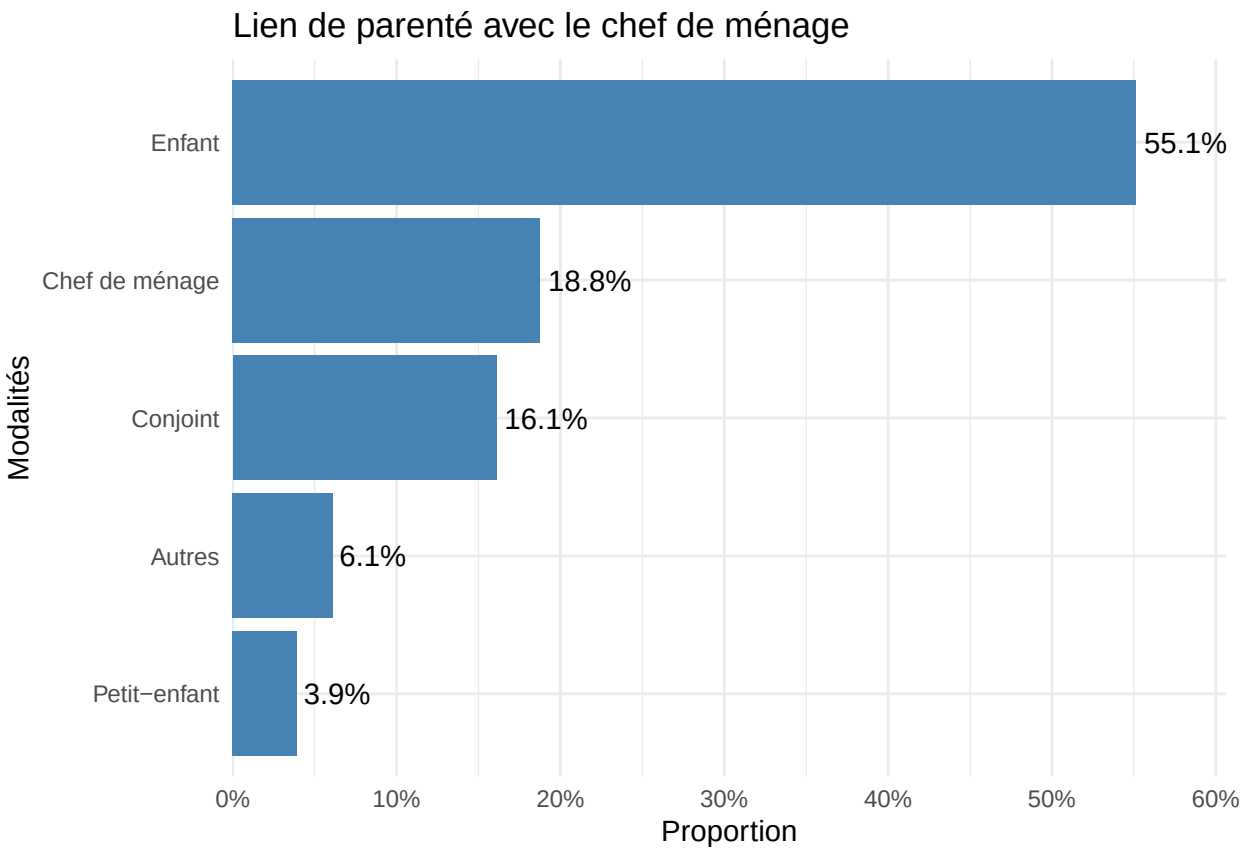


5. Comparaison de la taille moyenne des ménages entre zones rurales et urbaines

```
# Calculer taille des menages
data_traite <- data_traite %>%
  group_by(hhid) %>%
  mutate(taille_men = n()) %>%
  ungroup()
```

```
# traitement de la variable sector

# Transformer en facteur avec labels
data_traite$sector <- factor(data_traite$sector,
                             levels = c(1, 2),       # les valeurs numériques actuelles
                             labels = c("Urbain", "Rural"))  # nouveaux labels
```

```
# Boxplot des tailles de ménages par sector
ggplot(data_traite, aes(x = sector, y = taille_men, fill = sector)) +
  geom_boxplot(alpha = 0.6) +
  stat_summary(fun = mean, geom = "point", color = "red", size = 3) + # moyenne
  labs(
    title = "Distribution de la taille des ménages par zone",
    x = "Zone",
    y = "Taille du ménage"
  ) +
  theme_minimal() +
  scale_fill_manual(values = c("Urbain" = "steelblue", "Rural" = "orange"))
```

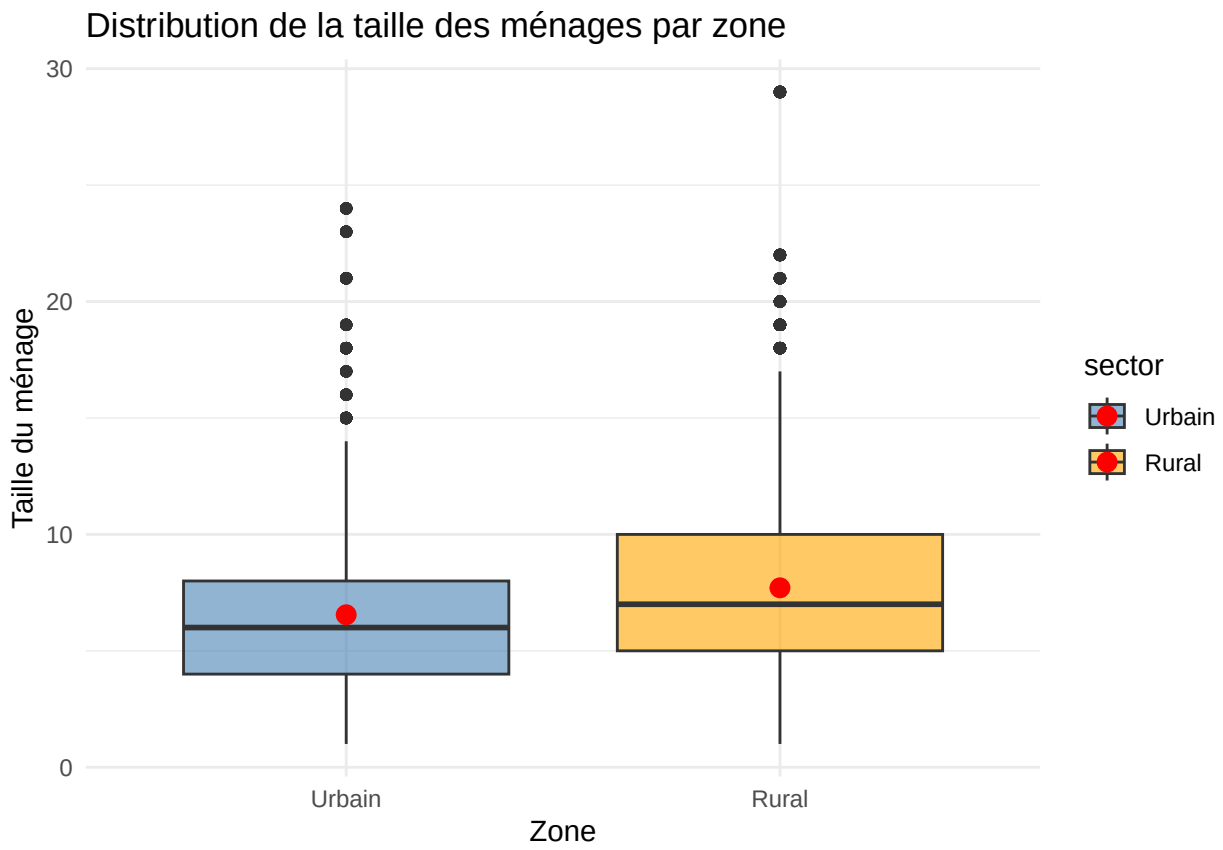


-

Les points en rouge représentent la taille moyenne des ménages en milieu rural et en milieu urbain. La moyenne rurale est nettement supérieure, cela peut indiquer une structure familiale plus large (ménages multigénérationnels, plus d'enfants, etc.) en zone rurale. Cependant, un test de comparaison des moyennes permettra d'établir si cette différence est significative. - La boîte rurale est plus haute (vers les valeurs élevées), cela confirme une tendance à des ménages plus grands. - La présence de points au-delà des moustaches indique des ménages exceptionnellement grands(moustaches supérieures) - La taille médiane des ménages en zonne rurale est supérieure à celle en zone urbaine. Test de Wilcoxon-Mann-Whitney.(test de comparaison des moyennes)

Robustesse du test:Le test de Wilcoxon compare les médianes (ou les rangs) plutôt que les moyennes, ce qui est plus représentatif pour des données sociales où quelques très grands ménages pourraient fausser une moyenne classique.

```
wilcox_test <- wilcox.test(taille_men ~ sector,
                                  data = data_traite,
                                  conf.int = TRUE,
                                  conf.level = 0.95)
print(wilcox_test)
```

```
##
##  Wilcoxon rank sum test with continuity correction
##
## data:  taille_men by sector
## W = 57208581, p-value < 2.2e-16
## alternative hypothesis: true location shift is not equal to 0
## 95 percent confidence interval:
##  -1.000019 -1.000025
## sample estimates:
```

```
## difference in location
##              -1.000027
```

Interpretation : - La p-value < 2.2e-16 est extrêmement faible (bien en dessous du seuil classique de 5% ou 0,05). On rejette l'hypothèse nulle (H_0): L'un des groupes possède une concentration de rangs significativement plus élevée que l'autre. En o observant nos boxplots, il s'agit bien du groupe des ménages en zone rurale.

La taille d'effet (r de rang)

```r
effect_size <- data_traite %>%
  wilcox_effsize(taille_men ~ sector)

effect_size
```

```
## # A tibble: 1 x 7
##   .y.        group1 group2 effsize    n1    n2 magnitude
## * <chr>      <chr>  <chr>    <dbl> <int> <int> <ord>
## 1 taille_men Urbain Rural    0.160  7567 18990 small
```

Interprétation: - La magnitude indique "small" (faible). La différence entre zones urbaine et rurale est petite. - Seulement ~2.6% de la variance expliquée ($r^2 = 0.16^2 = 0.0256$) - 97.4% de la variation de taille entre zones urbaine et rurale vient d'autres facteurs - La zone d'habitation n'est PAS un facteur déterminant de la taille du ménage.

6. On fait de même pour l'age et pour le sexe