Cours de statistiques descriptives et inférentielles

Notions fondamentales illustrées par le TP1 , GHS Nigeria Panel

De l'histogramme au test de Wilcoxon

Contents

1 Préliminaire : types de variables et choix des outils **3**

2 Les mesures de tendance centrale **3**
- 2.1 La moyenne . . . 3
- 2.2 La médiane . . . 4
- 2.3 Moyenne vs médiane : le diagnostic de l'asymétrie . . . 4

3 Les mesures de dispersion **5**
- 3.1 Les quartiles et l'étendue interquartile . . . 5
- 3.2 La variance et l'écart-type . . . 5
- 3.3 Le coefficient de variation . . . 5
- 3.4 L'asymétrie (skewness) . . . 6

4 L'histogramme **6**

5 La boîte à moustaches (boxplot) **7**

6 La pyramide des âges **8**
- 6.1 Les trois formes typiques . . . 8

7 Les intervalles de confiance sur les proportions **9**
- 7.1 L'intervalle exact de Clopper-Pearson . . . 9

8 Le test de Shapiro-Wilk : tester la normalité **10**

9 Le test de Wilcoxon-Mann-Whitney **11**
- 9.1 La taille d'effet r de rang . . . 11

10 Le test du chi-deux (χ^2) **12**
- 10.1 Le V de Cramér . . . 13

11 Le test de Kruskal-Wallis et le post-hoc de Dunn **13**

12 Le test de Kolmogorov-Smirnov **14**

13 La courbe de Lorenz et le coefficient de Gini **14**

14 Synthèse : quel outil pour quelle question ? **15**

1 Préliminaire : types de variables et choix des outils

Avant toute analyse statistique, la première question à poser est : *de quel type est ma variable ?* Ce type détermine entièrement quels outils sont légitimes.

Définition

Une **variable quantitative** représente une quantité mesurable sur laquelle les opérations arithmétiques (addition, moyenne) ont un sens. Elle peut être **continue** (l'âge, le revenu, la superficie) ou **discrète** (le nombre d'enfants, la taille du ménage).
Une **variable qualitative** représente une catégorie. Elle peut être **nominale** si les catégories n'ont pas d'ordre naturel (le sexe, la zone géographique, le lien de parenté), ou **ordinale** si elles sont ordonnées (le niveau d'éducation : aucun < primaire < secondaire < supérieur).

Point méthodologique

Calculer la moyenne d'une variable qualitative nominale est une erreur grave. Si l'on code le sexe 1 = Homme et 2 = Femme, la "moyenne" de 1.5 ne signifie rien. Elle donnerait l'impression qu'il existe un "sexe moyen" entre homme et femme, ce qui est absurde. Pour une variable qualitative, on calcule uniquement des **fréquences** et des **proportions**.
Dans le fichier GHS Nigeria, les variables `s1q2` (sexe), `s1q3` (lien de parenté), `sector` (milieu) et `zone` sont qualitatives nominales. Seule `s1q4` (l'âge) est quantitative continue et justifie un `summary()`.

2 Les mesures de tendance centrale

2.1 La moyenne

Définition

La **moyenne arithmétique** d'une série de n valeurs $x_1, x_2, \ldots, x_n$ est :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

Elle représente le "centre de gravité" de la distribution. Elle prend en compte toutes les valeurs, y compris les valeurs extrêmes.

Exemple concret

Dans le GHS Nigeria Wave 4, l'âge moyen des membres actifs des ménages est de **23.98 ans**. Cela signifie que si l'on redistribuait l'âge de façon égale entre tous les individus, chacun aurait environ 24 ans.

Point méthodologique

La moyenne est très sensible aux valeurs extrêmes. Un individu d'âge 130 ans (valeur aberrante identifiée dans notre base) tire la moyenne vers le haut de manière artificielle. C'est pourquoi on lui préfère souvent la médiane pour les distributions asymétriques.

2.2 La médiane

Définition

La **médiane** est la valeur qui partage la distribution en deux parties égales : 50% des observations lui sont inférieures, 50% lui sont supérieures. Si l'on range les valeurs par ordre croissant, la médiane est la valeur centrale.

Exemple concret

La médiane de l'âge dans le GHS Nigeria est de **18 ans**. Cela signifie que la moitié des membres des ménages enquêtés ont moins de 18 ans. C'est la signature démographique d'un pays à forte fécondité comme le Nigeria, où l'indice synthétique de fécondité était de 5.3 enfants par femme en 2018.

2.3 Moyenne vs médiane : le diagnostic de l'asymétrie

Définition

La comparaison entre moyenne et médiane renseigne sur la forme de la distribution.

- Si $\bar{x} >$ médiane : la distribution est **asymétrique à droite** (ou positivement asymétrique). Il y a des valeurs très élevées qui tirent la moyenne vers le haut.
- Si $\bar{x} <$ médiane : la distribution est **asymétrique à gauche**.
- Si $\bar{x} \approx$ médiane : la distribution est approximativement symétrique.

Exemple concret

Dans notre base : moyenne = 23.98 ans, médiane = 18 ans. Puisque $23.98 > 18$, la distribution de l'âge est asymétrique à droite. Il y a une concentration d'individus jeunes (base très large de la pyramide) et quelques individus très âgés qui tirent la moyenne vers le haut.

3 Les mesures de dispersion

3.1 Les quartiles et l'étendue interquartile

Définition

Les **quartiles** divisent la distribution en quatre parties égales, chacune contenant 25% des observations :

- Q_1 (premier quartile) : 25% des valeurs lui sont inférieures
- Q_2 (deuxième quartile) = médiane : 50% des valeurs lui sont inférieures
- Q_3 (troisième quartile) : 75% des valeurs lui sont inférieures

L'**étendue interquartile** (IQR) est définie par $IQR = Q_3 - Q_1$. Elle mesure la dispersion des 50% centraux de la distribution, sans être affectée par les valeurs extrêmes.

Exemple concret

Pour l'âge dans le GHS Nigeria : $Q_1 = 8$ ans, $Q_3 = 36$ ans. Donc $IQR = 36 - 8 = 28$ ans. Les 50% centraux des individus ont entre 8 et 36 ans, une plage très large qui reflète la structure démographique étendue des ménages nigérians (nourrissons, enfants, adultes actifs, personnes âgées cohabitent dans le même ménage).

3.2 La variance et l'écart-type

Définition

La **variance** mesure la dispersion moyenne des valeurs autour de la moyenne :

$$s^2 = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \bar{x})^2$$

L'**écart-type** est la racine carrée de la variance : $s = \sqrt{s^2}$. Il s'exprime dans la même unité que la variable, ce qui le rend plus interprétable que la variance.

3.3 Le coefficient de variation

Définition

Le **coefficient de variation** (CV) est le rapport de l'écart-type à la moyenne, exprimé en pourcentage :

$$CV = \frac{s}{\bar{x}} \times 100$$

Il permet de comparer la dispersion relative de deux distributions qui n'ont pas la même unité ou le même ordre de grandeur.

Exemple concret

Si l'écart-type de l'âge est de 18 ans et la moyenne de 24 ans, alors $CV = 18/24 \times 100 = 75\%$. Un CV élevé (conventionnellement supérieur à 30%) indique une forte hétérogénéité dans la distribution — ici, la coexistence de nourrissons et de personnes très âgées dans les mêmes ménages.

3.4 L'asymétrie (skewness)

Définition

L'**asymétrie** (ou skewness) mesure le degré de non-symétrie d'une distribution. La formule du coefficient d'asymétrie de Fisher est :

$$g_1 = \frac{1}{n} \sum_{i=1}^{n} \left(\frac{x_i - \bar{x}}{s} \right)^3$$

- $g_1 = 0$: distribution parfaitement symétrique
- $g_1 > 0$: queue longue à droite (valeurs élevées éloignées)
- $g_1 < 0$: queue longue à gauche

En R, ce coefficient se calcule avec `moments::skewness()`.

4 L'histogramme

Définition

Un **histogramme** représente la distribution d'une variable quantitative continue en découpant les valeurs en classes (intervalles) et en dessinant une barre dont la hauteur est proportionnelle à l'effectif (ou à la densité) de chaque classe.
Le paramètre **binwidth** contrôle la largeur de chaque classe. Ce choix est crucial : des classes trop larges masquent la structure de la distribution, des classes trop étroites créent du bruit.

Exemple concret

Pour l'âge dans le TP1, on utilise `binwidth = 5` car les classes quinquennales [0-5[, [5-10[, [10-15[... sont la convention internationale de l'ONU et de l'UNFPA pour les analyses démographiques. Elles correspondent aux cohortes de recensement et permettent la comparaison entre pays. Appliquer la règle de Sturges ($k = 1 + \log_2 n$) donnerait environ 15 classes pour 25 767 individus, ce qui produirait des classes trop larges pour voir la structure démographique par cohorte.

Comment interpréter

Pour lire un histogramme, on examine :

- **La forme générale** : symétrique (cloche), asymétrique à droite (queue longue vers les grandes valeurs), bimodale (deux bosses = deux populations

mélangées).

- **Le centre** : où se concentrent les valeurs ?
- **La dispersion** : les barres sont-elles étroitement groupées ou largement étalées ?
- **Les valeurs aberrantes** : y a-t-il des barres isolées très loin du reste ?

Dans le GHS Nigeria, l'histogramme de l'âge montre une base très haute pour les jeunes âges (0–20 ans) et un déclin progressif vers les âges élevés. C'est la forme caractéristique d'une population jeune à forte natalité.

5 La boîte à moustaches (boxplot)

Définition

La **boîte à moustaches** (boxplot ou diagramme de quartiles) représente en un seul graphique cinq statistiques résumées :

- La boîte centrale s'étend de Q_1 à Q_3 (l'étendue interquartile IQR)
- Le trait épais à l'intérieur de la boîte est la **médiane**
- Les moustaches s'étendent jusqu'à $Q_1 - 1.5 \times IQR$ (moustache inférieure) et $Q_3 + 1.5 \times IQR$ (moustache supérieure)
- Les points au-delà des moustaches sont les **valeurs aberrantes potentielles**

Exemple concret

Pour la taille des ménages dans le GHS Nigeria : $Q_1 = 3$, médiane $= 5$, $Q_3 = 7$, $IQR = 4$.
La moustache supérieure s'étend jusqu'à $7 + 1.5 \times 4 = 13$ membres. Tout ménage de plus de 13 membres apparaît comme un point isolé au-dessus de la moustache. Le ménage de 29 membres sera clairement visible comme valeur aberrante dans le graphique — ce qui nous invite à l'examiner et à comprendre son contexte (ménage polygame élargi dans le Nord du Nigeria).

Comment interpréter

Pour lire un boxplot :

- **Position de la médiane dans la boîte** : si le trait médian est proche du centre de la boîte, la distribution est symétrique. S'il est proche du bas de la boîte, la distribution est asymétrique à droite.
- **Longueur des moustaches** : des moustaches inégales indiquent une asymétrie.
- **Points aberrants** : leur présence ne signifie pas automatiquement une erreur — ils peuvent correspondre à des réalités sociologiques (très grands ménages) ou à de vraies erreurs de saisie (un âge de 130 ans).
- **Comparaison de boxplots groupés** : quand on affiche un boxplot pour chaque groupe (rural vs urbain), la comparaison visuelle des médianes et des étendues interquartiles permet de voir si les groupes diffèrent.

6 La pyramide des âges

Définition

La **pyramide des âges** est un double histogramme horizontal représentant la distribution de la population par groupe d'âge quinquennal, séparée par sexe. Par convention internationale (ONU, WHO, HMD) :

- Les **hommes** sont représentés à **gauche**
- Les **femmes** sont représentées à **droite**
- Les groupes d'âge les plus jeunes sont en **bas**, les plus âgés en **haut**
- L'axe horizontal représente les effectifs (ou les pourcentages)

6.1 Les trois formes typiques

Définition

Pyramide expansive (base large) : la base est très large et la pyramide se rétrécit régulièrement vers le sommet. Caractéristique des pays à forte natalité et mortalité élevée. C'est le profil attendu pour le Nigeria.
Pyramide stationnaire (forme de ruche) : les barres sont approximativement égales dans les classes actives. Caractéristique des pays développés à fécondité remplacement.
Pyramide régressive (sommet large) : la base est plus étroite que le milieu. Caractéristique des pays à très faible natalité (Europe du Sud, Japon).

Exemple concret

La pyramide des âges du GHS Nigeria Wave 4 devrait montrer :

- Une base très large pour les groupes [0-5) et [5-10) — reflet d'un ISF de 5.3 enfants par femme
- Un rétrécissement progressif avec l'âge
- Un léger déséquilibre homme/femme dans les groupes 20–35 ans, les hommes étant plus enclins à migrer
- Un étranglement dans les classes 0–4 ans dû à la mortalité infantile (69 décès pour 1000 naissances) et à la sous-déclaration des nourrissons

Comment interpréter

Pour lire une pyramide des âges :

- **La base** renseigne sur la natalité récente. Si la base se rétrécit brusquement sur les dernières années, cela peut indiquer une baisse de la fécondité ou une crise (guerre, famine, pandémie).
- **Les étranglements** au milieu de la pyramide signalent des évènements passés : une guerre a fortement réduit la cohorte des hommes de 60–70 ans.
- **L'asymétrie homme/femme** dans les classes adultes jeunes signale la migration masculine sélective.
- **Le sommet** renseigne sur la mortalité aux grands âges : plus il est large,

meilleure est l'espérance de vie.

7 Les intervalles de confiance sur les proportions

Définition

Quand on observe une proportion $\hat{p}$ dans un échantillon (par exemple, 19.3% de chefs de ménage), cette proportion est une **estimation** de la vraie proportion p dans la population. L'**intervalle de confiance** à 95% donne une plage de valeurs dans laquelle on est "sûr à 95%" que se trouve la vraie valeur p.

7.1 L'intervalle exact de Clopper-Pearson

Définition

L'intervalle exact de **Clopper-Pearson** est calculé à partir de la loi Beta et ne nécessite pas l'hypothèse de normalité. Il est valide même pour des proportions proches de 0 ou de 1, et pour de petits échantillons.
En R, il se calcule avec `binom.test(x, n)` où x est le nombre de succès et n la taille de l'échantillon.
L'intervalle normal approximatif $\hat{p} \pm 1.96\sqrt{\hat{p}(1-\hat{p})/n}$ est valide uniquement quand $n\hat{p} \geq 5$ et $n(1-\hat{p}) \geq 5$. Pour des catégories rares (taux d'adoption 0.3%), cet intervalle peut donner des bornes négatives, ce qui est impossible pour une proportion.

Exemple concret

Dans notre base, on observe 39 employés de maison (DOMESTIC HELP) sur 25 767 membres actifs. La proportion est $\hat{p} = 39/25767 = 0.0015$ (0.15%).
L'intervalle normal approximatif donnerait $0.0015 \pm 1.96 \times \sqrt{0.0015 \times 0.9985/25767} \approx [0.00072, 0.00228]$, ce qui est acceptable ici car l'effectif est suffisant.
Mais pour une catégorie encore plus rare avec seulement 3 observations sur 100, l'intervalle normal donnerait des bornes négatives. L'intervalle de Clopper-Pearson résout ce problème en s'appuyant sur la distribution Beta exacte.

Comment interpréter

Un intervalle de confiance à 95% ne signifie **pas** que "la vraie valeur est dans cet intervalle avec probabilité 95%". La vraie valeur est fixe (on ne la connaît pas, mais elle ne varie pas). Cela signifie que si l'on répétait l'échantillonnage un très grand nombre de fois, 95% des intervalles construits de cette façon contiendraient la vraie valeur. C'est une nuance importante pour l'interprétation rigoureuse.
Pratiquement : si l'intervalle de confiance pour la proportion de chefs de ménage femmes est [18.5%, 20.1%], on peut dire que la proportion de femmes chefs de ménage dans la population nigériane couverte par l'enquête est estimée à environ

19.3%, avec une incertitude d'environ ±0.8 point de pourcentage.

8 Le test de Shapiro-Wilk : tester la normalité

Définition

Le **test de Shapiro-Wilk** teste si une série de données provient d'une distribution normale. C'est un test d'hypothèse avec :

- $\mathbf{H}_0$ (hypothèse nulle) : les données suivent une loi normale
- $\mathbf{H}_1$ (hypothèse alternative) : les données ne suivent pas une loi normale

Le test calcule une statistique $W \in]0, 1]$. Plus W est proche de 1, plus les données ressemblent à une distribution normale. La **p-valeur** associée mesure la probabilité d'observer un W aussi petit (ou plus petit) si H_0 était vraie.

Règle de décision : si $p < 0.05$, on rejette H_0 et on conclut que les données ne sont pas normalement distribuées.

Point méthodologique

Le test de Shapiro-Wilk est limité à $n \leq 5000$ observations en R. Sur de grands échantillons (comme nos 25 767 individus), on applique le test sur un sous-échantillon aléatoire de 5000 observations, après avoir fixé `set.seed()` pour la reproductibilité.

De plus, sur de très grands échantillons, le test Shapiro-Wilk détecte des écarts infimes à la normalité qui n'ont aucune conséquence pratique. Il faut donc toujours compléter le test par une inspection visuelle (histogramme, QQ-plot). Si l'histogramme ressemble à une cloche symétrique, les écarts à la normalité détectés par le test sont probablement négligeables pour les analyses pratiques.

Exemple concret

La distribution de l'âge dans le GHS Nigeria est clairement non normale : elle est asymétrique à droite (moyenne 24 > médiane 18), a une base large de jeunes et une queue vers les personnes âgées. Le test de Shapiro-Wilk rejettera très probablement H_0 (p-valeur $\ll 0.05$), ce qui est attendu et cohérent avec la structure démographique observée.

Conséquence : puisque la normalité est rejetée, on n'utilisera pas le test t de Student pour comparer les moyennes entre groupes. On utilisera le test de Wilcoxon-Mann-Whitney, qui ne suppose pas la normalité.

9 Le test de Wilcoxon-Mann-Whitney

Définition

Le **test de Wilcoxon-Mann-Whitney** (ou test de la somme des rangs de Wilcoxon) est un test non paramétrique qui compare les distributions de deux groupes indépendants. Il ne suppose pas la normalité des données.

- $\mathbf{H}_0$: les deux groupes ont la même distribution (plus précisément, la probabilité qu'une valeur du groupe 1 soit supérieure à une valeur du groupe 2 est égale à 0.5)
- $\mathbf{H}_1$: les distributions des deux groupes sont différentes

Le principe : on classe toutes les observations des deux groupes ensembles, on attribue des rangs (1 pour la plus petite valeur, n pour la plus grande), puis on compare la somme des rangs des deux groupes. Si H_0 est vraie, les rangs devraient se distribuer équitablement entre les deux groupes.

Exemple concret

On veut tester si la taille des ménages diffère entre milieu rural et milieu urbain au Nigeria. On a 7324 ménages urbains et 18443 ménages ruraux.
Le test de Shapiro-Wilk ayant rejeté la normalité de la taille des ménages, on utilise Wilcoxon plutôt que le test t.
En R : `wilcox.test(taille_menage ~ milieu, data = sect1_clean)`
Si la p-valeur obtenue est < 0.05, on rejette H_0 et on conclut que la distribution de la taille des ménages diffère significativement entre rural et urbain. Ce résultat est attendu : les ménages ruraux nigérians sont structurellement plus grands à cause de la polygamie plus répandue et de la valeur économique de la main-d'œuvre familiale dans l'agriculture de subsistance.

9.1 La taille d'effet r de rang

Définition

Un test statistique indique si une différence existe, mais pas si elle est **importante**. Avec un très grand échantillon, même une différence infime peut être statistiquement significative. La **taille d'effet** mesure l'ampleur pratique de la différence.
Pour le test de Wilcoxon, la taille d'effet r de rang est calculée par :

$$r = \frac{|Z|}{\sqrt{N}}$$

où Z est le score standardisé de la statistique du test et N est la taille totale de l'échantillon.
Les seuils conventionnels de Cohen pour interpréter r :

- $r < 0.1$: effet négligeable
- $0.1 \leq r < 0.3$: petit effet
- $0.3 \leq r < 0.5$: effet moyen
- $r \geq 0.5$: grand effet

Exemple concret

Si le test de Wilcoxon donne $Z = -15.2$ et $N = 25767$, alors :

$$r = \frac{15.2}{\sqrt{25767}} = \frac{15.2}{160.5} \approx 0.095$$

Un $r \approx 0.1$ indique un petit effet : la différence rural/urbain dans la taille des ménages est statistiquement significative (la p-valeur est très faible avec ce grand échantillon) mais l'ampleur pratique de la différence est modéste. En contexte nigérien, cela suggèrerait que même si les ménages ruraux sont en moyenne plus grands, la différence n'est pas assez forte pour justifier des politiques très différenciées selon le milieu sur ce seul critère.

10 Le test du chi-deux (χ^2)

Définition

Le **test du chi-deux d'indépendance** teste si deux variables qualitatives sont indépendantes l'une de l'autre dans la population.

- $\mathbf{H}_0$: les deux variables sont indépendantes (la connaissance de l'une n'apporte aucune information sur l'autre)
- $\mathbf{H}_1$: les deux variables sont associées

On construit d'abord un **tableau de contingence** qui croise les deux variables. Pour chaque case du tableau, on calcule l'effectif *théorique* (ce qu'on attendrait si H_0 était vraie) et on le compare à l'effectif *observé*. Si les écarts sont grands, on rejette H_0.
La statistique du test est :

$$\chi^2 = \sum_{\text{cases}} \frac{(O-E)^2}{E}$$

où O est l'effectif observé et E l'effectif théorique sous H_0.

Point méthodologique

Le test du chi-deux est valide uniquement si tous les effectifs théoriques sont supérieurs à 5. Si certaines cases ont des effectifs théoriques inférieurs à 5, on utilise le **test exact de Fisher**, qui donne un résultat exact plutôt qu'approximatif.
En R : `chisq.test(table(var1, var2))` pour le chi-deux, `fisher.test(table(var1, var2))` pour Fisher.

Exemple concret

On veut tester si le lien de parenté (chef, conjoint, enfant, autre) est associé au milieu de résidence (urbain, rural).
On construit le tableau de contingence `table(sect1_clean$parente, sect1_clean$milieu)`, puis on applique `chisq.test()`. Si la p-valeur est < 0.05, on conclut que la structure familiale diffère significativement entre

milieux urbain et rural — ce qui est attendu : les ménages ruraux nigérians ont proportionnellement plus d'enfants et de famille élargie.

10.1 Le V de Cramér

Définition

Comme pour Wilcoxon, la p-valeur du chi-deux indique l'existence d'une association mais pas son intensité. Le **V de Cramér** mesure la force de l'association entre deux variables qualitatives :

$$V = \sqrt{\frac{\chi^2}{n \times (\min(r, c) - 1)}}$$

où r est le nombre de lignes et c le nombre de colonnes du tableau.
$V \in [0, 1]$: 0 = indépendance totale, 1 = association parfaite.

11 Le test de Kruskal-Wallis et le post-hoc de Dunn

Définition

Le **test de Kruskal-Wallis** est la généralisation du test de Wilcoxon à plus de deux groupes. Il teste si au moins un des groupes a une distribution différente des autres, sans supposer la normalité.

- $\mathbf{H}_0$: toutes les populations ont la même distribution
- $\mathbf{H}_1$: au moins une population a une distribution différente

Si le test de Kruskal-Wallis est significatif, on sait qu'il existe des différences entre groupes, mais pas *lesquels* diffèrent. On applique alors des **comparaisons post-hoc de Dunn** pour identifier quelles paires de groupes sont significativement différentes, avec correction pour les tests multiples (correction de Bonferroni ou de Benjamini-Hochberg).

Exemple concret

Dans le TP2 (éducation), on compare la distribution du niveau d'instruction entre les groupes d'âge [18-30], [31-45], [46-60] et [60+]. Le test de Kruskal-Wallis donnera une p-valeur globale. S'il est significatif, le post-hoc de Dunn précisera : "le groupe 18-30 ans a un niveau d'instruction significativement plus élevé que le groupe 60+, mais ne diffère pas significativement du groupe 31-45 ans", etc.

12 Le test de Kolmogorov-Smirnov

Définition

Le **test de Kolmogorov-Smirnov à deux échantillons** compare les distributions complètes de deux groupes, et non seulement leurs tendances centrales. Il mesure l'écart maximal entre les deux fonctions de répartition empiriques.

- $\mathbf{H}_0$: les deux échantillons proviennent de la même distribution
- $\mathbf{H}_1$: les deux échantillons proviennent de distributions différentes

Il est particulièrement adapté pour comparer l'évolution d'une distribution entre deux périodes — par exemple, la distribution de la consommation des ménages entre Wave 1 (2010) et Wave 4 (2018).

13 La courbe de Lorenz et le coefficient de Gini

Définition

La **courbe de Lorenz** représente l'inégalité dans une distribution. Sur l'axe horizontal figure la proportion cumulée de la population (de la plus pauvre à la plus riche), et sur l'axe vertical la proportion cumulée du revenu (ou de la consommation) détenu par cette fraction de la population.
La **droite d'égalité parfaite** est la diagonale : si 20% de la population détient exactement 20% du revenu, 50% en détient 50%, etc. Plus la courbe de Lorenz s'éloigne de cette diagonale, plus les inégalités sont élevées.

Définition

Le **coefficient de Gini** est une mesure synthétique des inégalités égale à deux fois l'aire entre la droite d'égalité et la courbe de Lorenz :

$$G \in [0, 1]$$

$G = 0$ signifie l'égalité parfaite (tout le monde a le même revenu). $G = 1$ signifie l'inégalité maximale (une seule personne détient tout le revenu). En pratique, les pays les plus égalitaires (pays scandinaves) ont $G \approx 0.25$, les plus inégalitaires (Afrique du Sud) ont $G \approx 0.63$.
Le Nigeria avait un coefficient de Gini d'environ 0.43 en 2018, reflétant des inégalités modérées à élevées, avec une forte hétérogénéité entre les États pétroliers du Sud et les États agricoles du Nord.

14 Synthèse : quel outil pour quelle question ?

Question	Type de variable	Outil
Décrire la distribution d'une variable continue	Quantitative	Histogramme, boxplot, summary()
Décrire les catégories d'une variable	Qualitative	table(), prop.table()
Comparer deux groupes (variable continue)	Quantitative + 2 groupes	Test de Wilcoxon
Comparer plus de deux groupes	Quantitative + k groupes	Kruskal-Wallis + Dunn
Tester l'association entre deux variables qualitatives	2 qualitatives	Chi-deux + V de Cramér
Mesurer la force d'une association	Quantitatives	Corrélation de Spearman
Mesurer les inégalités	Quantitative	Gini + Lorenz
Tester la normalité	Quantitative	Shapiro-Wilk
Comparer deux distributions complètes	Quantitative + 2 groupes	Kolmogorov-Smirnov

Point méthodologique

Règle fondamentale : le choix entre test paramétrique (test t, ANOVA) et test non paramétrique (Wilcoxon, Kruskal-Wallis) dépend du résultat du test de Shapiro-Wilk. Si la normalité est rejetée, on utilise systématiquement les tests non paramétriques. Dans les enquêtes sur les ménages africains, où les distributions de revenus et de consommation sont fortement asymétriques, les tests non paramétriques sont presque toujours préférables.