RÉPUBLIQUE DU SÉNÉGAL

Un Peuple - Un But - Une Foi

****

AGENCE NATIONALE DE LA STATISTIQUE ET DE LA DEMOGRAPHIE

****

ÉCOLE NATIONALE DE LA STATISTIQUE ET DE L'ANALYSE ÉCONOMIQUE
PIERRE NDIAYE

Rapport du TP1 de Projet Statistique sous R & Python :

Profil démographique des ménages nigérians

Présenté par :
David Landry AGNANGMA SANAM et Cheikh THIOUB

Elèves ingénieurs statisticiens économistes en 3e année, cycle long

Supervisé par :
M. Aboubacar HEMA

Analyste de recherche, IFPRI

Contents

1 Introduction **3**

2 Exploration et qualité des données (Tâche 1) **3**

3 Analyse univariée de l'âge (Tâche 2) **4**

4 Pyramide des âges par sexe — Vague 4 (Tâche 3) **5**

5 Lien de parenté avec le chef de ménage (Tâche 4) **6**

6 Comparaison rural / urbain de la taille des ménages (Tâche 5) **7**

7 Tableau récapitulatif stratifié par zone (Tâche 6) **8**

8 Évolution inter-vagues (W1–W4) **8**

9 Figure de synthèse et conclusion **9**

9.1 Conclusion 9

1 Introduction

Le présent rapport constitue le livrable principal du **TP1** du cours de Projet Statistique sous R et Python (ENSAE Pierre Ndiaye, ISE1-CL, 2025-2026). Il porte sur l'analyse descriptive du profil démographique des ménages nigérians à partir du **Nigeria General Household Survey (GHS) Panel**, enquête longitudinale en quatre vagues (W1 : 2010, W2 : 2012, W3 : 2015, W4 : 2018) conduite dans le cadre du programme LSMS-ISA de la Banque Mondiale.

L'objectif est de décrire la composition et les caractéristiques démographiques des ménages enquêtés en exploitant les sections `sect1_harvest` (roster des membres, visite Post-Harvest) et `secta_harvest` (identification géographique). Six tâches sont couvertes : exploration des données, analyse univariée de l'âge, pyramide des âges, lien de parenté, comparaison rural/urbain et tableau récapitulatif stratifié.

2 Exploration et qualité des données (Tâche 1)

Le fichier `sect1_harvestw4.dta` contient **30 337 individus** et **60 variables**. Chaque ligne correspond à un individu répertorié lors de la visite Post-Harvest de la vague 4 (2018). Les variables clés sont : `s1q2` (sexe), `s1q3` (lien de parenté), `s1q4` (âge), `s1q7` (statut matrimonial) et `sector` (1 = Urbain, 2 = Rural).

La vérification de la clé composite `(hhid, indiv)` confirme l'absence totale de doublons (**0** détectés), garantissant l'unicité de chaque individu dans le fichier.

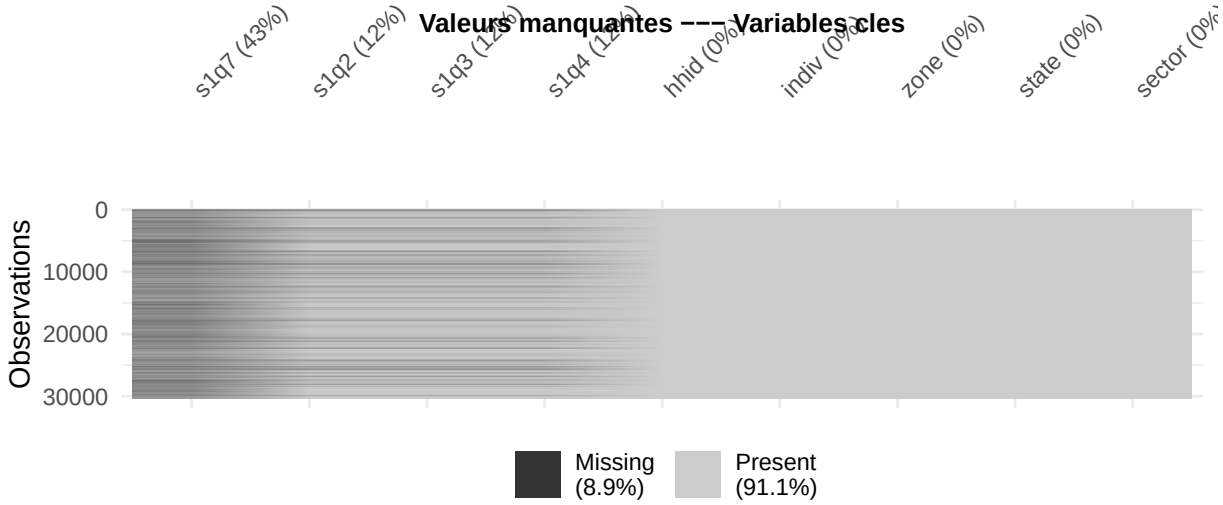

Figure 1. Cartographie des valeurs manquantes sur les variables clés de sect1_harvestw4.

Les identifiants géographiques (`hhid`, `zone`, `state`, `sector`) sont complets à 100%. Les variables `s1q2`, `s1q3` et `s1q4` affichent 12,5% de valeurs manquantes : il s'agit des individus listés dans le roster mais sortis du ménage (`s1q4a = 2`). Ce n'est pas de la non-réponse mais un filtrage structurel du questionnaire. Le statut matrimonial (`s1q7`) atteint 42,8% de NA car il n'est collecté que pour les individus de 12 ans et plus effectivement présents.

3 Analyse univariée de l'âge (Tâche 2)

Table 1. Statistiques descriptives de l'âge des membres des ménages (W4, 2018).

N	Moyenne	Médiane	Q1	Q3	Éc.-type	CV (%)	Asymétrie	Min	Max
26557	23.98	18	8	36	19.73	82.27	0.999	0	130

L'analyse porte sur 26 557 individus effectivement présents. L'âge moyen est de **23.98 ans** avec une médiane à **18 ans** : la moitié de la population enquêtée a moins de 18 ans, caractéristique d'une population très jeune. L'écart entre moyenne et médiane ($\approx$ 6 ans) traduit l'**asymétrie positive** de la distribution (coefficient = 0.999), c'est-à-dire un étalement vers les âges élevés. Le CV élevé (82.27%) reflète la forte hétérogénéité des âges. L'IQR [Q1 = 8, Q3 = 36] couvre 28 ans. L'âge maximal de 130 ans laisse suspecter des erreurs de saisie.

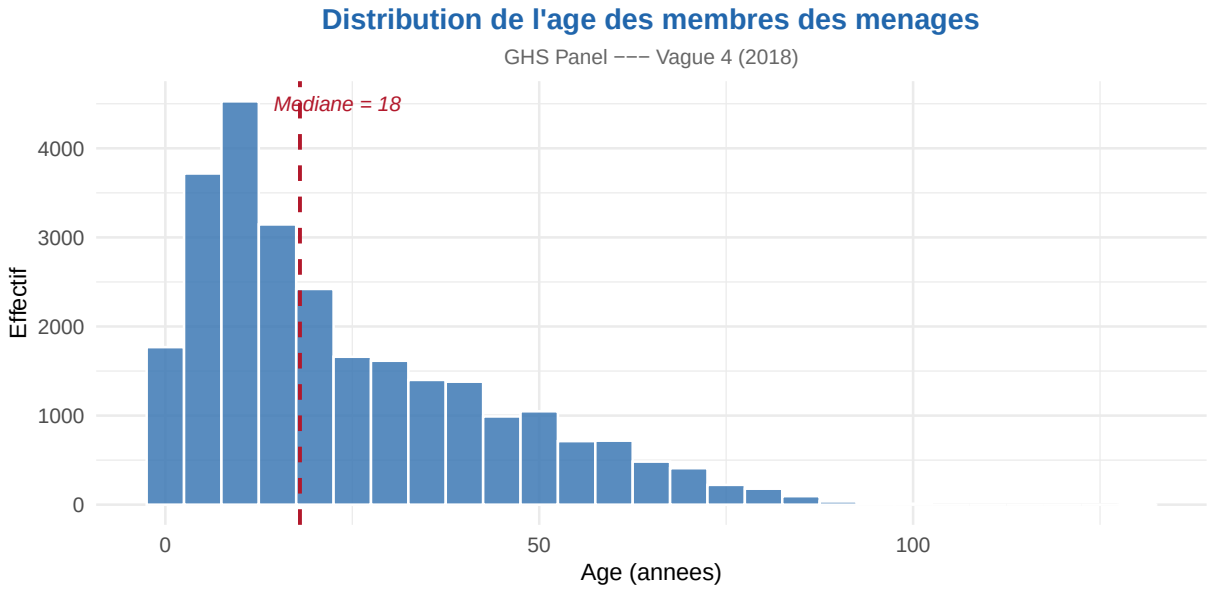

Figure 2. Distribution de l'âge (classes de 5 ans). La ligne rouge marque la médiane (18 ans).

La **classe modale est 0–4 ans** (plus de 4 000 individus). La décroissance est régulière au-delà de 15 ans, avec une longue queue vers les âges avancés. Cette forme est typique d'un pays à forte fécondité et mortalité encore significative.

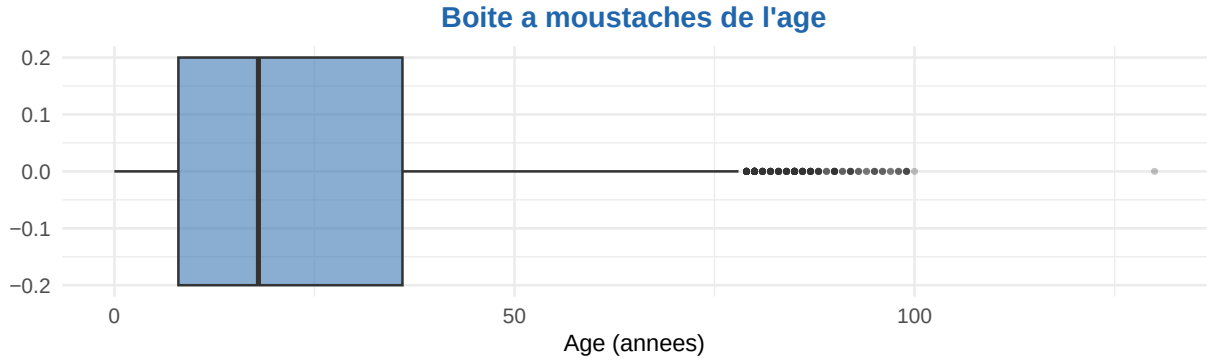

Figure 3. Boîte à moustaches de l'âge. Q1 = 8, médiane = 18, Q3 = 36.

La médiane est décalée vers le bas de la boîte, confirmant l'asymétrie. Des valeurs extrêmes au-delà de 90 ans (jusqu'à 130) nécessiteraient une vérification.

Le **test de Shapiro-Wilk** (n = 5 000) : W = 0.90947, $p < 2{,}2\times10^{-16}$ ⇒ rejet net de la normalité, justifiant les tests non paramétriques dans la suite.

4 Pyramide des âges par sexe — Vague 4 (Tâche 3)

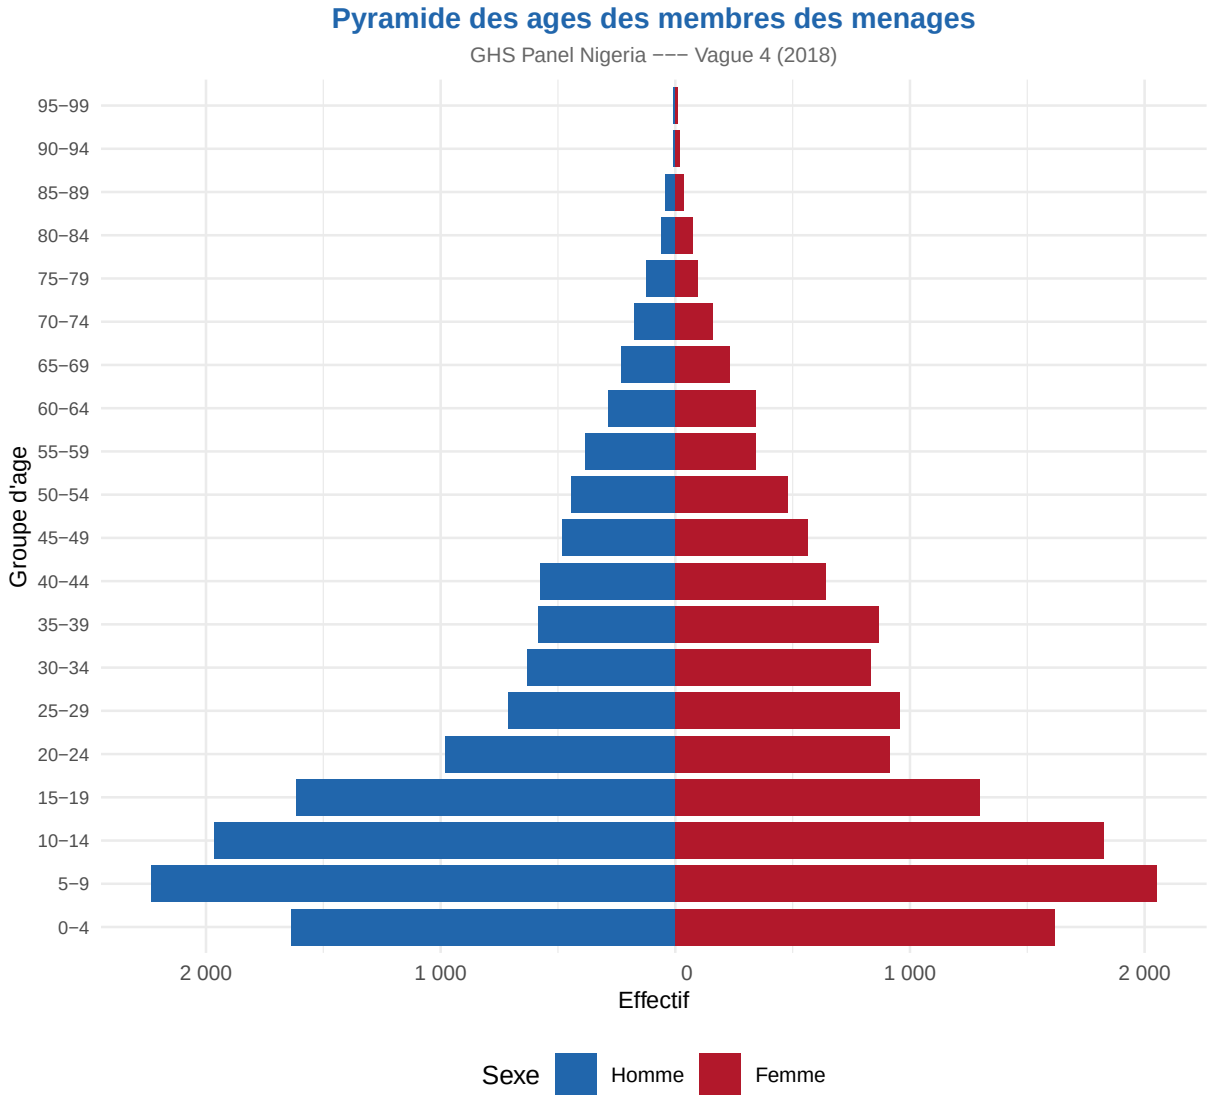

Figure 4. Pyramide des âges (W4, 2018). Hommes à gauche (bleu), femmes à droite (rouge). Classes quinquennales.

La pyramide présente la **forme triangulaire classique** d'une population en début de transition démographique :

- **Base très large (0–14 ans).** Plus de 42% de la population a moins de 15 ans, reflet des taux de fécondité élevés du Nigeria (≈ 5,3 enfants/femme en 2018, Banque Mondiale).
- **Rétrécissement progressif.** À partir de 15 ans, les effectifs diminuent régulièrement. Un léger renflement dans la tranche 25–34 ans correspond aux parents en âge de procréation.
- **Symétrie entre sexes.** La structure est globalement équilibrée, avec un léger excédent féminin dans les tranches 25–44 ans (émigration masculine possible).
- **Sommet étroit.** Les effectifs au-delà de 65 ans sont très faibles (≈ 4%), confirmant une espérance de vie encore limitée.

5 Lien de parenté avec le chef de ménage (Tâche 4)

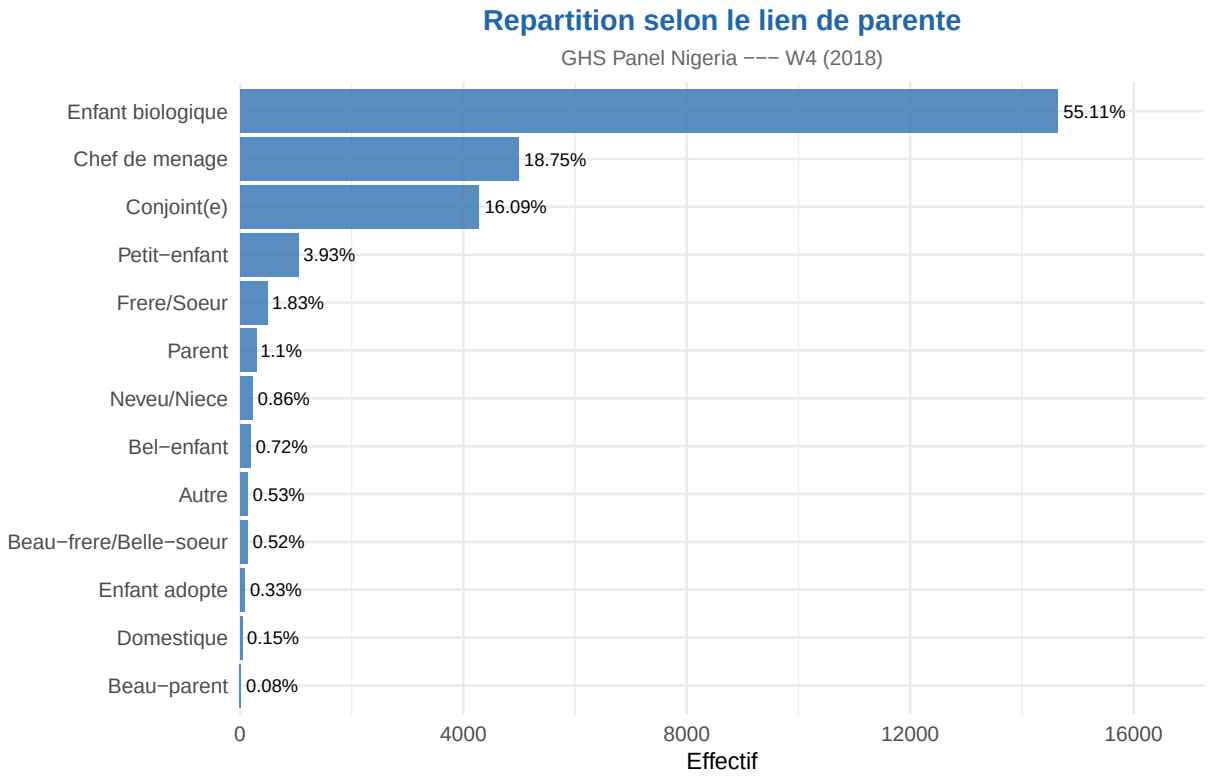

Figure 5. Répartition des membres selon le lien de parenté avec le chef de ménage.

Les **enfants biologiques** dominent largement (**55,11%**), suivis des **chefs de ménage** (18,75%) et des **conjoints** (16,09%). Ces trois catégories totalisent ≈ 90% de l'échantillon. Les 10% restants regroupent petits-enfants (3,93%), frères/soeurs (1,83%), parents ascendants (1,10%) et autres liens. Cette répartition illustre la coexistence de **ménages nucléaires** et de **structures familiales élargies**, fréquentes au Nigeria.

Table 2. Proportions avec IC à 95% (test binomial exact).

	Catégorie	Proportion (\%)	IC inf (\%)	IC sup (\%)
probability of success	Enfant biologique	55.11	54.51	55.71
probability of success1	Chef de menage	18.75	18.28	19.23
probability of success2	Conjoint(e)	16.09	15.65	16.54
probability of success3	Autre	10.05	9.69	10.41

Les IC sont très étroits (n = 26 557) : précision < ± 0,6 point. La catégorie "Autre" (10,05%) confirme la prévalence des ménages élargis au Nigeria.

6 Comparaison rural / urbain de la taille des ménages (Tâche 5)

Table 3. Taille des ménages par zone de résidence (W4).

Zone	N	Moyenne	Médiane	Q1	Q3	Éc.-type
Urbain	1595	5.47	5	3	7	3.26
Rural	3385	6.39	6	4	8	3.75

L'échantillon comprend 1 595 ménages urbains et 3 385 ménages ruraux.

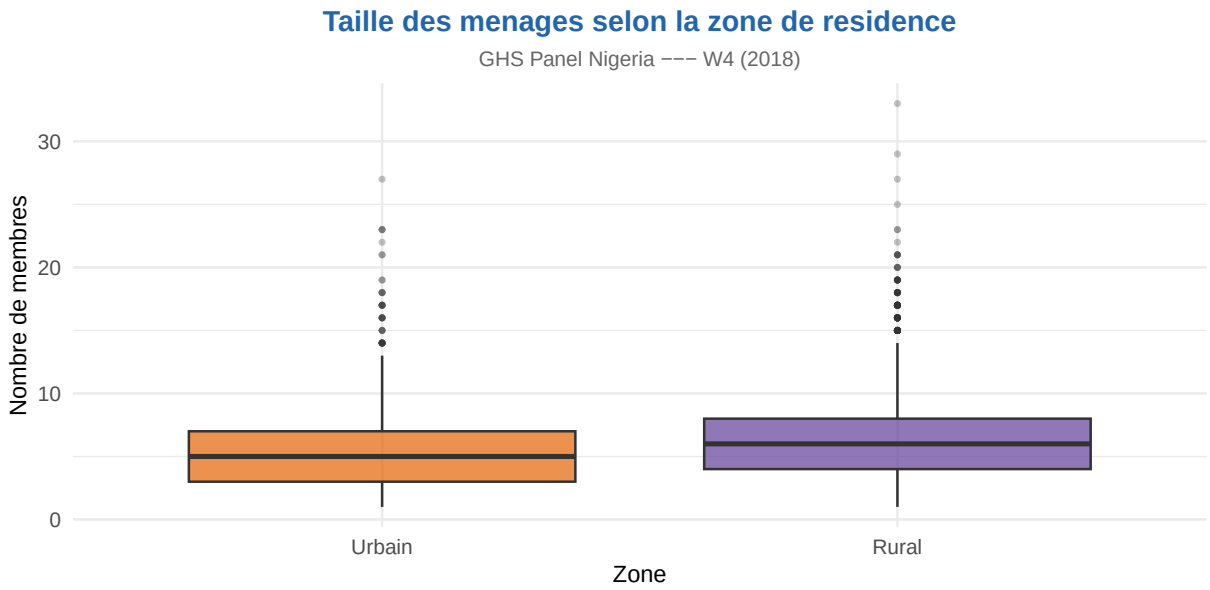

Figure 6. Taille des ménages par zone. Ruraux (violet) vs urbains (orange).

La médiane rurale (6) dépasse la médiane urbaine (5). La dispersion est plus forte en zone rurale (écart-type 3,75 vs 3,26), avec davantage de ménages de très grande taille.

Table 4. Test de Wilcoxon-Mann-Whitney : taille des ménages.

	W	p-value	Diff. loc.	r (rang)	Taille d'effet
W	2 307 181	8.32e-17	-1	0.118	Faible

Le test rejette H_0 ($p < 2{,}2\times10^{-16}$), mais la taille d'effet $r = 0.118$ est **faible** (Cohen $< 0{,}3$). La significativité s'explique par la grande taille de l'échantillon ; l'écart reste **modeste en pratique**. Les ménages ruraux plus grands résultent de taux de fécondité supérieurs, de la main-d'oeuvre familiale agricole et de la cohabitation intergénérationnelle.

Variable	Overall N = 30,337[1]	Urbain N = 8,719[1]	Rural N = 21,618[1]	p-value
Age (annees)	24 (20) | Med: 18 [8-36]	25 (19) | Med: 19 [9-38]	24 (20) | Med: 17 [8-35]	
Manquantes	3,780	1,152	2,628	
Sexe				
Homme	13,189 (50%)	3,730 (49%)	9,459 (50%)	
Femme	13,368 (50%)	3,837 (51%)	9,531 (50%)	
Manquantes	3,780	1,152	2,628	
Taille du menage	8 (4) | Med: 7 [5-10]	7 (4) | Med: 7 [5-9]	9 (4) | Med: 8 [6-11]	

[1] Mean (SD) | Med: Median [Q1-Q3]; n (%)

7 Tableau récapitulatif stratifié par zone (Tâche 6)

Le tableau confirme les constats précédents : âge moyen comparable entre zones (léger rajeunissement rural), répartition par sexe équilibrée (pas de différence significative au χ^2), et taille des ménages ruraux significativement supérieure (Wilcoxon, $p < 0{,}001$).

8 Évolution inter-vagues (W1–W4)

Table 5. Indicateurs démographiques par vague.

Vague	N	Âge moy.	Âge méd.	<15 (%)	15-64 (%)	65+ (%)
W1	28273	23.2	17	44.5	50.9	4.6
W2	29161	24.0	18	41.7	53.3	5.0
W3	26176	24.5	18	41.8	53.0	5.2
W4	26557	24.0	18	42.7	52.5	4.9

Table 6. Chefs de ménage féminins par vague.

Vague	Nb chefs	Chefs féminins (%)
W1	4914	15.0
W2	4770	15.4
W3	4582	20.4
W4	4980	20.1

La **structure par âge** reste stable (41–45% de < 15 ans ; âge médian constant à 17–18 ans), confirmant la lenteur de la transition démographique nigériane. La **proportion de chefs féminins** passe de 15,0% (W1) à 20,1% (W4), soit +5 points en 8 ans, traduisant des mutations socio-économiques (émigration masculine, autonomisation des femmes).

9 Figure de synthèse et conclusion

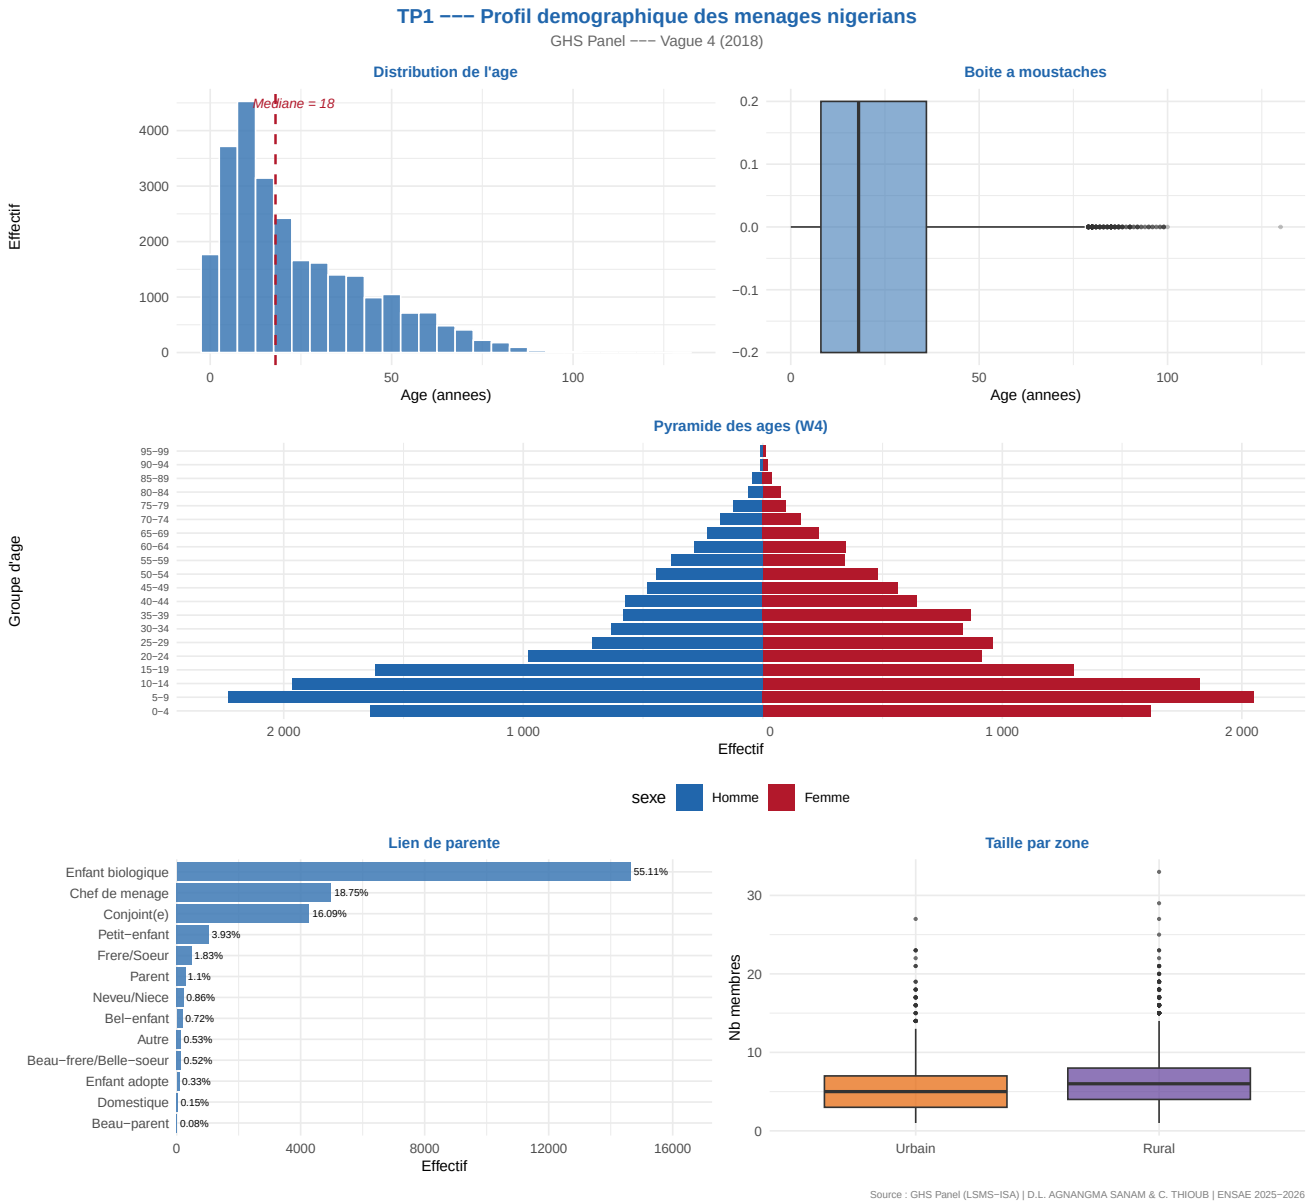

Figure 7. Planche de synthèse : distribution de l'âge, pyramide, parenté et comparaison par zone.

9.1 Conclusion

L'analyse du GHS Panel (W4, 2018) met en évidence : **(1)** une population très jeune (42% de < 15 ans, âge médian 18 ans), pyramide triangulaire typique d'un régime à forte fécondité ; **(2)** un rejet net de la normalité de l'âge (Shapiro-Wilk, W = 0,91), justifiant les tests non paramétriques ; **(3)** la prédominance des enfants biologiques (55%), avec 10% de membres hors noyau familial témoignant de structures élargies ; **(4)** des ménages ruraux significativement plus grands (médiane 6 vs 5, r = 0,12, effet faible) ; **(5)** une hausse des chefs féminins de 15% à 20% entre 2010 et 2018. Ces résultats fournissent le socle descriptif pour les TP suivants.

ENSAE Pierre Ndiaye — ISE1-CL — 2025-2026 — Enseignant : Aboubacar HEMA