Profil démographique des ménages enquêtés dans le GHS Panel

Analyse 1 – Projet Statistique sous R et Python | ENSAE ISE 1, 2025-2026 Nigeria General Household Survey (GHS) Panel – Wave 4 (2018/2019)

Groupe 7 | Herman YAMAHA — Bourama DIALLO
École Nationale de la Statistique et de l'Analyse Économique Pierre NDIAYE

17 mars 2026

Contents

Contexte et objectifs **1**

1 Données et méthodologie **1**
1.1 Sources mobilisées 1
1.2 Méthodes statistiques 2

2 Résultats **2**
2.1 Préparation et qualité des données 2
2.2 Analyse univariée de l'âge 3
2.3 Lien de parenté et intervalles de confiance 6
2.4 Taille des ménages : comparaison urbain/rural 7

3 Synthèse **8**

Références **9**

Contexte et objectifs

Le Nigeria est le pays le plus peuplé d'Afrique subsaharienne, avec une démographie caractérisée par une croissance rapide, une structure par âge très jeune et des contrastes marqués entre espaces ruraux et urbains. Comprendre la composition des ménages constitue un préalable indispensable à toute analyse des conditions de vie et des inégalités socio-économiques.

Ce rapport présente une analyse du **profil démographique des ménages** enquêtés dans la vague 4 du Nigeria General Household Survey-Panel (GHSP-W4, 2018/2019), collecté par le National Bureau of Statistics (NBS). Il est structuré en quatre parties : (i) préparation et contrôle qualité des données, (ii) analyse univariée de l'âge, (iii) étude du lien de parenté avec intervalles de confiance, et (iv) comparaison de la taille des ménages entre milieux urbain et rural.

1 Données et méthodologie

1.1 Sources mobilisées

L'analyse repose principalement sur la section `sect1_harvestw4.dta`, enrichie par les caractéristiques du ménage issues de `secta_harvestw4.dta`. La jointure est réalisée sur l'identifiant ménage `hhid`.

Table 1: Sources mobilisées pour l'analyse.

Fichier .dta	Variables clés	Vagues disponibles
sect1_harvestw1/…/w4	indiv_id, s1q2 (sexe), s1q4 (âge), s1q1 (lien parenté)	W1 – W4
sect1_plantingw1/…/w4	Mêmes variables, visite post-plantation	W1 – W4
secta_harvestw1/…/w4	hhid, zone (rural/urbain), état, LGA	W1 – W4

1.2 Méthodes statistiques

Exploration et qualité. La structure du fichier est examinée par `str()`, `glimpse()` et `summary()`. Les doublons sur la clé composite `hhid + indiv_id` sont contrôlés explicitement. Les valeurs manquantes sont visualisées par `naniar::vis_miss()`.

Analyse univariée de l'âge. La distribution est décrite par la moyenne, la médiane, les quartiles Q_1 et Q_3, l'écart-type et l'asymétrie. La normalité est testée par le **test de Shapiro-Wilk** sur un sous-échantillon aléatoire de 5 000 individus. La pyramide des âges par groupes quinquennaux est produite avec le package `apyramid`.

Liens de parenté. Les proportions sont accompagnées d'intervalles de confiance à 95% calculés par la méthode exacte de **Clopper-Pearson** (package `PropCIs`), plus robuste que l'approximation normale pour les valeurs proches des bornes.

Comparaison rural/urbain. La non-normalité justifie le test non paramétrique de **Wilcoxon-Mann-Whitney**. La taille d'effet est mesurée par le r de Rosenthal :

$$r = \frac{|Z|}{\sqrt{n}}$$

Tableau de synthèse. Un tableau `gtsummary` stratifié par zone est produit pour l'âge, le sexe et la taille du ménage, avec les p-valeurs des tests de comparaison appropriés.

2 Résultats

2.1 Préparation et qualité des données

2.1.1 Structure de la base

La base `sect1_harvestw4` contient **30 337 individus** répartis dans **4 980 ménages**, décrits par 67 variables. Les variables clés retenues sont l'âge (`s1q4`), le sexe (`s1q2`), le lien de parenté (`s1q3`), le secteur de résidence (`sector`) et la zone géographique (`zone`).

Un identifiant unique ménage × individu a été construit pour détecter les redondances : l'inspection révèle **0 doublon**, ce qui confirme l'intégrité de la structure individuelle de la base.

2.1.2 Contrôle des valeurs manquantes

Table 2: Valeurs manquantes par variable clé – `sect1_harvestw4`.

Variable	Manquants	Part (%)
Âge (s1q4)	3780	12.46
Sexe (s1q2)	3780	12.46
Secteur	0	0.00
Lien de parenté	0	0.00
Zone géographique	0	0.00

Les valeurs manquantes sont concentrées sur l'âge et le sexe (12.46% chacun), probablement liées aux membres absents lors du passage de l'enquêteur. Les variables structurantes — identifiants, secteur, zone et lien de parenté — sont intégralement renseignées, ce qui garantit la robustesse des analyses ultérieures.

2.2 Analyse univariée de l'âge

2.2.1 Statistiques descriptives

Table 3: Statistiques descriptives de l'âge des membres des ménages.

Statistique	Valeur (années)
Moyenne	23.98
Médiane	18.00
Écart-type	19.73
Min	0.00
Q1	8.00
Q3	36.00
Max	130.00

La distribution présente une **moyenne de 23.98 ans** et une **médiane de 18 ans**. L'écart entre ces deux mesures révèle une **asymétrie à droite** typique des populations à forte natalité : la présence d'individus âgés tire la moyenne vers le haut, tandis que la médiane reflète la jeunesse effective de la majorité des membres. L'écart-type de 19.73 ans traduit une forte dispersion, avec des âges allant de 0 à 130 ans.

2.2.2 Histogramme

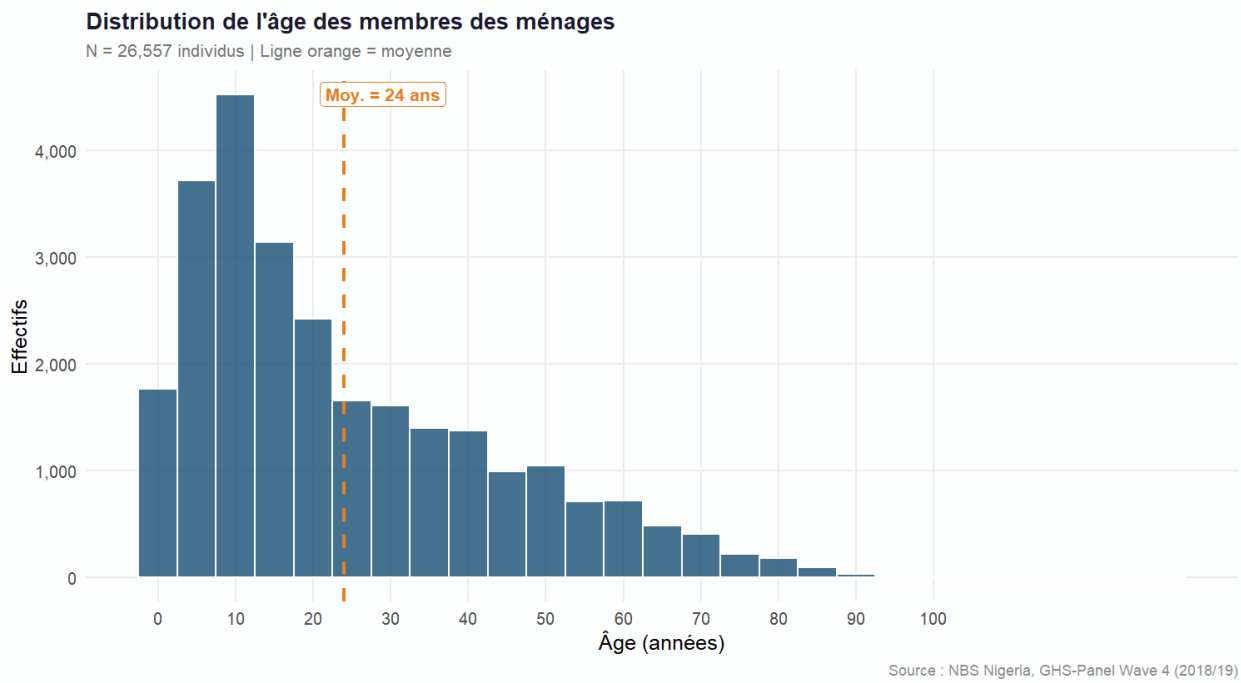

Figure 1: Distribution de l'âge des membres des ménages – histogramme avec moyenne (ligne pointillée). Source : Nigeria GHS Panel W4.

L'histogramme confirme la concentration des effectifs dans les premières tranches d'âge. La classe modale se situe entre 5 et 9 ans, et les effectifs décroissent de façon quasi-monotone au-delà de 20 ans. Cette structure est caractéristique d'un régime démographique expansif, à fécondité élevée et espérance de vie encore modérée.

2.2.3 Boîte à moustaches

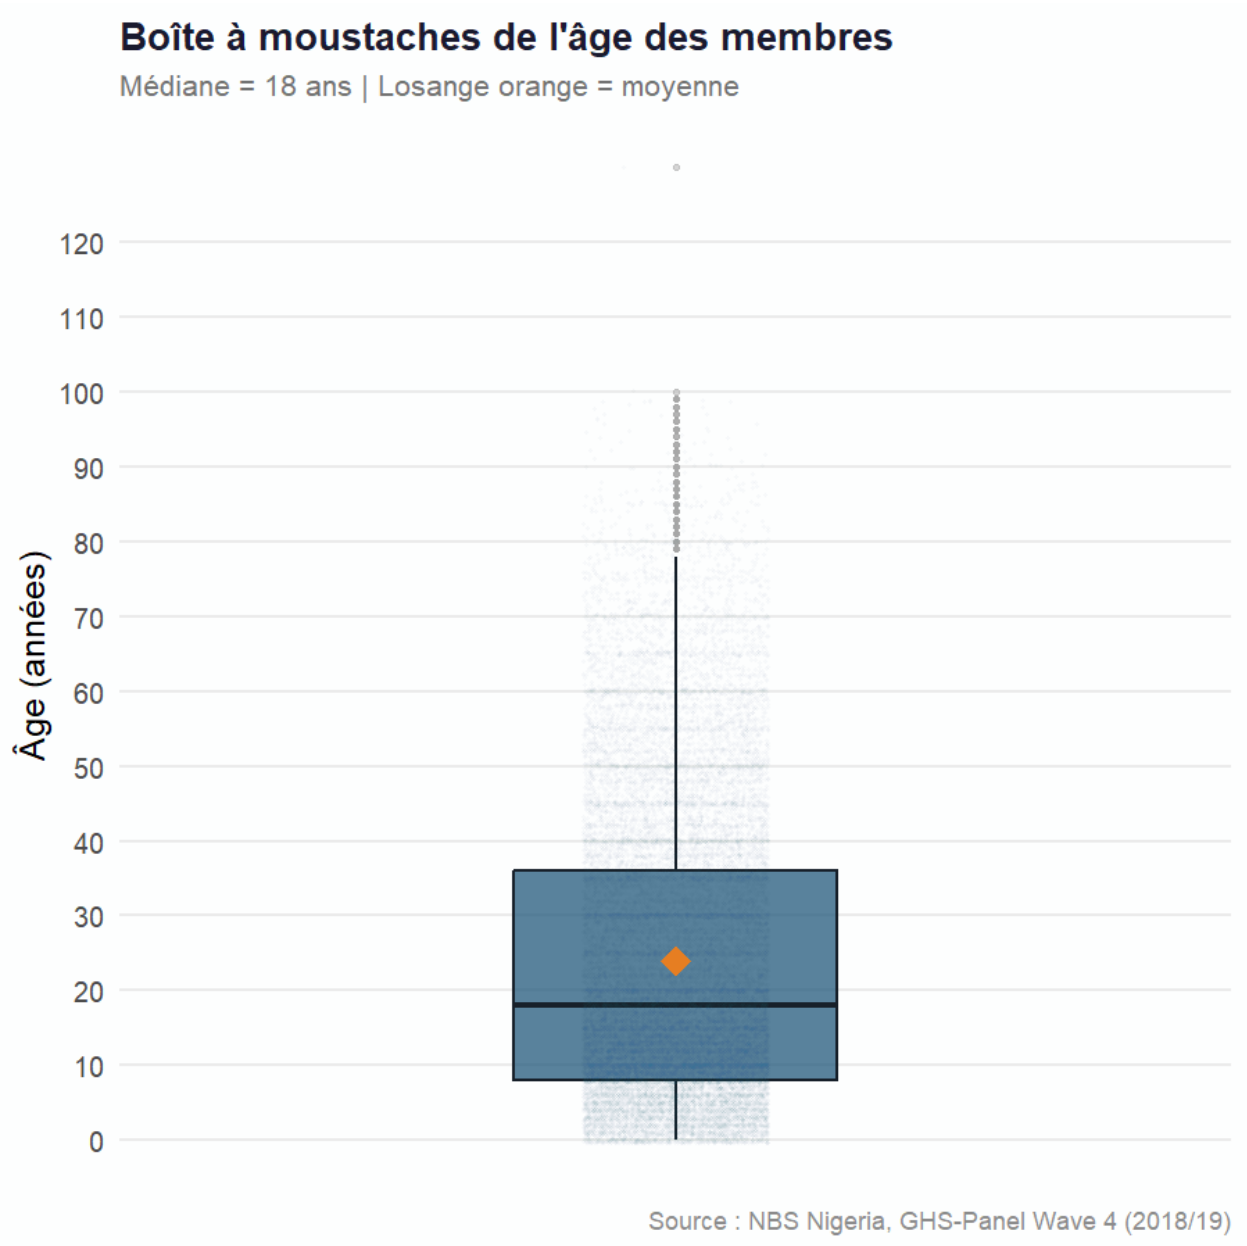

Figure 2: Boîte à moustaches de la distribution de l'âge – médiane et valeurs extrêmes. Source : Nigeria GHS Panel W4.

La boîte à moustaches met en évidence la présence de valeurs extrêmes au-delà de 90 ans, sans remettre en cause la qualité des données. Ces observations correspondent à des aînés intégrés dans des ménages élargis, phénomène courant dans le contexte nigérian. La médiane (18 ans), nettement inférieure au troisième quartile

(Q_3 = 36 ans), confirme l'asymétrie positive de la distribution.

2.2.4 Test de normalité et pyramide des âges

Le test de Shapiro-Wilk, appliqué sur un sous-échantillon de 5 000 individus tirés aléatoirement (graine fixée pour reproductibilité), confirme que la distribution est **significativement non normale** ($W = 0.937$; $p < 2{,}2\text{e-}16$). Ce résultat justifie le recours aux méthodes non paramétriques pour toutes les comparaisons ultérieures.

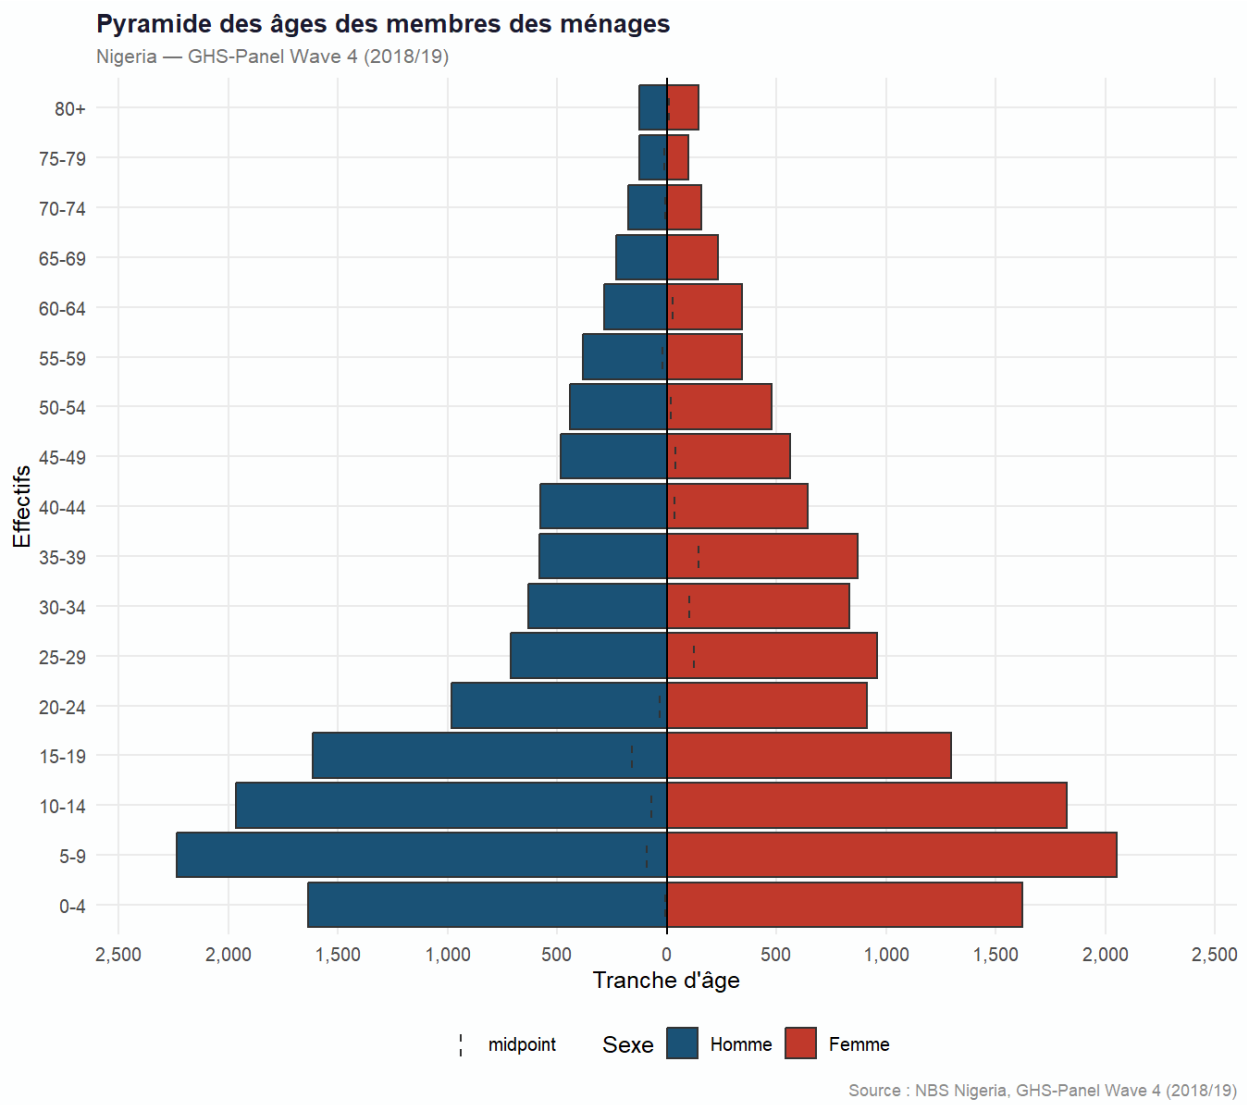

Figure 3: Pyramide des âges par groupes quinquennaux et par sexe – Wave 4. Source : Nigeria GHS Panel W4.

La pyramide des âges présente une **base large et un sommet étroit**, structure classique des pays en développement à forte natalité. Les groupes 0–4 ans et 5–9 ans constituent les cohortes les plus larges. Les effectifs masculins et féminins sont globalement équilibrés sur l'ensemble des tranches d'âge, avec une légère surreprésentation féminine aux grands âges, phénomène habituel lié à la surmortalité masculine.

2.3 Lien de parenté et intervalles de confiance

2.3.1 Fréquences observées

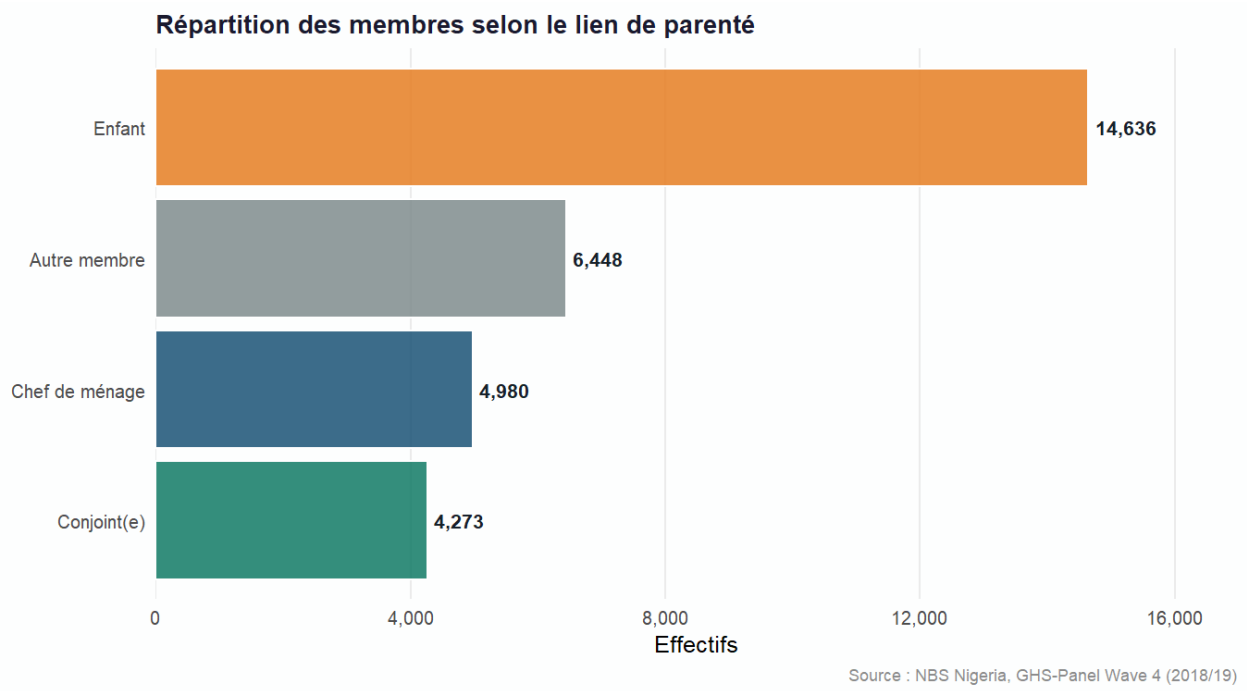

Figure 4: Fréquence du lien de parenté avec le chef de ménage (ordonné par effectif décroissant). Source : Nigeria GHS Panel W4.

Quatre catégories ont été distinguées : chef de ménage, conjoint(e), enfant et autre. Les **enfants constituent la catégorie dominante** avec 14 636 individus, résultat cohérent avec la pyramide des âges à base large. La catégorie « autre » (6 448 individus) regroupe principalement les membres de la famille élargie, témoignant de la prédominance des ménages élargis dans le contexte nigérian.

2.3.2 Proportions avec intervalles de confiance (Clopper-Pearson)

Table 4: Proportions par catégorie de parenté avec IC 95% exact (Clopper-Pearson).

Catégorie	Effectif	Proportion (%)	IC inf. 95% (%)	IC sup. 95% (%)
Chef de ménage	4980	16.42	16.00	16.84
Conjoint(e)	4273	14.09	13.70	14.48
Enfant	14636	48.24	47.68	48.81
Autre	6448	21.25	20.80	21.72

Les intervalles de confiance sont très étroits grâce à la grande taille de l'échantillon, conférant une haute précision aux estimations. Les enfants représentent près de la moitié des membres (48.24% ; IC 95% : [47.68% – 48.81%]). Le nombre de chefs de ménage (16.42%) coïncide exactement avec le nombre de ménages, attestant de la cohérence interne de la base. La proportion de conjoints (14.09%), inférieure à celle des chefs de ménage, reflète la présence de ménages monoparentaux dans l'échantillon.

2.4 Taille des ménages : comparaison urbain/rural

2.4.1 Statistiques descriptives par secteur

Table 5: Taille des ménages par secteur de résidence.

Secteur	N ménages	Moyenne	Médiane	Q1	Q3	Éc.-type	Max
Urbain	1595	5.47	5	3	7	3.26	27
Rural	3385	6.39	6	4	8	3.75	33

Les ménages ruraux présentent une taille médiane de **6 membres** contre **5 membres** en milieu urbain. La moyenne rurale (6.39) dépasse également la moyenne urbaine (5.47). Cette différence reflète des logiques d'organisation familiale distinctes : en milieu rural, la cohabitation intergénérationnelle et les besoins de main-d'œuvre agricole favorisent des ménages plus larges.

2.4.2 Test de Wilcoxon-Mann-Whitney

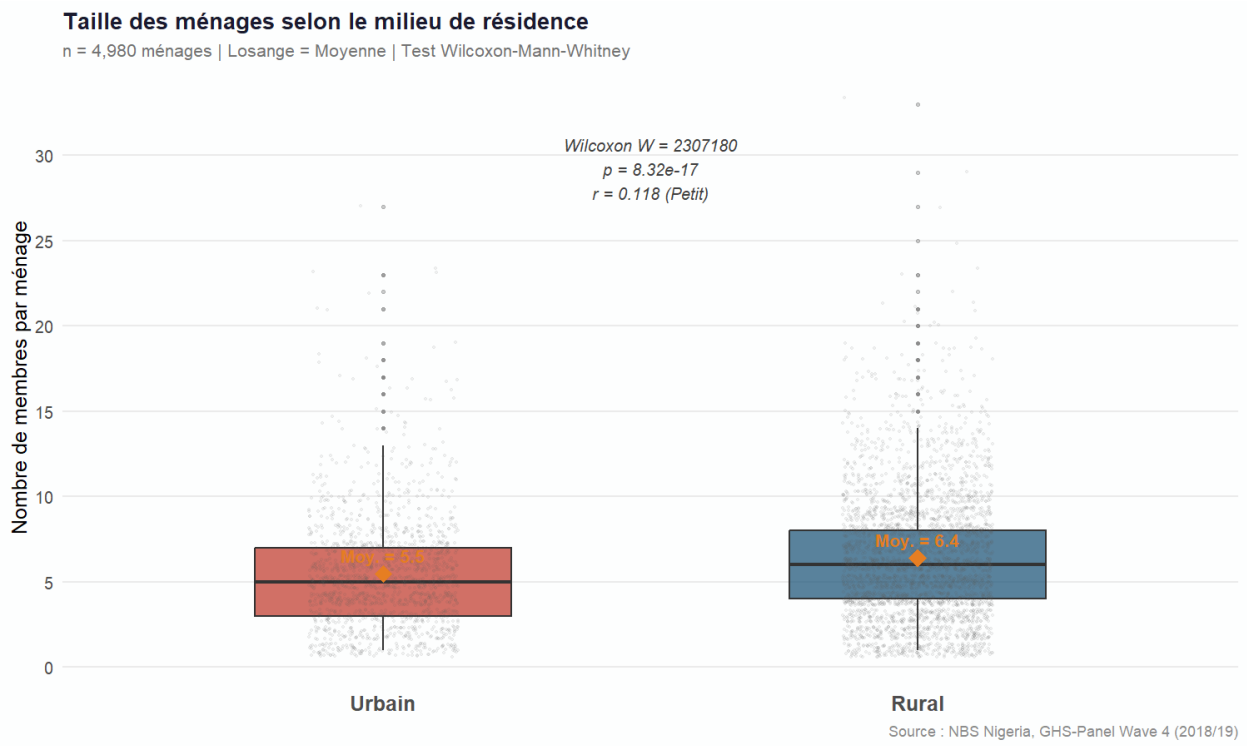

Figure 5: Taille des ménages par secteur de résidence – boxplot groupé avec annotation du test de Wilcoxon-Mann-Whitney. Source : Nigeria GHS Panel W4.

Table 6: Résultats du test de Wilcoxon-Mann-Whitney (taille des ménages urbain vs rural).

Statistique	Valeur
Statistique W	2 307 180
p-valeur	8,32e-17

Statistique	Valeur
IC 95% (différence de localisation)	[-1 ; -1]
Taille d'effet r de rang	0.118
Interprétation	Petit

La p-valeur (p = 8,32e-17) est très inférieure au seuil de 5%, conduisant au **rejet de l'hypothèse nulle** d'égalité des distributions. La différence est donc **hautement significative sur le plan statistique**. Toutefois, la taille d'effet $r = 0.118$ est qualifiée de **petite** : si la différence est réelle et détectable, son amplitude reste modeste à l'échelle individuelle, les deux milieux présentant une grande hétérogénéité interne (étendues de 1 à 27 en urbain, 1 à 33 en rural).

3 Synthèse

Table 7: Récapitulatif des principaux résultats – Nigeria GHS Panel W4 (2018/2019).

Indicateur	Résultat
Taille de l'échantillon	30 337 individus
Nombre de ménages	4 980 ménages
Doublons détectés	0
Valeurs manquantes – Âge	3 780 (12.46%)
Âge moyen (écart-type)	23.98 ans (19.73)
Âge médian [Q1 ; Q3]	18 ans [8 ; 36]
Test de normalité (Shapiro-Wilk)	W = 0.937 ; p < 2,2e-16 → non normale
Catégorie de parenté dominante	Enfant (48.24%)
Proportion d'enfants (IC 95%)	48.24% [47.68% – 48.81%]
Taille médiane – Urbain / Rural	5 / 6 membres
Test Wilcoxon (taille ménage)	W = 2 307 180 ; p = 8,32e-17
Taille d'effet r de rang	0.118 (petit)

Cette analyse conduit à quatre constats principaux :

1. Une base de données de qualité satisfaisante. L'absence totale de doublons et l'intégrité des variables structurantes garantissent la fiabilité des estimations. Les valeurs manquantes sur l'âge (12,46%) méritent attention mais n'affectent pas les analyses portant sur les autres variables.

2. Une structure démographique jeune. Avec une médiane à 18 ans et une pyramide à large base, la population enquêtée reflète le profil démographique typique du Nigeria. La distribution d'âge est significativement non normale, ce qui impose le recours aux méthodes non paramétriques pour toute comparaison.

3. Une composition familiale dominée par les enfants et la famille élargie. Les enfants représentent près de la moitié des membres enquêtés (48.24%), et la catégorie « autre » (21,25%) témoigne de la prégnance des ménages élargis, structures cohérentes avec les normes sociales et les conditions économiques du contexte nigérian.

4. Des ménages ruraux significativement plus grands que les ménages urbains. La différence de taille médiane (6 vs 5 membres) est hautement significative statistiquement (p = 8,32e-17), mais d'amplitude modeste ($r = 0.118$). Elle reflète des logiques d'organisation familiale contrastées, davantage liées aux besoins agricoles et aux solidarités communautaires rurales qu'à de simples différences de niveau de vie.

Références

- National Bureau of Statistics (NBS) Nigeria (2019). *General Household Survey-Panel Wave 4, 2018/2019*. Programme LSMS-ISA. Washington DC : Banque Mondiale.
- Clopper, C.J. & Pearson, E.S. (1934). The use of confidence or fiducial limits illustrated in the case of the binomial. *Biometrika*, 26(4), 404–413.
- Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6), 80–83.
- Cohen, J. (1988). *Statistical Power Analysis for the Behavioral Sciences* (2e éd.). Hillsdale : Lawrence Erlbaum Associates.

Rapport produit avec R Markdown dans le cadre du cours de Projet Statistique sous R et Python – ENSAE Pierre Ndiaye, 2025-2026.