Agence Nationale de la Statistique et de la Démographie

République du Sénégal
Un Peuple – Un But – Une Foi

École Nationale de la Statistique et de l'Analyse Économique Pierre Ndiaye

---

Année académique **2025–2026**

Cours : **Projet Statistique sous R et Python** | Enseignant : **Aboubacar HEMA**

Travaux Pratiques — Séance 2

Éducation et alphabétisation des membres des ménages au Nigeria

Nigeria General Household Survey-Panel Wave 4 (NBS, 2018/19)

Groupe 4

TEVOEDJRE Michel	ISE1-CL
DICKO Hamadou	ISE-MATHS

Table des matières

1 Introduction **3**

2 Chargement et jointure des données **3**
2.1 Description des fichiers 3
2.2 Inspection des valeurs manquantes 3

3 Construction de `niveau_educ` et distribution nationale **4**
3.1 Règles de codage (5 catégories ordonnées) 4
3.2 Fréquences et proportions 4
3.3 Barplot horizontal 5

4 Disparités selon le sexe **5**
4.1 Barplot 100% empilé 6
4.2 Table de contingence 6
4.3 Test du Chi-deux et V de Cramer 6

5 Disparités selon le groupe d'âge **7**
5.1 Boxplot du niveau d'éducation par groupe d'âge 7
5.2 Test de Kruskal-Wallis 7
5.3 Post-hoc de Dunn (correction de Bonferroni) 7

6 Scolarisation et profils éducatifs par État **8**
6.1 Taux de scolarisation des 6-17 ans par zone 8
6.2 Heatmap – Part des adultes sans instruction par État 9
6.3 Heatmap croisée – Distribution du niveau d'éducation par État 10

7 Conclusion **11**

1. Introduction

Ce rapport présente les résultats du second travail pratique du cours de **Projet Statistique sous R et Python**. L'objectif est d'analyser les **niveaux d'instruction** et les **taux de scolarisation** des membres des ménages au Nigeria, à partir des sections éducation de la *General Household Survey* (GHS) — vague 4 (2018), conduite par la Banque Mondiale en collaboration avec le Bureau National des Statistiques nigérien (NBS).

Trois fichiers sont mobilisés : `sect2_harvestw4.dta` (statut scolaire et niveau atteint), `sect1_harvestw4.dta` (sexe, âge) et `secta_harvestw4.dta` (zone de résidence). L'analyse porte sur **26 557 individus** après jointure, dont **13 400 adultes de 18 ans et plus** retenus pour les analyses principales.

Le travail est structuré en cinq parties : **(i)** chargement et jointure des données, **(ii)** construction de la variable de niveau d'éducation et distribution nationale, **(iii)** analyse des disparités par sexe, **(iv)** analyse par groupe d'âge, et **(v)** scolarisation des enfants et profils éducatifs par État.

---

2. Chargement et jointure des données

2.1. Description des fichiers

Table 1 – Fichiers .dta utilisés dans l'analyse

Fichier	Variables clés
sect2_harvestw4.dta	s2aq13 (scolarisé ?), s2aq9 (classe actuelle), s2aq15 (niveau atteint), s2aq10 (diplôme)
sect1_harvestw4.dta	s1q2 (sexe), s1q4 (âge), sector (zone)
secta_harvestw4.dta	sector, wt_wave4 (pondérations)

La jointure entre `sect2` et `sect1` est réalisée sur les clés **hhid** (identifiant ménage) et **indiv** (identifiant individu), permettant d'enrichir les informations éducatives avec le sexe et l'âge de chaque membre.

2.2. Inspection des valeurs manquantes

Table 2 – Valeurs manquantes par variable clé

Variable	Manquants	Part (%)
s2aq13 (scolarisé ?)	7286	27.44
s2aq9 (classe actuelle)	7286	27.44
s2aq15 (niveau atteint)	17248	64.95
s2aq10 (diplôme obtenu)	7286	27.44
Âge	0	0.00
Sexe	0	0.00

Les valeurs manquantes sur `s2aq15` et `s2aq9` sont **structurelles** : un individu renseigne soit son niveau actuel, soit son dernier niveau fréquenté. Les individus jamais scolarisés ne renseignent ni l'un ni l'autre, et sont codés systématiquement comme Aucun.

---

3. Construction de `niveau_educ` et distribution nationale

3.1. Règles de codage (5 catégories ordonnées)

Table 3 – Règles de codage de la variable niveau_educ (5 catégories ordonnées)

Catégorie	Codes s2aq15 / s2aq9	Codes s2aq10
Aucun	s2aq13 == 2, ou codes 1-3, 51-52	manquant / non applicable
Primaire	11-16 (Primary 1-6)	2 (FSLC), 3 (MSLC)
Junior Secondary	21-23 (JS 1-3)	5 (JSS Certificate)
Senior Secondary	24-28, 31, 33, 321	6 (SSS/O-Level), 7 (A-Level)
Tertiaire	34, 35, 41, 43, 322, 411-424	8 (NCE/OND), 9 (BSc/HND), 11-12 (Masters/PhD)

3.2. Fréquences et proportions

Table 4 – Distribution du niveau d'éducation – adultes 18+ (GHS-W4 2018)

Niveau d'éducation	Effectif	Proportion (%)
Aucun	12119	90.44
Primaire	75	0.56
Junior Secondary	162	1.21
Senior Secondary	483	3.60
Tertiaire	561	4.19

3.3. Barplot horizontal

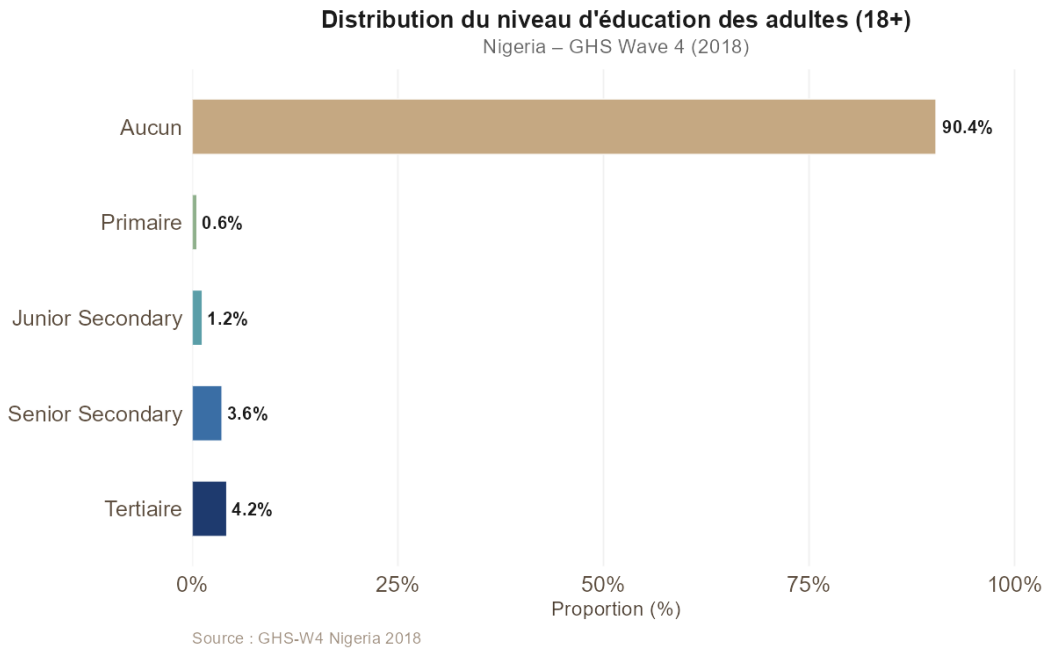

Figure 1 – Distribution du niveau d'éducation des adultes (18+) – Nigeria GHS-W4 2018

La majorité des adultes n'ont atteint aucun niveau d'instruction formel complet. Les niveaux secondaire et tertiaire restent très minoritaires, révélant des défis importants pour le capital humain du Nigeria.

---

4. Disparités selon le sexe

4.1. Barplot 100% empilé

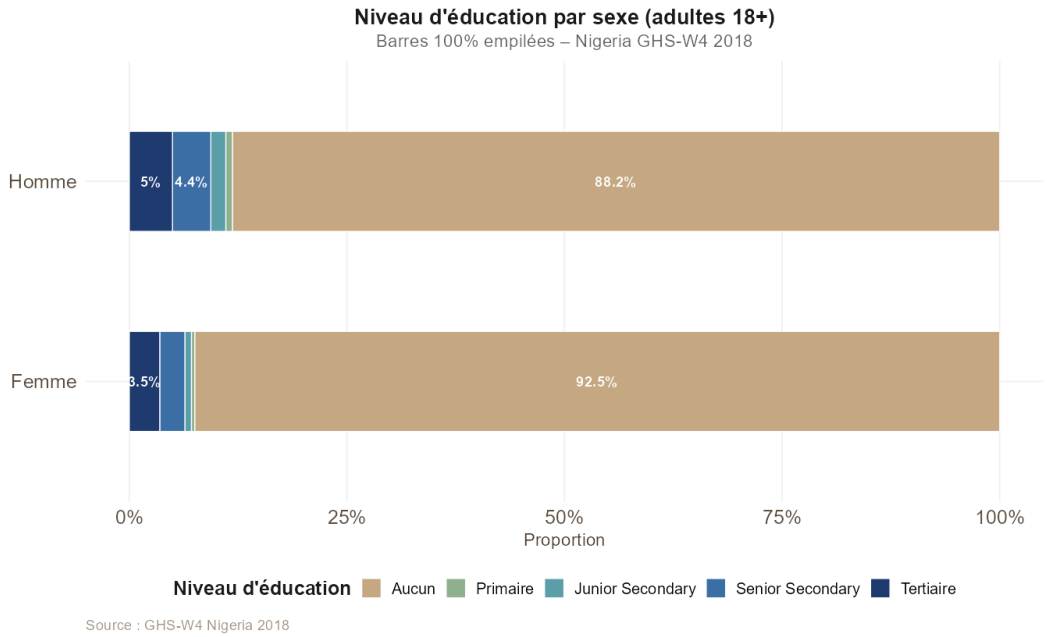

Figure 2 – Niveau d'éducation par sexe – barres 100% empilées (adultes 18+)

4.2. Table de contingence

Table 5 – Table de contingence : Sexe x Niveau d'éducation

	Aucun	Primaire	Junior Secondary	Senior Secondary	Tertiaire
Femme	6535	27	53	204	247
Homme	5584	48	109	279	314

4.3. Test du Chi-deux et V de Cramer

Table 6 – Résultats du test du Chi-deux – Sexe x Niveau d'éducation

Statistique	Valeur
Chi-deux	79.76
Degrés de liberté	4
p-valeur	1.95e-16
V de Cramer	0.077

Le test est hautement significatif ($p < 0{,}001$), confirmant que le niveau d'éducation **n'est pas indépendant du sexe**. Le V de Cramer de **0.077** indique une association modérée. Les femmes sont surreprésentées dans la catégorie Aucun et sous-représentées aux niveaux secondaire et tertiaire.

5. Disparités selon le groupe d'âge

5.1. Boxplot du niveau d'éducation par groupe d'âge

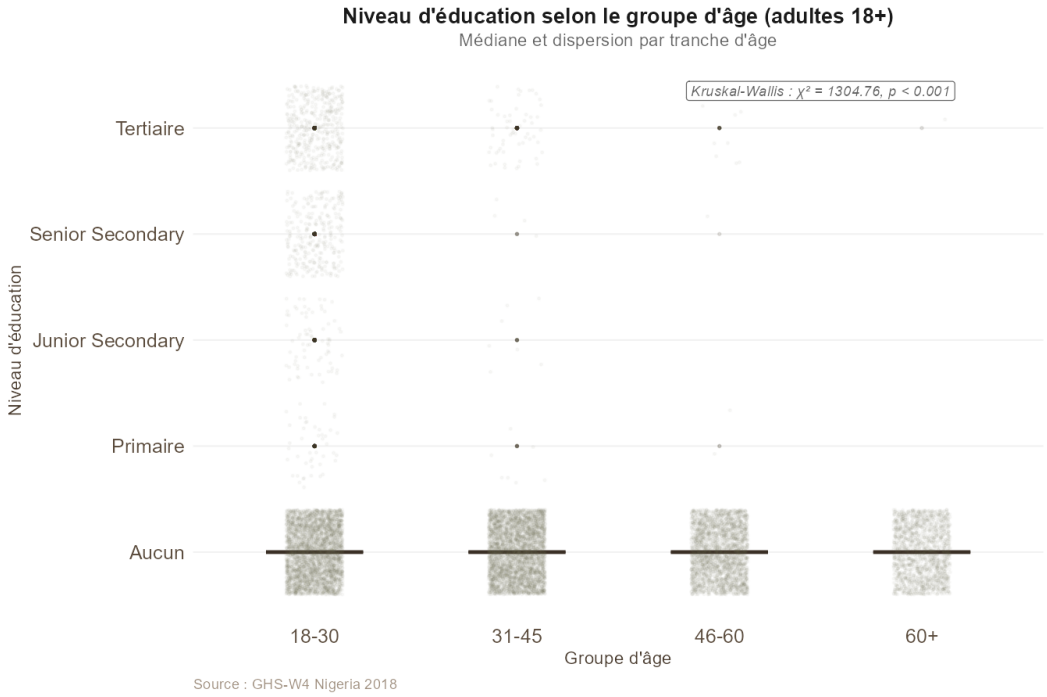

Figure 3 – Niveau d'éducation selon le groupe d'âge – test de Kruskal-Wallis annoté (adultes 18+)

5.2. Test de Kruskal-Wallis

Table 7 – Résultats du test de Kruskal-Wallis – Niveau d'éducation par groupe d'âge

Statistique	Valeur
Chi-deux de Kruskal-Wallis	1304.76
Degrés de liberté	3
p-valeur	1.37e-282

5.3. Post-hoc de Dunn (correction de Bonferroni)

Table 8 – Test post-hoc de Dunn – correction de Bonferroni

Groupe 1	Groupe 2	Statistique	p (brut)	p (ajusté)	Significativité
18-30	31-45	-29.229	0.0000	0.0000	****
18-30	46-60	-28.020	0.0000	0.0000	****
18-30	60+	-24.421	0.0000	0.0000	****
31-45	46-60	-2.200	0.0278	0.1667	ns
31-45	60+	-2.463	0.0138	0.0828	ns
46-60	60+	-0.538	0.5904	1.0000	ns

Groupe 1	Groupe 2	Statistique	p (brut)	p (ajusté)	Significativité

Le test de Kruskal-Wallis (chi2 = 1304.76, p < 0,001) révèle des différences significatives entre tous les groupes d'âge. Les **jeunes adultes (18-30 ans)** affichent un niveau d'éducation significativement plus élevé que les générations antérieures, témoignant de l'expansion progressive de la scolarisation au Nigeria.

---

6. Scolarisation et profils éducatifs par État

6.1. Taux de scolarisation des 6-17 ans par zone

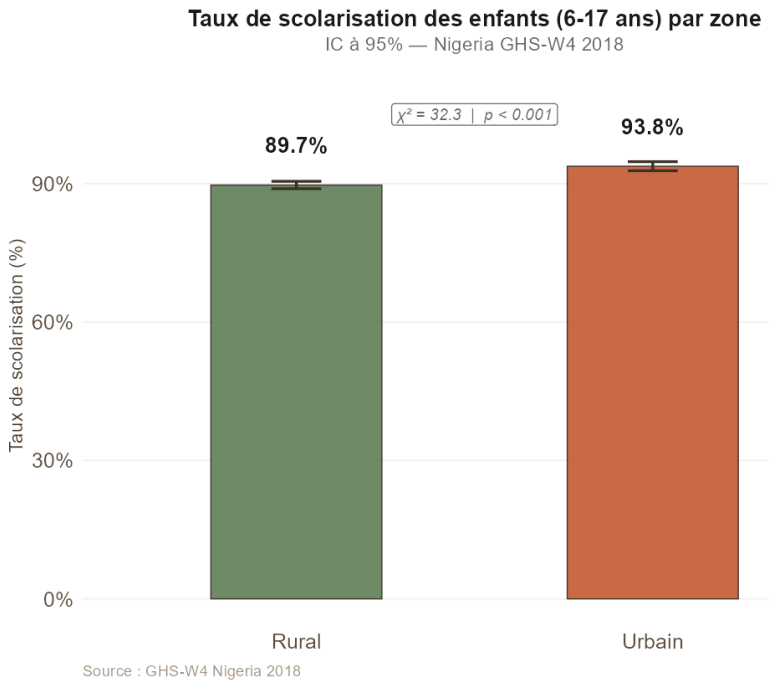

Figure 4 – Taux de scolarisation des enfants (6-17 ans) par zone – IC à 95%

Table 9 – Taux de scolarisation (6-17 ans) par zone avec IC à 95%

Zone	N	Scolarisés	Taux (%)	IC inf. 95% (%)	IC sup. 95% (%)
Rural	5 515	4 947	89.7	88.9	90.5
Urbain	2 315	2 171	93.8	92.8	94.8

Table 10 – Test du Chi-deux – Scolarisation (6-17 ans) par zone

Statistique	Valeur
Chi-deux	32.3
Degrés de liberté	1
p-valeur	1.3e-08

Le taux de scolarisation est de **93.8%** en zone urbaine contre **89.7%** en zone rurale. Cette différence de plus de 16 points est hautement significative (chi2 = 32.3, p < 0,001) et reflète les inégalités d'infrastructure scolaire et les coûts d'opportunité plus élevés en milieu rural.

6.2. Heatmap – Part des adultes sans instruction par État

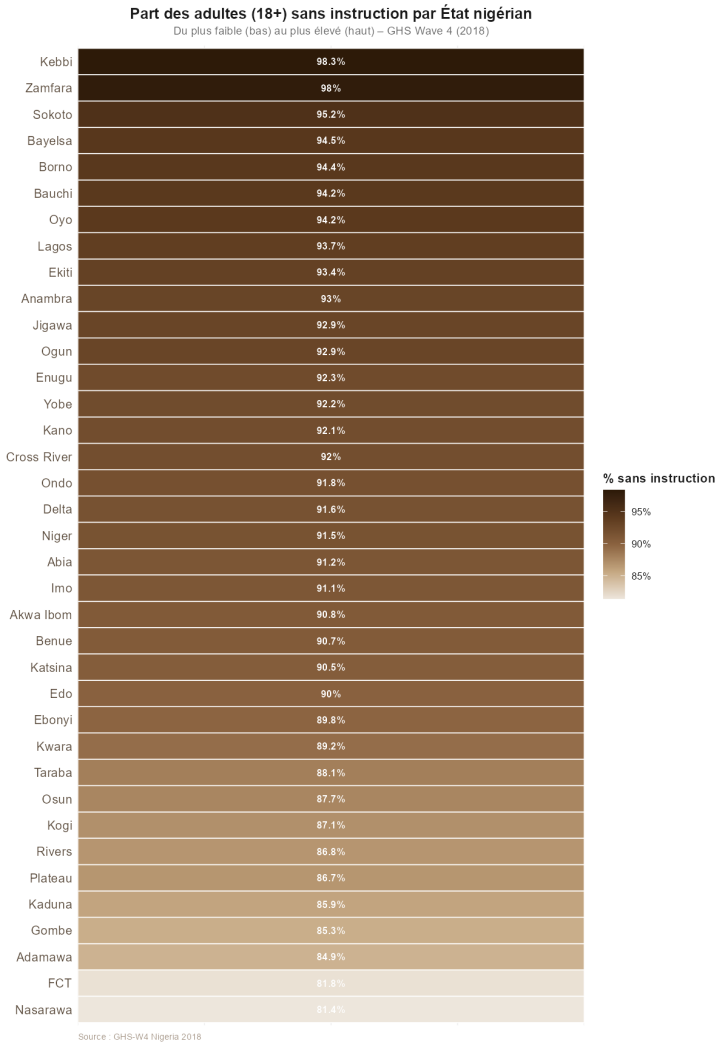

Figure 5 – Part des adultes (18+) sans instruction par État nigérien (du plus faible au plus élevé)

6.3. Heatmap croisée – Distribution du niveau d'éducation par État

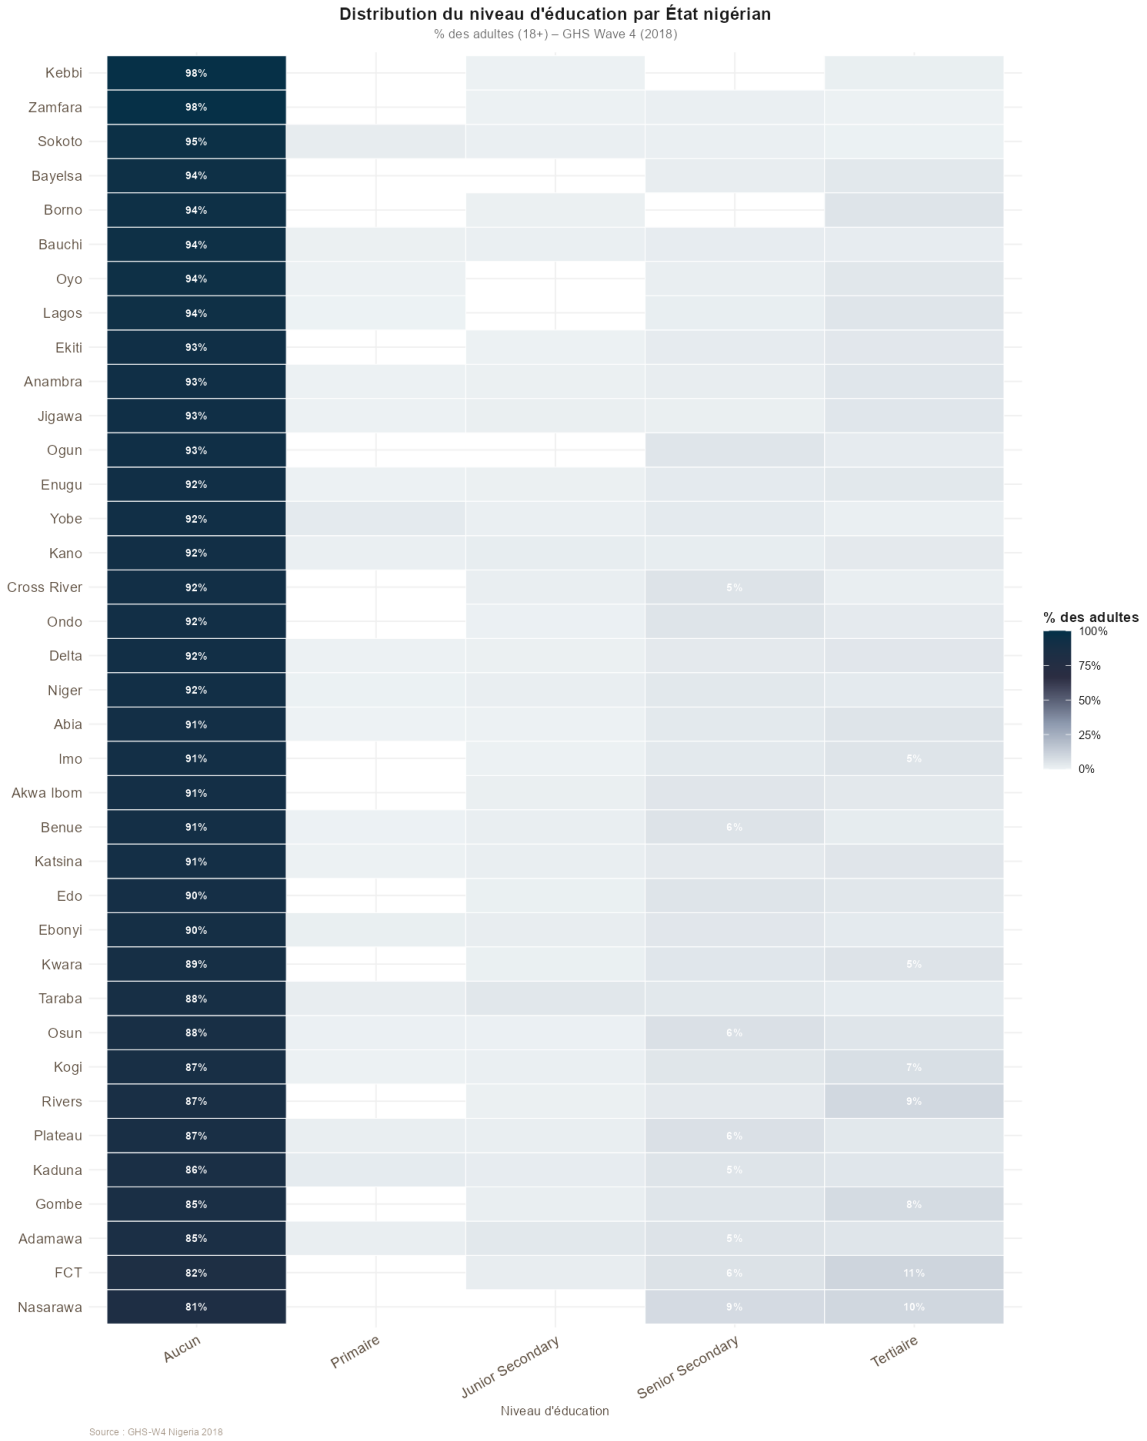

Figure 6 – Distribution du niveau d'éducation par État nigérien – pourcentage des adultes (18+)

Les deux heatmaps révèlent une **fracture Nord-Sud** très prononcée. Les États Kebbi, Zamfara, Sokoto, Bayelsa, Borno affichent les taux d'analphabétisme les plus élevés, tandis que les États du Sud (Lagos, Edo, Anambra, Rivers) présentent les profils éducatifs les plus avancés.

---

7. Conclusion

Ce travail pratique a permis de déployer une chaîne d'analyse statistique complète sur les dimensions éducatives du GHS-Panel Wave 4 du Nigeria. Les principaux enseignements sont les suivants :

- La **distribution nationale** révèle une majorité d'adultes sans instruction formelle complète, avec une forte hétérogénéité entre États.
- Les **disparités de genre** sont significatives (Chi-deux, $p < 0{,}001$; V de Cramer = 0.077) : les femmes sont surreprésentées parmi les personnes sans instruction.
- L'**effet générationnel** est net (Kruskal-Wallis, chi2 = 1304.76, $p < 0{,}001$) : les jeunes adultes de 18-30 ans sont nettement mieux instruits que les générations antérieures.
- La **scolarisation** des enfants de 6-17 ans est significativement plus élevée en zone urbaine (93.8%) qu'en zone rurale (89.7%).
- La **fracture Nord-Sud** est très marquée : les États du Nord-Ouest concentrent les taux d'analphabétisme les plus élevés.

Ces résultats constituent une base solide pour des politiques éducatives ciblées, notamment en direction des zones rurales du Nord et des filles.

Source des données : National Bureau of Statistics (NBS) Nigeria — General Household Survey-Panel Wave 4, 2018/2019.