Analyse 1 — Profil demographique des menages nigerians

Nigeria GHS Panel – Wave 4 (2018) | ENSAE ISE 1 – 2025-2026

ANDRIALALAOSOA Marcellin
Andil Ben Andjiboudine

17 mars 2026

Table des matières

1 Exploration et qualité des données **2**

1.1 Dimensions du fichier 2

1.2 Vérification des doublons 2

1.3 Carte des valeurs manquantes 3

2 Analyse univariée de l'âge **3**

2.1 Statistiques descriptives 3

2.2 Histogramme et boxplot 4

2.3 Test de normalité de Shapiro-Wilk 4

3 Pyramide des âges (Wave 4) **5**

4 Analyse du lien de parenté **5**

4.1 Fréquences et intervalles de confiance 5

4.2 Diagramme en barres horizontales 6

5 Taille des ménages selon la zone de résidence **7**

5.1 Statistiques comparatives par zone 7

5.2 Boxplot groupé Rural vs Urbain 7

5.3 Test de Wilcoxon-Mann-Whitney et taille d'effet 7

6 Tableau récapitulatif stratifié par zone **8**

7 Synthèse de l'Analyse 1 **8**

Objectif : Décrire la composition et les caractéristiques démographiques des ménages enquêtés dans la Wave 4 (2018) du GHS Panel à partir de la section `sect1_harvestw4`.

Fichier utilisé : `sect1_harvestw4.dta` | **Variables clés :** `hhid`, `indiv`, `s1q2` (sexe), `s1q3` (lien de parenté), `s1q4` (âge), `sector` (zone rurale/urbaine)

---

1 Exploration et qualité des données

1.1 Dimensions du fichier

Table 1: Dimensions et qualite du fichier sect1_harvestw4

Description	Valeur
Nombre d'observations	30 337
Nombre de variables	65
Menages uniques	4 980
Valeurs manquantes – Age (s1q4)	3 780
Valeurs manquantes – Sexe (s1q2)	3 780

Le fichier `sect1_harvestw4` contient **30 337 observations** réparties sur **4980 ménages** distincts. Chaque ligne correspond à un membre individuel d'un ménage enquêté lors de la visite Post-Harvest de la Wave 4 (2018). On dénombre **3780 valeurs manquantes** sur l'âge et **3780** sur le sexe, ce qui reste marginal au regard de la taille totale de l'échantillon.

1.2 Vérification des doublons

Table 2: Verification des doublons sur l'identifiant individuel

Verification	Nombre	Statut
Doublons sur (hhid + indiv)	0	OK – Aucun doublon detecte

Le fichier est **exempt de doublons** : chaque individu est identifié de manière unique par la combinaison hhid + indiv. Cette vérification préliminaire garantit l'intégrité des analyses ultérieures.

1.3 Carte des valeurs manquantes

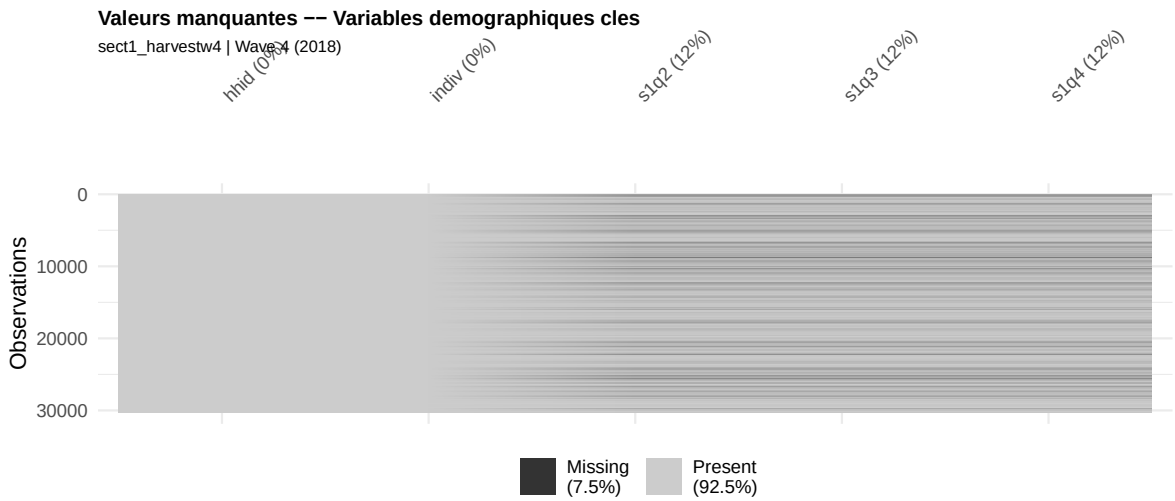

FIGURE 1 – Carte des valeurs manquantes – variables demographiques cles (Wave 4)

La carte des valeurs manquantes offre une vision synthétique de la complétude des variables démographiques clés. Les variables `hhid` et `indiv` (identifiants) sont complètes à 100%, ce qui est attendu. La variable `s1q3` (lien de parenté) présente le taux de valeurs manquantes le plus élevé, ce qui peut s'expliquer par des refus de réponse ou des situations familiales difficiles à classifier. Ces lacunes devront être prises en compte dans les analyses de fréquences du lien de parenté.

---

2 Analyse univariée de l'âge

2.1 Statistiques descriptives

TABLE 3: Statistiques descriptives de l'age des membres du menage (Wave 4)

Moyenne	Mediane	Q1	Q3	Min	Max	Ecart-type	CV (%)	Asymetrie
23.98	18	8	36	0	130	19.73	82.27	0.91

L'âge moyen des membres des ménages enquêtés est de **24 ans**, avec une médiane de **18 ans**. L'écart entre la moyenne et la médiane indique une distribution légèrement asymétrique. L'interquartile s'étend de **8** à **36 ans**, reflétant la concentration de la population dans les tranches jeunes. Le coefficient de variation (**CV = 82.3%**) traduit une dispersion très forte des âges, caractéristique des populations à forte fécondité où coexistent de nombreux enfants et des adultes d'âges très variés.

2.2 Histogramme et boxplot

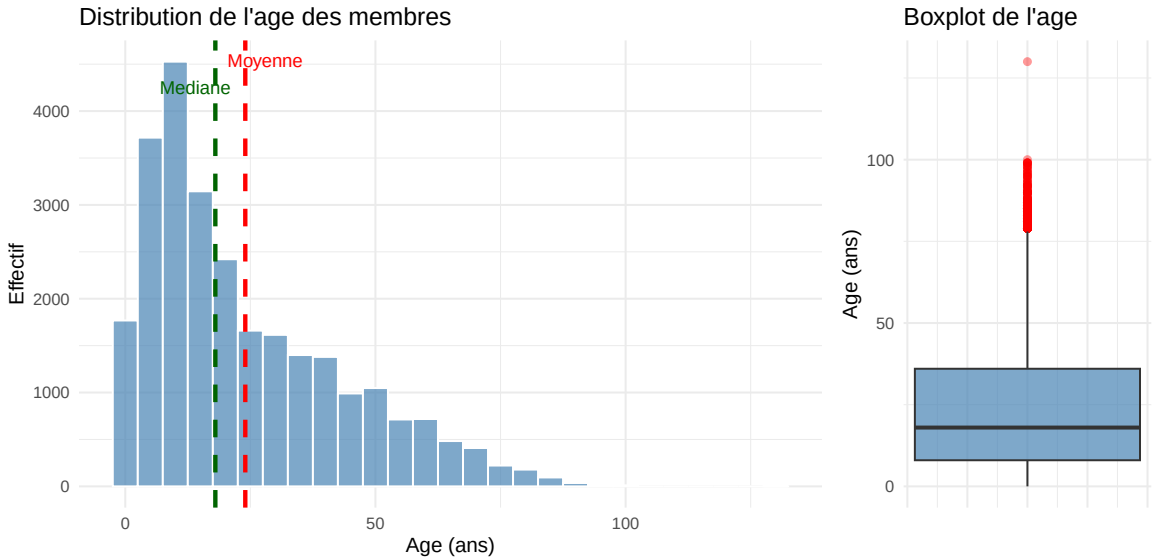

FIGURE 2 – Distribution et dispersion de l'age des membres du menage – Wave 4

L'histogramme confirme la structure jeune de la population nigériane : les tranches d'âge 0-4 et 5-9 ans sont les plus représentées, formant une base large caractéristique des populations à forte fécondité. La distribution est **asymétrique à droite** (queue vers les âges élevés), avec un effilement progressif à partir de 30 ans. Le boxplot met en évidence plusieurs valeurs aberrantes aux âges très élevés (au-delà de 90 ans), qui pourraient correspondre à des erreurs de déclaration ou à de rares cas de grande longévité. La ligne rouge (moyenne) est légèrement décalée vers la droite par rapport à la ligne verte (médiane), confirmant l'asymétrie positive de la distribution.

2.3 Test de normalité de Shapiro-Wilk

TABLE 4: Resultat du test de normalite de Shapiro-Wilk sur l'age

	Taille.echantillon	Statistique.W	p.valeur	Conclusion
W	5000	0.9037	< 2.2e-16	Distribution NON normale ($p < 0.05$)

Le test de Shapiro-Wilk, réalisé sur un échantillon aléatoire de **5000 observations** (limite technique du test), retourne une statistique W = **0.9037** avec une p-valeur **= < 2.2e-16**. Ce résultat conduit au **rejet de l'hypothèse de normalité** ($p < 0{,}05$) : la distribution de l'âge **n'est pas normale**. Cette conclusion, cohérente avec l'observation visuelle de l'histogramme, justifie pleinement le recours à des **tests non paramétriques** (Wilcoxon, Kruskal-Wallis) pour toutes les comparaisons ultérieures impliquant cette variable.

3 Pyramide des âges (Wave 4)

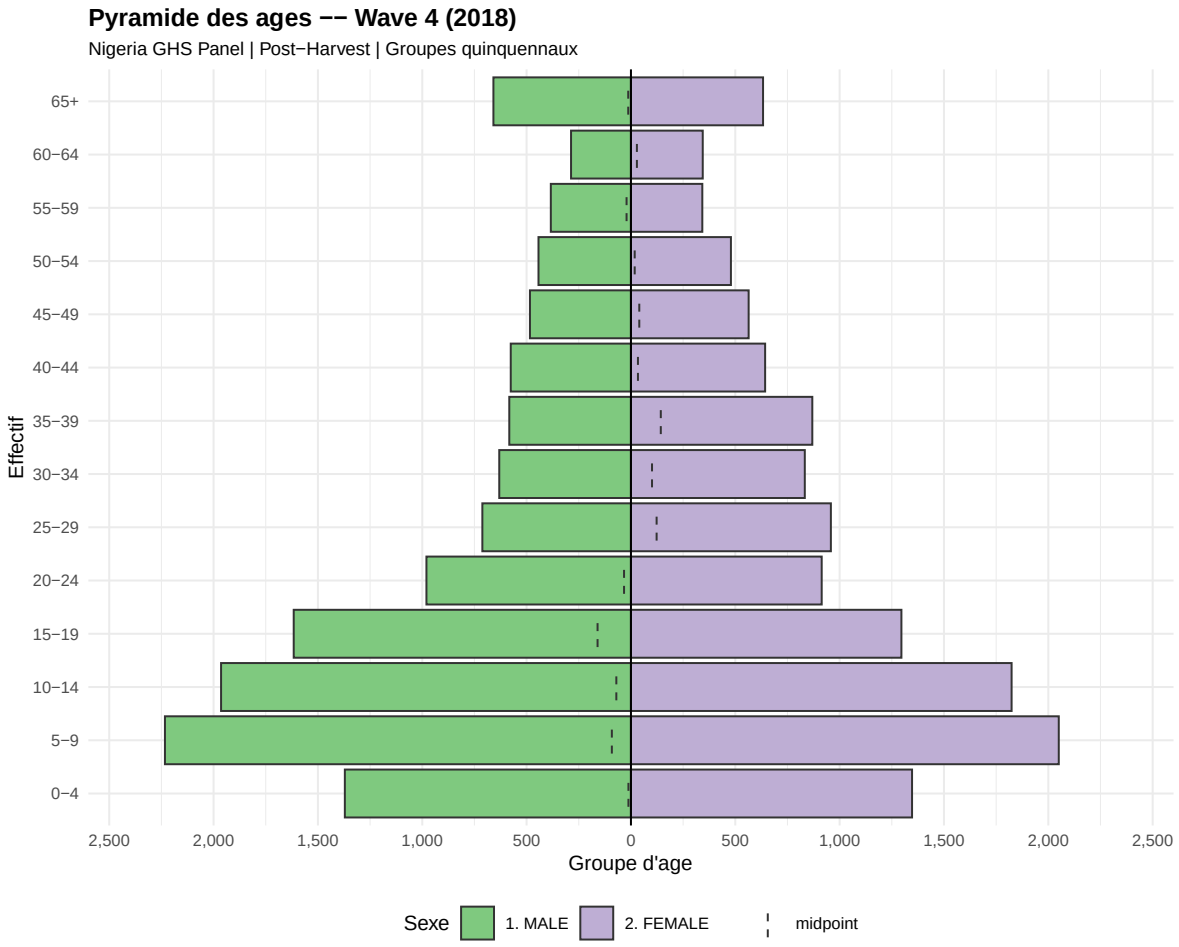

FIGURE 3 – Pyramide des ages par sexe – Wave 4, Post-Harvest (2018)

La pyramide des âges de la Wave 4 présente une forme **expansive** à base large, caractéristique des pays en voie de développement avec une forte natalité. Les groupes d'âge 0-4 et 5-9 ans constituent les cohortes les plus nombreuses, témoignant d'un taux de fécondité encore élevé. Le rétrécissement progressif avec l'âge reflète une mortalité significative aux âges adultes et une espérance de vie encore limitée. La structure est **quasi-symétrique** entre hommes et femmes dans les jeunes classes d'âge, avec une légère sur-représentation féminine observée aux âges élevés (65+), phénomène classique de surmortalité masculine. Cette structure démographique implique une forte pression sur les services d'éducation et de santé pédiatrique, et annonce un important dividende démographique potentiel si les jeunes cohortes accèdent à l'éducation et à l'emploi.

---

4 Analyse du lien de parenté

4.1 Fréquences et intervalles de confiance

Table 5: Distribution du lien de parente avec IC a 95% – Wave 4

Lien de parente	Effectif	Proportion (%)	IC 95% inf (%)	IC 95% sup (%)
3. OWN CHILD	14636	55.1	54.5	55.7
1. HEAD	4980	18.8	18.3	19.2
2. SPOUSE	4273	16.1	15.6	16.5
6. GRANDCHILD	1045	3.9	3.7	4.2
7. BROTHER/SISTER	487	1.8	1.7	2.0
10. PARENT	291	1.1	1.0	1.2
8. NIECE/NEPHEW	229	0.9	0.8	1.0
4. STEP CHILD	192	0.7	0.6	0.8
9. BROTHER/SISTER-IN-LAW	137	0.5	0.4	0.6
14. OTHER RELATION (SPECIFY)	123	0.5	0.4	0.6
5. ADOPTED CHILD	88	0.3	0.3	0.4
12. DOMESTIC HELP	39	0.1	0.1	0.2
11. PARENT-IN-LAW	20	0.1	0.0	0.1
15. OTHER NON-RELATION (SPECIFY)	17	0.1	0.0	0.1

4.2 Diagramme en barres horizontales

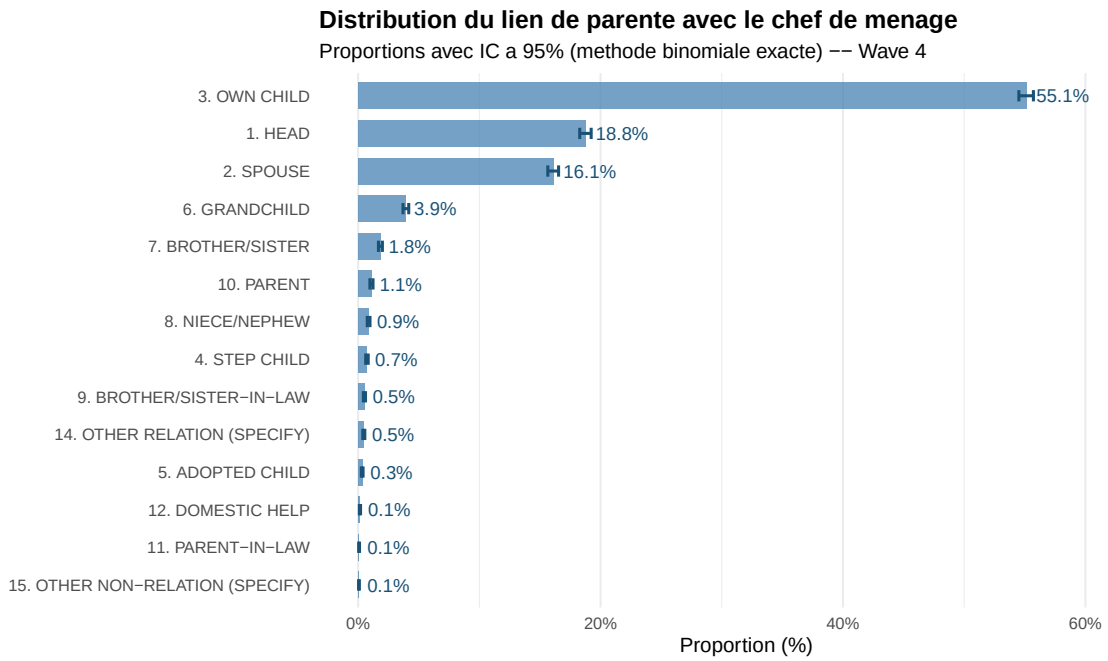

Figure 4 – Repartition du lien de parente avec le chef de menage (IC a 95%) – Wave 4

La catégorie **3. OWN CHILD** est la plus représentée au sein des ménages (**55.1%**), suivie par les **1. HEAD** (**18.8%**). Cette structure confirme la prédominance des **ménages élargis** au Nigeria, où plusieurs générations cohabitent sous le même toit. La forte proportion d'enfants dans la composition des ménages est cohérente avec la pyramide des âges à base large observée précédemment. Les intervalles de confiance à 95% (calculés par la méthode binomiale exacte) sont étroits pour les catégories les plus fréquentes, témoignant de la précision des estimations grâce à la large taille de l'échantillon. Les catégories moins fréquentes (belle-famille, autre parent) présentent des IC plus larges, reflétant une moins grande précision d'estimation.

5 Taille des ménages selon la zone de résidence

5.1 Statistiques comparatives par zone

Table 6: Statistiques de la taille des menages par zone de residence

zone	N individus	N menages	Moy. taille	Med. taille	Min	Max
Rural	8719	1595	7.41	7	1	27
Urbain	21618	3385	8.59	8	1	33

5.2 Boxplot groupé Rural vs Urbain

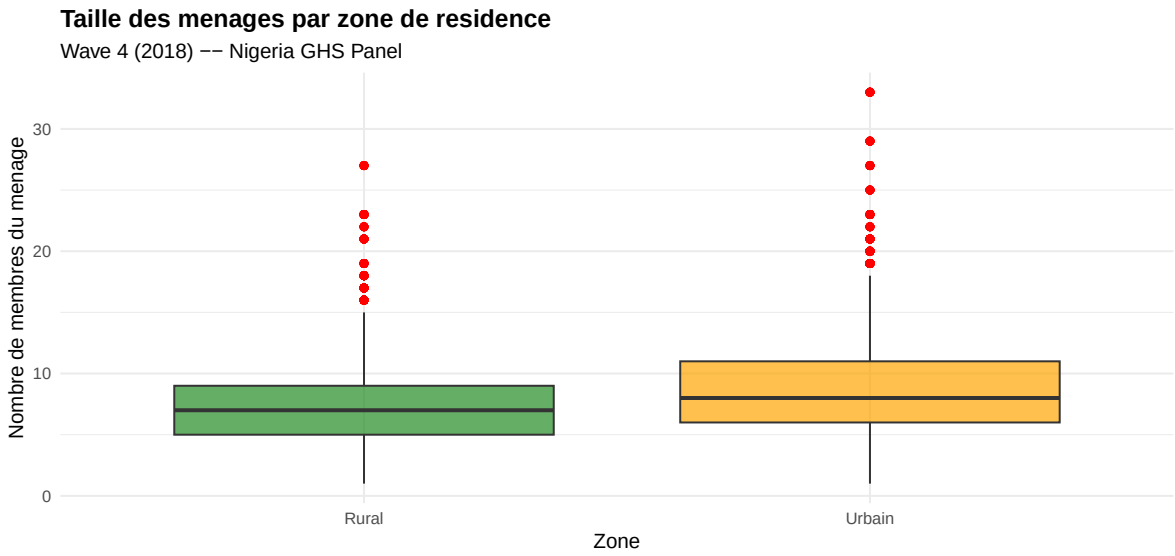

Figure 5 – Taille des menages selon la zone de residence – Wave 4

5.3 Test de Wilcoxon-Mann-Whitney et taille d'effet

Table 7: Test de Wilcoxon – Taille des menages Rural vs Urbain

	Test	Med..Rural	Med..Urbain	p.valeur	r.de.rang	Interpretation
Effect size (r)	Wilcoxon-Mann-Whitney	7	8	< 2.2e-16	0.151	Faible

Le boxplot révèle clairement que les **ménages ruraux sont plus grands** que les ménages urbains. La taille médiane est de **7 membres** en milieu rural contre **8 membres** en milieu urbain, soit un écart de **-1 membre(s)**. Le test de Wilcoxon-Mann-Whitney confirme que cette différence est statistiquement **significative** (p = <2e-16). La taille d'effet (r de rang = 0.151) est qualifiée de **faible**, indiquant que la zone de résidence explique une part limitée de la variabilité de la taille des ménages. Ce résultat est cohérent avec les dynamiques socio-économiques nigérianes : en milieu rural, la fécondité plus élevée et les structures

familiales élargies expliquent la plus grande taille des ménages, tandis qu'en milieu urbain, le coût de la vie et les contraintes de logement favorisent des ménages plus restreints.

---

6 Tableau récapitulatif stratifié par zone

Table 8 – **Tableau 1 – Caracteristiques demographiques par zone (Wave 4)**

Variable	**Overall** N = 30,337	**Rural** N = 8,719	**Urbain** N = 21,618	**p-value**
Age (annees)	24.0 (19.7)	25.0 (19.4)	23.6 (19.8)	<0.001
Sexe				0.5
Homme	13,189 (50%)	3,730 (49%)	9,459 (50%)	
Femme	13,368 (50%)	3,837 (51%)	9,531 (50%)	
Taille du menage	8.3 (4.2)	7.4 (4.0)	8.6 (4.3)	<0.001

[1] Mean (SD) ; n (%)

[2] Wilcoxon rank sum test ; Pearson's Chi-squared test

Ce tableau synthétique compare les principales caractéristiques démographiques des ménages selon la zone de résidence (rurale vs urbaine). Les p-valeurs issues du test de Wilcoxon pour les variables continues (âge, taille du ménage) et du test du Chi-deux pour les variables catégorielles (sexe) permettent d'évaluer la significativité statistique des différences observées. La colonne "Overall" présente les statistiques pour l'ensemble de l'échantillon. Ce tableau constitue un outil de synthèse essentiel pour les décideurs et chercheurs souhaitant comparer les profils démographiques entre milieux rural et urbain au Nigeria.

---

7 Synthèse de l'Analyse 1

Table 9: Synthese des resultats – Analyse 1

Qualite des donnees (Tache 1)	0 doublon(s) &#124 ; 3780 valeurs manquantes sur l'age
Distribution de l'age (Tache 2)	Moyenne = 24 ans &#124 ; Mediane = 18 ans &#124 ; CV = 82.3%
Normalite de l'age (Tache 2)	Shapiro-Wilk W = 0.9037 &#124 ; p = <2e-16 –> Non normale
Pyramide des ages (Tache 3)	Structure expansive &#124 ; Base large 0-14 ans &#124 ; Symetrie H/F
Lien de parente (Tache 4)	3. OWN CHILD dominant (55.1%) &#124 ; Menages elargis nigerians
Taille menage Rural/Urbain (Tache 5)	Rural med. = 7 vs Urbain = 8 &#124 ; Wilcoxon p = <2e-16 &#124 ; r = 0.151

L'Analyse 1 dresse un portrait démographique complet des ménages nigérians enquêtés lors de la Wave 4 (2018). La population est **jeune et en croissance**, avec une médiane d'âge de **18 ans** et une pyramide expansive. Les ménages ruraux sont significativement plus grands que les ménages urbains, reflétant des différences de fécondité et de structures familiales. La catégorie dominante au sein des ménages est celle des **3. OWN CHILD**, confirmant la prédominance des ménages élargis intergénérationnels. Ces caractéristiques démographiques constituent la toile de fond indispensable pour l'interprétation des analyses d'éducation, de santé et de bien-être économique développées dans les analyses suivantes.

Rapport généré avec R 4.5.2 — Source : Nigeria General Household Survey Panel, Wave 4 (2018), World Bank LSMS-ISA.