TP2 : Éducation et alphabétisation des membres des ménages

Rapport d'analyse

Auteurs :

Mouhamet SECK

Manampisoa Clarrat FINARITRINIAINA

Projet statistique avec R ou python

ENSAE - ISE1-CL / ISE1 MATH - Mars 2026

Contents

1 Introduction **2**

2 Méthodologie **2**
2.1 Données et Variables Clés 2
2.2 Traitements Effectués 2

3 Résultats **3**
3.1 Qualité des Données et Valeurs Manquantes 3
3.2 Répartition du Niveau d'Éducation 3
3.3 Comparaison Hommes / Femmes (Adultes 18+) 4
3.4 Relation entre Âge et Niveau d'Éducation 5
3.5 Taux de Scolarisation des 6–17 ans par Zone 7
3.6 Carte du Taux d'Adultes sans Instruction par État 8

4 Discussion **9**

5 Conclusion **10**

1 Introduction

Ce rapport présente les analyses descriptives et les tests statistiques réalisés dans le cadre du TP2, à partir des données de la Nigeria General Household Survey (GHS) Panel – vague 4 (2018–2019). L'objectif est d'étudier les niveaux d'instruction et les taux d'alphabétisation des membres des ménages nigérians, et de comparer les profils selon le sexe, l'âge et la zone de résidence (urbain/rural).

2 Méthodologie

2.1 Données et Variables Clés

Les fichiers suivants ont été utilisés :

- **sect1_harvestw4.dta** : 30 337 individus, variables démographiques (`s1q2` sexe, `s1q4` âge, `sector` milieu, `state` état).
- **sect2_harvestw4.dta** : 26 557 individus, module éducation (`s2aq5` alphabétisation, `s2aq6` a déjà été à l'école, `s2aq9` niveau d'éducation le plus élevé, `s2aq13a` scolarisation actuelle).
- **secta_harvestw4.dta** : 5 025 ménages, utilisé pour vérifier la couverture des identifiants.

Après vérification, aucun doublon n'est présent sur la clé (`hhid`, `indiv`). Les ménages communs entre `sect1` et `sect2` sont au nombre de 4 980, garantissant une jointure fiable.

2.2 Traitements Effectués

```r
# Construction de la variable niveau d'éducation (5 catégories)
sect2_educ <- sect2_w4 %>%
  mutate(
    niveau_educ = case_when(
      s2aq9 %in% c(0, 1, 2, 3)        ~ "Aucun",
      s2aq9 %in% 11:16                ~ "Primaire",
      s2aq9 %in% 21:23                ~ "Junior Secondary",
      s2aq9 %in% c(24:28, 321)        ~ "Senior Secondary",
      s2aq9 %in% c(31, 33, 34, 35,
                   41, 43, 322, 411,
                   412, 421:424,
                   51, 52, 61)        ~ "Tertiaire",
      TRUE                            ~ NA_character_
    ),
    niveau_num = case_when(
      niveau_educ == "Aucun"              ~ 0,
      niveau_educ == "Primaire"           ~ 1,
      niveau_educ == "Junior Secondary"   ~ 2,
      niveau_educ == "Senior Secondary"   ~ 3,
      niveau_educ == "Tertiaire"          ~ 4,
      TRUE                                ~ NA_real_
    )
```

```r
  )

# Jointure avec les variables démographiques de sect1
educ_demo <- sect2_educ %>%
  left_join(
    sect1_w4 %>% select(hhid, indiv, sexe = s1q2,
                        age = s1q4, secteur = sector, etat = state),
    by = c("hhid", "indiv")
  )

# Tests statistiques :
#   - Chi-deux + V de Cramér : sexe × niveau d'éducation (adultes 18+)
#   - Kruskal-Wallis : niveau d'éducation par groupe d'âge
#   - Test post-hoc de Dunn (Bonferroni) : comparaisons multiples
#   - Chi-deux : zone × scolarisation (enfants 6-17 ans)
```

Les traitements réalisés comprennent la construction d'une variable ordonnée de niveau d'éducation en cinq catégories à partir des codes détaillés de `s2aq9`, la jointure avec les variables démographiques de `sect1`, et une série de tests statistiques : chi-deux avec V de Cramér pour l'association sexe–niveau d'éducation, test de Kruskal-Wallis suivi du test post-hoc de Dunn (correction de Bonferroni) pour la comparaison du niveau d'éducation entre groupes d'âge, et chi-deux pour l'association zone–scolarisation des enfants de 6 à 17 ans.

3 Résultats

3.1 Qualité des Données et Valeurs Manquantes

L'examen des valeurs manquantes sur les variables clés révèle une situation contrastée selon les fichiers. Dans `sect1_w4`, les variables démographiques (`s1q2`, `s1q4`, `sector`, `state`) sont quasi exhaustives avec moins de 0,5 % de NA. Dans `sect2_w4`, les taux de manquants pour `s2aq5` (alphabétisation) et `s2aq9` (niveau d'éducation) sont élevés (environ 27 %), ce qui est structurellement attendu : ces questions ne s'adressent qu'aux personnes de 3 ans et plus, et les individus non scolarisés n'ont pas de niveau d'éducation à déclarer. Les analyses ultérieures ne portent que sur les individus ayant effectivement répondu.

3.2 Répartition du Niveau d'Éducation

La distribution du niveau d'éducation le plus élevé, parmi les personnes ayant répondu, est la suivante :

Table 1: Effectifs et proportions du niveau d'éducation

niveau_educ	n	prop	prop_label
Primaire	7068	0.367	36.7%
Senior Secondary	4617	0.240	24.0%
Tertiaire	3595	0.187	18.7%
Junior Secondary	2129	0.110	11.0%

niveau_educ	n	prop	prop_label
Aucun	1862	0.097	9.7%

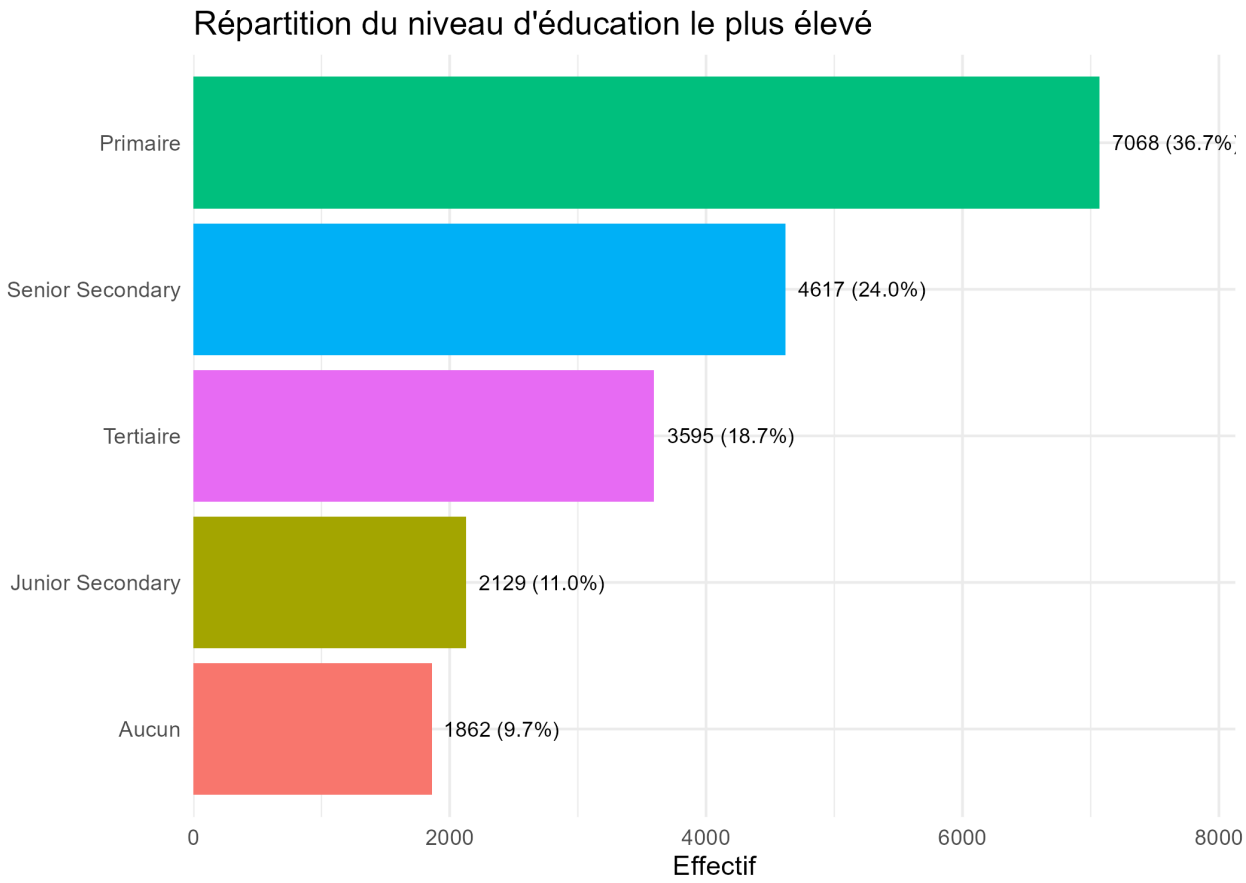

Le niveau Primaire est le plus fréquent (36,7 %), suivi du Senior Secondary (24,0 %) et du Tertiaire (18,7 %). Les personnes sans aucune instruction représentent 9,7 % de l'échantillon. Ce profil reflète des progrès importants dans l'accès à l'éducation de base, mais une déperdition scolaire significative entre le primaire et les niveaux supérieurs.

3.3 Comparaison Hommes / Femmes (Adultes 18+)

L'analyse porte sur les adultes de 18 ans et plus. Le tableau de contingence croise le sexe et le niveau d'éducation.

Table 2: Tableau de contingence sexe × niveau d'éducation (adultes 18+)

	Aucun	Primaire	Junior.Secondary	Senior.Secondary	Tertiaire
Homme	26	1198	359	2158	1690
Femme	47	1416	379	1687	1385

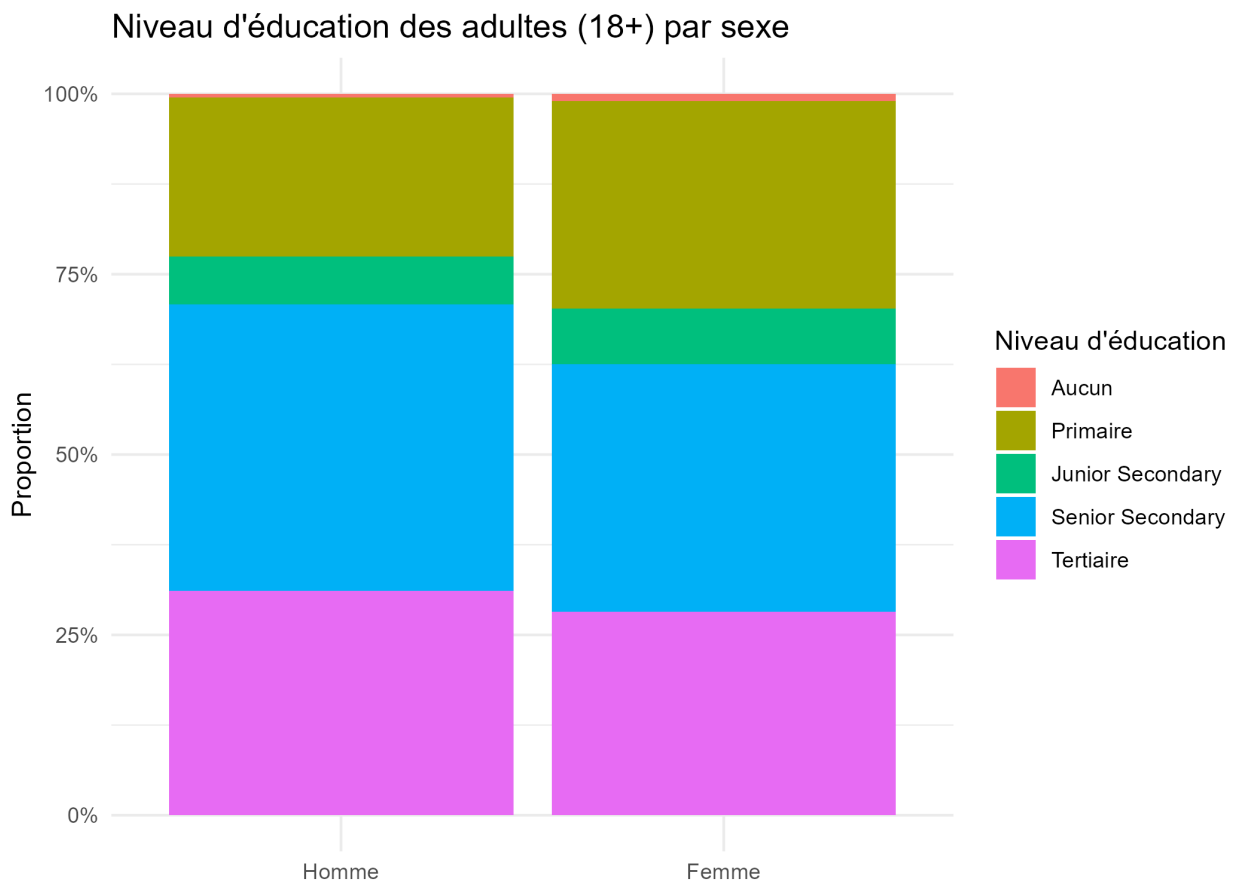

Le test du χ^2 est hautement significatif (p < 2,2e-16), indiquant une dépendance entre le sexe et le niveau d'éducation. Le V de Cramér (0,092) correspond à une association faible mais statistiquement robuste. Le graphique en barres 100 % empilées illustre la nature de cet écart : les hommes sont proportionnellement plus nombreux dans les niveaux Senior Secondary et Tertiaire, tandis que les femmes sont surreprésentées dans les niveaux Primaire et Aucun. Ces inégalités de genre persistent malgré les progrès de la scolarisation féminine au Nigeria, et reflètent des abandons scolaires plus précoces chez les filles.

3.4 Relation entre Âge et Niveau d'Éducation

Les adultes ont été regroupés en quatre tranches d'âge. Le boxplot ci-dessous montre la distribution du niveau d'éducation (variable numérique de 0 à 4) pour chaque groupe.

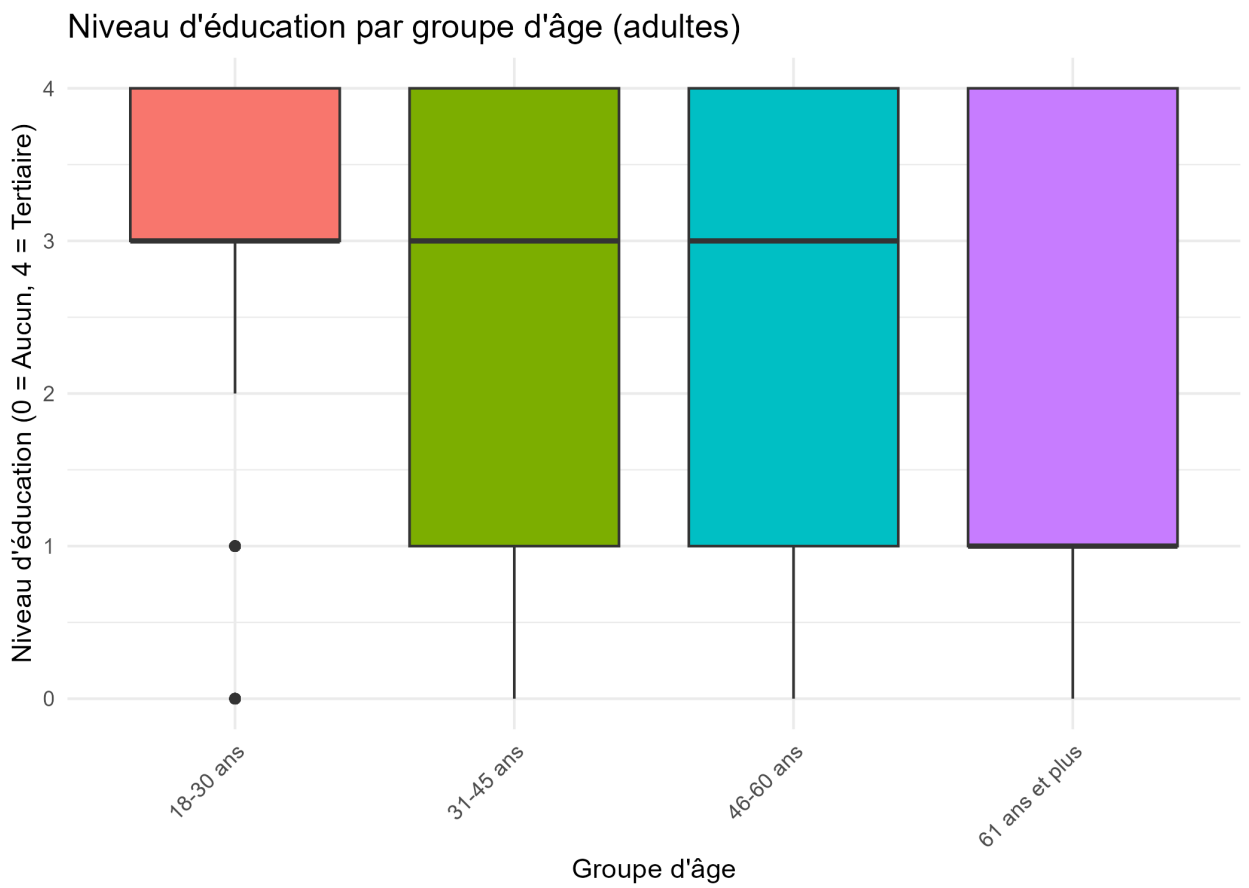

Table 3: Statistiques du niveau d'éducation par groupe d'âge

age_group	n	mediane	Q1	Q3
18-30 ans	4505	3	3	4
31-45 ans	3149	3	1	4
46-60 ans	1858	3	1	4
61 ans et plus	833	1	1	4

Les jeunes adultes de 18–30 ans ont un niveau médian de 3 (Senior Secondary), tandis que les 61 ans et plus affichent une médiane de 1 (Primaire). Cette progression générationnelle du niveau d'éducation traduit les efforts d'expansion du système scolaire nigérian au cours des dernières décennies. Le test de Kruskal-Wallis confirme une différence très significative entre les groupes (p < 2,2e-16).

Table 4: Test de Dunn – comparaisons multiples par groupe d'âge (correction Bonferroni)

group1	group2	p.adj	p.adj.signif
18-30 ans	31-45 ans	0.0001403	***
18-30 ans	46-60 ans	0.0000000	****

group1	group2	p.adj	p.adj.signif
18-30 ans	61 ans et plus	0.0000000	****
31-45 ans	46-60 ans	0.0161158	*
31-45 ans	61 ans et plus	0.0000000	****
46-60 ans	61 ans et plus	0.0000265	****

Le test post-hoc de Dunn montre que tous les groupes d'âge diffèrent significativement les uns des autres. Ces résultats confirment que le gradient éducatif entre générations est graduel et statistiquement robuste à chaque échelon.

3.5 Taux de Scolarisation des 6–17 ans par Zone

La scolarisation est mesurée par la variable `s2aq13a` (fréquentation scolaire actuelle) sur les enfants de 6 à 17 ans.

Table 5: Effectifs et taux de scolarisation par zone

zone	scolarise	n	total_zone	prop	ic_low	ic_high	prop_label
Rural	Non	635	5515	0.115	0.107	0.124	11.5%
Rural	Oui	4880	5515	0.885	0.876	0.893	88.5%
Urbain	Non	179	2315	0.077	0.067	0.089	7.7%
Urbain	Oui	2136	2315	0.923	0.911	0.933	92.3%

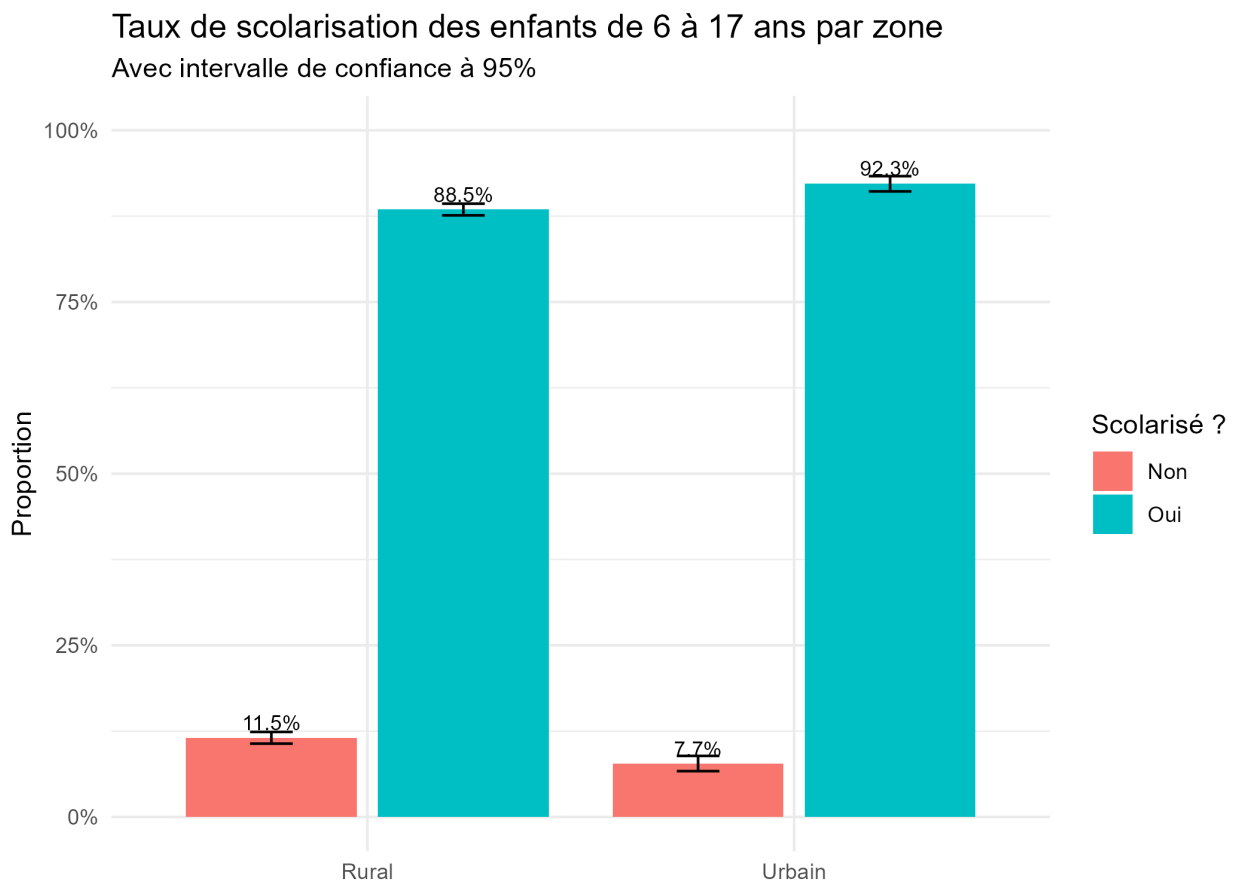

Le taux de scolarisation est plus élevé en zone urbaine (92,3 %) qu'en zone rurale (88,5 %), soit un écart de près de 4 points de pourcentage. Les intervalles de confiance à 95 % (méthode binomiale exacte) ne se chevauchant pas, cette différence est statistiquement significative, ce que confirme le test du χ^2 ($p < 0{,}001$). Si l'écart reste modéré en valeur absolue, il suggère que les contraintes d'accès à l'école – distance, coûts directs et indirects, travail des enfants – pèsent davantage en milieu rural.

3.6 Carte du Taux d'Adultes sans Instruction par État

La proportion d'adultes (18 ans et plus) n'ayant aucun niveau d'instruction a été calculée pour chaque État nigérian et reportée sur une carte choroplèthe.

Taux d'adultes sans instruction par État au Nigéria
Données GHS-Panel, Vague 4 (2018-2019)

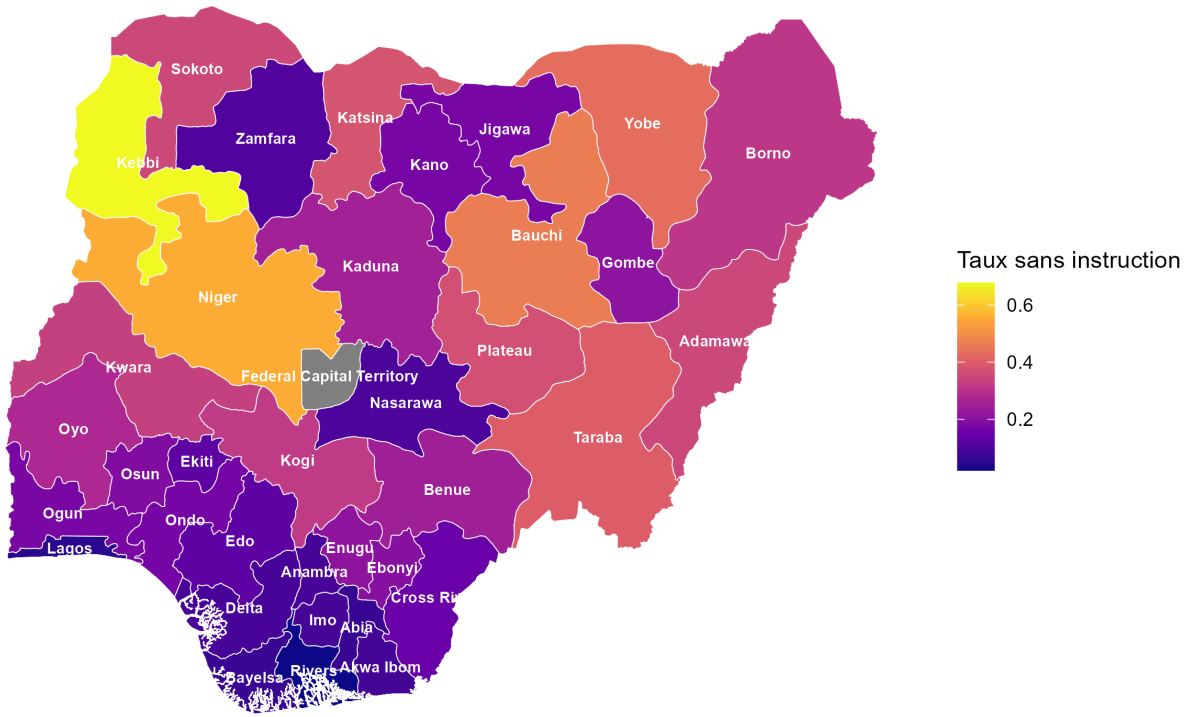

Source: Calculs à partir des données LSMS-ISA

Les États du Nord-Ouest notamment Sokoto et Kebbi affichent les taux les plus élevés (proches de 60 %), suivis des États du Nord-Est (Yobe, Borno, Bauchi, entre 30 et 50 %). À l'inverse, les États du Sud (Lagos, Abia, Anambra, Rivers) présentent des taux inférieurs à 5 %. Cette fracture Nord-Sud reflète des inégalités historiques dans l'implantation des infrastructures scolaires, renforcées par des facteurs culturels, religieux et économiques. La zone FCT apparaît en gris en raison d'une non-correspondance entre le nom dans les données et le shapefile, à corriger si nécessaire.

4 Discussion

Les analyses confirment des inégalités marquées en matière d'éducation au Nigeria, selon trois axes principaux. Sur le plan du **genre**, les femmes adultes sont moins instruites que les hommes, avec une surreprésentation dans les niveaux les plus bas et une sous-représentation dans l'enseignement supérieur. Sur le plan **générationnel**, les jeunes (18–30 ans) sont nettement plus éduqués que les générations précédentes, témoignant des progrès de l'accès à l'école au cours des dernières décennies, même si la déperdition entre le primaire et les niveaux supérieurs reste importante. Sur le plan **géographique**, de fortes disparités régionales persistent, avec un retard

structurel des États du Nord qui concentrent l'essentiel des adultes sans instruction.

Ces trois axes d'inégalité se renforcent mutuellement : les États du Nord sont aussi ceux où les inégalités de genre dans l'éducation sont les plus prononcées, et où les taux de scolarisation des enfants – notamment des filles – sont les plus faibles. Toute politique éducative efficace devra donc cibler simultanément ces dimensions géographiques, de genre et générationnelles.

Limites :

- Les données sont déclaratives et peuvent souffrir de biais de mémoire, notamment pour la déclaration du niveau d'éducation des personnes âgées.
- Les poids d'échantillonnage n'ont pas été utilisés ; les résultats sont donc représentatifs de l'échantillon mais pas nécessairement de la population nationale.
- La variable d'alphabétisation (`s2aq5`) n'a pas été exploitée ici ; elle pourrait faire l'objet d'analyses complémentaires pour affiner le diagnostic éducatif.

5 Conclusion

Ce travail a permis de décrire la structure éducative de la population nigériane à partir des données GHS-Panel vague 4. Il met en évidence des progrès générationnels réels, mais aussi des inégalités persistantes selon le sexe, le milieu de résidence et la région. La fracture Nord-Sud constitue le défi structurel le plus important, tandis que les inégalités de genre, bien que statistiquement significatives, semblent s'atténuer dans les générations les plus jeunes. Ces résultats constituent une base descriptive utile pour orienter les politiques éducatives vers les populations et territoires les plus vulnérables.