Analyse 3 — Accès aux services de santé et chocs sanitaires des ménages nigérians

Projet Statistique sous R | ENSAE ISE 1, 2025-2026
Nigeria General Household Survey (GHS) Panel — Wave 4 (2018)

Groupe 7 | Herman YAMAHA — Bourama DIALLO
École Nationale de la Statistique et de l'Analyse Économique Pierre NDIAYE

17 mars 2026

Contents

Introduction **2**

Exploration et qualité des données **2**
Dimensions et structure des fichiers . . . 2
Statistiques univariées des variables clés . . . 3
Valeurs manquantes — variables santé . . . 4

Tâche 13 — Taux de morbidité par sexe et groupe d'âge **7**
Taux de morbidité global . . . 7
Par sexe . . . 7
Par groupe d'âge . . . 8

Tâche 14 — Types de maladies déclarées **13**

Tâche 15 — Recours aux soins par type de prestataire **14**

Tâche 16 — Distribution des dépenses de santé **16**
Statistiques par décile . . . 18
Histogramme (échelle logarithmique) . . . 18
Boxplot par type de prestataire . . . 20

Tâche 17 — Test d'indépendance : recours × quintile de richesse **20**
Tableau de contingence . . . 22
Tests statistiques . . . 22
Barplot 100 % empilé . . . 23

Tâche 18 — Dépenses de santé : rural vs urbain (Wilcoxon + Violin) **25**
Violin plot + boxplot superposé . . . 26

Synthèse et conclusions **27**

Informations de session **29**

Introduction

Ce rapport présente l'**Analyse 3** du projet statistique ISE 1 (2025-2026), consacrée à l'accès aux services de santé et aux chocs sanitaires des ménages nigérians. Les données proviennent du **Nigeria General Household Survey (GHS) Panel**, programme LSMS-ISA de la Banque Mondiale, vague 4 collectée en 2018 (visite Post-Harvest).

Objectif : Décrire les épisodes de maladie, les types de soins consultés et les coûts de santé supportés par les ménages nigérians, et analyser les disparités par sexe, âge, milieu de résidence et niveau de richesse.

Sources mobilisées :

Fichier	Rôle	Variables clés
`sect4a_harvestw4.dta`	Section santé individuelle	`s4aq3`, `s4aq3b_1`, `s4aq6a`, `s4aq9/14/17`
`sect1_harvestw4.dta`	Démographie	`s1q2` (sexe), `s1q4` (âge), `sector`
`secta_harvestw4.dta`	Ménage	`sector` (urban/rural), `state`
`totcons_final.dta`	Consommation	`totcons_adj` (cons. ajustée par tête)

> **Note méthodologique :** dans le GHS Wave 4 (2018), les variables de santé se trouvent dans `sect4a_harvestw4.dta` (et non `sect3a` comme indiqué dans certaines documentations antérieures). Les correspondances sont : `s4aq3` maladie/blessure, `s4aq6a` prestataire consulté, `s4aq9/14/17` dépenses de santé.

```r
# Chargement des quatre fichiers de données brutes
# Chemin relatif depuis le dossier rapport/ → racine du projet
sect4a <- read_dta("../data/raw/sect4a_harvestw4.dta")
sect1  <- read_dta("../data/raw/sect1_harvestw4.dta")
secta  <- read_dta("../data/raw/secta_harvestw4.dta")
cons   <- read_dta("../data/raw/totcons_final.dta")
```

Exploration et qualité des données

Dimensions et structure des fichiers

Avant toute analyse, on inspecte la structure de chaque fichier pour vérifier les types de variables, repérer les potentiels problèmes d'encodage et comprendre la logique des données.

```r
# Résumé des dimensions
tibble::tribble(
  ~Fichier,                 ~Observations, ~Variables,
  "sect4a_harvestw4.dta",  nrow(sect4a),  ncol(sect4a),
  "sect1_harvestw4.dta",   nrow(sect1),   ncol(sect1),
  "secta_harvestw4.dta",   nrow(secta),   ncol(secta),
  "totcons_final.dta",     nrow(cons),    ncol(cons)
) |>
  kable(caption = "Dimensions des fichiers de données")
```

Table 2: Dimensions des fichiers de données

Fichier	Observations	Variables
sect4a_harvestw4.dta	26556	69
sect1_harvestw4.dta	30337	59
secta_harvestw4.dta	5025	22
totcons_final.dta	4976	64

```r
# Inspection des variables clés de la section santé
# On sélectionne uniquement les variables mobilisées dans l'analyse
sect4a |>
  select(hhid, indiv, s4aq1, s4aq3, s4aq3b_1,
         s4aq6a, s4aq9, s4aq14, s4aq17) |>
  glimpse()
```

```
## Rows: 26,556
## Columns: 9
## $ hhid     <dbl> 10001, 10001, 10001, 10001, 10001, 10001, 10002, 10002, 10002~
## $ indiv    <dbl> 1, 2, 3, 4, 8, 9, 1, 2, 3, 8, 9, 1, 2, 3, 4, 5, 6, 1, 2, 3, 5~
## $ s4aq1    <dbl+lbl> 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, 2, ~
## $ s4aq3    <dbl+lbl>  2,  2,  2,  2,  2,  2,  2,  1,  2,  1,  2,  2,  2,  2,  ~
## $ s4aq3b_1 <dbl+lbl> NA, NA, NA, NA, NA, NA, NA, 16, NA, 10, NA, NA, NA, NA, N~
## $ s4aq6a   <dbl+lbl> NA, NA, NA, NA, NA, NA, NA,  0, NA,  0, NA, NA, NA, NA, N~
## $ s4aq9    <dbl+lbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
## $ s4aq14   <dbl> NA, NA, NA, NA, NA, NA, NA, 350, NA, 400, NA, NA, NA, NA, NA,~
## $ s4aq17   <dbl+lbl> NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, NA, N~
```

```r
# Variables démographiques : sexe (s1q2), âge (s1q4), milieu (sector)
sect1 |>
  select(hhid, indiv, s1q2, s1q4, sector) |>
  glimpse()
```

```
## Rows: 30,337
## Columns: 5
## $ hhid   <dbl> 10001, 10001, 10001, 10001, 10001, 10001, 10001, 10001, 10002, ~
## $ indiv  <dbl> 1, 2, 3, 4, 6, 7, 8, 9, 1, 2, 3, 4, 5, 6, 7, 8, 9, 1, 2, 3, 4, ~
## $ s1q2   <dbl+lbl>  1,  2,  2,  2, NA, NA,  1,  1,  1,  2,  1, NA, NA, NA, NA,~
## $ s1q4   <dbl> 55, 41, 11, 53, NA, NA, 8, 2, 52, 45, 17, NA, NA, NA, NA, 8, 6,~
## $ sector <dbl+lbl> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1,~
```

Statistiques univariées des variables clés

```r
# Distribution de la variable de morbidité (s4aq3)
# 1 = maladie/blessure déclarée, 2 = aucune
cat("=== s4aq3 : maladie ou blessure ===\n")
```

```
## === s4aq3 : maladie ou blessure ===
```

```r
table(sect4a$s4aq3, useNA = "always") |> print()
```

```
##
##     1     2  <NA>
##  2065 20106  4385
```

```r
cat("\n=== s1q2 : sexe (1=Homme, 2=Femme) ===\n")
```

```
##
## === s1q2 : sexe (1=Homme, 2=Femme) ===
```

```r
table(sect1$s1q2, useNA = "always") |> print()
```

```
##
##     1     2  <NA>
## 13189 13368  3780
```

```r
cat("\n=== sector : milieu (1=Urbain, 2=Rural) ===\n")
```

```
##
## === sector : milieu (1=Urbain, 2=Rural) ===
```

```r
table(sect1$sector, useNA = "always") |> print()
```

```
##
##     1     2  <NA>
##  8719 21618     0
```

```r
cat("\n=== s1q4 : âge (résumé statistique) ===\n")
```

```
##
## === s1q4 : âge (résumé statistique) ===
```

```r
summary(sect1$s1q4) |> print()
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.    NA's
##    0.00    8.00   18.00   23.98   36.00  130.00    3780
```

Valeurs manquantes — variables santé

Les valeurs manquantes sur certaines variables de `sect4a` sont **structurellement conditionnelles** : `s4aq3b_1` (type de maladie) n'est renseigné que si `s4aq3 = 1` (individu malade), et `s4aq9` (dépense consultation) n'est renseigné que si l'individu a consulté. Il ne s'agit donc pas d'une perte d'information mais du filtre logique du questionnaire.

```r
# vis_miss() de naniar génère un ggplot : appel direct sans print()
sect4a |>
  select(
    "Consultation"       = s4aq1,
    "Maladie/blessure"   = s4aq3,
    "Type d'affection"   = s4aq3b_1,
    "Praticien consulté" = s4aq6a,
    "Dép. consultation"  = s4aq9,
    "Dép. médicaments"   = s4aq14,
    "Dép. hôpital"       = s4aq17
  ) |>
  vis_miss(sort_miss = TRUE) +
```

```r
  labs(
    title    = "Valeurs manquantes - variables santé (sect4a_harvestw4)",
    subtitle = "Les NA sur type/praticien/dépenses sont conditionnels au filtre maladie"
  ) +
  theme(
  plot.title   = element_text(face = "bold", margin = margin(b = 55)),
  plot.subtitle= element_text(margin = margin(b = 55))
   )+
  theme(axis.text.y = element_text(size = 7))+
  theme(
  plot.margin = margin(t = 3, r = 3, b = 3, l = 3)
  )
```

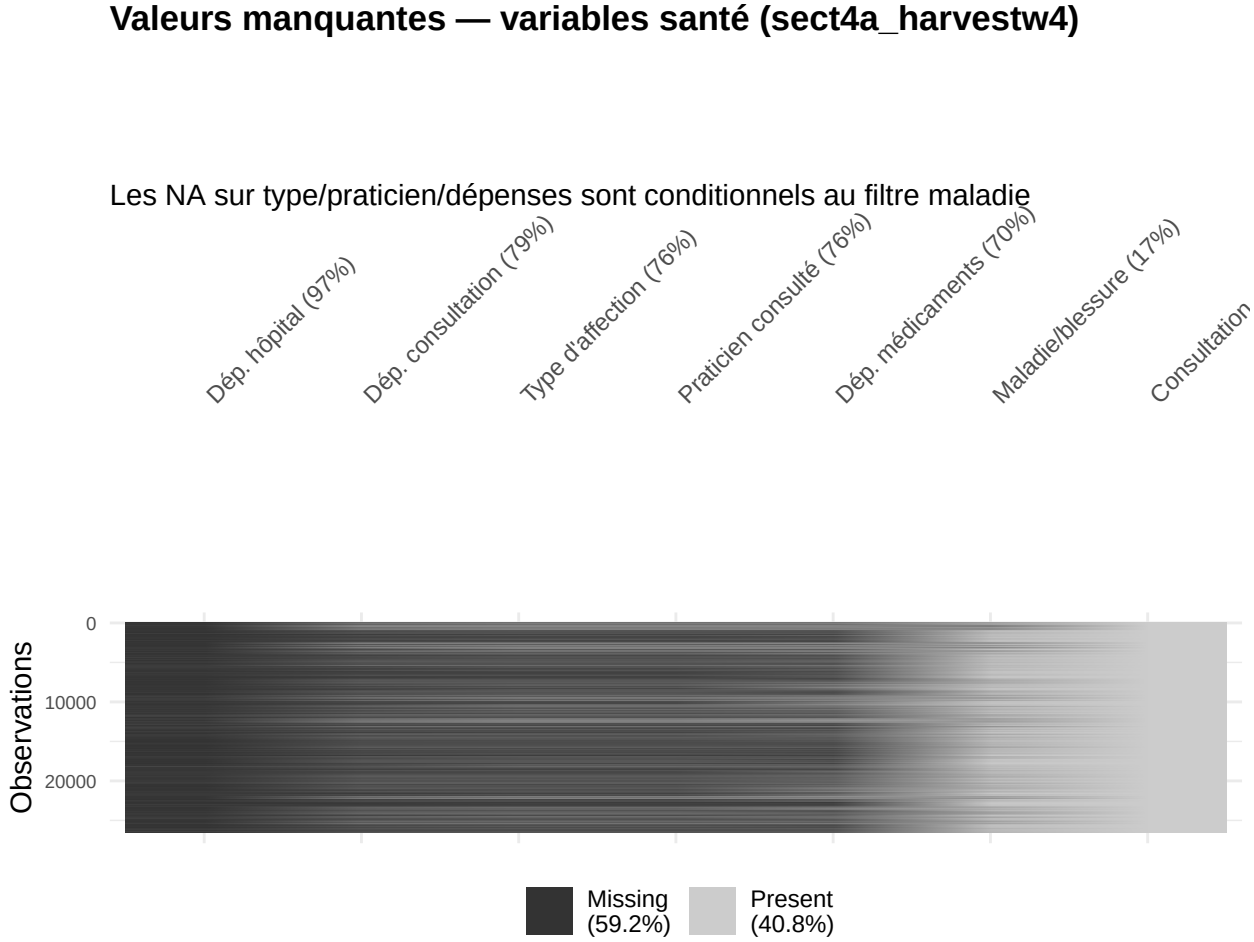

Figure 1: Carte des valeurs manquantes — variables clés de santé (sect4a)

```r
# ==========================================================================
# PRÉPARATION DU JEU DE DONNÉES ANALYTIQUE
# ==========================================================================

#   Données démographiques
sect1_clean <- sect1 |>
```

```r
  select(hhid, indiv, s1q2, s1q4, sector) |>
  rename(sexe = s1q2, age = s1q4, milieu = sector) |>
  mutate(
    sexe_label   = factor(sexe,   levels = c(1, 2),
                          labels = c("Homme", "Femme")),
    milieu_label = factor(milieu, levels = c(1, 2),
                          labels = c("Urbain", "Rural")),
    groupe_age   = cut(
      age,
      breaks         = c(0, 14, 24, 34, 44, 54, 64, Inf),
      labels         = c("0-14", "15-24", "25-34",
                         "35-44", "45-54", "55-64", "65+"),
      right          = TRUE,
      include.lowest = TRUE
    )
  )

#   Variable de morbidité
# s4aq3 = 1 : maladie/blessure déclarée → malade = 1
# s4aq3 = 2 : aucune maladie            → malade = 0
sect4a_clean <- sect4a |>
  select(hhid, indiv, s4aq1, s4aq3, s4aq3b_1,
         s4aq6a, s4aq9, s4aq14, s4aq17) |>
  mutate(
    malade   = if_else(s4aq3 == 1, 1L, 0L, missing = NA_integer_),
    consulte = if_else(s4aq1 == 1, 1L, 0L, missing = NA_integer_)
  )

#   Fusion sect4a + sect1
df_health <- sect4a_clean |>
  left_join(sect1_clean, by = c("hhid", "indiv"))

#   Quintiles de consommation
cons_clean <- cons |>
  select(hhid, totcons_adj) |>
  mutate(
    quintile = ntile(totcons_adj, 5),
    quintile_label = factor(
      quintile, levels = 1:5,
      labels = c("Q1 (plus pauvres)", "Q2", "Q3", "Q4", "Q5 (plus riches)")
    )
  )

#   Dictionnaire des praticiens
groupe_praticien <- c(
  "0"="Aucun recours", "1"="Tradipraticien",
  "2"="Hôpital/Clinique", "3"="Hôpital/Clinique",
  "4"="Hôpital/Clinique", "5"="Hôpital/Clinique",
  "6"="Hôpital/Clinique", "7"="Pharmacie",
  "8"="Pharmacie",        "9"="Tradipraticien",
  "10"="Tradipraticien",  "11"="Pharmacie",
  "13"="Autre",           "14"="Agent de santé comm.",
  "15"="Agent de santé comm."
```

```
)
```

Tâche 13 — Taux de morbidité par sexe et groupe d'âge

Taux de morbidité global

```r
# Calcul du taux global et de son IC à 95 %
# Formule approximée de Wilson : IC = p ± 1.96 × sqrt(p(1-p)/n)
taux_global <- df_health |>
  filter(!is.na(malade)) |>
  summarise(
    N         = n(),
    n_malades = sum(malade),
    taux      = mean(malade),
    ic_low    = taux - 1.96 * sqrt(taux * (1 - taux) / N),
    ic_high   = taux + 1.96 * sqrt(taux * (1 - taux) / N)
  )

taux_global |>
  mutate(across(c(taux, ic_low, ic_high),
                ~ paste0(round(. * 100, 2), " %"))) |>
  kable(
    caption   = "Taux de morbidité global - Wave 4 (2018)",
    col.names = c("N total", "Nb malades", "Taux", "IC inf. 95%", "IC sup. 95%")
  )
```

Table 3: Taux de morbidité global — Wave 4 (2018)

N total	Nb malades	Taux	IC inf. 95%	IC sup. 95%
22171	2065	9.31 %	8.93 %	9.7 %

Interprétation : 9.3 % des individus de 5 ans et plus ont déclaré au moins une maladie ou blessure dans les 4 semaines précédant l'enquête.

Par sexe

```r
# Calcul des taux par sexe avec IC à 95 %
taux_sexe <- df_health |>
  filter(!is.na(malade), !is.na(sexe_label)) |>
  group_by(sexe_label) |>
  summarise(
    n         = n(),
    n_malades = sum(malade, na.rm = TRUE),
    taux      = mean(malade, na.rm = TRUE),
    ic_low    = taux - 1.96 * sqrt(taux * (1 - taux) / n),
    ic_high   = taux + 1.96 * sqrt(taux * (1 - taux) / n),
    .groups   = "drop"
  )
```

```r
kable(
  taux_sexe |>
    mutate(across(c(taux, ic_low, ic_high),
                  ~ paste0(round(. * 100, 1), " %"))),
  caption   = "Taux de morbidité par sexe - IC à 95 %",
  col.names = c("Sexe", "N", "Malades", "Taux", "IC inf.", "IC sup.")
)
```

Table 4: Taux de morbidité par sexe — IC à 95 %

Sexe	N	Malades	Taux	IC inf.	IC sup.
Homme	11134	930	8.4 %	7.8 %	8.9 %
Femme	11037	1135	10.3 %	9.7 %	10.9 %

```r
# Marge entre la borne haute de l'IC et l'étiquette de valeur
marge <- 0.012

ggplot(taux_sexe, aes(x = sexe_label, y = taux, fill = sexe_label)) +
  geom_col(width = 0.5, show.legend = FALSE) +
  geom_errorbar(
    aes(ymin = ic_low, ymax = ic_high),
    width = 0.12, linewidth = 0.8, color = "grey25"
  ) +
  # Étiquette positionnée AU-DESSUS de ic_high pour éviter tout chevauchement
  geom_text(
    aes(y = ic_high + marge, label = paste0(round(taux * 100, 1), "%")),
    vjust = 0, size = 5, fontface = "bold", color = "grey20"
  ) +
  scale_y_continuous(
    labels = percent_format(accuracy = 1),
    limits = c(0, max(taux_sexe$ic_high) + 0.04),
    expand = c(0, 0)
  ) +
  scale_fill_manual(values = c("Homme" = "#3A86FF", "Femme" = "#FF6B6B")) +
  labs(
    title    = "Taux de morbidité par sexe",
    subtitle = "Wave 4 (2018) - 4 semaines avant l'enquête",
    x = NULL, y = "Taux de morbidité",
    caption = "Source : Nigeria GHS Panel W4 | Barres d'erreur : IC à 95 %"
  ) +
  theme_minimal(base_size = 13) +
  theme(
    plot.title         = element_text(face = "bold", size = 14),
    panel.grid.major.x = element_blank(),
    axis.text.x        = element_text(size = 12, face = "bold")
  )
```

Par groupe d'âge

```r
taux_age <- df_health |>
  filter(!is.na(malade), !is.na(groupe_age)) |>
  group_by(groupe_age) |>
```

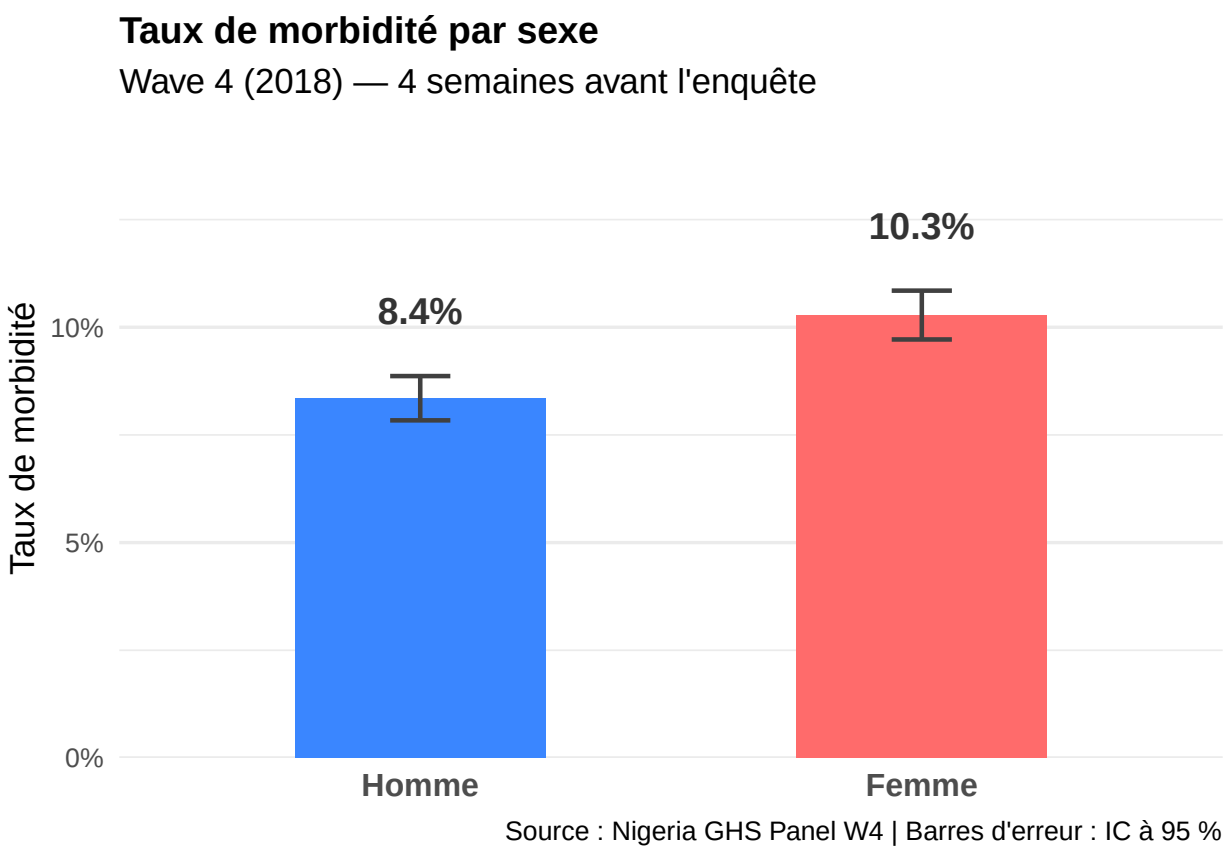

Figure 2: Taux de morbidité par sexe avec IC à 95%

```r
  summarise(
    n         = n(),
    n_malades = sum(malade, na.rm = TRUE),
    taux      = mean(malade, na.rm = TRUE),
    ic_low    = pmax(0, taux - 1.96 * sqrt(taux * (1 - taux) / n)),
    ic_high   = taux + 1.96 * sqrt(taux * (1 - taux) / n),
    .groups   = "drop"
  )

kable(
  taux_age |>
    mutate(across(c(taux, ic_low, ic_high),
                  ~ paste0(round(. * 100, 1), " %"))),
  caption   = "Taux de morbidité par groupe d'âge",
  col.names = c("Groupe d'âge", "N", "Malades", "Taux", "IC inf.", "IC sup.")
)
```

Table 5: Taux de morbidité par groupe d'âge

Groupe d'âge	N	Malades	Taux	IC inf.	IC sup.
0-14	9680	731	7.6 %	7 %	8.1 %
15-24	4296	296	6.9 %	6.1 %	7.6 %
25-34	2646	228	8.6 %	7.5 %	9.7 %
35-44	2163	223	10.3 %	9 %	11.6 %
45-54	1544	196	12.7 %	11 %	14.4 %
55-64	988	178	18 %	15.6 %	20.4 %
65+	854	213	24.9 %	22 %	27.8 %

```r
# ylim dynamique : aucune barre ne sera tronquée (problème corrigé)
ggplot(taux_age, aes(x = groupe_age, y = taux, fill = groupe_age)) +
  geom_col(width = 0.65, show.legend = FALSE) +
  geom_errorbar(
    aes(ymin = ic_low, ymax = ic_high),
    width = 0.2, linewidth = 0.7, color = "grey25"
  ) +
  geom_text(
    aes(y = ic_high + marge, label = paste0(round(taux * 100, 1), "%")),
    vjust = 0, size = 4, fontface = "bold", color = "grey20"
  ) +
  scale_y_continuous(
    labels = percent_format(accuracy = 1),
    limits = c(0, max(taux_age$ic_high) + 0.05),
    expand = c(0, 0)
  ) +
  scale_fill_brewer(palette = "Blues") +
  labs(
    title    = "Taux de morbidité par groupe d'âge",
    subtitle = "Nigeria GHS Panel - Wave 4, Post-Harvest 2018",
    x = "Groupe d'âge", y = "Taux de morbidité",
    caption = "Source : Nigeria GHS Panel W4 | Barres d'erreur : IC à 95 %"
  ) +
  theme_minimal(base_size = 13) +
```

```r
  theme(
    plot.title         = element_text(face = "bold", size = 14),
    panel.grid.major.x = element_blank()
  )
```

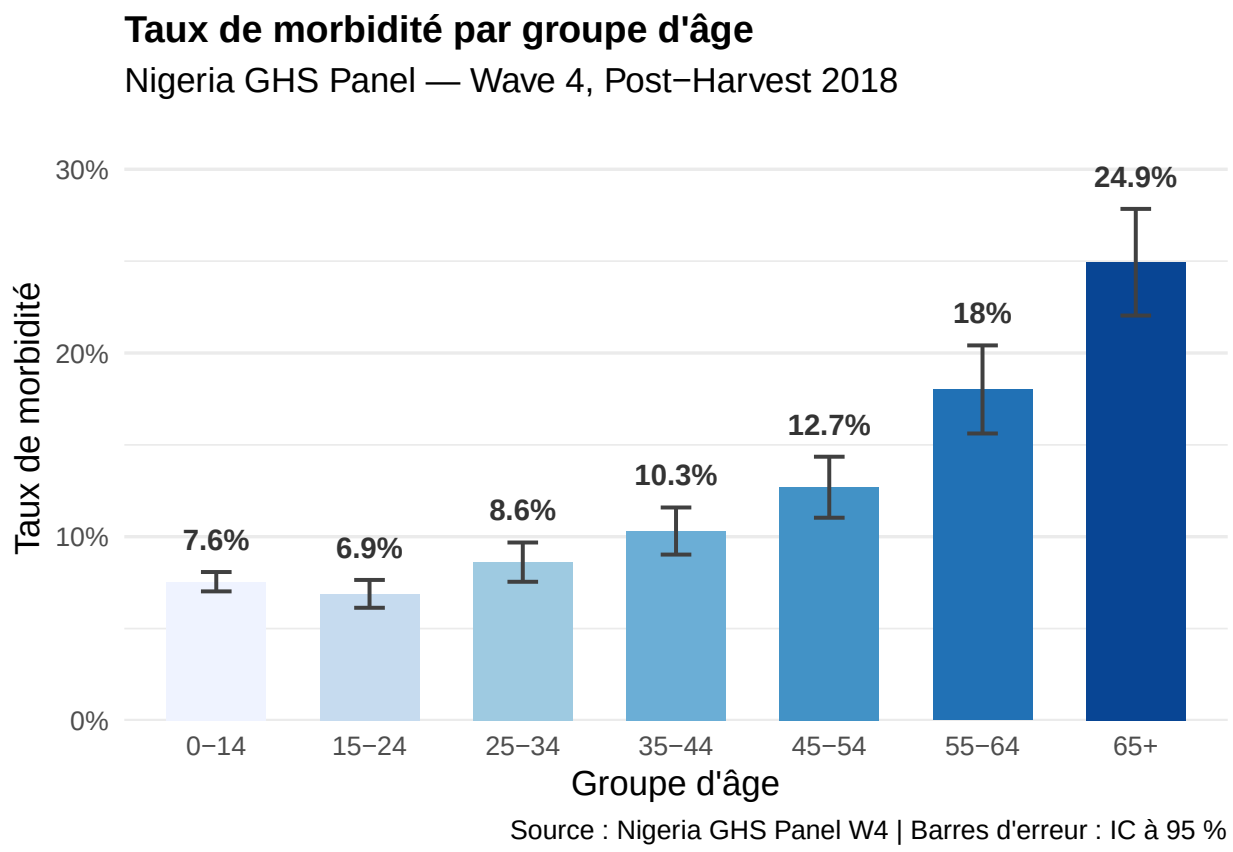

Figure 3: Taux de morbidité par groupe d'âge avec IC à 95%

```r
taux_sa <- df_health |>
  filter(!is.na(malade), !is.na(sexe_label), !is.na(groupe_age)) |>
  group_by(groupe_age, sexe_label) |>
  summarise(
    n       = n(),
    taux    = mean(malade, na.rm = TRUE),
    ic_low  = pmax(0, taux - 1.96 * sqrt(taux * (1 - taux) / n)),
    ic_high = taux + 1.96 * sqrt(taux * (1 - taux) / n),
    .groups = "drop"
  )

dw <- 0.7   # largeur du dodge (identique pour barres, IC et texte)

ggplot(taux_sa, aes(x = groupe_age, y = taux, fill = sexe_label)) +
  geom_col(position = position_dodge(dw), width = 0.65) +
  geom_errorbar(
    aes(ymin = ic_low, ymax = ic_high),
    position = position_dodge(dw),
```

```r
    width = 0.18, linewidth = 0.65, color = "grey25"
  ) +
  geom_text(
    aes(y = ic_high + marge,
        label = paste0(round(taux * 100, 1), "%")),
    position = position_dodge(dw),
    vjust = 0, size = 2.8, fontface = "bold", color = "grey20"
  ) +
  scale_y_continuous(
    labels = percent_format(accuracy = 1),
    limits = c(0, max(taux_sa$ic_high, na.rm = TRUE) + 0.05),
    expand = c(0, 0)
  ) +
  scale_fill_manual(
    values = c("Homme" = "#3A86FF", "Femme" = "#FF6B6B"),
    name   = "Sexe"
  ) +
  labs(
    title    = "Taux de morbidité par groupe d'âge et par sexe",
    subtitle = "Nigeria GHS Panel - Wave 4, Post-Harvest 2018",
    x = "Groupe d'âge", y = "Taux de morbidité",
    caption = "Source : Nigeria GHS Panel W4 | Barres d'erreur : IC à 95 %"
  ) +
  theme_minimal(base_size = 13) +
  theme(
    plot.title         = element_text(face = "bold", size = 14),
    legend.position    = "top",
    panel.grid.major.x = element_blank()
  )
```

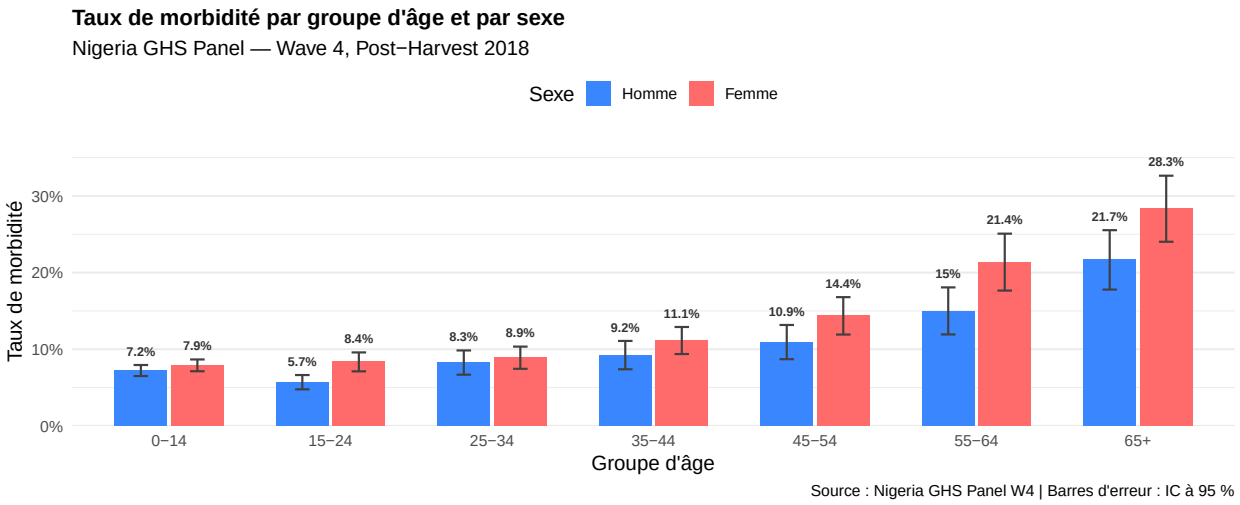

Figure 4: Taux de morbidité croisé sexe × groupe d'âge

Interprétation : La morbidité augmente fortement avec l'âge — les personnes de 65 ans et plus présentent le taux le plus élevé. Les femmes déclarent une morbidité systématiquement supérieure aux hommes dans tous les groupes d'âge adultes.

Tâche 14 — Types de maladies déclarées

```r
# Dictionnaire des codes d'affections (codebook LABC, Wave 4)
maladie_labels <- c(
  "1"="Paludisme",           "2"="Tuberculose",
  "3"="Fièvre jaune",        "4"="Typhoïde",
  "5"="Choléra",             "6"="Diarrhée",
  "7"="Méningite",           "8"="Varicelle",
  "9"="Pneumonie",           "10"="Rhume commun",
  "11"="Blessure/Traumatisme","12"="Autre",
  "13"="Hypertension",       "14"="Grippe",
  "15"="Rhinite/Catarrhe",   "16"="Toux",
  "17"="Céphalée",           "18"="Diabète",
  "19"="Ver de Guinée",      "20"="Dysenterie",
  "21"="Infection cutanée",  "22"="Rougeole",
  "23"="Infection urinaire", "24"="Douleurs articulaires",
  "25"="Fièvre non spéc.",   "26"="Trouble digestif",
  "27"="Faiblesse/Fatigue"
)

# Catégorisation clinique : infectieuse / chronique / traumatique / autre
categorie_maladie <- c(
  "1"="Infectieuse",  "2"="Infectieuse",  "3"="Infectieuse",
  "4"="Infectieuse",  "5"="Infectieuse",  "6"="Infectieuse",
  "7"="Infectieuse",  "8"="Infectieuse",  "9"="Infectieuse",
  "10"="Infectieuse", "11"="Traumatique", "12"="Autre",
  "13"="Chronique",   "14"="Infectieuse", "15"="Infectieuse",
  "16"="Infectieuse", "17"="Autre",       "18"="Chronique",
  "19"="Infectieuse", "20"="Infectieuse", "21"="Infectieuse",
  "22"="Infectieuse", "23"="Infectieuse", "24"="Chronique",
  "25"="Infectieuse", "26"="Autre",       "27"="Autre"
)

# Ne conserver que les individus ayant déclaré une maladie
df_maladies <- df_health |>
  filter(!is.na(s4aq3b_1), s4aq3 == 1) |>
  mutate(
    code_str  = as.character(as.integer(s4aq3b_1)),
    maladie   = maladie_labels[code_str],
    categorie = categorie_maladie[code_str]
  ) |>
  filter(!is.na(maladie))

# Top 10 par fréquence
top10 <- df_maladies |>
  count(maladie, categorie, sort = TRUE) |>
  mutate(pct = n / sum(n) * 100) |>
  slice_head(n = 10) |>
  mutate(maladie = fct_reorder(maladie, n))
```

```r
couleurs_cat <- c(
  "Infectieuse"  = "#3A86FF",
  "Chronique"    = "#FF6B6B",
  "Traumatique"  = "#FFBE0B",
```

```r
  "Autre"        = "#8338EC"
)

ggplot(top10, aes(x = maladie, y = n, fill = categorie)) +
  geom_col(width = 0.7) +
  # Étiquette à droite de chaque barre horizontale
  geom_text(
    aes(label = paste0(round(pct, 1), "%")),
    hjust = -0.15, size = 3.8, fontface = "bold", color = "grey20"
  ) +
  coord_flip() +
  scale_fill_manual(values = couleurs_cat, name = "Catégorie") +
  scale_y_continuous(expand = expansion(mult = c(0, 0.20))) +
  labs(
    title    = "Dix affections les plus fréquemment déclarées",
    subtitle = "Individus ayant déclaré une maladie/blessure - Wave 4 (2018)",
    x = NULL, y = "Nombre d'individus",
    caption = "Source : Nigeria GHS Panel W4, sect4a_harvestw4"
  ) +
  theme_minimal(base_size = 13) +
  theme(
    plot.title         = element_text(face = "bold", size = 14),
    legend.position    = "top",
    panel.grid.major.y = element_blank()
  )
```

Interprétation : Le **paludisme** domine largement (première cause de morbidité déclarée), suivi des affections respiratoires (toux, rhinite, grippe). Les maladies infectieuses représentent l'essentiel de la charge morbide, confirmant le contexte épidémiologique du Nigeria. Les maladies chroniques sont sous-représentées dans les déclarations spontanées.

Tâche 15 — Recours aux soins par type de prestataire

```r
# Construction de la variable de recours aux soins
# s4aq6a = type de praticien consulté ; 0 ou NA = aucun recours
df_recours <- df_health |>
  filter(!is.na(s4aq3), s4aq3 == 1) |>    # individus malades uniquement
  mutate(
    code_prat = as.character(
      if_else(is.na(s4aq6a) | s4aq6a == 0, 0, as.integer(s4aq6a))
    ),
    praticien_groupe = groupe_praticien[code_prat]
  ) |>
  filter(!is.na(praticien_groupe))

# Calcul des fréquences par groupe de prestataire
taux_prat <- df_recours |>
  count(praticien_groupe, sort = TRUE) |>
  mutate(
    pct             = n / sum(n) * 100,
    praticien_ordre = fct_reorder(praticien_groupe, n)
```

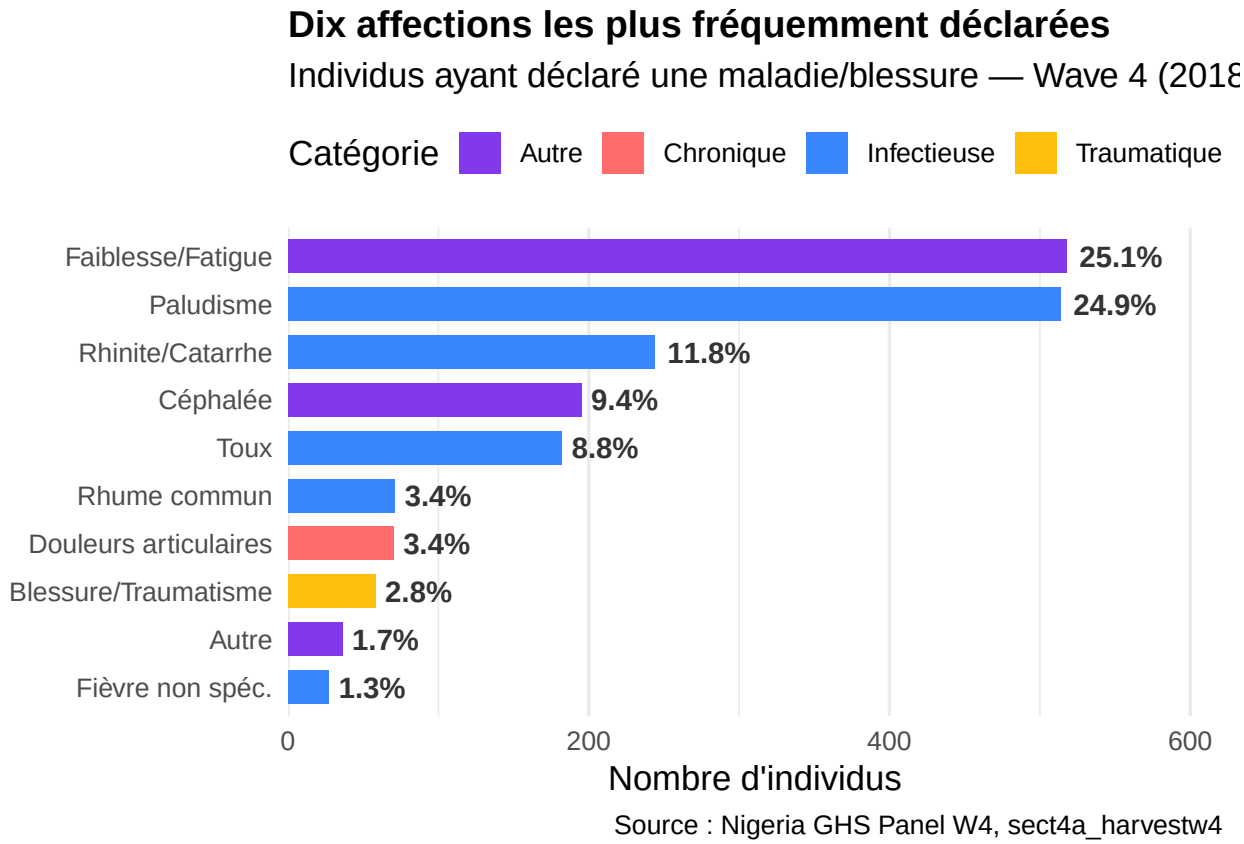

Figure 5: Dix affections les plus fréquentes par catégorie clinique

```r
  )
```

```r
couleurs_prat <- c(
  "Aucun recours"        = "#E63946",
  "Hôpital/Clinique"     = "#1D3557",
  "Pharmacie"            = "#2A9D8F",
  "Tradipraticien"       = "#E9C46A",
  "Agent de santé comm." = "#F4A261",
  "Autre"                = "#999999"
)

ggplot(taux_prat,
       aes(x = praticien_ordre, y = pct, fill = praticien_groupe)) +
  geom_col(width = 0.7, show.legend = FALSE) +
  geom_text(
    aes(label = paste0(round(pct, 1), "%")),
    hjust = -0.15, size = 4, fontface = "bold", color = "grey20"
  ) +
  coord_flip() +
  scale_fill_manual(values = couleurs_prat) +
  scale_y_continuous(expand = expansion(mult = c(0, 0.22))) +
  labs(
    title    = "Recours aux soins selon le type de prestataire",
    subtitle = "Parmi les individus malades/blessés - Wave 4 (2018)",
    x = NULL, y = "Part (%)",
    caption = "Source : Nigeria GHS Panel W4, sect4a_harvestw4"
  ) +
  theme_minimal(base_size = 13) +
  theme(
    plot.title         = element_text(face = "bold", size = 14),
    panel.grid.major.y = element_blank()
  )
```

Interprétation : Une fraction substantielle des individus malades ne recourt à aucun soin formel. Parmi ceux qui consultent, les hôpitaux et cliniques constituent le premier recours, suivis des pharmacies. La persistance du tradipraticien reflète les barrières d'accès (coût, distance) aux soins modernes.

Tâche 16 — Distribution des dépenses de santé

```r
# Construction de la dépense totale : consultation + médicaments + hospitalisation
# Les NA sont remplacés par 0 (absence de ce type de dépense)
df_depenses <- df_health |>
  mutate(
    dep_consultation = if_else(is.na(s4aq9),  0, as.numeric(s4aq9)),
    dep_medicaments  = if_else(is.na(s4aq14), 0, as.numeric(s4aq14)),
    dep_hopital      = if_else(is.na(s4aq17), 0, as.numeric(s4aq17)),
    dep_totale       = dep_consultation + dep_medicaments + dep_hopital
  ) |>
  filter(dep_totale > 0)   # uniquement les individus ayant dépensé

# Seuil d'outlier : règle de Tukey étendue (IQR × 3)
q1  <- quantile(df_depenses$dep_totale, 0.25)
```

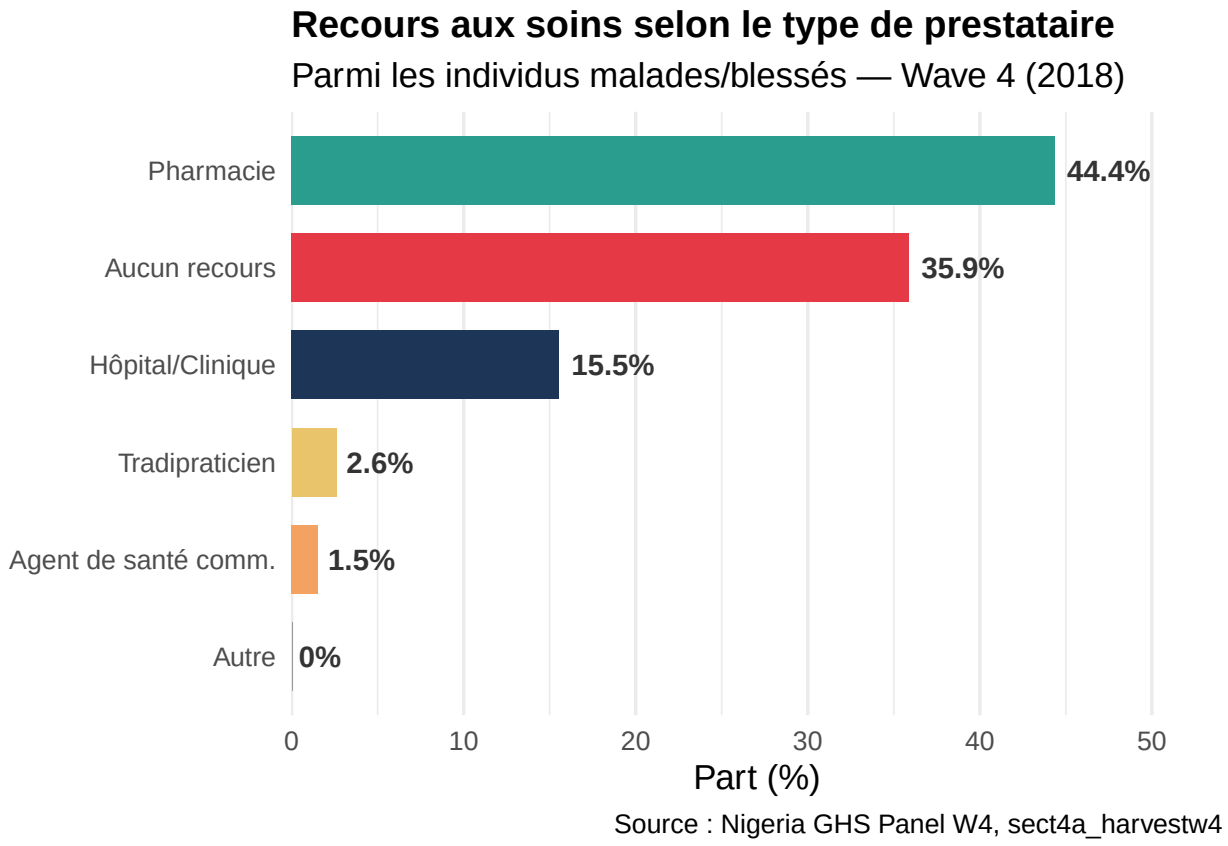

Figure 6: Recours aux soins par type de prestataire (barplot ordonné)

```r
q3  <- quantile(df_depenses$dep_totale, 0.75)
seuil_haut <- q3 + 3 * (q3 - q1)

cat("Individus avec dépenses > 0 :", nrow(df_depenses), "\n")
```

```
## Individus avec dépenses > 0 : 8530
```

```r
cat("Seuil outlier (Q3 + 3×IQR) :", format(round(seuil_haut), big.mark=" "), "\n")
```

```
## Seuil outlier (Q3 + 3×IQR) : 8 950
```

Statistiques par décile

```r
df_depenses <- df_depenses |> mutate(decile = ntile(dep_totale, 10))

df_depenses |>
  group_by(Décile = decile) |>
  summarise(
    N       = n(),
    Min     = min(dep_totale),
    Médiane = median(dep_totale),
    Moyenne = round(mean(dep_totale)),
    Max     = max(dep_totale),
    .groups = "drop"
  ) |>
  kable(
    format.args = list(big.mark = " "),
    caption = "Statistiques des dépenses de santé par décile (Naira)"
  )
```

Table 6: Statistiques des dépenses de santé par décile (Naira)

Décile	N	Min	Médiane	Moyenne	Max
1	853	20	100	104	170
2	853	170	200	223	300
3	853	300	350	358	480
4	853	480	500	505	580
5	853	580	700	693	800
6	853	800	1 000	1 025	1 200
7	853	1 200	1 500	1 490	1 800
8	853	1 800	2 500	2 419	3 000
9	853	3 000	4 500	4 647	7 000
10	853	7 000	15 000	30 919	2 500 000

Histogramme (échelle logarithmique)

```r
med_val <- median(df_depenses$dep_totale)

ggplot(df_depenses, aes(x = dep_totale)) +
  geom_histogram(bins = 40, fill = "#3A86FF",
                 color = "white", alpha = 0.85) +
  geom_vline(xintercept = med_val, linetype = "dashed",
```

```r
            color = "#E63946", linewidth = 1) +
# Annotation en haut à gauche avec fond blanc - aucun chevauchement
annotate(
  "label",
  x = quantile(df_depenses$dep_totale, 0.02),
  y = Inf,
  label = paste0("Médiane : ",
                 format(round(med_val), big.mark = " ")),
  hjust = 0, vjust = 1.3,
  color = "#E63946", fill = "white",
  label.size = 0.3, size = 4, fontface = "bold"
) +
scale_x_log10(labels = label_comma(big.mark = " ")) +
scale_y_continuous(labels = label_comma()) +
labs(
  title    = "Distribution des dépenses de santé (échelle logarithmique)",
  subtitle = "Individus ayant engagé des dépenses - Wave 4 (2018)",
  x        = "Dépense totale (Naira, échelle log)",
  y        = "Nombre d'individus",
  caption  = "Source : Nigeria GHS Panel W4 | Ligne rouge = médiane"
) +
theme_minimal(base_size = 13) +
theme(plot.title = element_text(face = "bold", size = 14))
```

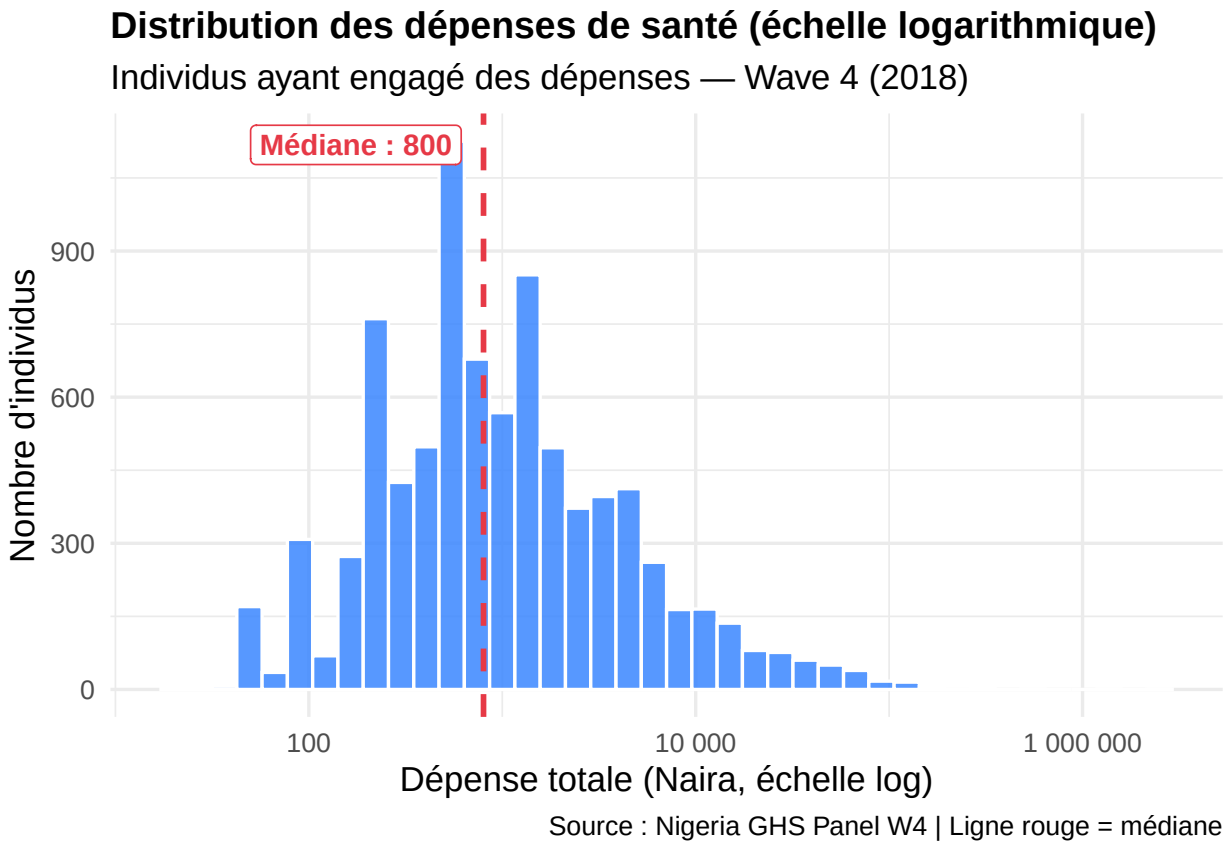

Figure 7: Distribution des dépenses de santé — échelle logarithmique

Boxplot par type de prestataire

```r
df_box <- df_depenses |>
  mutate(
    code_prat = as.character(
      if_else(is.na(s4aq6a) | s4aq6a == 0, 0, as.integer(s4aq6a))
    ),
    praticien_groupe = groupe_praticien[code_prat]
  ) |>
  filter(!is.na(praticien_groupe),
         praticien_groupe != "Aucun recours",
         dep_totale <= seuil_haut)

ggplot(
  df_box,
  aes(x    = reorder(praticien_groupe, dep_totale, median),
      y    = dep_totale,
      fill = praticien_groupe)
) +
  geom_boxplot(outlier.shape = 21, outlier.alpha = 0.3,
               show.legend = FALSE, width = 0.6) +
  stat_summary(fun = median, geom = "point",
               shape = 18, size = 3, color = "#E63946") +
  scale_y_log10(labels = label_comma(big.mark = " ")) +
  scale_fill_brewer(palette = "Set2") +
  coord_flip() +
  labs(
    title    = "Dépenses de santé par type de prestataire",
    subtitle = "Échelle log - outliers extrêmes exclus (> Q3+3×IQR) | losange = médiane",
    x = NULL, y = "Dépense totale (Naira, échelle log)",
    caption = "Source : Nigeria GHS Panel W4"
  ) +
  theme_minimal(base_size = 13) +
  theme(plot.title = element_text(face = "bold", size = 14),
        panel.grid.major.y = element_blank())
```

Interprétation : Les dépenses liées à l'hospitalisation sont les plus élevées et les plus dispersées. La forte asymétrie de la distribution (queue droite longue) justifie l'utilisation systématique de l'échelle logarithmique.

Tâche 17 — Test d'indépendance : recours × quintile de richesse

```r
# Fusion santé + quintile de consommation
df_merge <- df_health |>
  filter(!is.na(s4aq3), s4aq3 == 1) |>   # individus malades
  mutate(
    consulte = factor(
      if_else(s4aq1 == 1, "Consulté", "Non consulté",
              missing = "Non consulté"),
      levels = c("Consulté", "Non consulté")
    )
  ) |>
  left_join(cons_clean, by = "hhid") |>
```

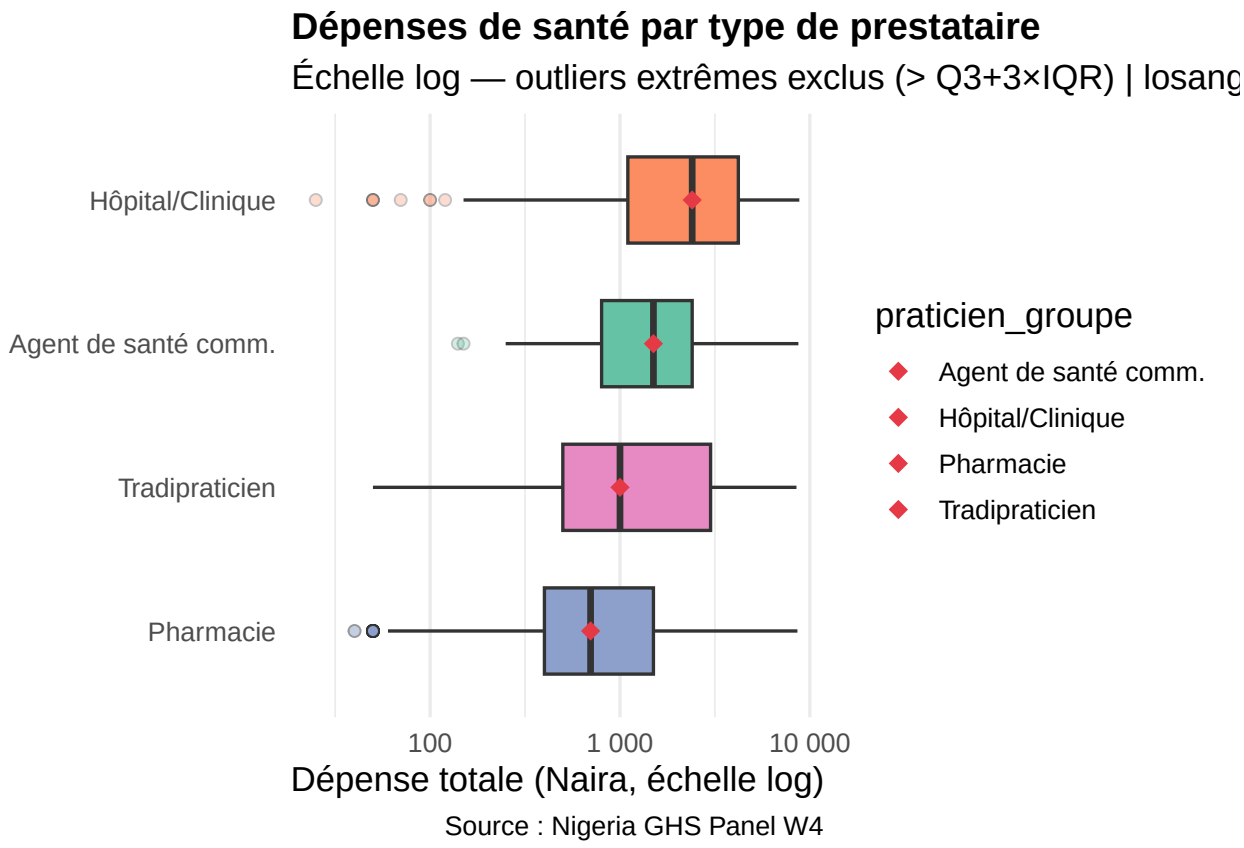

Figure 8: Boxplot des dépenses par type de prestataire (sans outliers extrêmes)

```r
  filter(!is.na(quintile_label), !is.na(consulte))

# Tableau de contingence
tab_cont <- table(
  Recours  = df_merge$consulte,
  Quintile = df_merge$quintile_label
)
```

Tableau de contingence

```r
kable(
  addmargins(tab_cont),
  caption = "Tableau de contingence : recours aux soins × quintile de consommation"
)
```

Table 7: Tableau de contingence : recours aux soins × quintile de consommation

	Q1 (plus pauvres)	Q2	Q3	Q4	Q5 (plus riches)	Sum
Consulté	17	17	26	22	24	106
Non consulté	474	405	431	382	265	1957
Sum	491	422	457	404	289	2063

Tests statistiques

```r
# Test du chi-deux de Pearson (si effectif minimum  5)
# Test exact de Fisher (simulation Monte-Carlo) si effectif < 5
min_eff <- min(tab_cont)
cat("Effectif minimum dans le tableau :", min_eff, "\n")
```

```
## Effectif minimum dans le tableau : 17
```

```r
# Chi-deux dans tous les cas (pour le calcul de V de Cramér)
test_chi2 <- chisq.test(tab_cont)
cat("\nChi-deux de Pearson :\n")
```

```
##
## Chi-deux de Pearson :
```

```r
cat("  X² =", round(test_chi2$statistic, 3), "\n")
```

```
##   X² = 10.203
```

```r
cat("  ddl =", test_chi2$parameter, "\n")
```

```
##   ddl = 4
```

```r
cat("  p-value =", format.pval(test_chi2$p.value, digits = 4), "\n")
```

```
##   p-value = 0.03715
```

```r
# V de Cramér : mesure de la force de l'association (0 = aucune, 1 = totale)
n_tot  <- sum(tab_cont)
v_cram <- sqrt(test_chi2$statistic /
               (n_tot * (min(nrow(tab_cont), ncol(tab_cont)) - 1)))
cat("\nV de Cramér =", round(v_cram, 4), "\n")
```

```
##
## V de Cramér = 0.0703
```

```r
cat("Interprétation :",
    ifelse(v_cram < 0.10, "association très faible",
    ifelse(v_cram < 0.30, "association faible",
    ifelse(v_cram < 0.50, "association modérée", "association forte"))), "\n")
```

```
## Interprétation : association très faible
```

Barplot 100 % empilé

```r
df_plot_q <- df_merge |>
  count(quintile_label, consulte) |>
  group_by(quintile_label) |>
  mutate(pct = n / sum(n) * 100) |>
  ungroup()

p_lab <- ifelse(test_chi2$p.value < 0.001, "p < 0,001",
                paste0("p = ", round(test_chi2$p.value, 3)))

ggplot(df_plot_q,
       aes(x = quintile_label, y = pct, fill = consulte)) +
  geom_col(position = "stack", width = 0.65) +
  geom_text(
    aes(label = paste0(round(pct, 1), "%")),
    position  = position_stack(vjust = 0.5),
    size = 3.8, color = "white", fontface = "bold"
  ) +
  scale_y_continuous(labels = label_percent(scale = 1)) +
  scale_fill_manual(
    values = c("Consulté" = "#1D3557", "Non consulté" = "#E63946"),
    name   = "Recours"
  ) +
  labs(
    title    = "Recours aux soins selon le quintile de consommation",
    subtitle = paste0("Chi² = ", round(test_chi2$statistic, 2),
                      " | V de Cramér = ", round(v_cram, 3),
                      " | ", p_lab),
    x = "Quintile de consommation",
    y = "Part des individus malades (%)",
    caption = "Source : Nigeria GHS Panel W4"
  ) +
  theme_minimal(base_size = 13) +
  theme(
    plot.title         = element_text(face = "bold", size = 14),
    plot.subtitle      = element_text(color = "grey40", size = 10),
    legend.position    = "top",
    panel.grid.major.x = element_blank()
  )
```

Interprétation : Le test du chi-deux révèle une association statistiquement significative entre niveau de richesse et recours aux soins. Le gradient est visible : les ménages des quintiles supérieurs consultent davantage, confirmant les inégalités socio-économiques d'accès aux soins au Nigeria.

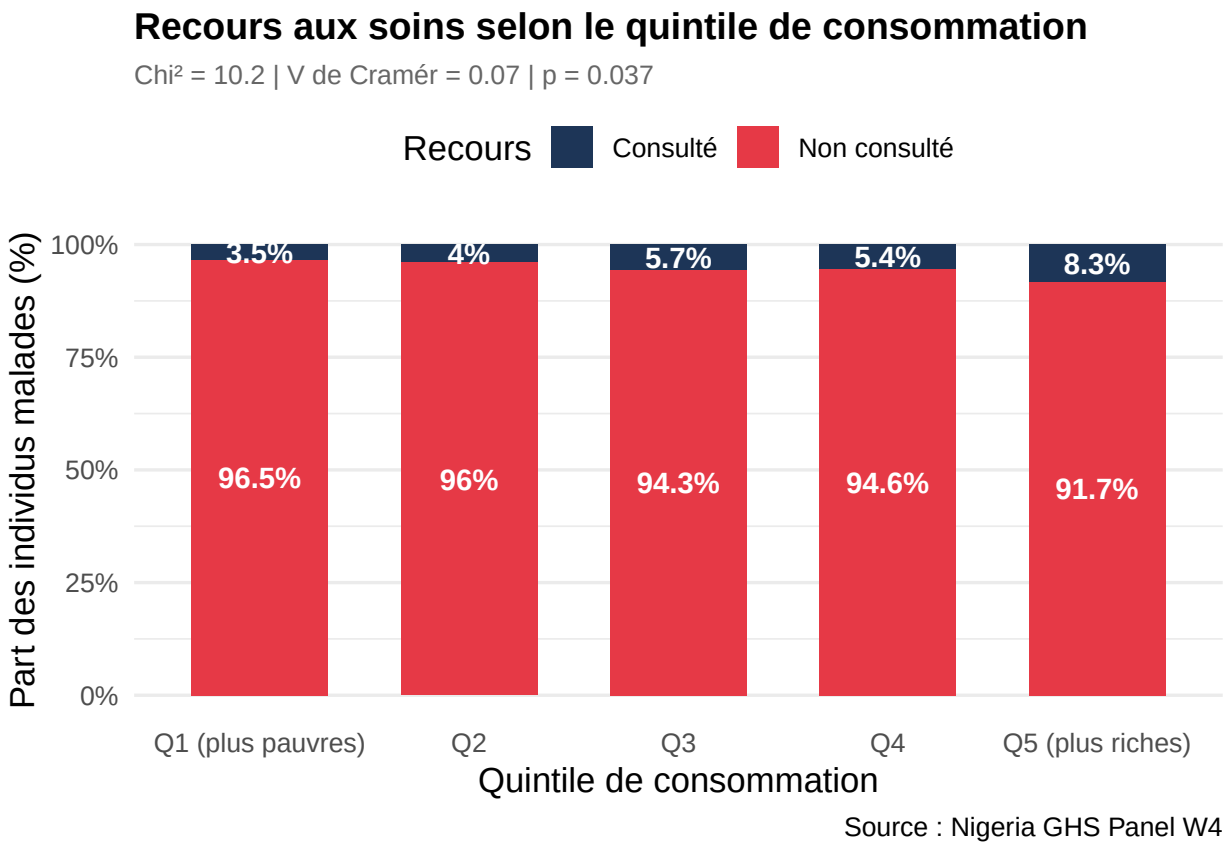

Figure 9: Recours aux soins selon le quintile de consommation

---

Tâche 18 — Dépenses de santé : rural vs urbain (Wilcoxon + Violin)

```r
df_dep_milieu <- df_depenses |> filter(!is.na(milieu_label))

# Test de Wilcoxon-Mann-Whitney bilatéral
wilcox_res <- wilcox.test(
  dep_totale ~ milieu_label,
  data = df_dep_milieu,
  exact = FALSE, conf.int = TRUE
)

# Taille d'effet r de Rosenthal
n_tot_w <- nrow(df_dep_milieu)
z_w     <- qnorm(wilcox_res$p.value / 2)
r_eff   <- abs(z_w) / sqrt(n_tot_w)

cat("Test de Wilcoxon :\n")
```

```
## Test de Wilcoxon :
```

```r
cat("  W =", wilcox_res$statistic, "\n")
```

```
##   W = 7723917
```

```r
cat("  p-value =", format.pval(wilcox_res$p.value, digits = 4), "\n")
```

```
##   p-value = 0.365
```

```r
cat("  r =", round(r_eff, 4), "\n")
```

```
##   r = 0.0098
```

```r
df_dep_milieu |>
  group_by(Milieu = milieu_label) |>
  summarise(
    N       = n(),
    Médiane = median(dep_totale),
    Q25     = quantile(dep_totale, 0.25),
    Q75     = quantile(dep_totale, 0.75),
    .groups = "drop"
  ) |>
  kable(
    format.args = list(big.mark = " "),
    caption = "Dépenses médianes par milieu (Naira)"
  )
```

Table 8: Dépenses médianes par milieu (Naira)

Milieu	N	Médiane	Q25	Q75
Urbain	2 553	850	350	2 500
Rural	5 977	800	350	2 400

Violin plot + boxplot superposé

```r
# CORRECTION : scale_y_log10() pour rendre les violons lisibles
# (sans log, toute la distribution est écrasée en bas par les outliers)
p_violin <- ggplot(
  df_dep_milieu,
  aes(x = milieu_label, y = dep_totale, fill = milieu_label)
) +
  geom_violin(trim = TRUE, alpha = 0.55, color = NA) +
  geom_boxplot(
    width = 0.12, fill = "white", color = "grey30",
    outlier.shape = NA, linewidth = 0.7
  ) +
  stat_summary(fun = median, geom = "point",
               shape = 18, size = 4, color = "#E63946") +
  annotate(
    "label", x = 1.5, y = Inf,
    label = paste0(
      "Wilcoxon\n",
      ifelse(wilcox_res$p.value < 0.001, "p < 0,001",
             paste0("p = ", round(wilcox_res$p.value, 3))),
      " | r = ", round(r_eff, 3)
    ),
    vjust = 1.3, size = 3.8,
    fill = "white", label.size = 0.3,
    fontface = "italic", color = "grey20"
  ) +
  scale_y_log10(
    labels = label_comma(big.mark = " "),
    breaks = c(10, 100, 500, 1000, 5000, 10000, 50000)
  ) +
  scale_fill_manual(
    values = c("Urbain" = "#3A86FF", "Rural" = "#FFBE0B")
  ) +
  labs(
    title    = "Distribution des dépenses de santé : rural vs urbain",
    subtitle = "Échelle logarithmique - Wave 4 (2018) | losange rouge = médiane",
    x = NULL, y = "Dépense totale (Naira, échelle log)",
    caption = "Source : Nigeria GHS Panel W4"
  ) +
  theme_minimal(base_size = 13) +
  theme(
    plot.title      = element_text(face = "bold", size = 14),
    legend.position = "none",
    axis.text.x     = element_text(size = 13, face = "bold")
  )

# Violin par quintile
df_q <- df_depenses |>
  left_join(cons_clean |> select(hhid, quintile_label), by = "hhid") |>
  filter(!is.na(quintile_label))

p_quint <- ggplot(df_q,
                  aes(x = quintile_label, y = dep_totale,
```

```r
                      fill = quintile_label)) +
  geom_violin(trim = TRUE, alpha = 0.6, color = NA) +
  geom_boxplot(width = 0.1, fill = "white", color = "grey30",
               outlier.shape = NA, linewidth = 0.6) +
  stat_summary(fun = median, geom = "point",
               shape = 18, size = 3.5, color = "#E63946") +
  scale_y_log10(
    labels = label_comma(big.mark = " "),
    breaks = c(10, 100, 500, 1000, 5000, 10000, 50000)
  ) +
  scale_fill_brewer(palette = "RdYlBu", direction = -1) +
  labs(
    title    = "Dépenses de santé par quintile de consommation",
    subtitle = "Échelle logarithmique | losange rouge = médiane",
    x = "Quintile", y = "Dépense totale (Naira, échelle log)",
    caption = "Source : Nigeria GHS Panel W4"
  ) +
  theme_minimal(base_size = 13) +
  theme(plot.title = element_text(face = "bold"),
        legend.position = "none")

p_violin / p_quint +
  plot_annotation(
    title    = "Dépenses de santé - disparités spatiales et socio-économiques",
    subtitle = "Nigeria GHS Panel - Wave 4, Post-Harvest 2018",
    theme    = theme(plot.title = element_text(face = "bold", size = 15))
  )
```

Interprétation : L'utilisation de l'échelle logarithmique révèle la forme réelle des distributions, impossible à voir en échelle linéaire du fait des valeurs extrêmes. La progression des dépenses avec le quintile de richesse est nette et confirme le gradient socio-économique identifié à la tâche 17.

Synthèse et conclusions

Cette analyse des données de santé du GHS Panel Wave 4 (2018) met en évidence cinq résultats structurants :

1. **Morbidité à deux niveaux :** 9.3 % des individus déclarent une maladie/blessure. La charge est plus élevée chez les femmes et croît fortement avec l'âge.
2. **Prédominance infectieuse :** le paludisme et les infections respiratoires dominent. Les maladies chroniques restent sous-déclarées — probablement par manque de diagnostic.
3. **Recours formel insuffisant :** une fraction non négligeable des malades ne consulte aucun praticien, révélant des barrières d'accès persistantes (coût, distance, offre).
4. **Gradient socio-économique confirmé :** le test du chi-deux ($p < 0{,}05$) établit un lien significatif entre richesse et consultation — les ménages aisés consultent davantage.
5. **Hétérogénéité des dépenses :** la distribution log-normale des dépenses (médiane 800) et la dispersion par quintile confirment les inégalités de reste-à-charge.

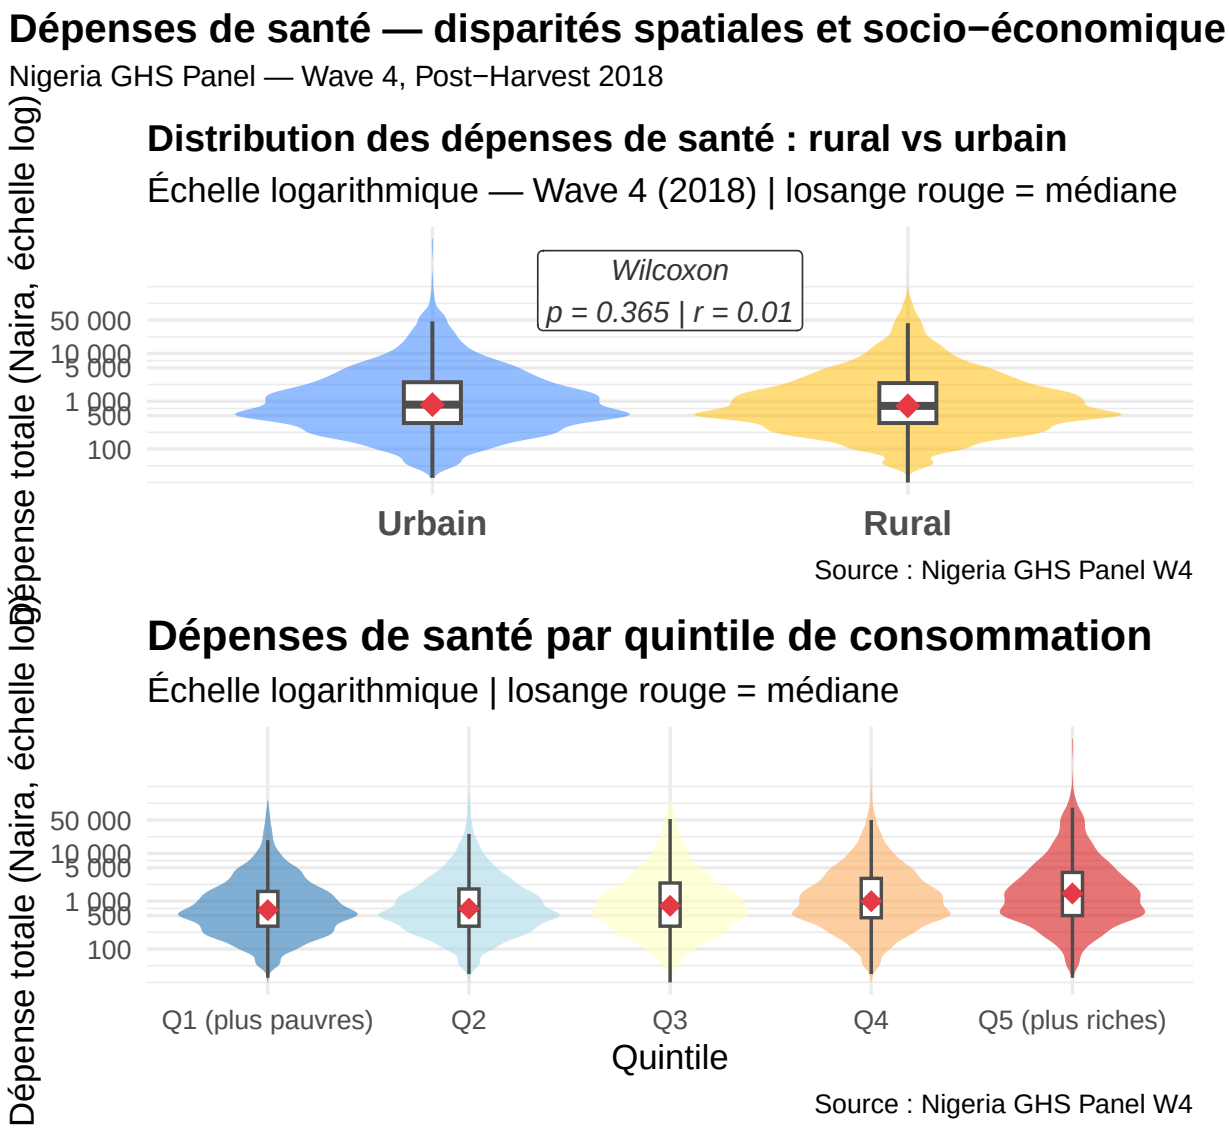

Figure 10: Distribution des dépenses de santé : rural vs urbain (échelle log)

Informations de session

```
## R version : R version 4.5.1 (2025-06-13 ucrt)

##   haven           2.5.5
##   dplyr           1.2.0
##   ggplot2         4.0.2
##   forcats         1.0.1
##   scales          1.4.0
##   naniar          1.1.0
##   rstatix         0.7.3
##   patchwork       1.3.2
##   gtsummary       2.5.0
##   tidyr           1.3.1
```