Analyse des données de morbidité et recours aux soins

DIALLO Mamadou Moussa - DIOP Papa Boubacar

2026-03-17

Contents

1 Importation des données **1**

2 Taux de morbidité global **2**

3 Préparation des données pour l'analyse **2**

4 Analyse par sexe **2**
4.1 Taux de morbidité par sexe avec intervalle de confiance 2
4.2 Visualisation 3

5 Analyse par groupe d'âge **4**
5.1 Taux de morbidité par groupe d'âge 4
5.2 Visualisation 5

6 Distribution des types de maladies **6**
6.1 Visualisation des principales maladies 6

7 Analyse des dépenses de santé **7**
7.1 Statistiques par décile des dépenses 8

8 Tests d'indépendance **9**
8.1 Importation et préparation des données de consommation 9

```r
library(haven)
library(dplyr)
library(ggplot2)
library(naniar)
library(rstatix)
library(scales)
library(gtsummary)
library(patchwork)
library(gt)
library(knitr)
```

1 Importation des données

```r
# Chargement des données de morbidité
data <- read_stata("../data/raw/sect4a_harvestw4.dta")

# Chargement et préparation des données sociodémographiques
```

```r
data_to_join <- read_stata("../data/raw/sect1_harvestw4.dta")
data_to_join <- data_to_join %>% select(hhid, indiv, s1q2, s1q4)

# Jointure
data <- inner_join(data, data_to_join, by = c("hhid", "indiv"))
```

2 Taux de morbidité global

```r
taux_global <- data %>%
  summarise(
    taux_de_morbidite = mean(s4aq3 == 1, na.rm = TRUE),
    .groups = "drop"
  )

taux_global %>%
  mutate(taux_de_morbidite = percent(taux_de_morbidite, accuracy = 0.1)) %>%
  kable(col.names = "Taux de morbidité global", caption = "Taux de morbidité dans la population")
```

Table 1: Taux de morbidité dans la population

Taux de morbidité global
9.3%

Le taux de morbidité affiché est de 9,3%, c'est-à-dire 9,3% des individus de la population ont déclarés être malade ou blessé.

3 Préparation des données pour l'analyse

```r
data_morb <- data %>%
  mutate(
    malade = ifelse(s4aq3 == 1, 1, 0),
    sexe = as_factor(s1q2),
    age = s1q4,
    groupe_age = cut(
      age,
      breaks = c(0, 5, 15, 25, 45, 65, Inf),
      right = FALSE,
      labels = c("0-4 ans", "5-14 ans", "15-24 ans", "25-44 ans", "45-64 ans", "65 ans et plus")
    )
  ) %>%
  filter(!is.na(malade), !is.na(sexe), !is.na(groupe_age))
```

4 Analyse par sexe

4.1 Taux de morbidité par sexe avec intervalle de confiance

```r
tab_sexe <- data_morb %>%
  group_by(sexe) %>%
  summarise(
```

```r
    effectif = n(),
    cas = sum(malade, na.rm = TRUE),
    proportion = cas / effectif,
    IC_low = prop.test(cas, effectif)$conf.int[1],
    IC_up = prop.test(cas, effectif)$conf.int[2],
    .groups = "drop"
  ) %>%
  mutate(
    proportion_pct = percent(proportion, accuracy = 0.1),
    IC = paste0("[", percent(IC_low, accuracy = 0.1), " ; ", percent(IC_up, accuracy = 0.1), "]")
  )

# Affichage du tableau
tab_sexe %>%
  select(sexe, effectif, cas, proportion_pct, IC) %>%
  kable(
    col.names = c("Sexe", "Effectif", "Cas", "Proportion", "IC à 95%"),
    caption = "Taux de morbidité par sexe"
  )
```

Table 2: Taux de morbidité par sexe

Sexe	Effectif	Cas	Proportion	IC à 95%
1. MALE	11134	930	8.4%	[7.8% ; 8.9%]
2. FEMALE	11037	1135	10.3%	[9.7% ; 10.9%]

Le tableau ci-dessus montre que le taux de morbidité est de 8,4% dans la sous-population des individus de sexe masculin tandis qu'il est de 10,3% dans les individus de sexe féminin.

4.2 Visualisation

```r
ggplot(tab_sexe, aes(x = sexe, y = proportion)) +
  geom_col(fill = "steelblue", alpha = 0.8) +
  geom_errorbar(aes(ymin = IC_low, ymax = IC_up), width = 0.2, color = "darkblue") +
  scale_y_continuous(labels = percent_format(accuracy = 1)) +
  labs(
    x = "Sexe",
    y = "Taux de morbidité",
    title = "Taux de morbidité par sexe avec intervalle de confiance à 95%"
  ) +
  theme_minimal() +
  theme(plot.title = element_text(face = "bold", hjust = 0.5))
```

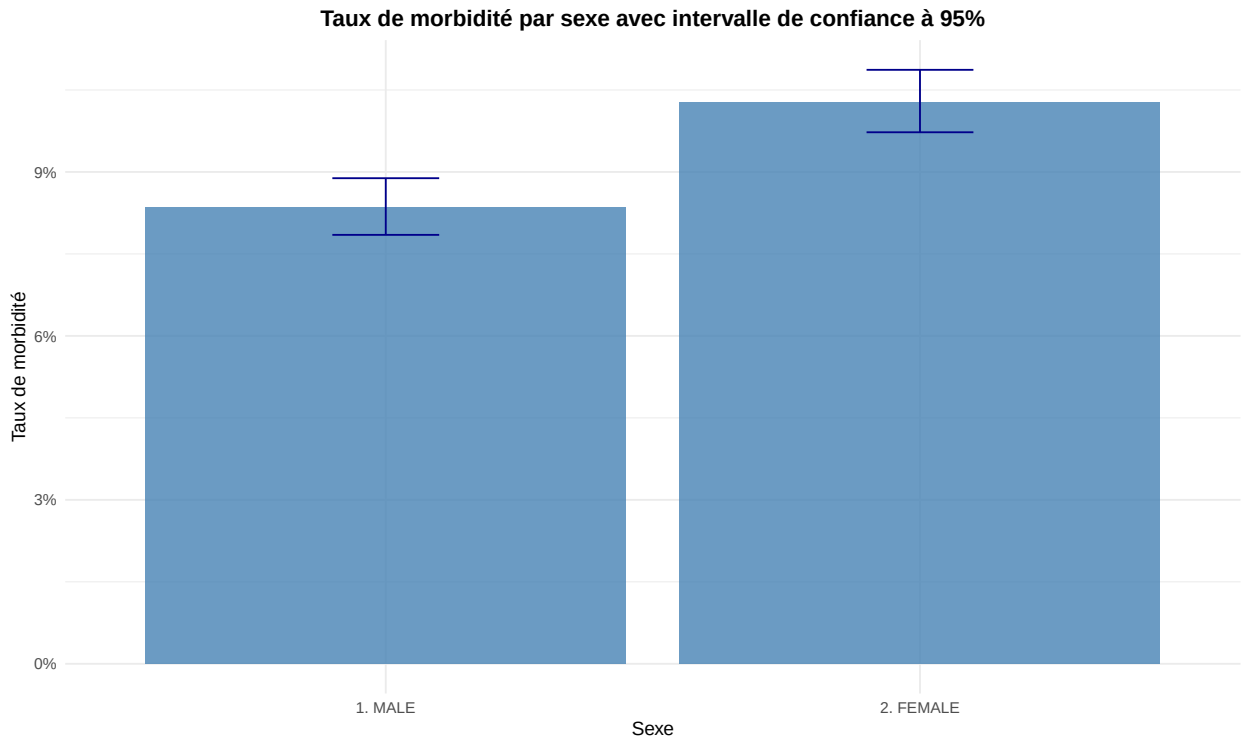

5 Analyse par groupe d'âge

5.1 Taux de morbidité par groupe d'âge

```
tab_age <- data_morb %>%
  group_by(groupe_age) %>%
  summarise(
    effectif = n(),
    cas = sum(malade, na.rm = TRUE),
    proportion = cas / effectif,
    IC_low = prop.test(cas, effectif)$conf.int[1],
    IC_up = prop.test(cas, effectif)$conf.int[2],
    .groups = "drop"
  ) %>%
  mutate(
    proportion_pct = percent(proportion, accuracy = 0.1),
    IC = paste0("[", percent(IC_low, accuracy = 0.1), " ; ", percent(IC_up, accuracy = 0.1), "]")
  )

# Affichage du tableau
tab_age %>%
  select(groupe_age, effectif, cas, proportion_pct, IC) %>%
  kable(
    col.names = c("Groupe d'âge", "Effectif", "Cas", "Proportion", "IC à 95%"),
    caption = "Taux de morbidité par groupe d'âge"
  )
```

Table 3: Taux de morbidité par groupe d'âge

Groupe d'âge	Effectif	Cas	Proportion	IC à 95%
0-4 ans	2561	295	11.5%	[10.3% ; 12.8%]
5-14 ans	7119	436	6.1%	[5.6% ; 6.7%]
15-24 ans	4296	296	6.9%	[6.2% ; 7.7%]
25-44 ans	4809	451	9.4%	[8.6% ; 10.2%]
45-64 ans	2532	374	14.8%	[13.4% ; 16.2%]
65 ans et plus	854	213	24.9%	[22.1% ; 28.0%]

Ce tableau ci-dessus présente le taux de morbidité par tranche d'âge. On constate que ce taux est plus élevé chez les individus de plus de 65 ans. Ce taux est plus faible chez les individus de 5 à 14 ans.

5.2 Visualisation

```r
ggplot(tab_age, aes(x = groupe_age, y = proportion)) +
  geom_col(fill = "darkgreen", alpha = 0.8) +
  geom_errorbar(aes(ymin = IC_low, ymax = IC_up), width = 0.2, color = "darkgreen") +
  scale_y_continuous(labels = percent_format(accuracy = 1)) +
  labs(
    x = "Groupe d'âge",
    y = "Taux de morbidité",
    title = "Taux de morbidité par groupe d'âge avec intervalle de confiance à 95%"
  ) +
  theme_minimal() +
  theme(plot.title = element_text(face = "bold", hjust = 0.5))
```

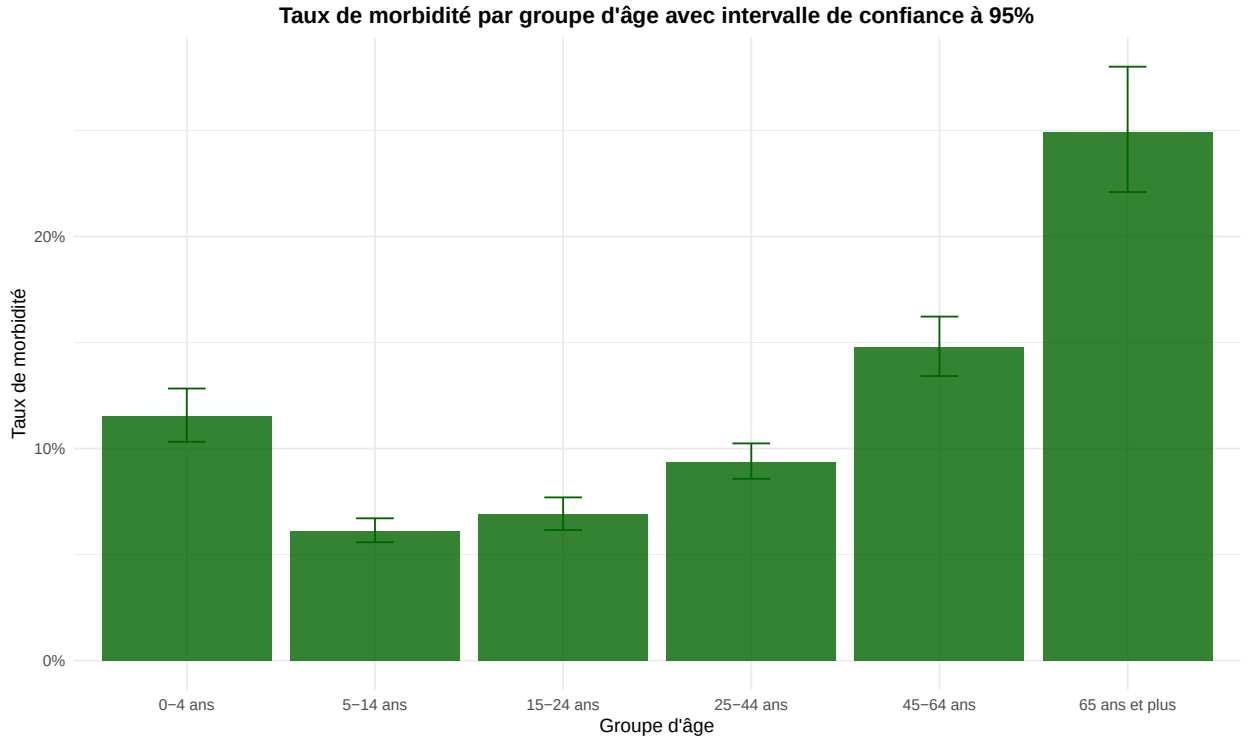

6 Distribution des types de maladies

```r
data_maladie <- data %>%
  mutate(type_maladie = as_factor(s4aq3b_1)) %>%
  filter(!is.na(type_maladie))

top_maladies <- data_maladie %>%
  count(type_maladie, sort = TRUE) %>%
  slice_head(n = 10) %>%
  mutate(
    proportion = n / sum(n),
    proportion_pct = percent(proportion, accuracy = 0.1)
  )

# Tableau des 10 principales maladies
top_maladies %>%
  select(type_maladie, n, proportion_pct) %>%
  kable(
    col.names = c("Type de maladie", "Nombre de cas", "Proportion"),
    caption = "Top 10 des maladies déclarées"
  )
```

Table 4: Top 10 des maladies déclarées

Type de maladie	Nombre de cas	Proportion
1. MALARIA	2039	34.8%
27. BODY PAINS	1411	24.1%
15. CATARRH	584	10.0%
16. COUGH	440	7.5%
17. HEADACHE	428	7.3%
24. ULCER/STOMACH PAIN	246	4.2%
10. COMMON COLD	238	4.1%
11. INJURY	184	3.1%
4. TYPHOID	153	2.6%
12. OTHER(SPECIFY)	135	2.3%

6.1 Visualisation des principales maladies

```r
ggplot(top_maladies,
       aes(x = n, y = reorder(type_maladie, n))) +
  geom_col(fill = "steelblue", alpha = 0.8) +
  geom_text(aes(label = n), hjust = -0.2, size = 3.5) +
  labs(
    x = "Nombre de cas",
    y = "",
    title = "Top 10 des maladies déclarées",
    caption = "Source: Enquête Harvest W4"
  ) +
  theme_minimal() +
  theme(plot.title = element_text(face = "bold", hjust = 0.5)) +
  xlim(0, max(top_maladies$n) * 1.1)
```

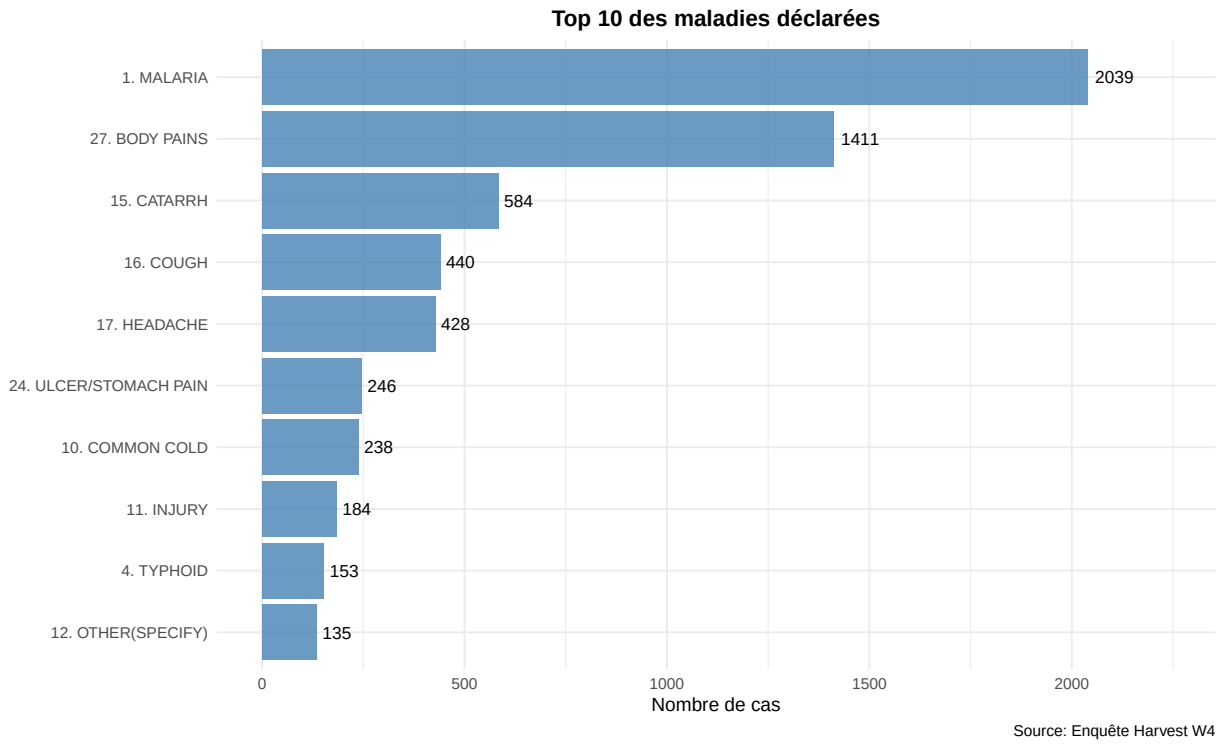

Ce graphique nous montre les 10 maladies les plus déclarées par les individus. La malaria est la maladie la plus déclarée avec un effectif de 2039 individus.

7 Analyse des dépenses de santé

```
# Vérification de l'existence de la variable
if("s4aq9" %in% names(data)) {

  p2 <- ggplot(data, aes(x = s4aq9)) +
    geom_histogram(binwidth = 5000, fill = "darkblue", color = "black", alpha = 0.7) +
    scale_y_log10() +
    labs(
      title = "Distribution des dépenses de santé (échelle log sur effectifs)",
      x = "Dépenses de santé (FCFA)",
      y = "Effectif (échelle log)"
    ) +
    theme_minimal()

  p2
  # Statistiques descriptives
  data %>%
    filter(!is.na(s4aq9)) %>%
    summarise(
      effectif = n(),
      moyenne = mean(s4aq9),
      ecart_type = sd(s4aq9),
      mediane = median(s4aq9),
      q1 = quantile(s4aq9, 0.25),
      q3 = quantile(s4aq9, 0.75),
```

```r
      min = min(s4aq9),
      max = max(s4aq9)
    ) %>%
    mutate(across(where(is.numeric), ~round(., 0))) %>%
    kable(caption = "Statistiques descriptives des dépenses de santé")

} else {
  cat(" La variable s4aq9 (dépenses de santé) n'est pas disponible dans les données.")
}
```

Table 5: Statistiques descriptives des dépenses de santé

effectif	moyenne	ecart_type	mediane	q1	q3	min	max
5538	401	2013	0	0	200	0	50000

L'histogramme nous montre que malgré la log-transformation, la part des dépenses inférieures à 20000 est toujours importante par rapport à celle des dépenses supérieures à 20000.

7.1 Statistiques par décile des dépenses

```r
if("s4aq9" %in% names(data)) {
  stats_deciles <- data %>%
    filter(!is.na(s4aq9)) %>%
    mutate(
      decile = ntile(s4aq9, 10)
    ) %>%
    group_by(decile) %>%
    summarise(
      n = n(),
      min = min(s4aq9),
      q1 = quantile(s4aq9, 0.25),
      mediane = median(s4aq9),
      moyenne = mean(s4aq9),
      q3 = quantile(s4aq9, 0.75),
      max = max(s4aq9),
      sd = sd(s4aq9),
      .groups = "drop"
    ) %>%
    mutate(
      intervalle = paste0(format(min, big.mark = " ", scientific = FALSE),
                          " - ",
                          format(max, big.mark = " ", scientific = FALSE)),
      decile_label = paste0("D", decile, " (", intervalle, ")")
    )

  # Affichage du tableau
  stats_deciles %>%
    select(decile_label, n, moyenne, mediane, q1, q3, sd) %>%
    mutate(across(where(is.numeric), ~round(., 0))) %>%
    kable(
      col.names = c("Décile", "n", "Moyenne", "Médiane", "Q1", "Q3", "Écart-type"),
      caption = "Statistiques des dépenses de santé par décile"
```

```r
    )

  # Visualisation
  stats_deciles %>%
    ggplot(aes(x = reorder(decile_label, decile), y = moyenne)) +
    geom_col(fill = "darkorange", alpha = 0.7) +
    geom_errorbar(aes(ymin = moyenne - sd, ymax = moyenne + sd), width = 0.2) +
    labs(
      title = "Dépenses moyennes de santé par décile (± écart-type)",
      x = "Décile",
      y = "Dépenses moyennes (FCFA)"
    ) +
    theme_minimal() +
    theme(axis.text.x = element_text(angle = 45, hjust = 1))

} else {
  cat("Analyse par décile non disponible : variable s4aq9 manquante")
}
```

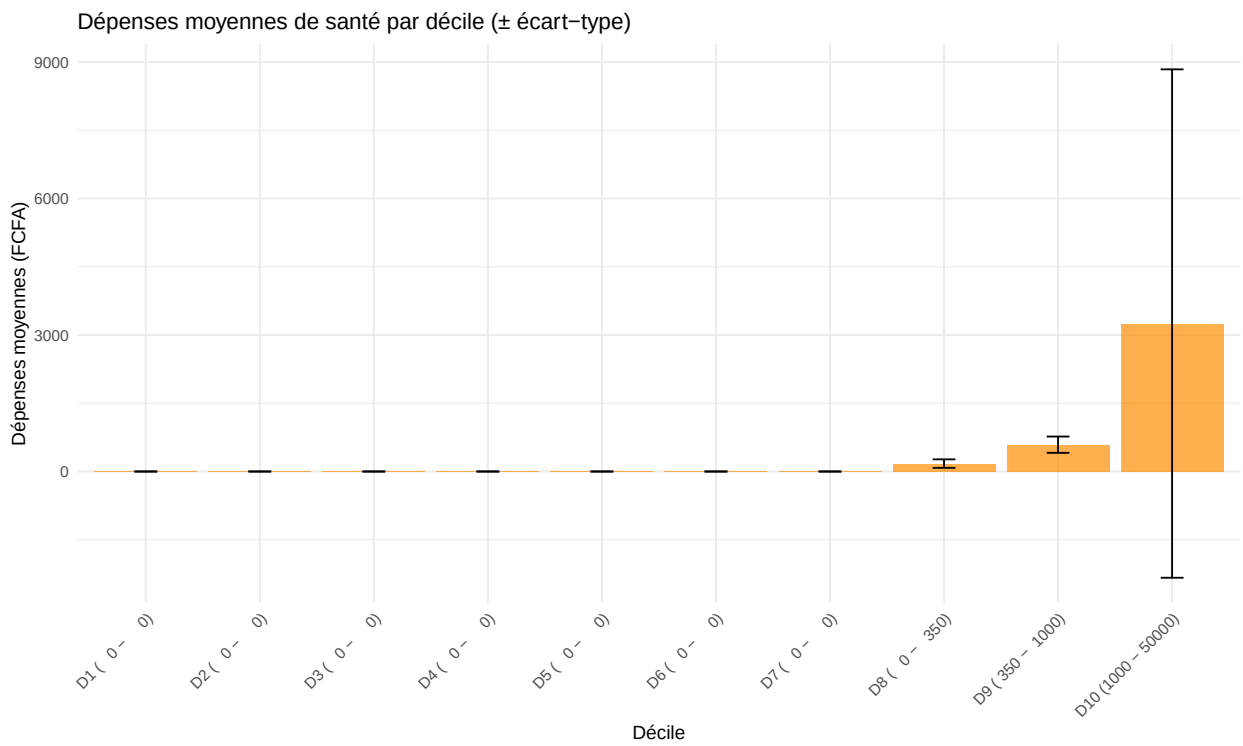

Ce graphique nous montre les dépenses moyennes de santé par décile.

8 Tests d'indépendance

8.1 Importation et préparation des données de consommation

```r
# Chargement des données de consommation
data_cons <- read_stata("../data/raw/totcons_final.dta")

# Construction des quintiles
```

```r
data_cons <- data_cons %>%
  mutate(quintile = ntile(totcons_adj_norm, 5))

# Fusion avec la base data
data <- data %>%
  left_join(data_cons %>% select(hhid, quintile), by = "hhid")

tab <- table(
  as_factor(data$quintile),
  as_factor(data$s4aq1)
)
tab
```

```
##
##     1. YES 2. NO
##   1    961  6989
##   2   1062  5171
##   3    973  4184
##   4    951  3285
##   5    774  2183
```

```r
chisq.test(tab)
```

```
##
##  Pearson's Chi-squared test
##
## data:  tab
## X-squared = 388.25, df = 4, p-value < 2.2e-16
```

```r
cramer_v(tab)
```

```
## [1] 0.1209658
```

Le tableau ci-dessus présente la répartition des consultations selon le quintile de consommation.